

FACULTAD DE CIENCIAS EXACTAS UNICEN

Acceso a datos

Fundamentos de la Ciencia de Datos - Clase Práctica Nro. 2

¿Qué vamos a ver hoy?

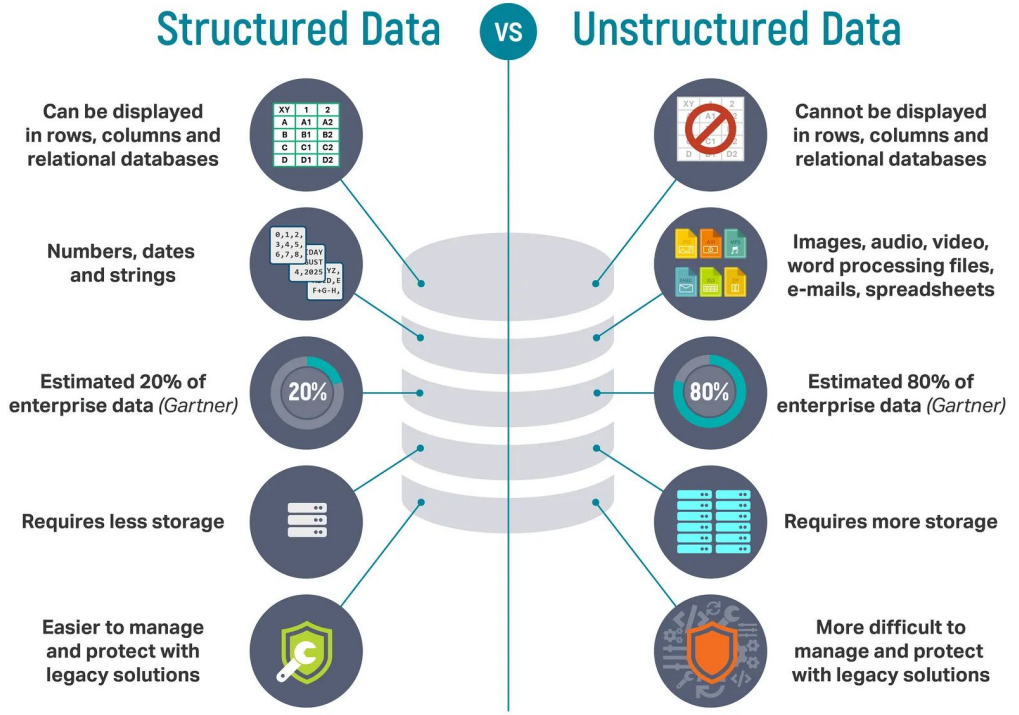
- Parte “teórica” de la clase (15:30 a 16:00):
  - Un breve repaso de lo que vieron en la teoría
  - Tipos de datos más comunes para almacenamiento de data estructurada
  - La librería Pandas
- Parte práctica en Colab (16:00 a 17:00):
  - Lectura de archivos CSV
  - Pandas y uso general de la librería para análisis exploratorio de los datos
- Resuelvan el práctico en clase!

Repasemos de qué hablamos cuando hablamos de

Datos / Taxonomía

Datos estructurados (structured)
Los que podemos representar en tablas (filas y columnas), por ende en bases de datos relacionales (registros y campos)
Ejemplos: financieros, sociales, comportamentales, …

Datos no estructurados (unstructured)
Los que no podemos representar en tablas
Ejemplos: texto libre, imágenes, video, sonido.
No vamos a trabajar con estos en el curso!

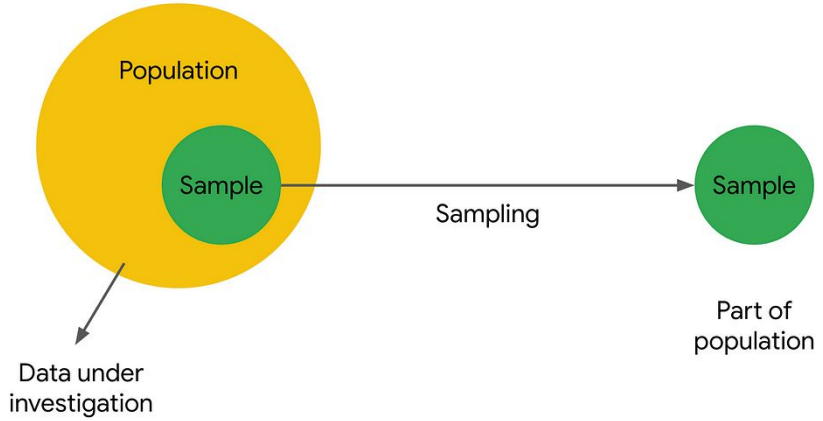


Más info:
sdfsdfsdf

Repasemos de qué hablamos cuando hablamos de

Datos / Muestra vs. población

- **Población (population)**: el grupo completo que queremos estudiar.
- **Muestra (sample)**: subconjunto de esa población, obtenido por muestreo.
- **Muestreo (sampling)**: proceso de selección de una muestra a partir de una población.
  - Muestreo “representativo” = Aquel que nos brinda un conjunto de muestras que sirven de ejemplo del comportamiento real de la población.
- Nuestros datos provienen siempre de una **población** - Siempre necesitamos **contexto** (metadata)



Nuestra muestra va a estar siempre dada, y va a venir en uno o más archivos (o en una base de datos). **Tendremos poco control sobre el proceso de sampleo!**

Más info:
sdfsdfsdf

Repasemos de qué hablamos cuando hablamos de

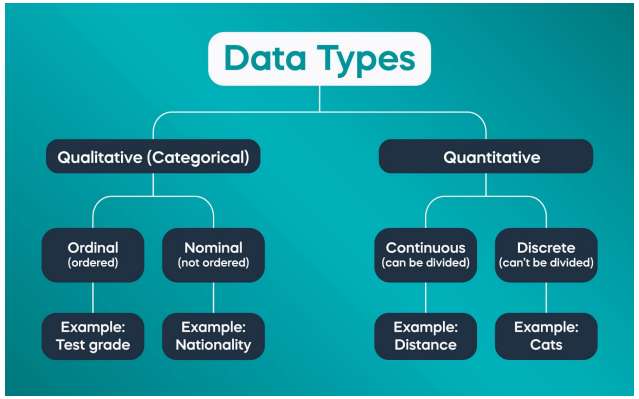
Datos / Observaciones

- **Observación** (individuo, a veces “sample” también) = cada elemento de la muestra.
  - Registro de una base de datos, fila de una tabla.
- **Cada observación tiene un conjunto de atributos** (descriptores, características, variables, features) asociados.
  - Campos de cada registro, columnas de una tabla.
- Cada **atributo** tiene un **tipo de dato** asociado:
  - Cualitativo (categórico)
    - Ordinal: si puedo establecer una relación de orden entre dos valores (“1er año” < “2do año”)
    - Nominal: si no hay orden (“argentino”, “inglés”)
  - Cuantitativo (numérico)
    - Continuo: “se puede dividir” (“altura”)
    - Discreto: “no se puede dividir” (“nro. hijos”)
- Y las binarias?

Ejemplo: housing.csv

	CRIM	ZN	INDUS	CHAS	NOX	RM	AGE	DIS	RAD	TAX	PTRATIO	B	LSTAT	MEDV
0	0.00632	18.0	2.31	0.0	0.538	6.575	65.2	4.0900	1.0	296.0	15.3	396.90	4.98	24.0
1	0.02731	0.0	7.07	0.0	0.469	6.421	78.9	4.9671	2.0	242.0	17.8	396.90	9.14	21.6
2	0.02729	0.0	7.07	0.0	0.469	7.185	61.1	4.9671	2.0	242.0	17.8	392.83	4.03	34.7
3	0.03237	0.0	2.18	0.0	0.458	6.998	45.8	6.0622	3.0	222.0	18.7	394.63	2.94	33.4
4	0.06905	0.0	2.18	0.0	0.458	7.147	54.2	6.0622	3.0	222.0	18.7	396.90	5.33	36.2
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
501	0.06263	0.0	11.93	0.0	0.573	6.593	69.1	2.4786	1.0	273.0	21.0	391.99	9.67	22.4
502	0.04527	0.0	11.93	0.0	0.573	6.120	76.7	2.2875	1.0	273.0	21.0	396.90	9.08	20.6
503	0.06076	0.0	11.93	0.0	0.573	6.976	91.0	2.1675	1.0	273.0	21.0	396.90	5.64	23.9
504	0.10959	0.0	11.93	0.0	0.573	6.794	89.3	2.3889	1.0	273.0	21.0	393.45	6.48	22.0
505	0.04741	0.0	11.93	0.0	0.573	6.030	80.8	2.5050	1.0	273.0	21.0	396.90	7.88	11.9

506 rows × 14 columns



Repasemos de qué hablamos cuando hablamos de

Datos / Matriz de diseño

El **conjunto de observaciones y sus vectores de características** asociados suele representarse en una [matriz de diseño]

	Superficie (en m2)	Tiene patio?	m de frente	Nro de plantas
Casa 1	150	1	20	2
Casa 2	22	0	5	1
Casa 3	76	0	21	1
Casa 4	98	1	35	2
	...	...	...	...



$$X : \overbrace{\begin{bmatrix} 150 & 1 & 20 & 2 \\ 22 & 0 & 5 & 1 \\ 76 & 0 & 21 & 1 \\ 98 & 1 & 35 & 2 \\ \dots & \dots & \dots & \dots \end{bmatrix}}^{d} \Bigg\} n$$

Ahora sí - Hablemos de

Almacenamiento de datos

Algunos de los **formatos de archivo** más utilizados **para almacenar y compartir datos**

- **Texto plano** con separadores de columnas (ej. comas) y separados de línea (ej. saltos de línea \n)
  Ocupan más espacio, pero los puedo abrir hasta en Excel!
  - **.csv**
  - **.txt**
  - **.dat**
- **Archivos con compresión** que permiten hacer persistencia de objetos (incluyendo tablas)
  Necesito rutinas especiales para abrirlos, pero pesan bastante menos
  - **.pkl**
  - **.mat**
  - **.db**
  - **.xlsx**

Ahora sí - Hablemos de

Almacenamiento de datos

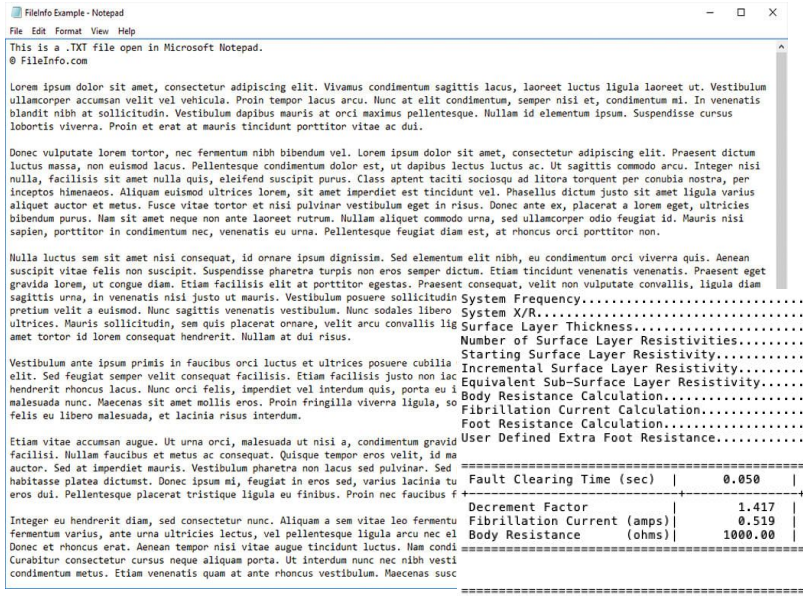
Algunos de los **formatos de archivo** más utilizados **para almacenar y compartir datos**

- **Texto plano** con separadores de columnas (ej. comas) y separados de línea (ej. saltos de línea \n)
  Ocupan más espacio, pero los puedo abrir hasta en Excel!
  - .csv
  - .txt
  - .dat
- **Archivos con compresión** que permiten hacer persistencia de objetos (incluyendo tablas)
  Necesito rutinas especiales para abrirlos, pero pesan bastante menos
  - .pkl
  - .mat
  - .db
  - .xlsx

Almacenamiento de datos

Los archivos TXT

- **El clásico archivo de texto del bloc de notas**
- No hay formato ni estructura
- Son fáciles de leer y escribir desde el código, pero es difícil extraer su estructura.
- Son compatibles universalmente (no necesito un software especializado para leerlos).
- No son eficientes si manejo un volumen grande de datos.
- Atención a la codificación!
  - UTF-8 vs. ASCII - Las famosas tildes rotas
- No usen TXT para guardar datos estructurados! Usen otros formatos




```
System Frequency.....................................:  50.000(Hertz)
System X/R...........................................:  20.000
Surface Layer Thickness..............................:  18.000(cm)
Number of Surface Layer Resistivities................:  19
Starting Surface Layer Resistivity...................:  50.000(ohm-m)
Incremental Surface Layer Resistivity................:  50.000(ohm-m)
Equivalent Sub-Surface Layer Resistivity............ .:  100.00(ohm-m)
Body Resistance Calculation..........................:  IEEE Std.80-2013
Fibrillation Current Calculation.....................:  IEEE Std.80-2013 (50kg)
Foot Resistance Calculation..........................:  IEEE Std.80-2013
User Defined Extra Foot Resistance...................:  0.0000  ohms
```

Fault Clearing Time (sec)	0.050	0.100	0.150
Decrement Factor	1.417	1.269	1.192
Fibrillation Current (amps)	0.519	0.367	0.300
Body Resistance (ohms)	1000.00	1000.00	1000.00



Surface Layer Resistivity (ohm-m)	Fault Clearing Time 0.050 sec. Step Voltage (Volts)	0.050 sec. Touch Voltage (Volts)	0.100 sec. Step Voltage (Volts)	0.100 sec. Touch Voltage (Volts)	0.150 sec. Step Voltage (Volts)	0.150 sec. Touch Voltage (Volts)	Foot Resistance (ohms)
50.0	493.2	397.8	389.7	314.3	338.6	273.1	173.8(*)
NONE	594.8	423.2	469.9	334.4	408.3	290.6	312.5
150.0	692.0	447.5	546.7	353.6	475.1	307.2	445.3
200.0	787.5	471.4	622.1	372.4	540.6	323.6	575.7
250.0	882.0	495.0	696.8	391.1	605.5	339.8	704.8
300.0	976.1	518.6	771.1	409.7	670.1	356.0	833.3
350.0	1069.8	542.0	845.2	428.2	734.5	372.1	961.4
400.0	1163.4	565.4	919.1	446.7	798.7	388.1	1089.1

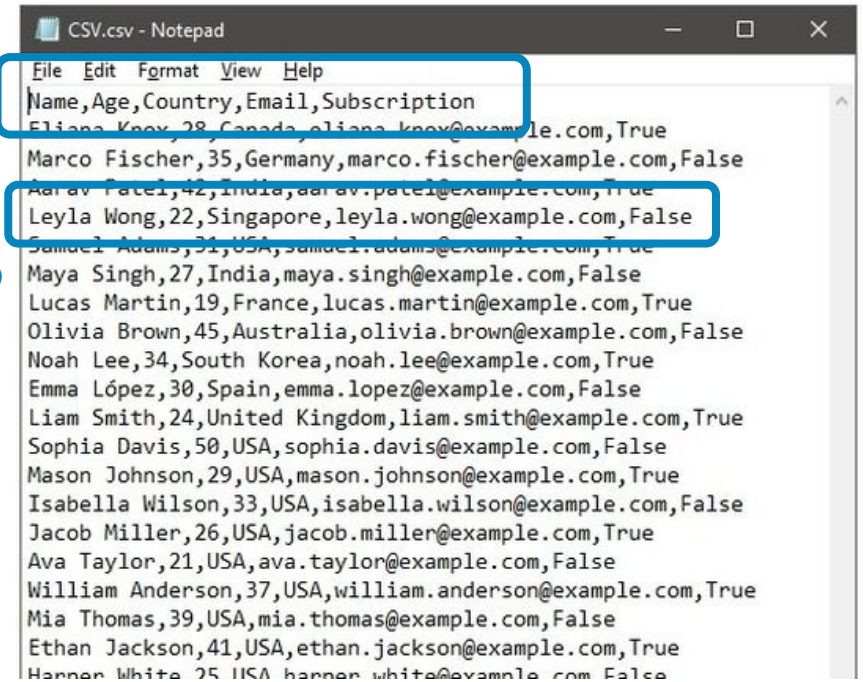
Almacenamiento de datos

Los archivos CSV

- **CSV = Comma Separated Value = Archivo separado por comas.**
- Cada campo está separado por una coma.
- Se usa el \n para indicar cambios de registro.
- Normalmente incluyen una primera fila para el header (cabecera, nombre de los atributos)
- Se puede abrir en software de hoja de cálculo sin problemas.
- Que se llame CSV no implica que sí o sí use comas para separarlos
  - ¿Qué pasa si usamos “,” como separador de decimales? → Usemos “;” para separar
  - Si no usan comas, avisen! (un readme)

Header

Registro



Podés ver acá cómo abrir un archivo CSV en Excel, en Numbers y en LibreOffice

Los archivos XLSX

- **XLSX = Archivo de datos de Excel** (a partir de Excel 2007, antes era XLS).
- Es un archivo binario (no es texto plano)
- Internamente, es un archivo .zip formado por varios archivos internos:
  - Varios XML explicando la estructura de los datos y del archivo, el formato para mostrarlo, etc.
  - Un archivo con los datos crudos.
- Permite almacenar hasta 1M de registros, con 16.000 columnas.
- Recomendado para compartir datos con gente que no es experta, porque es fácil de abrir con herramientas de cálculo comunes.
- *No es buena idea compartir datos crudos en este formato*.



Almacenamiento de datos

Los archivos PKL

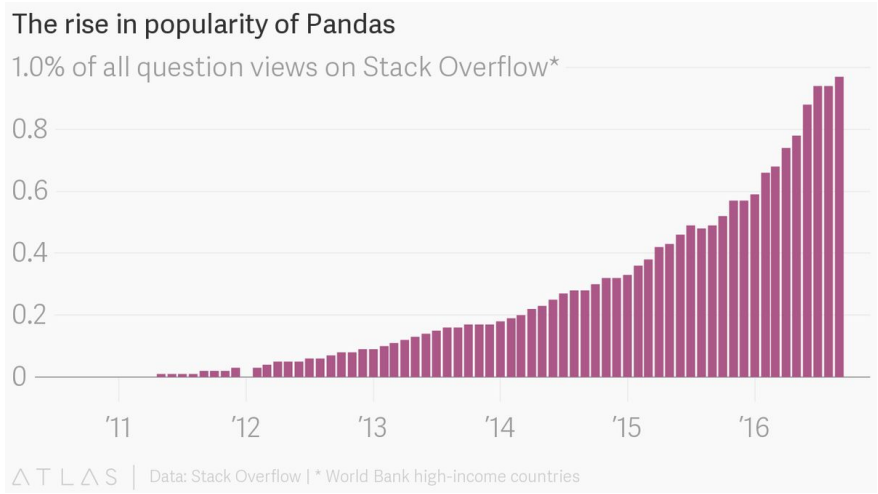
- **PKL = Archivo pickle** (sí, como las verduritas encurtidas!).
- Es un archivo binario (no es texto plano) que se usa para serializar objetos de Python
  - Serializar un objeto = guardar una copia exacta del estado de un objeto, tal como estaba en RAM en ese momento
- Puedo guardar lo que se me ocurra, manteniendo la estructura original del objeto, y permitiéndome operar con él como estaba.
- No es seguro contra datos maliciosos - Te puedo meter cualquier cosa adentro sin que te des cuenta (pickle envenenado!)
- Hay que usarlos con cuidado, y para casos bien específicos
  - Checkpoints en pipelines de procesamiento de datos
  - Cosas que son extremadamente grandes como para bajar en archivos no binarios.



Librerías de Python para Data Science

Pandas

- Librería open source de Python para hacer análisis y manipulación de datos
- Tiene estructuras propias para facilitar el trabajo con datos (DataFrame, Series, …)
  - “Como trabajar con una BD, pero con código imperativo”
- Permite leer archivos que vienen en distintos formatos (CSV, XLSX, SQL, etc.)
- Tiene muchas herramientas para limpieza y transformación de los datos, para fusionarlos, agruparlos, indexarlos rápidamente, e incluso visualizarlos (aunque con otras herramientas).
- **Es la librería que más vamos a usar en el curso!**



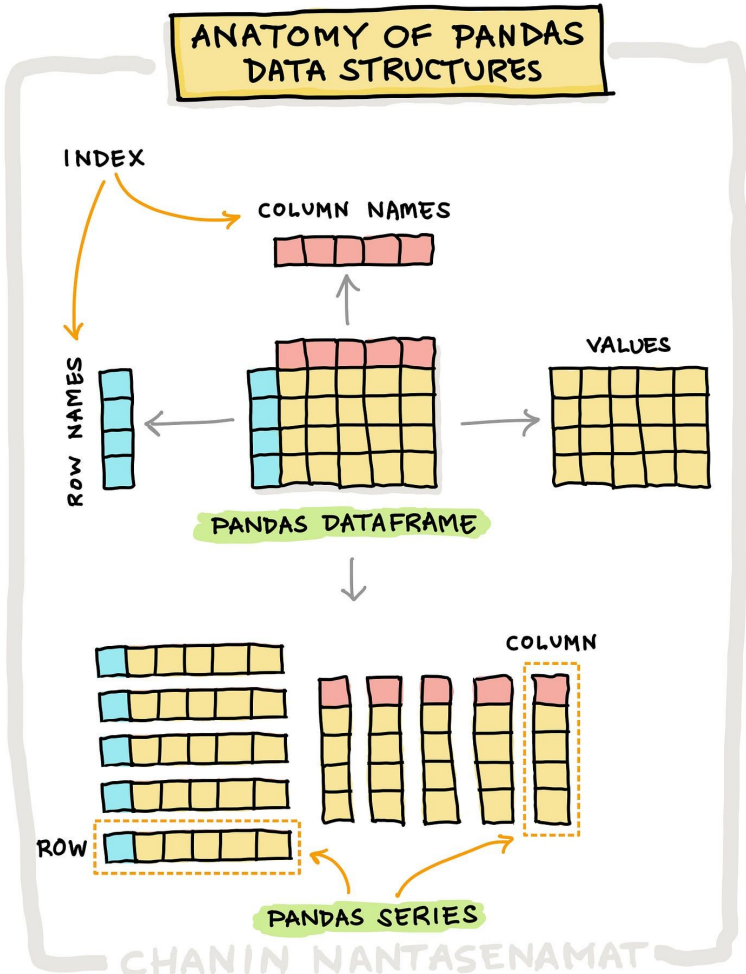


ciencia-datos-unicen-practica-2-python.ipynb

Librerías de Python para Data Science

Pandas / DataFrames y Series

- **DataFrame → estructura de datos bidimensional**
  - Una especie de tabla/hoja de cálculo.
  - Facilita bastante manipular y analizar datos estructurados
    - Operaciones vectorizadas → Procesa rapidísimo todo lo que le pidamos
    - Indexa los datos → Podemos hacer búsquedas muy eficientes
- **Serie → estructura de datos unidimensional**
  - Secuencia ordenada de datos
  - El equivalente a una columna o una lista
  - DataFrame = “arreglo” de Series





ciencia-datos-unicen-practica-2-python.ipynb

Miremos un poco los datos

Boston





Acceso a datos y análisis (parte I)

¿Qué vimos hoy?

1. Repasamos lo que van a ver el jueves en la teoría!
2. Los tipos de datos más comunes para compartir data estructurada
3. ¿Cómo usar Python para leer este tipo de archivos?
4. ¿Cómo usar Pandas para hacer análisis exploratorio del contenido de estos archivos?

Material adicional:

- ¿Qué es un DataFrame? Un video cortito yendo más al hueso.
- Curso de Pandas desde cero (7 videos).
- Curso de Python con Pandas desde cero (11 videos)
- Capítulo 4 del libro de Nathan George.