

FACULTAD DE CIENCIAS EXACTAS UNICEN

Análisis preliminar de datos

Fundamentos de la Ciencia de Datos - Clase Práctica Nro. 3

Librerías de Python para Data Science

Numpy & Scipy

- Librería de Python para procesamiento eficiente de matrices y vectores
  - Basta de bucles para recorrerlas! → operaciones matriciales y vectoriales (*"slicing"*)
- Base de otras librerías (Pandas, Scipy, Scikit Learn, Matplotlib), incluidas las más populares para hacer machine learning!





- Brinda funciones para matemática, álgebra lineal, optimización, y estadísticas, entre otras áreas.
- En ciencia de datos, se usa para análisis de correlación, test estadísticos, y modelado.
- Complementa a NumPy, con herramientas más sofisticadas y especializadas para el procesamiento de datos.

Algunas formas de

Analizar nuestros datos

- **Análisis univariado: estudiar el comportamiento estadístico de una variable de manera aislada.**
  - Medidas de tendencia central (media, mediana, moda)
  - Medidas de dispersión (varianza, desvío estándar)
  - Cuantiles (cuartiles, percentiles, deciles, rangos)
  - Estudio gráfico mediante histogramas.
- **Análisis bivariado: estudiar la relación entre una variable y otra**
  - Correlación (de Pearson, de Spearman, de Kendall), prueba de chi-cuadrado.
  - Gráficos de dispersión
  - Tablas de contingencia (muestro la frecuencia de combinaciones de dos variables categóricas)
- **Análisis multivariado: estudiar la relación entre múltiples variables**
  - (ya las veremos!!!)

Más info: Joel Grus, “Data Science from Scratch: First Principles with Python”. Capítulo 10.

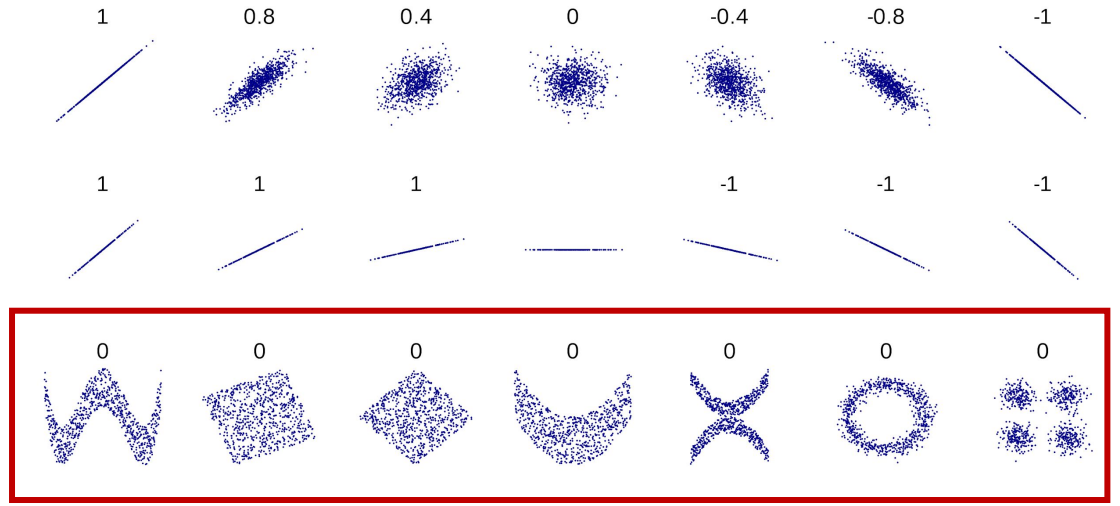
Análisis bivariado / Correlación

Correlación entre dos variables = dirección y fuerza de la relación entre variables

Coeficiente de correlación de Pearson

$$r = \frac{\sum (x - \bar{x})(y - \bar{y})}{\sqrt{\sum (x - \bar{x})^2 \sum (y - \bar{y})^2}}$$

- Mide la correlación lineal e/ 2 variables.
- No te dice si dos variables tienen o no relación, sólamente te dice si la relación es lineal
- No confundir correlación con causalidad!



En estos casos hay otras relaciones entre las variables que no se pueden capturar con Pearson → estudiar gráficamente

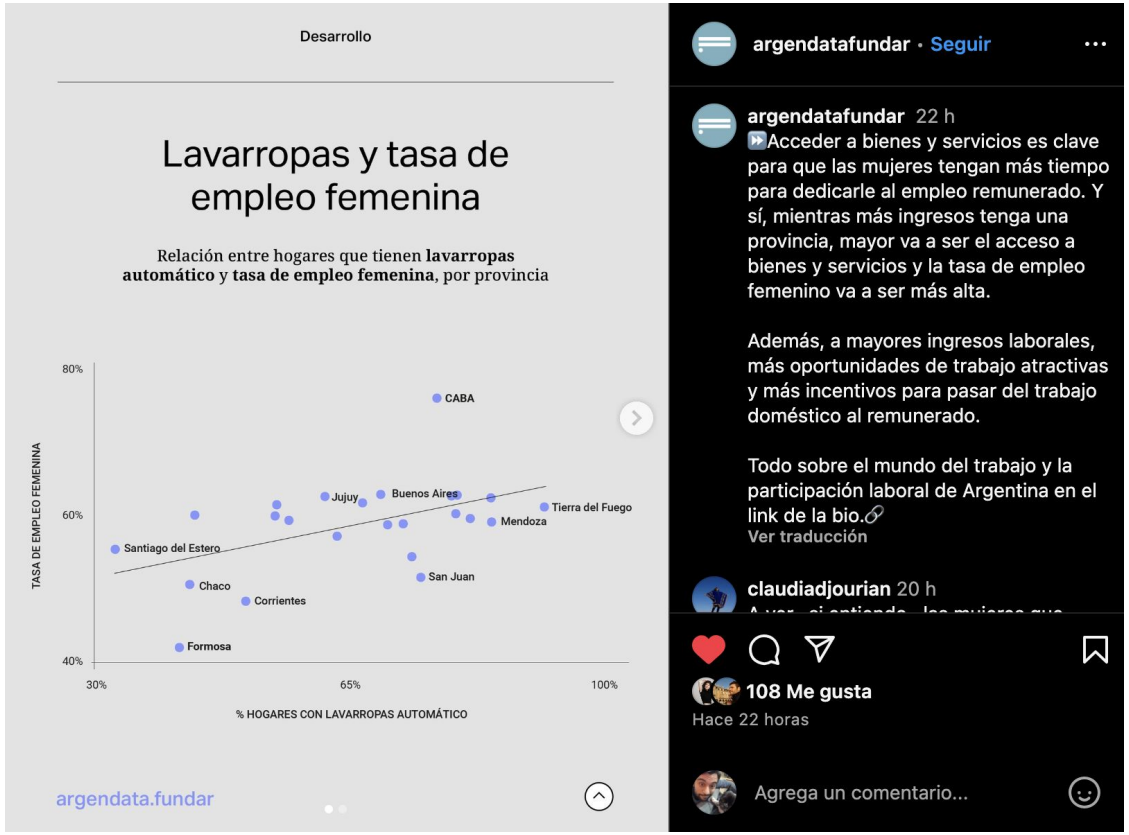
Más info: Pág. 99 del libro de Joel Grus.

Análisis de los datos

Análisis bivariado / Scatter plot

Una buena herramienta para estudiar la relación entre dos variables

- Graficamos los valores de dos variables x, y en un plano cartesiano, con un par ordenado (x, y) para cada muestra i del conjunto
- La forma en la que los puntos se distribuyen en el espacio nos da una idea general de la relación entre ambas variables
- Ojo que los problemas típicos se mantienen:
  - Pocas muestras? Malas conclusiones
  - Muchas muestras mal recolectadas? Malas conclusiones
  - Correlación no es causalidad

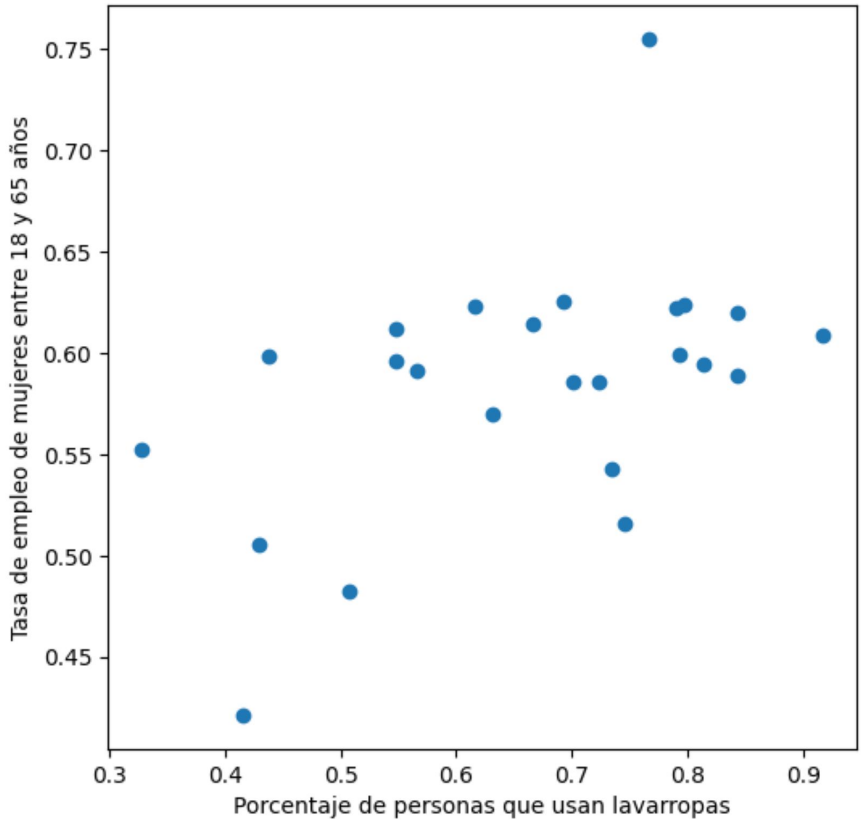


Más info: Pág. 99 del libro de Joel Grus.

Análisis bivariado / Scatter plot

Una buena herramienta para estudiar la relación entre dos variables

- Graficamos los valores de dos variables x, y en un plano cartesiano, con un par ordenado (x, y) para cada muestra i del conjunto
- La forma en la que los puntos se distribuyen en el espacio nos da una idea general de la relación entre ambas variables
- Ojo que los problemas típicos se mantienen:
  - Pocas muestras? Malas conclusiones
  - Muchas muestras mal recolectadas? Malas conclusiones
  - Correlación no es causalidad

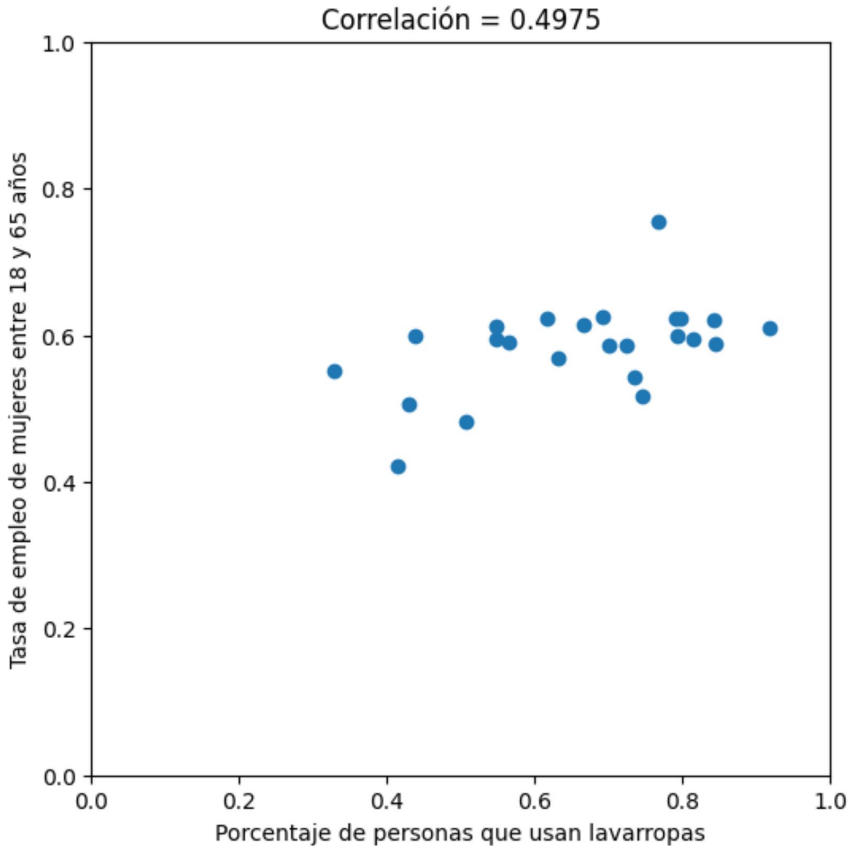


Más info: Pág. 99 del libro de Joel Grus.

Análisis bivariado / Scatter plot

Una buena herramienta para estudiar la relación entre dos variables

- Graficamos los valores de dos variables x, y en un plano cartesiano, con un par ordenado (x, y) para cada muestra i del conjunto
- La forma en la que los puntos se distribuyen en el espacio nos da una idea general de la relación entre ambas variables
- Ojo que los problemas típicos se mantienen:
  - Pocas muestras? Malas conclusiones
  - Muchas muestras mal recolectadas? Malas conclusiones
  - Correlación no es causalidad



Más info: Pág. 99 del libro de Joel Grus.



ciencia-datos-unicen-practica-3-python.ipynb

Acceso a datos y análisis (parte II)

¿Qué vimos hoy?

1. Estudiamos un poco sobre análisis bivariado
2. Aprendimos a estudiar correlaciones en Python usando Pandas
3. Tenemos todo para empezar y terminar el práctico 3!

Material adicional:

- Pág. 40 (57 en el PDF) del libro de Skiena, hasta la 46 (63 en el PDF). Una introducción bien detallada sobre la correlación.
- Pág. 99 a 106 del libro de Joel Grus. Algunas curiosidades sobre la correlación.
- Un video introductorio al análisis exploratorio bivariado.