

FACULTAD DE CIENCIAS EXACTAS UNICEN

Fundamentos de la Ciencia de Datos

Clase 1

¿Qué vamos a ver hoy?

- Presentación y contenidos de la materia
- Conceptos introductorios a la Ciencia de Datos
- Roles
- Ingeniería de datos
- Calidad de datos

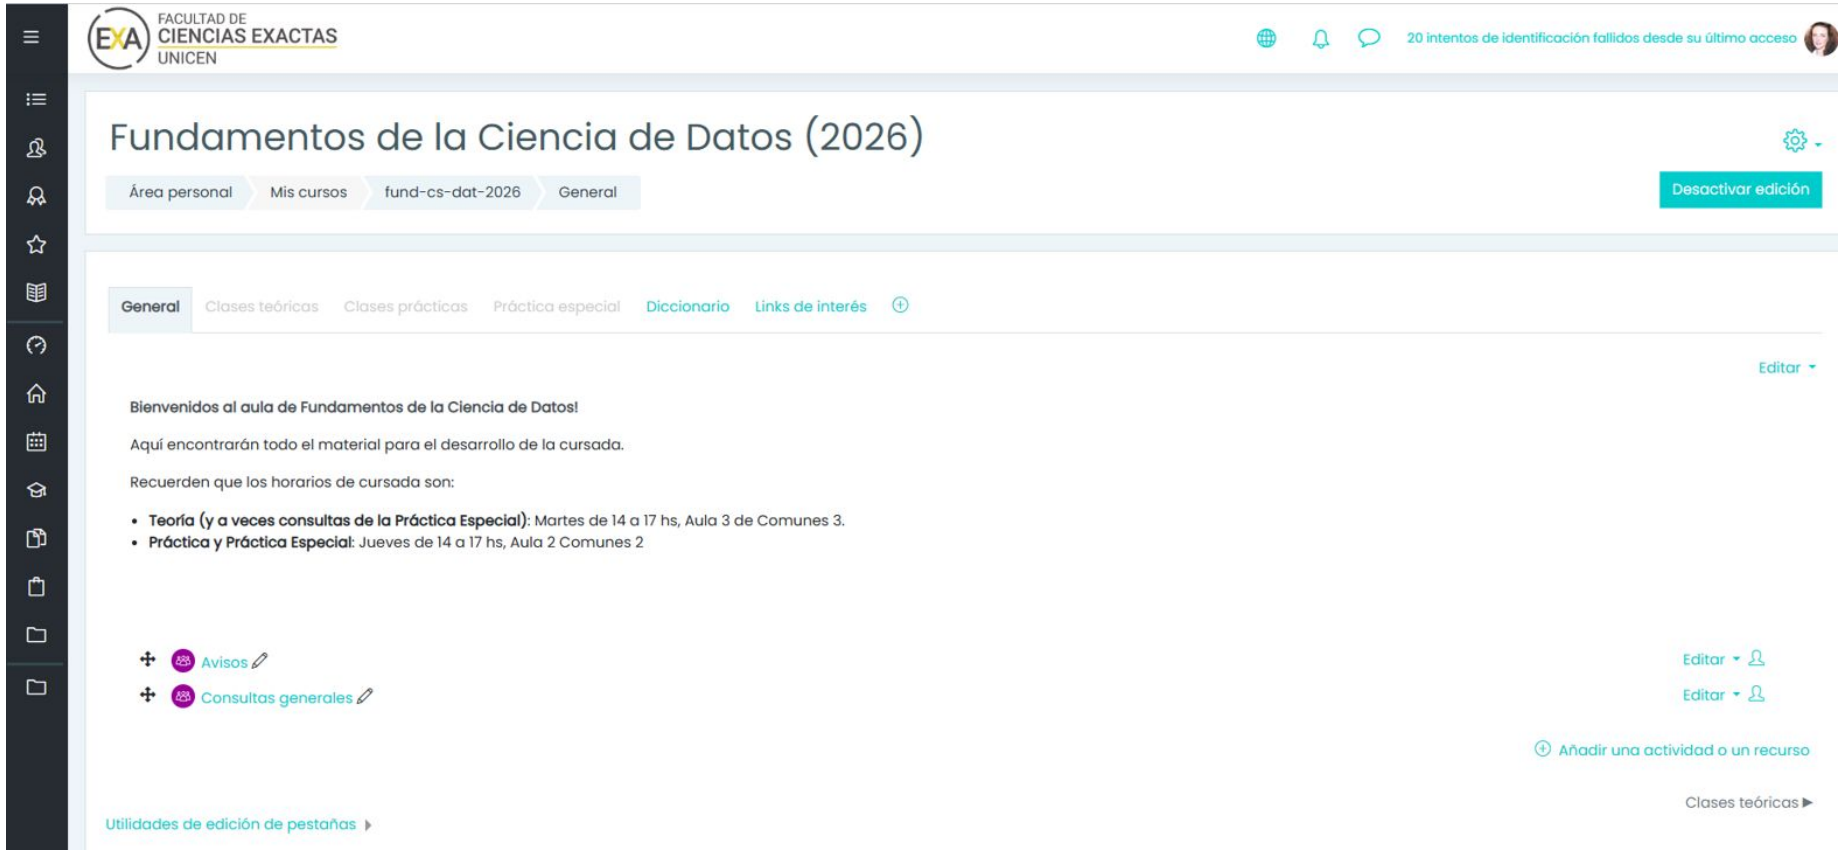


Equipo docente 2026

- Prof. Mg. Rosana Cepeda.
- Prof. Dra. Daniela Godoy (Prof. responsable)
- Prof. Dra. Sandra González Císaro
- JTP Dr. J. Ignacio Orlando (Responsable práctica)
- Ay. Dip. Prof. Débora Perez Fernández

Fundamentos de la Ciencia de Datos

Aula Moodle



https://moodle.exa.unicen.edu.ar/course/view.php?id=1134&section=0

Consultas **en clase**.

Objetivos

- Identificar las **etapas** de los **procesos de Ciencia de Datos** y desarrollarlos en casos prácticos.
- Dominar las **técnicas y algoritmos** principales para el **análisis de datos**, y ser capaz de **interpretar y evaluar** adecuadamente sus **resultados**.
- Identificar las **técnicas** más apropiadas para determinados **problemas** en un **dominio de estudio específico**.
- Comprender las bases necesarias para el **análisis de la calidad en los datos**, identificando las complejidades de los mismos y la importancia de ésta para la obtención de valor agregado durante el proceso.
- **Comunicar** efectivamente los **resultados** en cada etapa del proceso de Ciencia de Datos.
- Contar con los conocimientos básicos de **análisis y preprocesamiento de datos** necesarios para el desarrollo de **modelos de inteligencia artificial y aprendizaje automático**.

Régimen de cursada

Clases teóricas + Práctica Especial - Aula 3 Comunes 3 - Martes de 14 a 17 hs. 2 horas de teoría + 1hora de práctica especial

Clases prácticas + Práctica Especial - Aula 1 Pabellón de la facultad - Jueves de 14 a 17 hs.

Acreditación: Examen parcial (con sus dos recuperatorios) y un Trabajo Práctico Especial (TPE), siendo necesaria la aprobación de ambos para la aprobación de la cursada.

Alcanzando una calificación mínima de 7 en el parcial o recuperatorio (primera instancia) y en el TPE, se promociona la materia.

Fundamentos de la Ciencia de Datos

Contenidos

Introducción a la Ciencia de Datos

Procesamiento y preparación de datos

Introducción al análisis multivariado

Reducción de dimensionalidad

Técnicas de agrupamiento

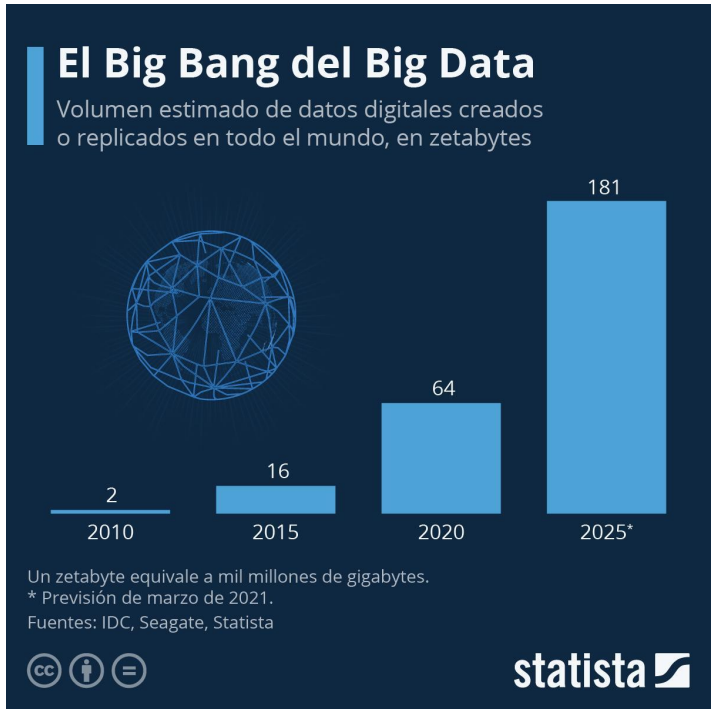
Modelos predictivos

Presentación y Comunicación de Resultados



Fundamentos de la Ciencia de Datos

¿Por qué esta materia?

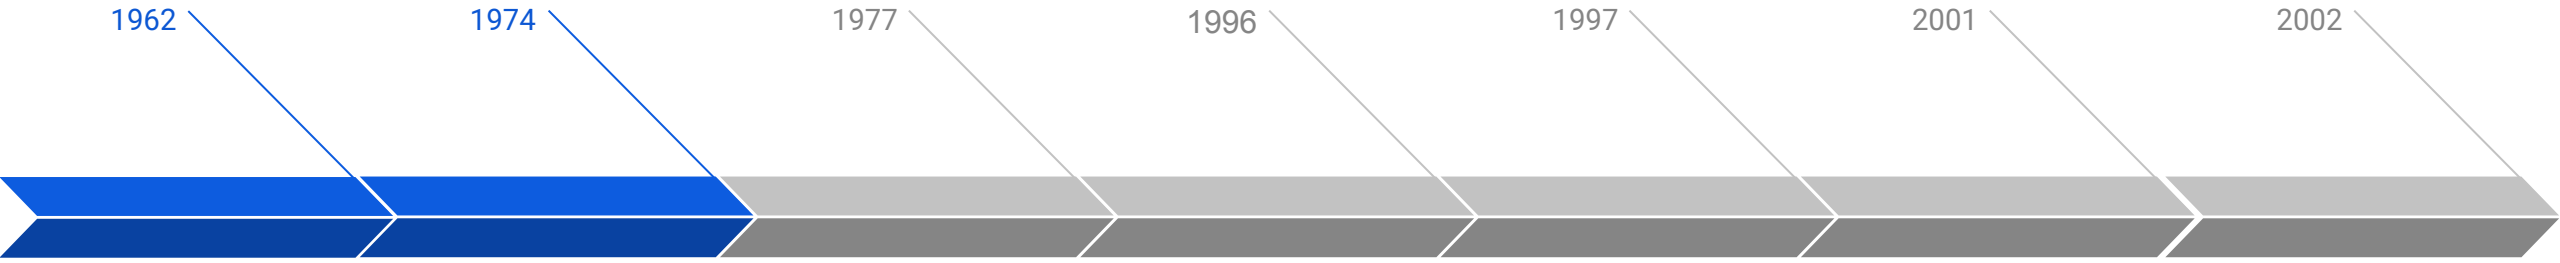






Fundamentos de la Ciencia de Datos

Timeline de la ciencia de datos



John Tukey

The future of data analysis

Peter Naur

Concise Survey of Computer Methods

IASC

Fundan IASC como parte IIS

Tukey EDA

Fayyad, Piatetsky-Shapiro & Smyth

From Data Mining to Knowledge Discovery in Databases.

Jeff Wu

Conferencia: *Statistics = Data Science?*

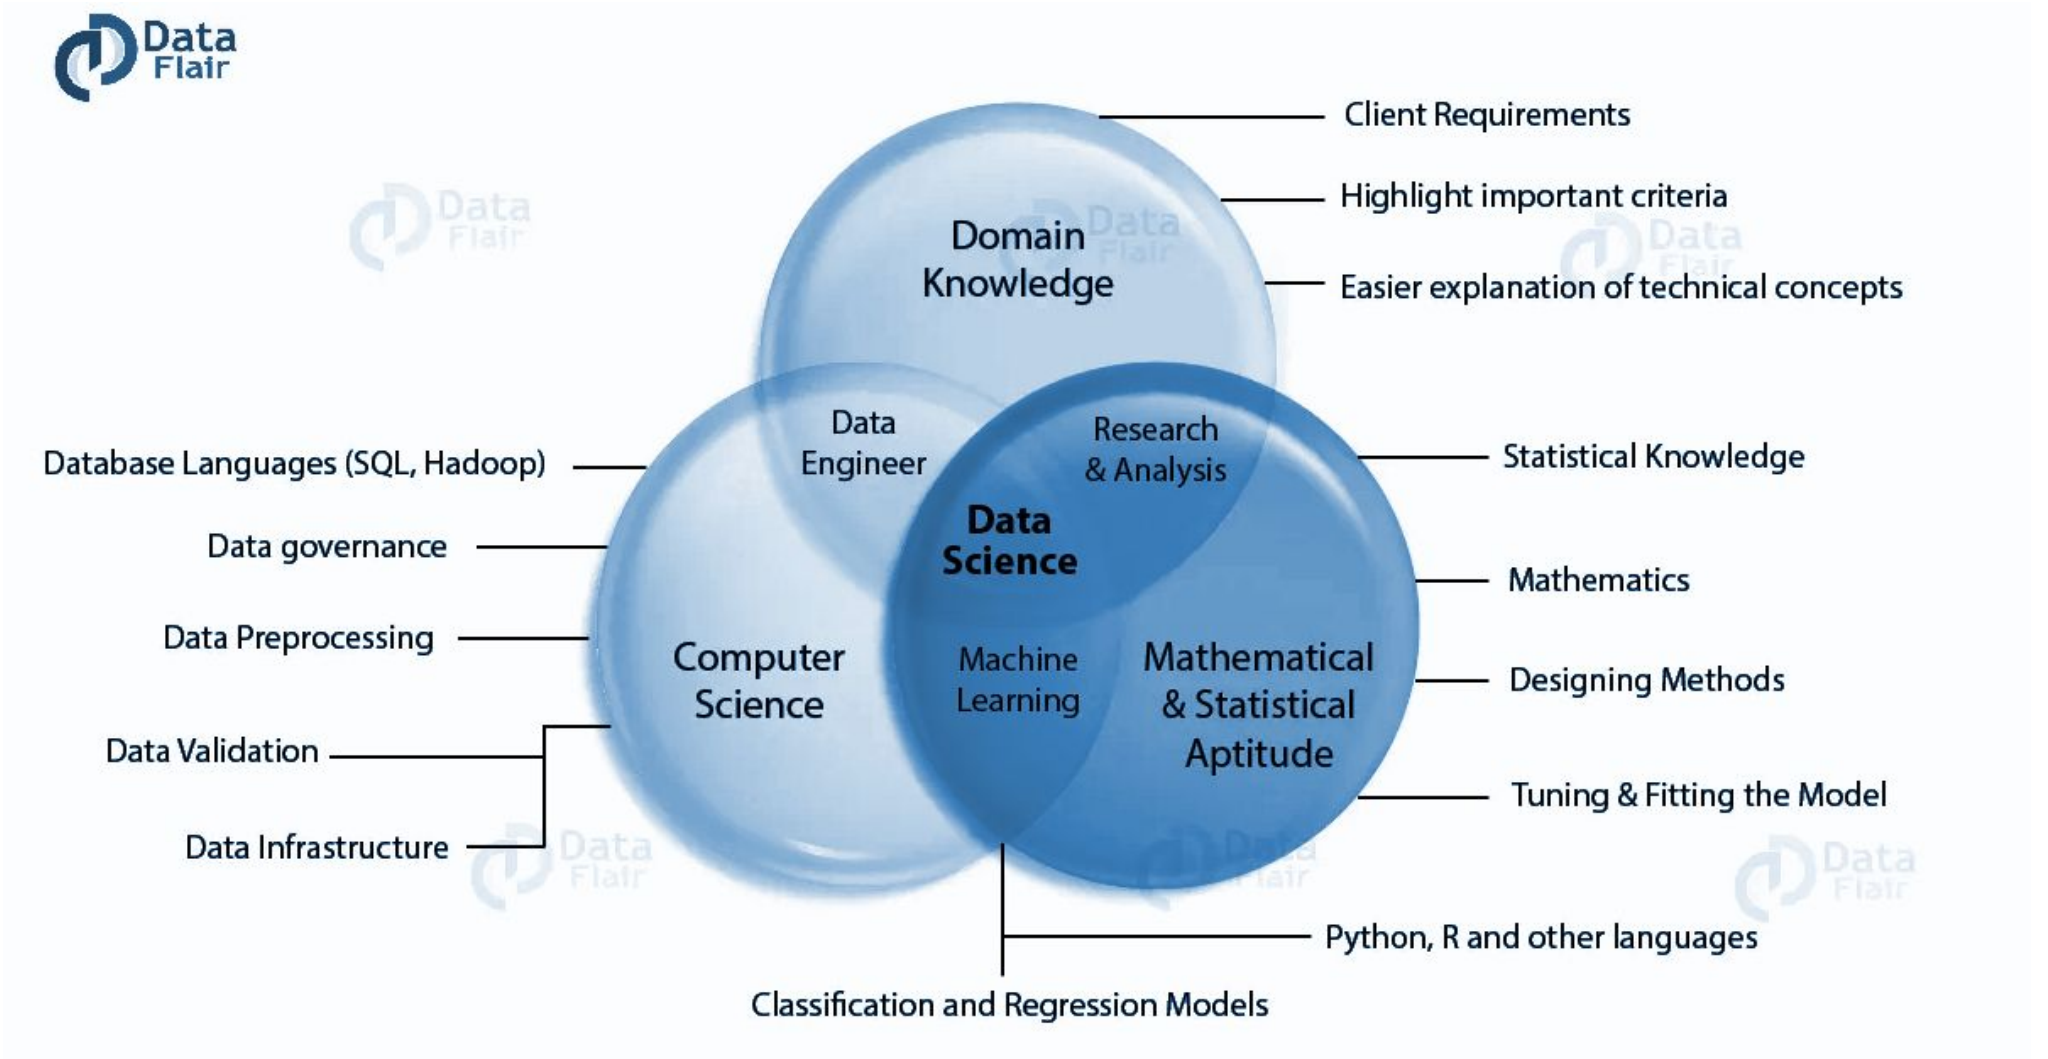
William S. Cleveland

Data science: an action plan for expanding the technical areas of the field of statistics

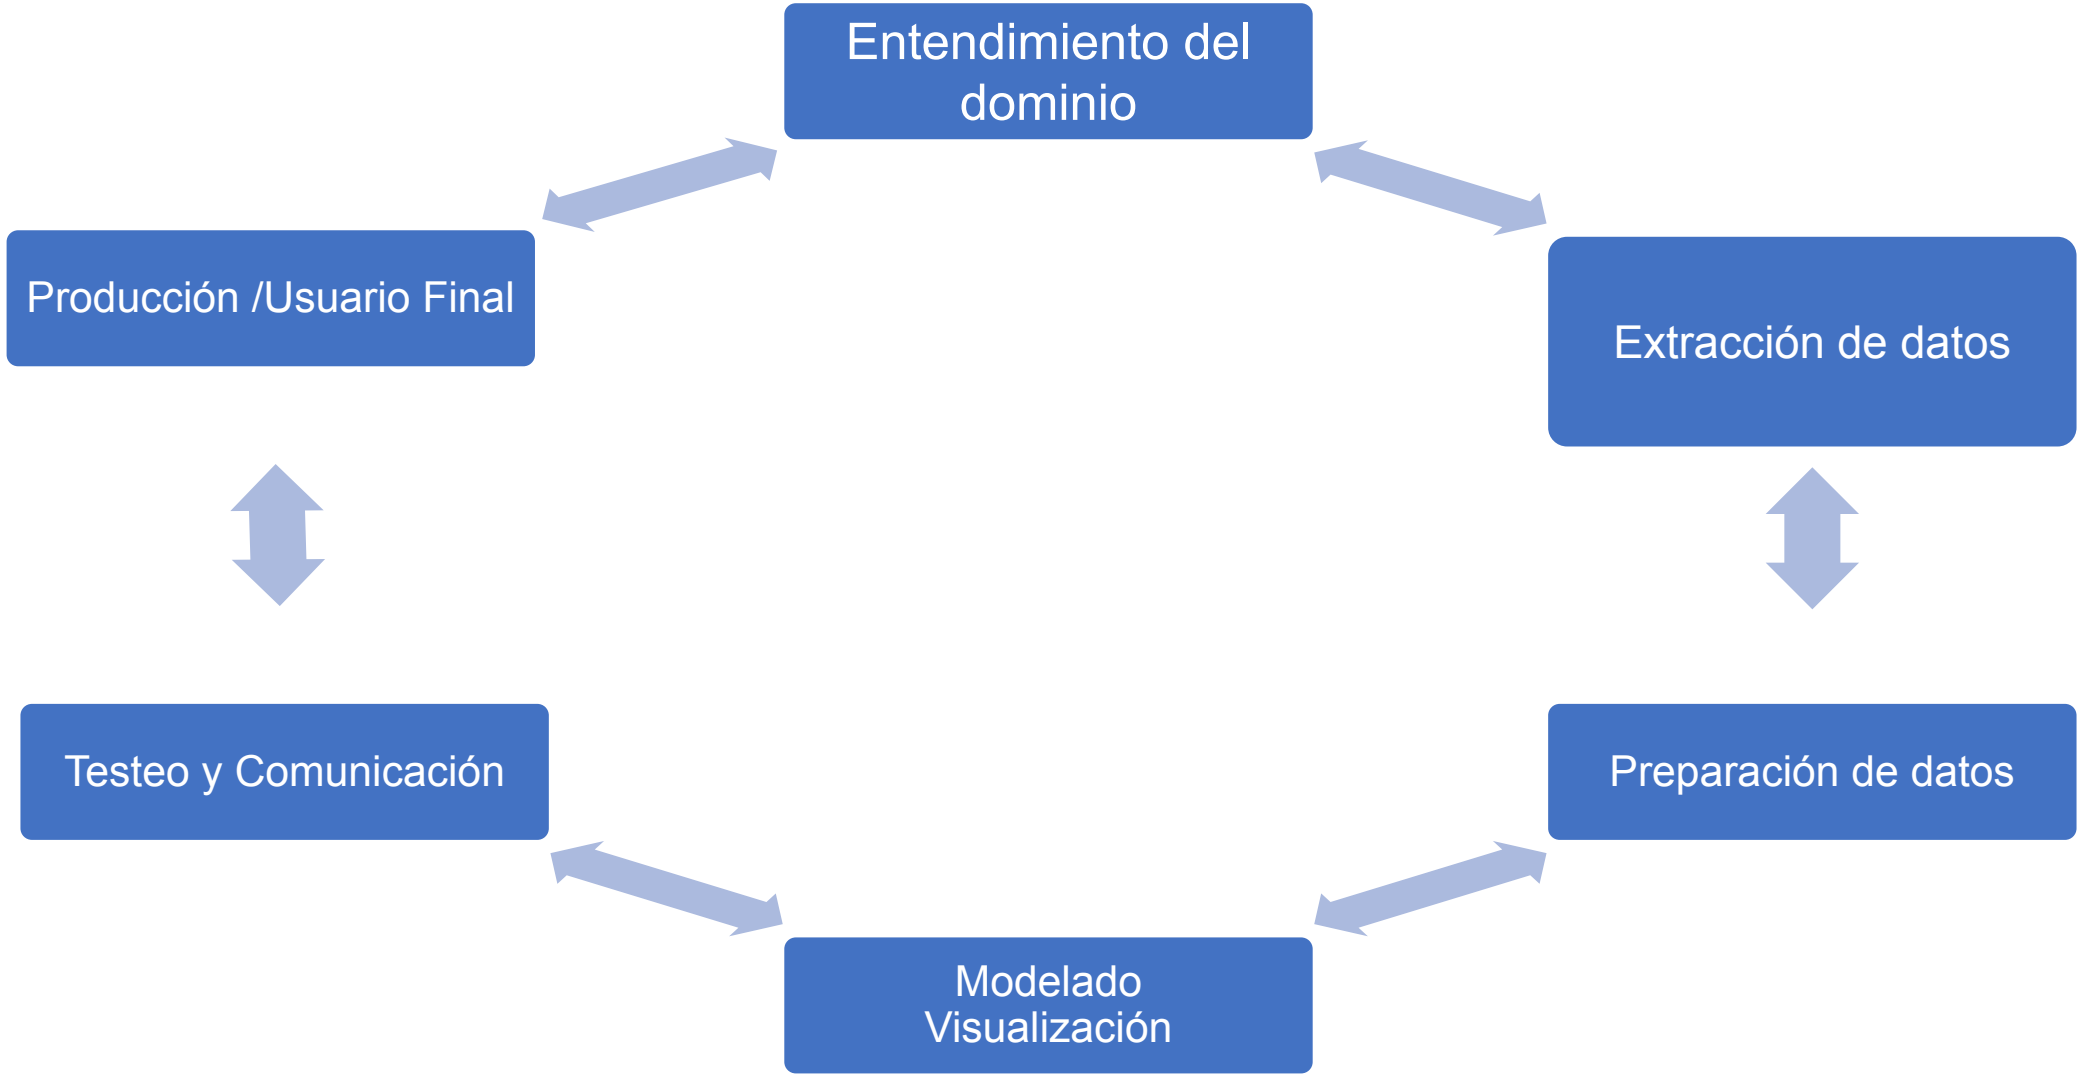
Data Science journal

International Council for Science: Committee on Data for Science and Technology

Concepto


Data Flair
Client Requirements
Highlight important criteria
Domain Knowledge
Easier explanation of technical concepts
Database Languages (SQL, Hadoop)
Data governance
Data Preprocessing
Data Validation
Data Infrastructure
Data Engineer
Research & Analysis
Statistical Knowledge
Data Science
Mathematics
Computer Science
Machine Learning
Mathematical & Statistical Aptitude
Designing Methods
Tuning & Fitting the Model
Python, R and other languages
Classification and Regression Models

El proceso de Ciencia de Datos



Tareas en Ciencia de Datos

- **Descriptivas**: lograr una o varias descripciones a partir de dataset. ¿Qué pasó? Ej: segmentación de clientes.
- **Diagnósticas**: Realizando análisis sobre datos históricos y actuales, podemos obtener detalles de por qué un determinado evento en realidad sucedió en un determinado período de tiempo.¿Qué está pasando?. Ej: pérdidas de cosechas.
- **Predictivas**: el objetivo es obtener un modelo para predecir comportamientos o valores. ¿Qué pasará? Ej: obtener las reglas que me determinan los tipos de clientes, obtener una función que me prediga si apruebo CD.
- **Prescriptivas/recomendación**: encontrar las causas del problema y dar alternativas de solución. ¿Qué pasó y cómo puedo mejorar? Ej: medicina.

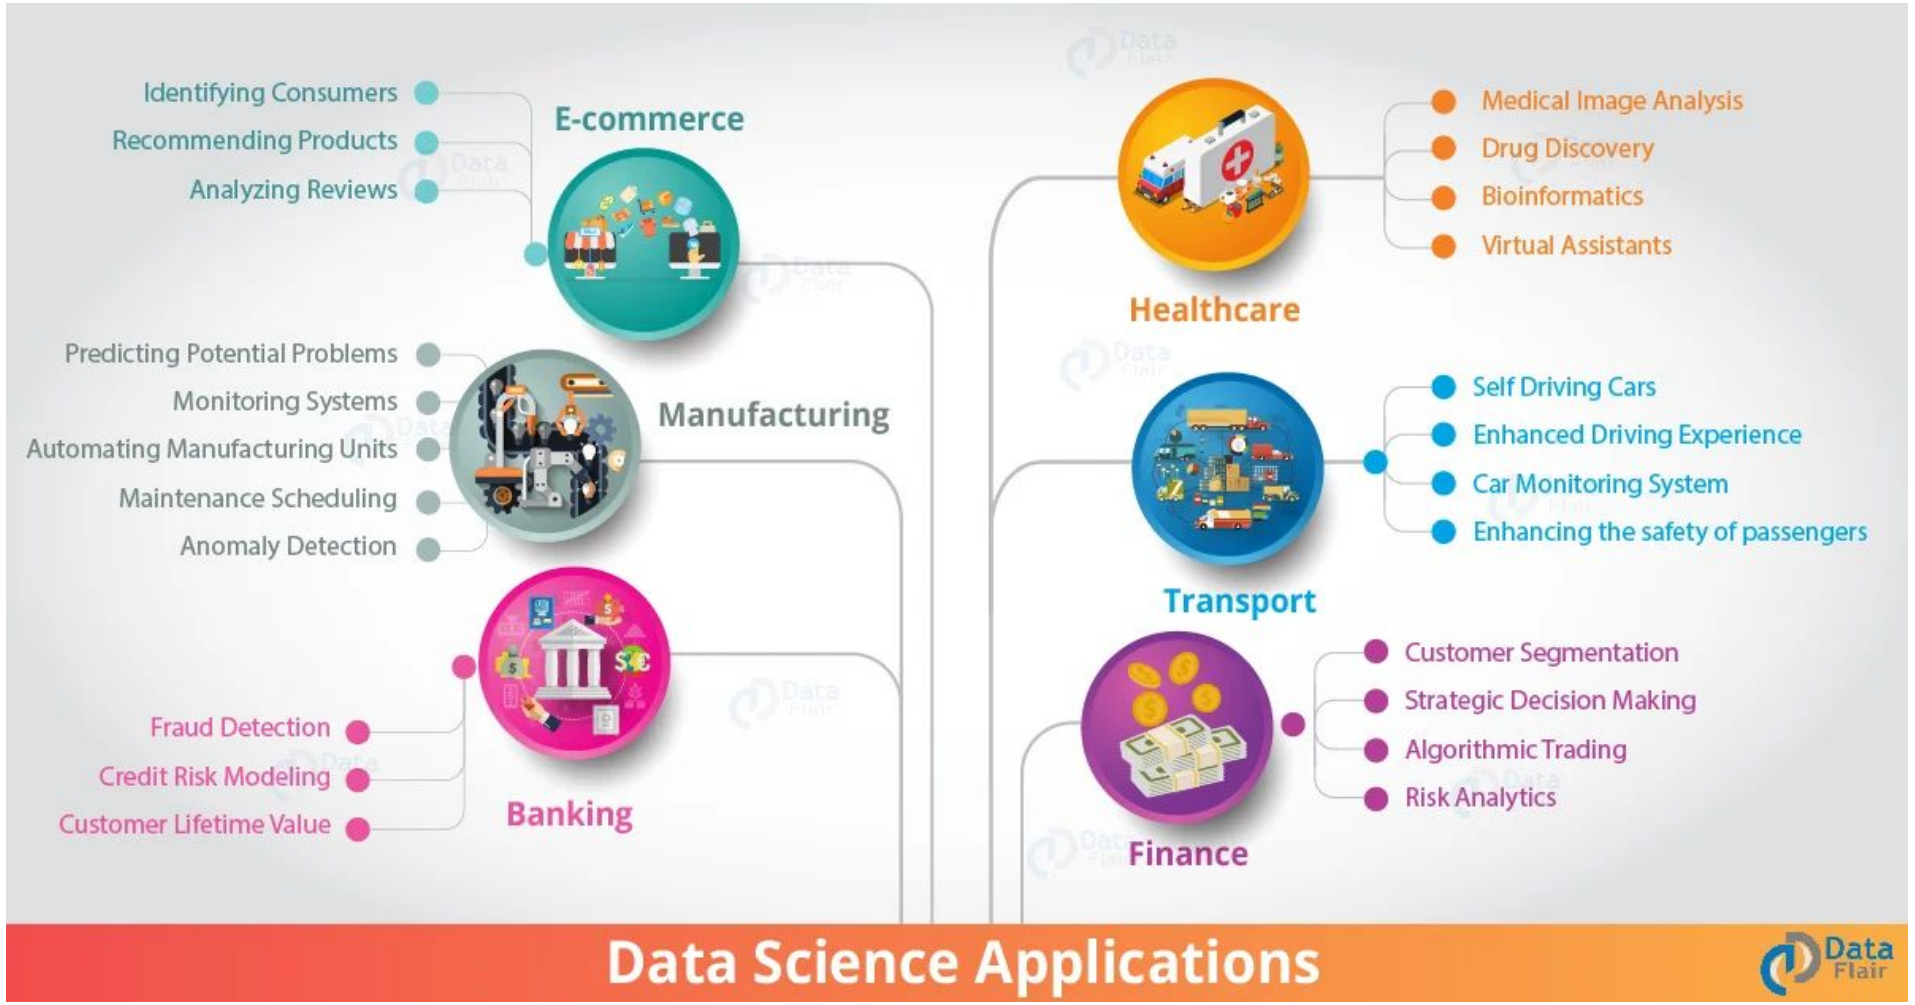
Roles en la ciencia de datos

	Business Understanding	Data Understanding	Data Preparation	Modeling	Evaluation	Deployment
Data Scientist	Mid	High	Mid	Top	High	Lower
Data Engineer	Mid	High	Top	Lower	Lower	Mid
Data Analyst	Mid	Top	Mid	Mid	Lower	Lower
ML Engineer	Mid	Lower	Mid	Mid	High	Top
Product Owner	Top	Mid	Lower	Lower	Top	Lower
Project Manager	High	Lower	Lower	Lower	Mid	Mid

https://www.datascience-pm.com/data-science-roles/

Fundamentos de la Ciencia de Datos

Aplicaciones



Hablemos de datos

¿Qué entienden por **datos**?

Fundamentos de la Ciencia de Datos

Los datos

"Los datos son información sin procesar que se recopila, almacena y procesa. Pueden estar en formatos estructurados o no estructurados, como bases de datos, texto, imágenes o videos. Los datos pueden ser: hechos, números, nombres, cifras o descripciones de cosas. Pueden organizarse en gráficos, diagramas o tablas."

- Un atributo (característica, *feature*, variable) es una propiedad o característica de un objeto. Ej: nacionalidad, color, altura, etc.
- Una colección de atributos describe un objeto (registro, punto, caso, muestra, entidad, instancia).
- Metadato: datos acerca de los datos, es decir que representan cada uno de esos datos en el dominio, Ej: qué valores pueden tomar, cuando fueron modificados/cargados, como, quien...



Tipos de datos

- **Estructurados**: se presentan un esquema bien definido y los datos se organizan en filas y columnas.



- **No estructurados**: no presentan un esquema definido, sino que como punto de partida hay que encontrar la manera de indexar e identificar el significado de los datos, para recién pensar en cómo se procesarán.



- **Semi-estructurados**: poseen determinada forma de organización interna (jerarquías, tags, etc.) que debe ser identificada.



https://www.linkedin.com/pulse/tipo-de-datos-estructurados-semi-y-dario-bernabeu-bseof/

Calidad de datos

La calidad de los datos es la optimización de los datos hacia el estado deseado, aproximándonos a la pregunta: *"¿Qué obtenés en comparación con lo que esperás?"* Los datos deben ajustarse a las expectativas en los metadatos del dominio. *¿Los datos coinciden con la definición acordada por la empresa/dominio?*

Características:

- **Exactitud**: ¿Los datos recopilados son objetivamente correctos? ¿Hay valores duplicados? ¿Los valores numéricos son precisos?
- **Completitud**: ¿Están completos los registros? ¿Todos los campos obligatorios contienen valores válidos?
- **Oportunidad**: ¿Están los registros disponibles de manera oportuna?

Fundamentos de la Ciencia de Datos

Calidad de datos: dimensiones



ACCURACY

Does it reflect the reality correctly?



CONSISTENCY

Consistent across multiple sources?



COMPLETENESS

Do we have all the required data?



TIMELINESS

Up to date?



VALIDITY

Format respecting business requirements?



UNIQUENESS

Are all features unique?

https://towardsdatascience.com/what-is-data-quality-f2c0274a6404

Ninguna

Fundamentos de la Ciencia de Datos

Calidad de datos: dimensiones

Dimensión	Descripción	Comprobaciones de calidad de datos predefinidas que identifican problemas asociados a esta dimensión
Precisión (Accuracy)	Los valores de datos están lo más cerca posible de los valores reales.	Ninguna.
Nivel de detalle (Completeness)	Todos los valores de datos necesarios están presentes.	**Valores perdidos inesperados**
Coherencia (Consistency)	Los valores de datos dentro de una columna cumplen con una regla.	**Mayúsculas y minúsculas incoherentes** **Representación incoherente de los valores perdidos** **Valores sospechosos**
Puntualidad (Timeliness)	Los datos representan la realidad desde un punto en el tiempo requerido.	Ninguna.
Exclusividad (Uniqueness)	Los valores distintos sólo aparecen una vez.	**Valores duplicados inesperados**
Validez (Validity)	Los datos se ajustan al formato, tipo o rango de su definición.	**Infracciones de clase de datos** **Infracciones de tipo de datos** **Infracciones de formato** **Valores fuera de rango**

Ingeniería de datos

La **ingeniería de datos (*data engineering*)** es el desarrollo, implementación y mantenimiento de sistemas y procesos que toman datos sin procesar y producen información consistente y de alta calidad que respalda casos de uso posteriores, como el análisis y el aprendizaje automático.

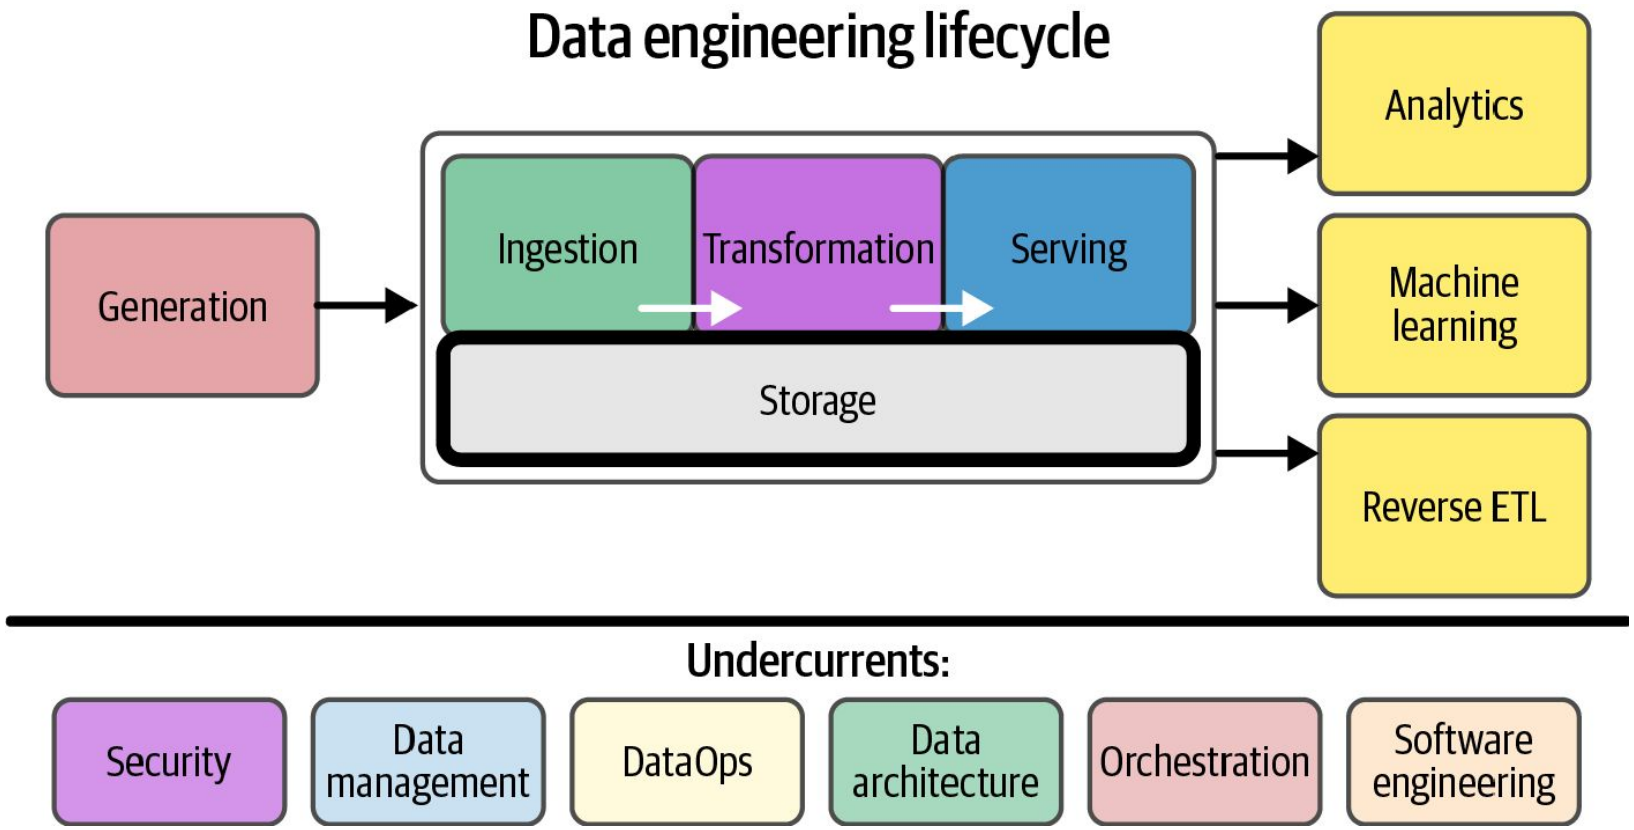
La ingeniería de datos es la intersección de la seguridad, la gestión de datos, DataOps, la arquitectura de datos, la orquestación y la ingeniería de software.

Un **ingeniero de datos (*data engineer*)** gestiona el ciclo de vida de la ingeniería de datos, comenzando con la obtención de datos de los sistemas de origen y terminando con la entrega de datos para casos de uso, como análisis o aprendizaje automático.



Reis J. and Housley M.(2022) Fundamentals of Data Engineering.

Ciclo de vida de la ingeniería de datos



Reis J. and Housley M.(2022) Fundamentals of Data Engineering.

¿Qué vimos hoy?

1. Los temas que vamos a aprender durante esta cursada y como aprobar/promocionar.
2. La Ciencia de datos como un proceso centrado en los datos para dar valor agregado y mejorar la toma de decisiones. Necesitamos **saber aplicar** matemática, ciencias de la computación y tener conocimiento del dominio(o pedir ayuda).
3. Reconocimos los roles.
4. Empezamos a entender qué es la calidad de datos.
5. Descubrimos la ingeniería de datos.

Material adicional:

- Reis J. and Housley M.(2022) Fundamentals of Data Engineering.



¿Dudas?

