

FACULTAD DE CIENCIAS EXACTAS UNICEN

Acceso y análisis de datos (parte I)

Fundamentos de la Ciencia de Datos

Roadmap

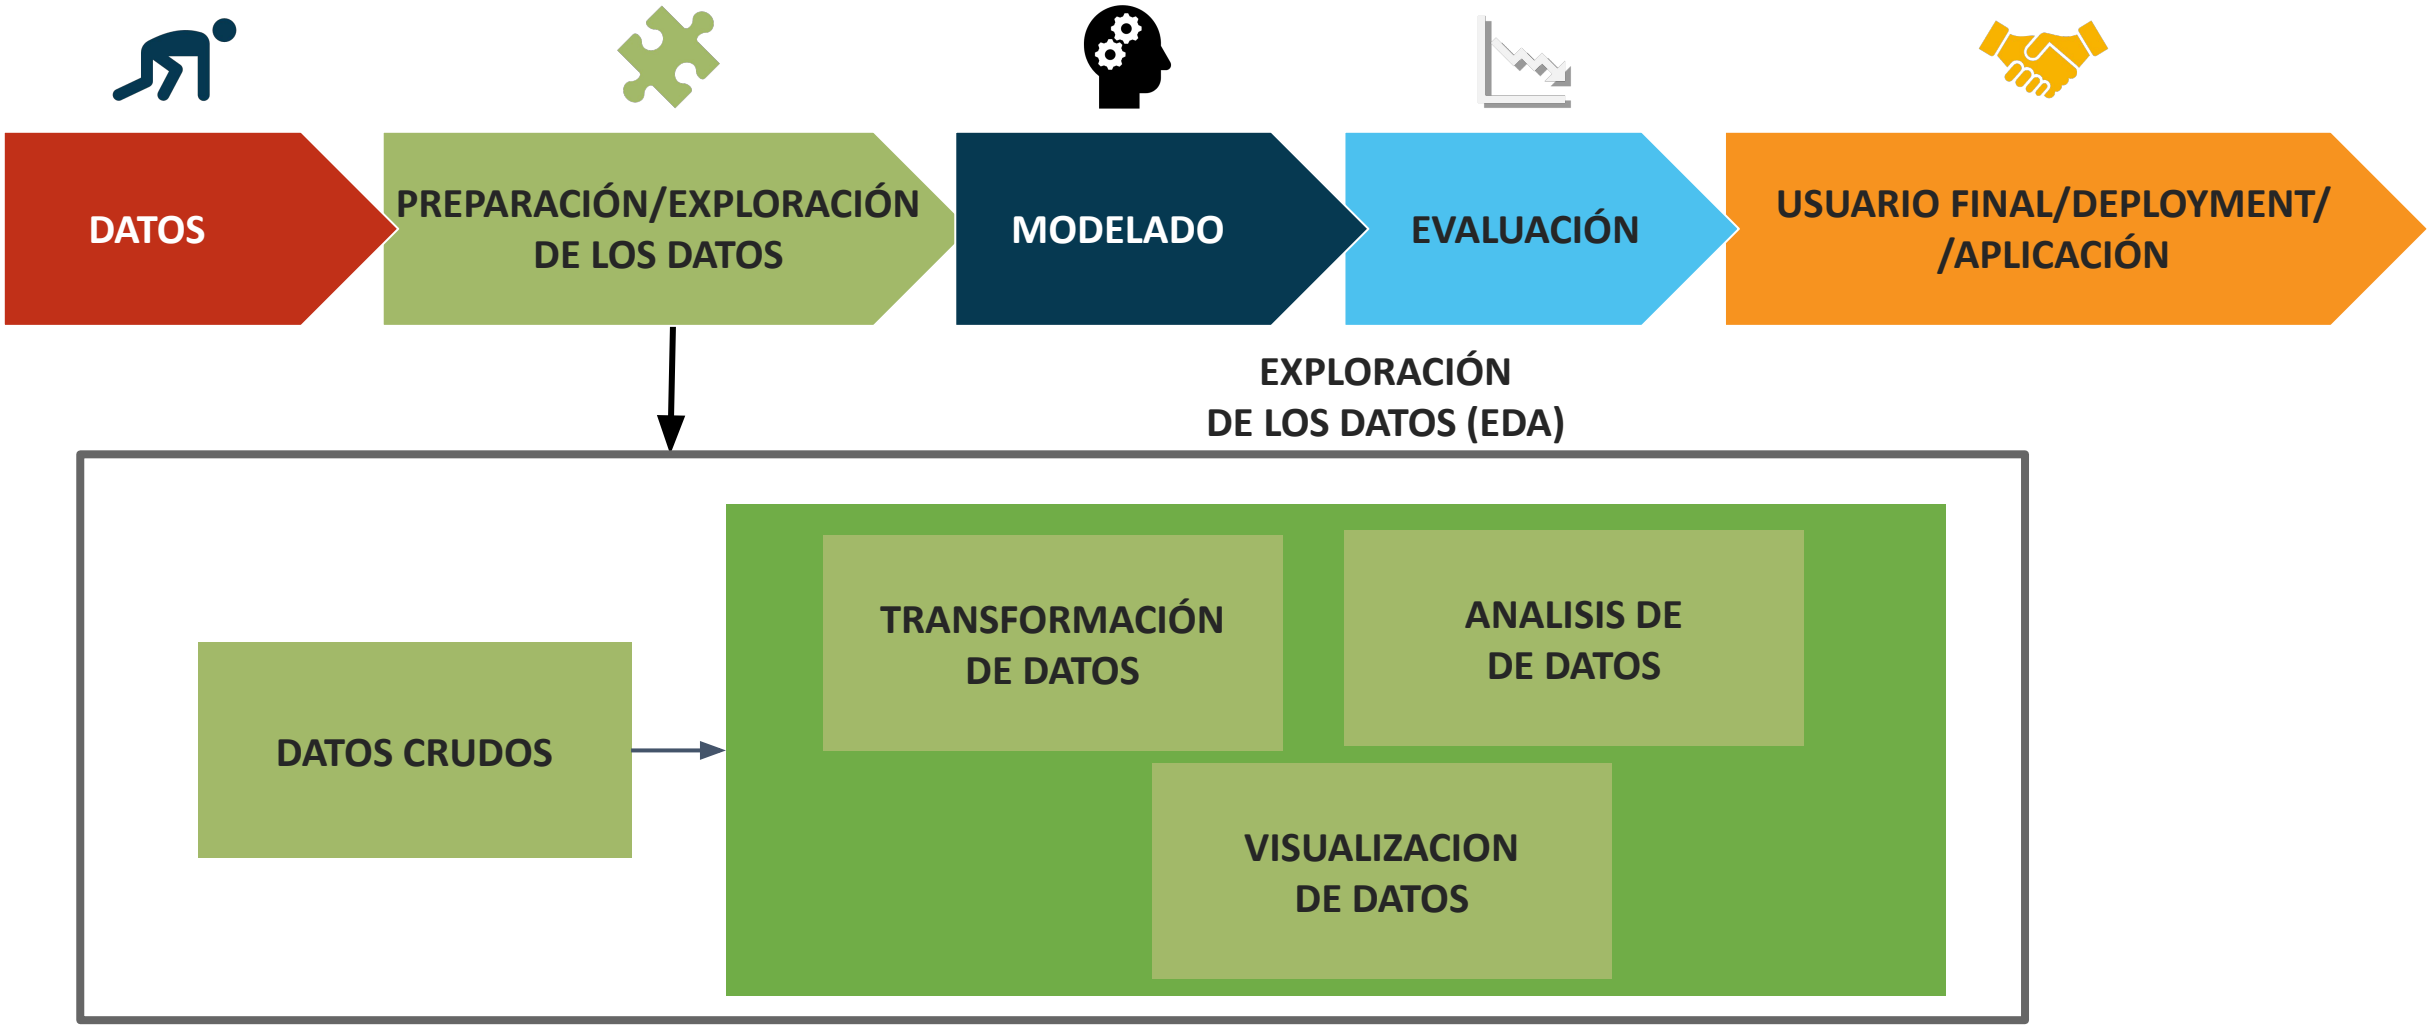






DATOS → PREPARACIÓN/EXPLORACIÓN DE LOS DATOS → MODELADO → EVALUACIÓN → USUARIO FINAL/DEPLOYMENT/ /APLICACIÓN

Roadmap


DATOS
PREPARACIÓN/EXPLORACIÓN DE LOS DATOS
MODELADO
EVALUACIÓN
USUARIO FINAL/DEPLOYMENT/ /APLICACIÓN
EXPLORACIÓN DE LOS DATOS (EDA)
DATOS CRUDOS
TRANSFORMACIÓN DE DATOS
ANALISIS DE DE DATOS
VISUALIZACION DE DATOS

Análisis Exploratorio de Datos (EDA)

Proceso para:

- Comprender patrones, relaciones y tendencias en los datos
- Chequear suposiciones sobre los datos
- Identificar problemas o anomalías en los datos que puedan afectar el análisis subsecuente
- Informar el análisis o modelado posterior de los datos (ej. características importantes)
- Descubrir posibles hipótesis (nuevas hipótesis puede disparar la investigación sobre algún aspecto de los datos)

Mantener una actitud abierta!
Look for what you believe is there and what you believe is not there (Tukey, 1965)

Análisis Exploratorio de Datos (EDA)

Datos

Tipos de datos: ¿Cómo están registrados nuestros datos? ¿Es un número? ¿Es una categoría? ¿Es un texto libre?

Granularidad: ¿Qué tan “fino”/”grueso” es cada dato? ¿Es un dato individual/crudo, o es un dato resumen/agregado?

Alcance: ¿Qué tan completo/incompletos están los datos? ¿cómo fueron recolectados?

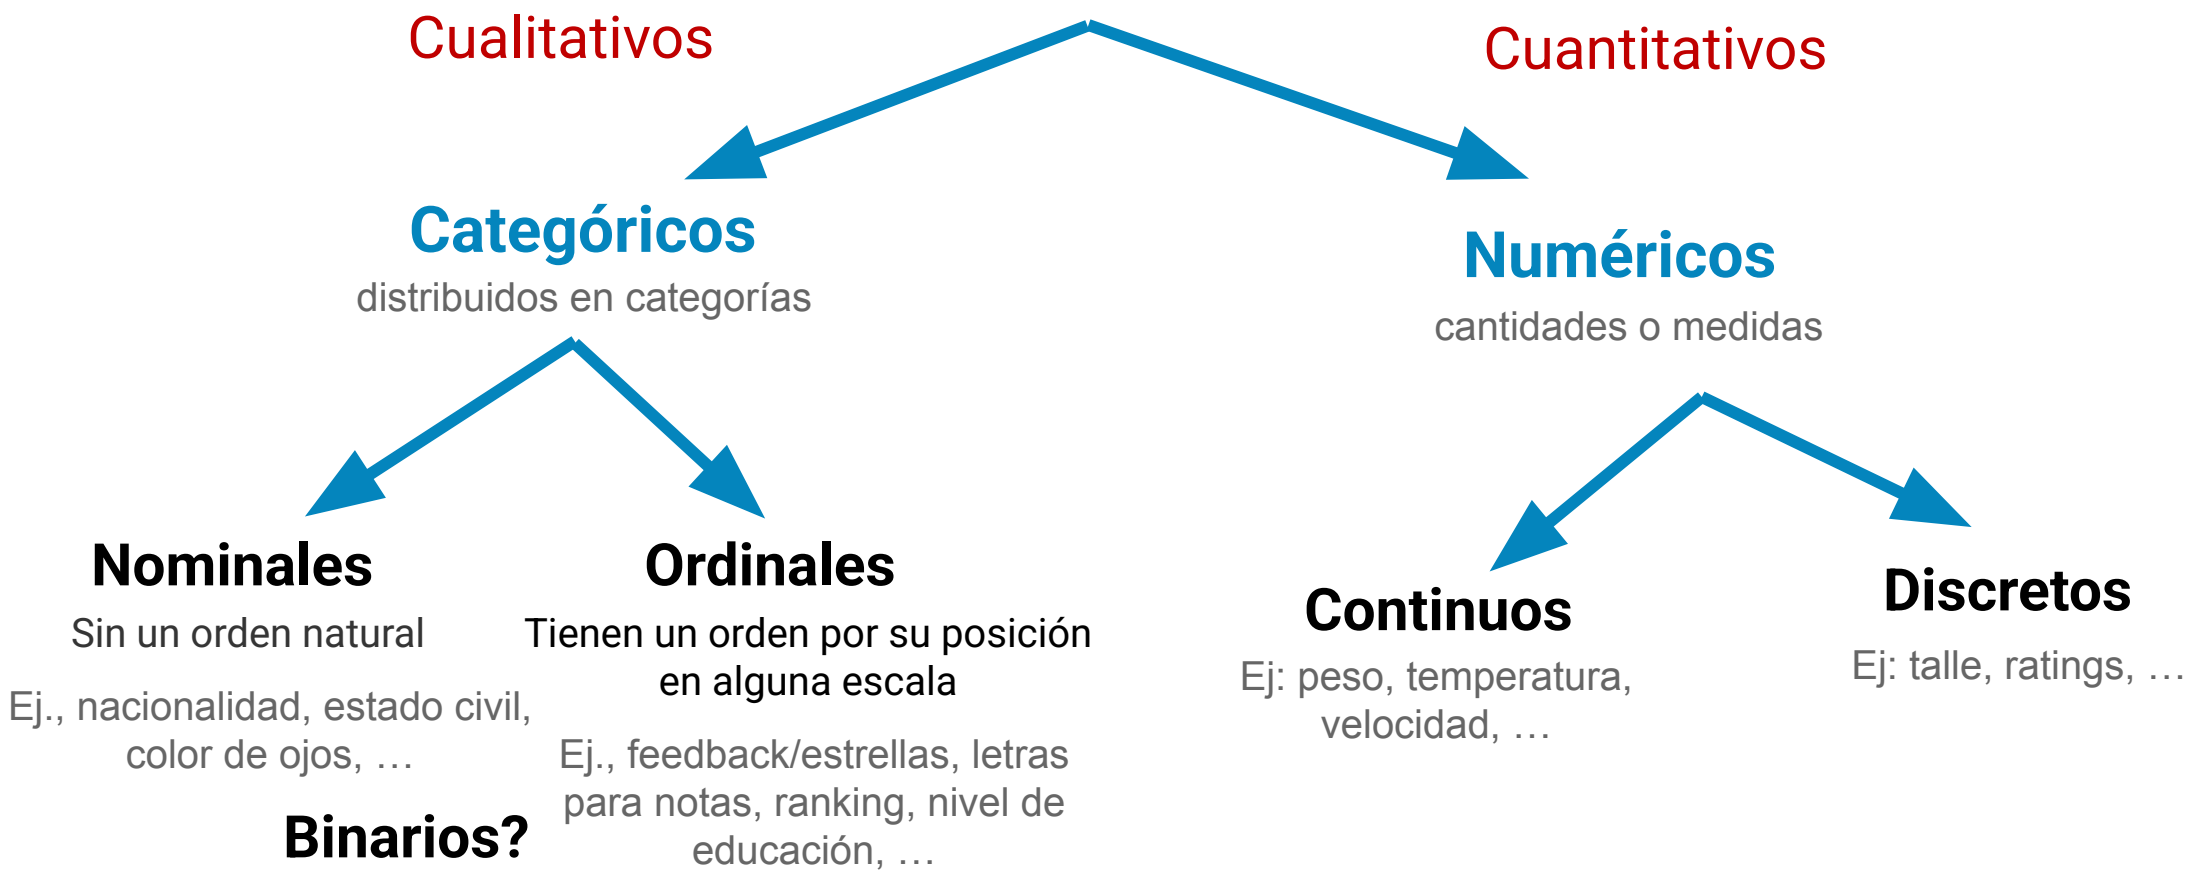
Temporalidad: ¿Cómo están situados los datos en el tiempo?

Confiabilidad: ¿Con qué precisión los datos describen el dominio?

Análisis Exploratorio de Datos (EDA)

Datos / Tipo de Datos

Desde un punto de vista estadístico:



Datos / Tipo de Datos

Desde un punto de vista computacional:

- Tipos de datos: int, float, string, boolean, etc.
- Cada columna (en pandas por ej.) tiene un tipo de dato, pero eso no implica un tipo de dato estadístico
  - Ej. la provincia se puede codificar como 0 (Bs As), 1 (La Pampa), 2 (Santa Fe)..., pero eso no implica un tipo de dato numérico

Análisis Exploratorio de Datos (EDA)

Datos / Granularidad

Granularidad se refiere al nivel de detalle o al grado en que los datos están divididos o desagregados

- Identificar valores únicos: una cardinalidad más alta indica una granularidad fina, baja cardinalidad sugiere granularidad más gruesa
- Investigar relaciones jerárquicas: como categorías y subcategorías de productos, ver la profundidad y amplitud de la jerarquía (ej. e-commerce)

Granularidad alta

ID_compra	Fecha	Cliente	Producto	Cantidad	Precio
001	2025-08-25	123	Zapatillas	1	50
002	2025-08-25	456	Camiseta	2	30

Granularidad baja

Fecha	Producto	Cantidad_total	Ingreso_total
2025-08-25	Zapatillas	10	500
2025-08-25	Camiseta	25	375

Relaciones jerárquicas: Producto → Subcategoría → Categoría.

- Zapatillas → Calzado → Indumentaria
- Camiseta → Ropa → Indumentaria

Datos / Granularidad

¿Hay datos agregados? ¿cómo fue la agregación? ¿Qué formas de agregación son posibles?

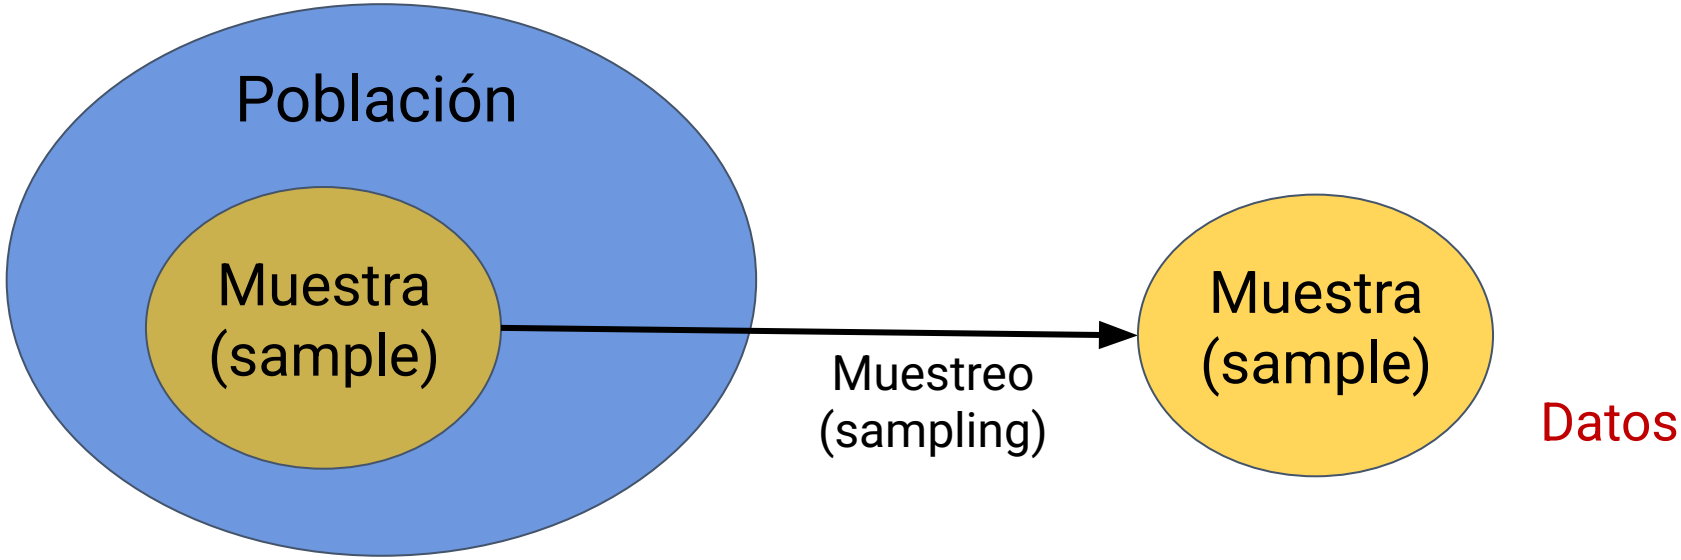
- Promedio, suma, min, max, etc.
- De individuos a categorías
- De episodios a totales en el tiempo o por categoría

Por ejemplo en el caso de ventas de un local deportivo:

- Registro del promedio diario de venta de zapatillas
- Gasto máximo por cliente
- De episodios a totales en el tiempo: suma de ventas por me.

Datos / Alcance

¿Cómo fue diseñado el muestreo de los datos?



Población de interés

Tendremos poco control sobre el proceso de sampleo!

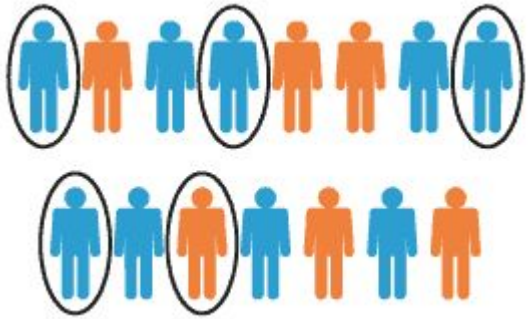
Análisis Exploratorio de Datos (EDA)

Datos / Alcance

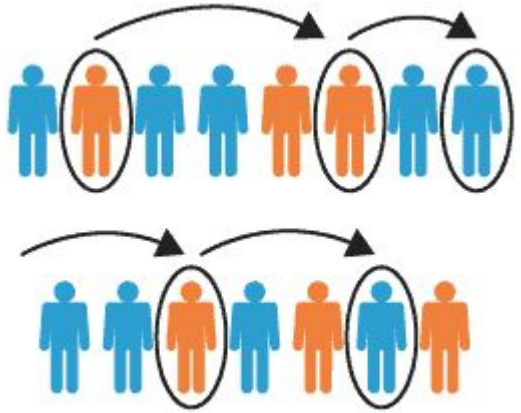
Muestreos probabilísticos:

Muestreo aleatorio simple

Cada elemento tiene la misma probabilidad de ser seleccionado



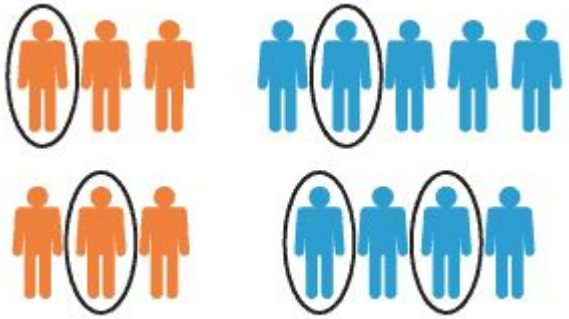
Muestreo sistemático



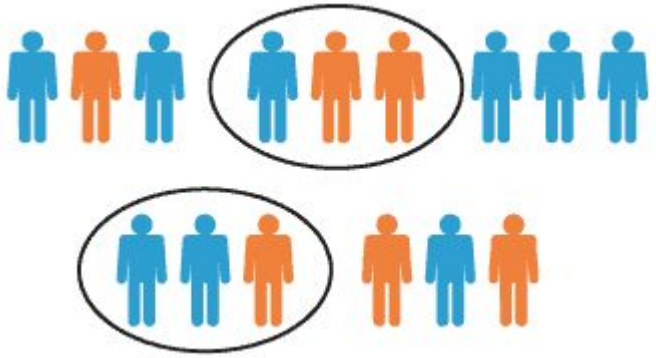
Implica seleccionar elementos a intervalos regulares

Muestreo estratificado

Divide a la población en estratos que no se superponen en función de características compartidas



Muestreo por clusters



Agrupa la población en clusters y se selecciona una muestra aleatoria de clusters

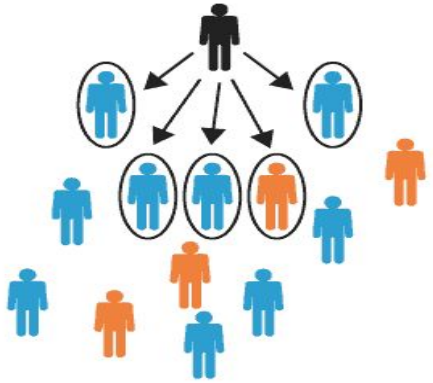
Análisis Exploratorio de Datos (EDA)

Datos / Alcance

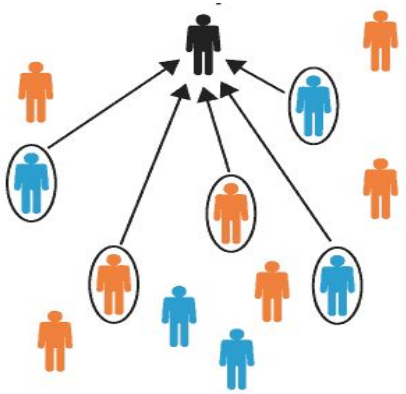
Muestreos no probabilísticos:

Muestreo de conveniencia

Implica seleccionar elementos que estén fácilmente disponibles o de fácil acceso



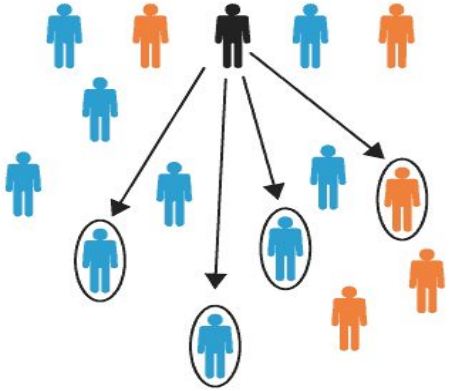
Muestreo de respuesta voluntaria



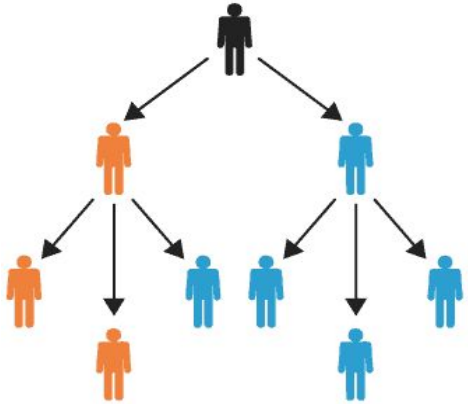
Los participantes son autoelegidos

Muestreo intencional

Seleccionar a los participantes en función del conocimiento y juicio de quién sería un participante apropiado



Muestreo snowball



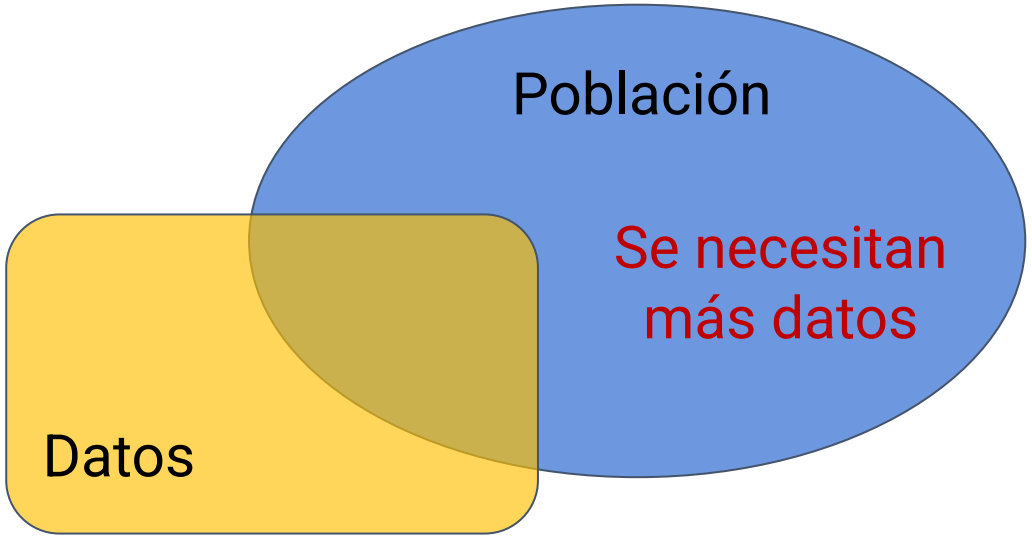
Los participantes ayudan a reclutar a otros

Datos / Alcance

¿Los datos que tengo cubren mi área de interés?

- Ejemplo: me interesa estudiar la criminalidad en la Provincia de Bs. As., pero solo tengo datos de Tandil

En general, solo podríamos hacer inferencias sobre la muestra de la población que nos interesa



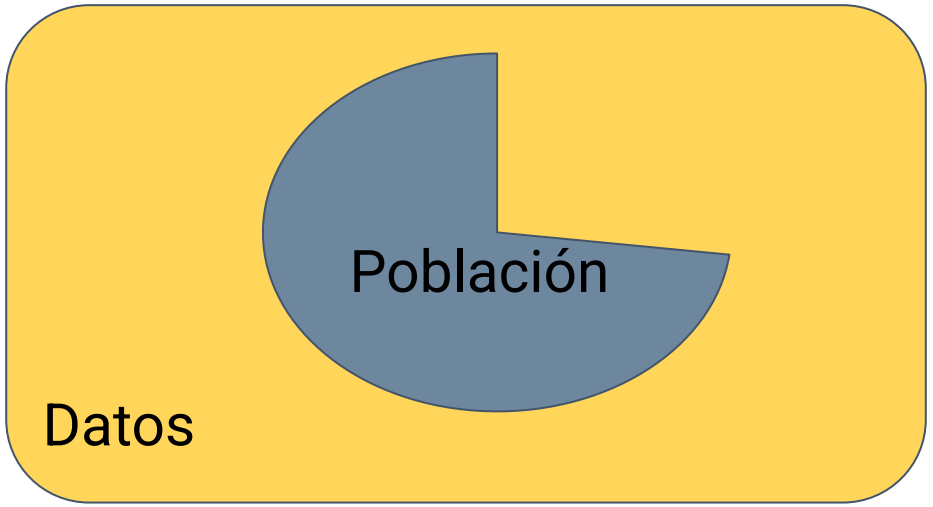
Datos / Alcance

¿Los datos cubren más que mi área de interés?

- Ejemplo: me interesa estudiar la criminalidad en la Provincia de Bs. As. y tengo datos de todo el país

Una muestra sobre un alcance amplio podría tener poca cobertura en el alcance específico

Se necesitan filtrar los datos



Datos / Temporalidad

Cuál es el significado de los datos que implican tiempo:

- Cuándo ocurrió el evento?
- Cuándo se registraron o ingresaron los datos al sistema?

El tiempo y su formato depende de la ubicación:

- Zonas horarias
- Horario de verano (que cambia en diferentes días en diferentes regiones)
- Formato regional (07/06 vs 06/07)

Datos / Confiabilidad

¿Debería confiar en los datos que tengo?

- Contienen valores incorrectos o poco realistas?
  - Fechas en el futuro para eventos pasados
  - Ubicaciones que no existen
  - Valores inconsistentes o valores fuera de rango
  - Errores ortográficos
  - Números con errores de tipeo
- Los datos violan dependencias obvias?
  - Ej. La fecha de nacimiento y la edad no coinciden
- Fueron los datos ingresados a mano?
  - Errores de tipeo, campos corridos, etc.

Datos / Confiabilidad

- El formulario de ingreso de los datos daba opciones por defecto?
- Hay señales de falsificación de los datos?
  - Nombres repetidos, email inexistentes, nombres comunes (John Doe)

Datos / Fuente de Datos

Por su fuente:

- Fuente primaria: recolectados directamente desde su fuente, alto control y precisión
- Fuente secundaria: recolectados por terceros, requieren análisis cuidados por sesgos y limitaciones

Por el tiempo:

- Transversal: un punto simple en el tiempo, sin seguimiento, instantanea (snapshot)
- Series de tiempo: datos en un período de tiempo, permite analizar tendencias y cambios

Limpieza de Datos

La limpieza de datos usualmente trabaja sobre:

- La estructura de los datos
- El encoding y/o formateo de variables (por e., strings -> números)
- Valores faltantes o con ruido
- Conversión de unidades e interpretación de magnitudes
- Extracción de características de valores complejos (por ej. el año en un timestamp: 2025-08-25 14:32:10)

Limpieza de Datos

- **Inconsistente**: contiene discrepancias

  Ej. edad="42", nacimiento="03/07/2010"

  "1, 2, 3", "A, B, C"

  discrepancia entre registros duplicados

  Ej. Jan. 1 es el cumpleaños de todos?

- **Tamaño excesivo**: en número de filas o de columnas (selección de features o instancias)

Transformación

La transformación de características es el proceso de convertir o modificar características existentes en un dataset en otras representaciones, incluyendo:

- Encoding
- Escalado
- Normalización
- Transformaciones
- Discretización
- Smoothing

Transformación / Encoding

Encoding (“codificación”): el proceso de convertir datos categóricos o textuales a formato numérico

Datos categóricos:

- Datos ordinales: las categorías se pueden clasificar u ordenar de mayor a menor o viceversa (ej. notas)
- Datos nominales: no se pueden ordenar (ej. ciudades)

La mayoría de los algoritmos de machine learning funcionan con números y no con texto o variables categóricas

Transformación / Ordinal Encoding

Label encoding: cada valor único de una característica se mapea a un entero

- Rating: {low, medium, high} → {1,2,3}

Película	Rating	Género
Misión Imposible	high	acción
High School Musical	medium	musical
Alien	low	sci-fi



Película	Rating	Género
Misión Imposible	3	acción
High School Musical	2	musical
Alien	1	sci-fi

Transformación / Ordinal Encoding

Ventajas

- Simple, eficiente
- La forma y densidad del dataset continúa siendo la misma

Desventajas

- El mapeo debe ser cuidadoso para preservar el orden natural
- **Solo puede usarse cuando la categoría es ordinal, el orden es significativo!**

Transformación / Label Encoding

Label encoding: cada valor único de una característica se mapea a un entero

- Género: {acción, musical, sci-fi} → {1,2,3}
- medium > low, pero sci-fi > musical ?

Película	Rating	Género
Misión Imposible	high	acción
High School Musical	medium	musical
Alien	low	sci-fi



Película	Rating	Género
Misión Imposible	3	1
High School Musical	2	2
Alien	1	3

Un algoritmo de ML podría inducir que hay un orden que no es tal!

Se usa solo para atributos de clase o variables objetivo

Transformación / One-Hot Encoding

A cada valor de una categoría se lo transforma en una característica binaria, que será 1 si la característica tiene dicho valor

Película	Rating	Género
Misión Imposible	high	acción
High School Musical	medium	musical
Alien	low	sci-fi



Película	Rating	acción	musical	sci-fi
Misión Imposible	3	1	0	0
High School Musical	2	0	1	0
Alien	1	0	0	1

Transformación / One-Hot Encoding

Ventajas

- Nuevos valores se pueden agregar más tarde como nuevas columnas
- Evita la ordinalidad, si no es importante

Desventajas

- Aumenta la dimensionalidad ya que cada valor de la categoría se transforma en una columna (complejidad, procesamiento, etc.)
- El dataset se vuelve más esperso ya que introduce muchos 0 en cada fila

Transformación / Dummy Encoding

En lugar de crear k características binarias igual al número de categorías, usa k-1 características

- Remueve una característica redundante del hot-one encoding

Película	Rating	Género
Misión Imposible	high	acción
High School Musical	medium	musical
Alien	low	sci-fi

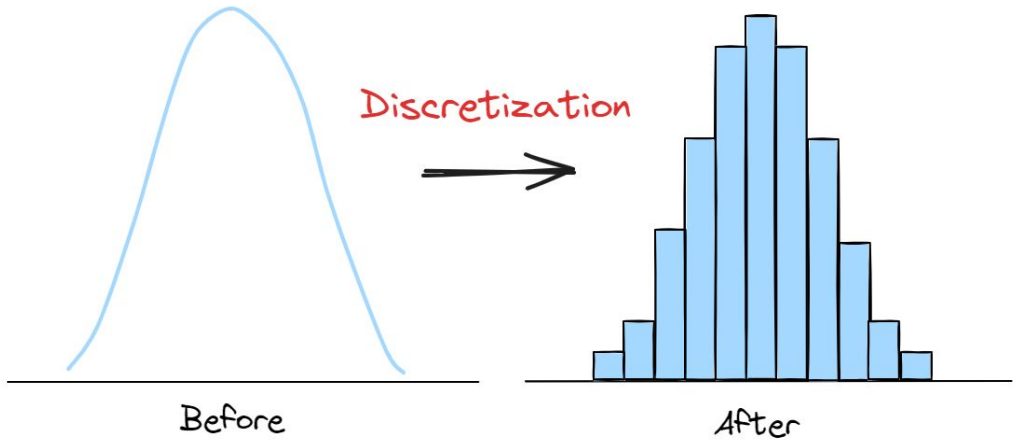


Película	Rating	g1	g2
Misión Imposible	3	1	0
High School Musical	2	0	1
Alien	1	0	0

Transformación / Discretización

Los valores discretos representan información de forma más concisa, son más fácil de entender y más cercano a la representación de conocimiento

- Ej. edad -> {niños, jovenes, adultos, ancianos}



Transformación / Discretización

La discretización convierte variables continuas en intervalos discretos, haciéndolos más adecuados para el análisis

- Las etiquetas de intervalo se pueden usar para reemplazar los valores de datos reales
- Reducir el tamaño de los datos mediante discretización
- Dividir (de arriba hacia abajo) versus fusionar (de abajo hacia arriba)
- La discretización se puede realizar de forma recursiva en un atributo

Transformación / Discretización

¿Cómo discretizamos un atributo?

Por ej. edad:

<=16

16...24

24...30

30+

Dependiente de los datos!

¿Qué pasa si queremos predecir riesgo de Alzheimer?

Transformación / Discretización

Igual anchura (equal-width)

- Divide el rango de datos en N intervalos de igual tamaño (uniforme)
- Dados el máximo y mínimo de valores del atributo, el ancho de los intervalos será:

$$w = \frac{max(x) - min(x)}{N}$$

- Los outliers caen en bins (contenedores) separados
- No maneja bien distribuciones sesgadas

Igual profundidad o frecuencia (equal-depth)

- Divide el rango de datos en N intervalos, conteniendo (aproximadamente) el mismo número de datos
- Se ordenan los datos y se divide en partes iguales

Transformación / Discretización

Datos ordenados: 10, 15, 18, 20, 31, 34, 41, 46, 51, 53, 54

Equal-width bins:

BIN 1 = [(min) , (min + w -1)] = [10, 20]

BIN 2 = [(min + w) , (min + 2w -1)] = [21, 31]

BIN 3 = [(min + 2w) , (min + 3w -1)] = [32, 42]

BIN 4 = [(min + 3w) , (max)] = [43, 54]

Dato	BIN
10	B1
15	B1
18	B1
20	B1
31	B2
34	B3
41	B3
46	B4
51	B4
53	B4
54	B4

Transformación / Discretización

Datos ordenados: 10,15, 18, 20, 31, 34, 41, 46, 51, 53, 54, 60

Equal-depth bins:

BIN 1: 10, 15, 18, 20

BIN 2: 31, 34, 41, 46

BIN 3: 51, 53, 54, 60

Dato	BIN
10	B1
15	B1
18	B1
20	B1
31	B2
34	B3
41	B3
46	B4
51	B4
53	B4
54	B4
60	B4

Transformación / Discretización

Discretización basada en Entropía:

- Entropía es una medida de la (in)pureza de un conjunto de datos
- Dada una colección S y p_i la proporción de S perteneciente a la clase *i*
  - Si todos los miembros de S pertenecen a la misma clase, entonces Entropia(S)=0
  - Si hay igual número de ejemplos en cada clase, entonces Entropia(S)=1

	Sueldo <= 50K	Sueldo > 50K
Edad >= 25	4	6

	Sueldo <= 50K	Sueldo > 50K
Edad < 25	9	1

Transformación / Discretización

Discretización basada en Entropía:

$$Entropy(S) = -\sum_{i=1}^{m} p_i \log_2 p_i$$

donde p_i es la probabilidad de una clase *i* en S

	Sueldo <= 50K	Sueldo > 50K
Edad >= 25	4	6

$$Entropy(\text{Edad} < 25) = -\left(\frac{4}{10}\log_2\left(\frac{4}{10}\right) + \frac{6}{10}\log_2\left(\frac{6}{10}\right)\right) = .529 + .442 = .971$$

	Sueldo <= 50K	Sueldo > 50K
Edad < 25	9	1

$$Entropy(\text{Edad} < 25) = -\left(\frac{9}{10}\log_2\left(\frac{9}{10}\right) + \frac{1}{10}\log_2\left(\frac{1}{10}\right)\right) = .137 + .332 = .469$$

Transformación / Discretización

Dada una muestra S, si particionamos en dos intervalos S_1 y S_2 usando un threshold T, podemos calcular:

$$I(S) = \frac{|S_1|}{|S|} Entropy(S_1) + \frac{|S_2|}{|S|} Entropy(S_2)$$

	Sueldo <= 50K	Sueldo > 50K
Edad < 25	9	1
Edad >= 25	4	6

$$I(S) = \frac{1}{2}(.469) + \frac{1}{2}(.971)$$

El T que minimice el valor de I de todos los posibles thresholds sería el elegido para la discretización binaria

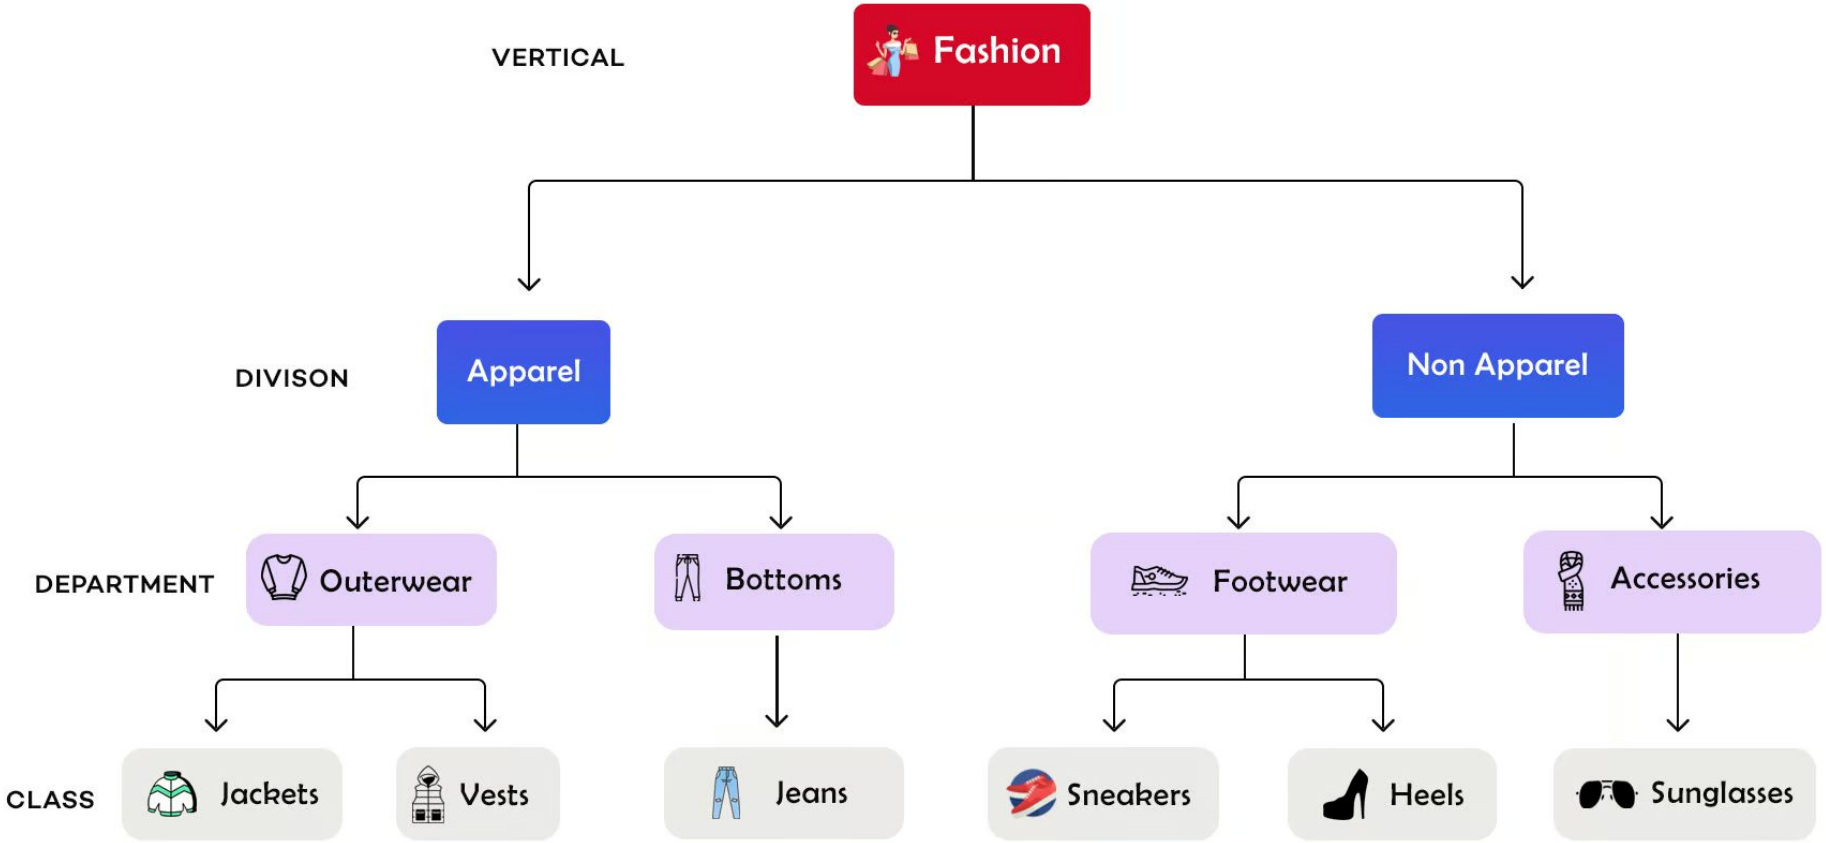
Transformación / Discretización

La discretización basada en entropía realiza el siguiente algoritmo:

- Calcule la entropía de sus datos
- Para cada posible división de sus datos
  - Calcular la entropía en cada bin potencial
  - Encuentrar la entropía neta de la división
  - Calcular la ganancia de entropía
- Seleccione la división con la mayor ganancia de entropía
- Realice la partición de forma recursiva en cada división hasta que se cumpla un criterio de terminación
  - Termine una vez que alcance un número específico de bins
  - Termine una vez que la ganancia de entropía caiga por debajo de cierto umbral

Análisis Exploratorio de Datos (EDA)

Transformación / Discretización



Puede ser necesario balancear!

Se puede aprender con técnicas de clustering

Análisis Exploratorio de Datos (EDA)

Transformación / Escalado

Por qué escalar las características?

Edad	Nuevo rol	Equipo	Rating	Ventas
30	no	12	5	150000
22	si	15	3	100000
24	no	14	4	90000
25	no	15	3	110000
24	no	9	4	98000
28	no	11	5	112000
26	no	10	3	95000
31	no	14	1	135000
25	si	12	4	75000
29	no	9	2	120000

Distancia Euclídea

$$d(\mathbf{x}^{(u)}, \mathbf{x}^{(v)}) = \sqrt{\sum_i (\mathbf{x}_i^{(u)} - \mathbf{x}_i^{(v)})^2}$$

El análisis de datos puede verse verse seriamente afectado si los datos viven en rangos muy distintos entre sí, algunas variables tendrían preponderancia por sobre otras

Transformación / Escalado

Ejemplo: supongamos que tenemos que analizar la distancia (por ejemplo, Euclidea) entre las muestras en el espacio de características:

$$\mathbf{x}^{(0)} = [0.1, 10] \qquad \mathbf{x}^{(1)} = [0.2, 20] \qquad \mathbf{x}^{(2)} = [0.9, 20]$$

Asumimos que la primer feature toma valores en [0,1] y la segunda en [0, 100]

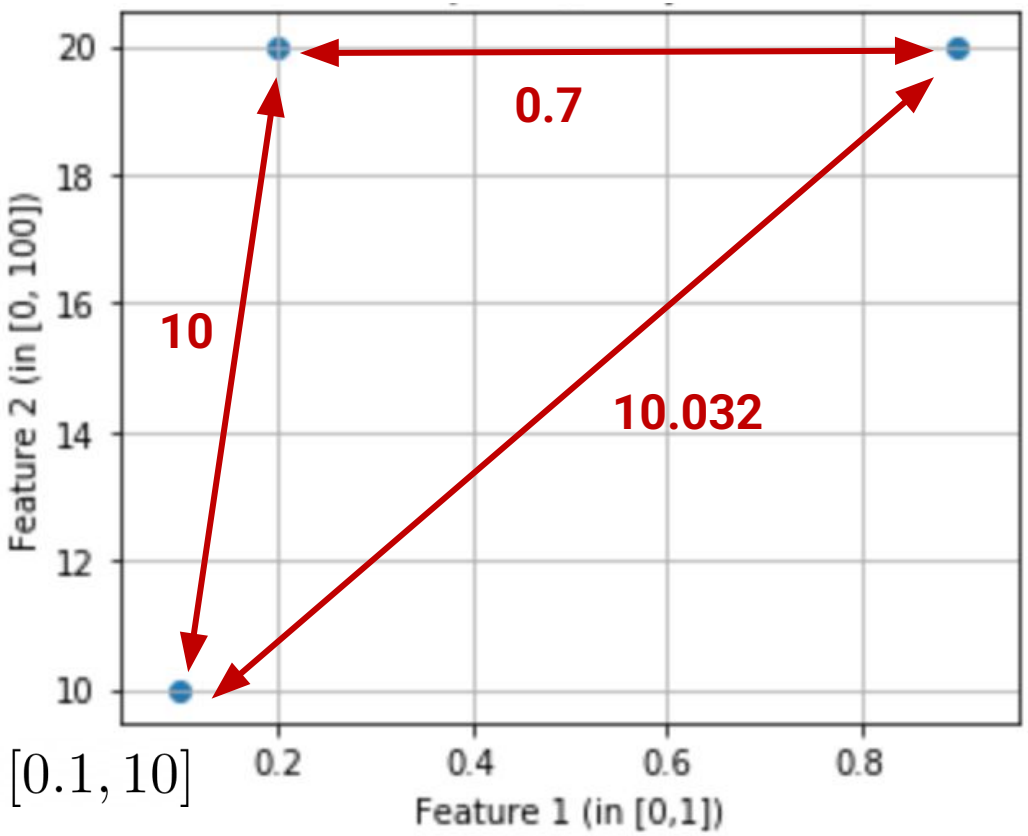
	F1	F2
x0	0.1	10
x1	0.2	20
x2	0.9	20

Más info: Joel Grus, “Data Science from Scratch: First Principles with Python”. Capítulo 10.

Transformación / Escalado

$\mathbf{x}^{(1)} = [0.2, 20]$

$\mathbf{x}^{(2)} = [0.9, 20]$



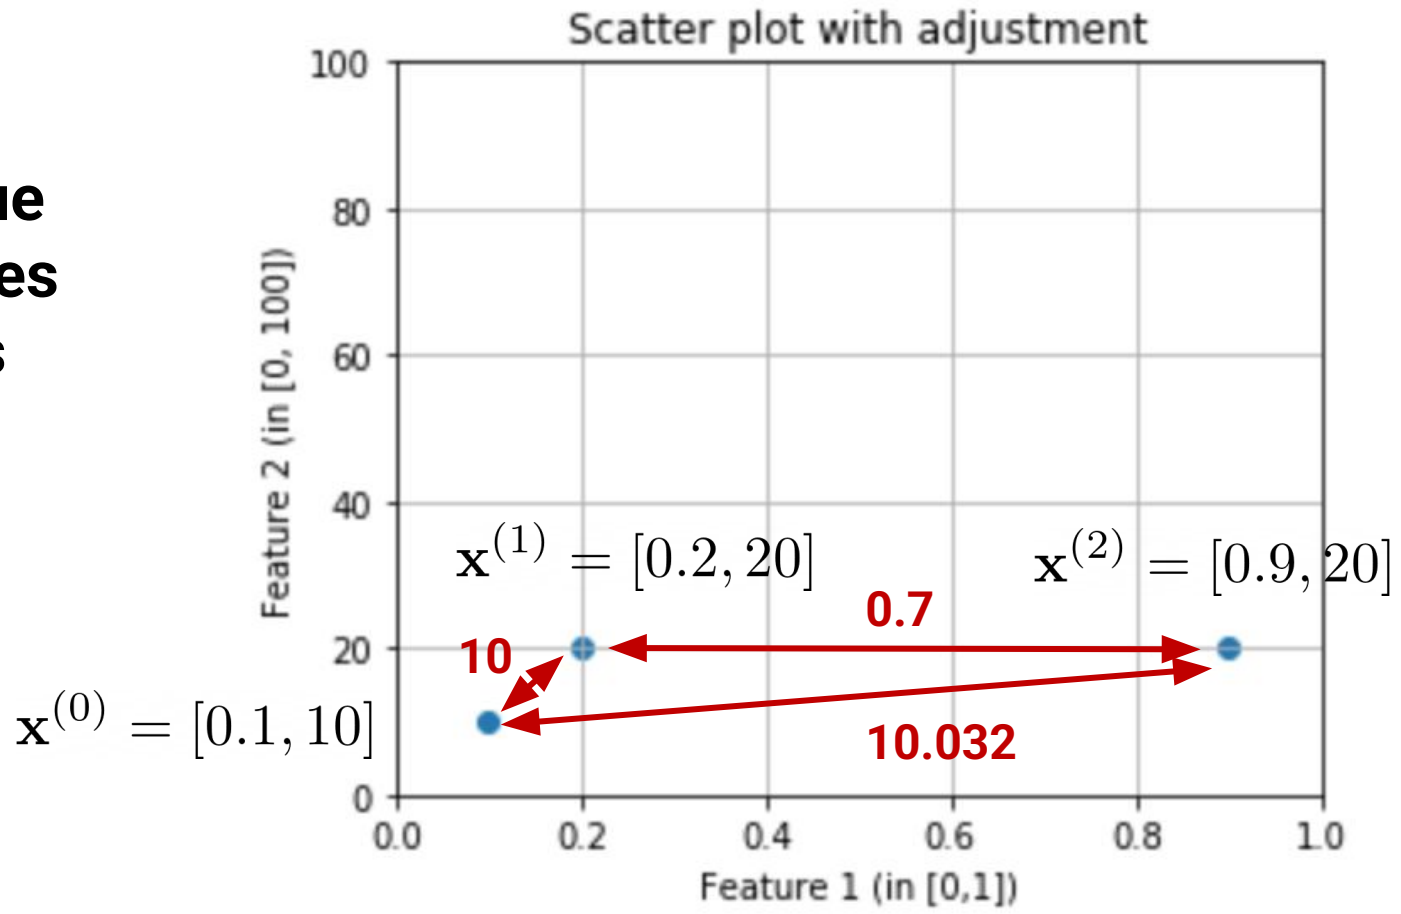
$\mathbf{x}^{(0)} = [0.1, 10]$

Distancia Euclídea

$$d(\mathbf{x}^{(u)}, \mathbf{x}^{(v)}) = \sqrt{\sum_i (\mathbf{x}_i^{(u)} - \mathbf{x}_i^{(v)})^2}$$

Transformación / Escalado

Si corregimos la gráfica para que los ejes reflejen los rangos reales de los indicadores que estamos comparando, podemos ver que esas distancias no son representativas!



Escalado / Normalización

La normalización es una operación que permite corregir los rangos de diferentes características para que vivan en un mismo intervalo, el [0, 1]

$$x' = \frac{x - x_{min}}{x_{max} - x_{min}}$$

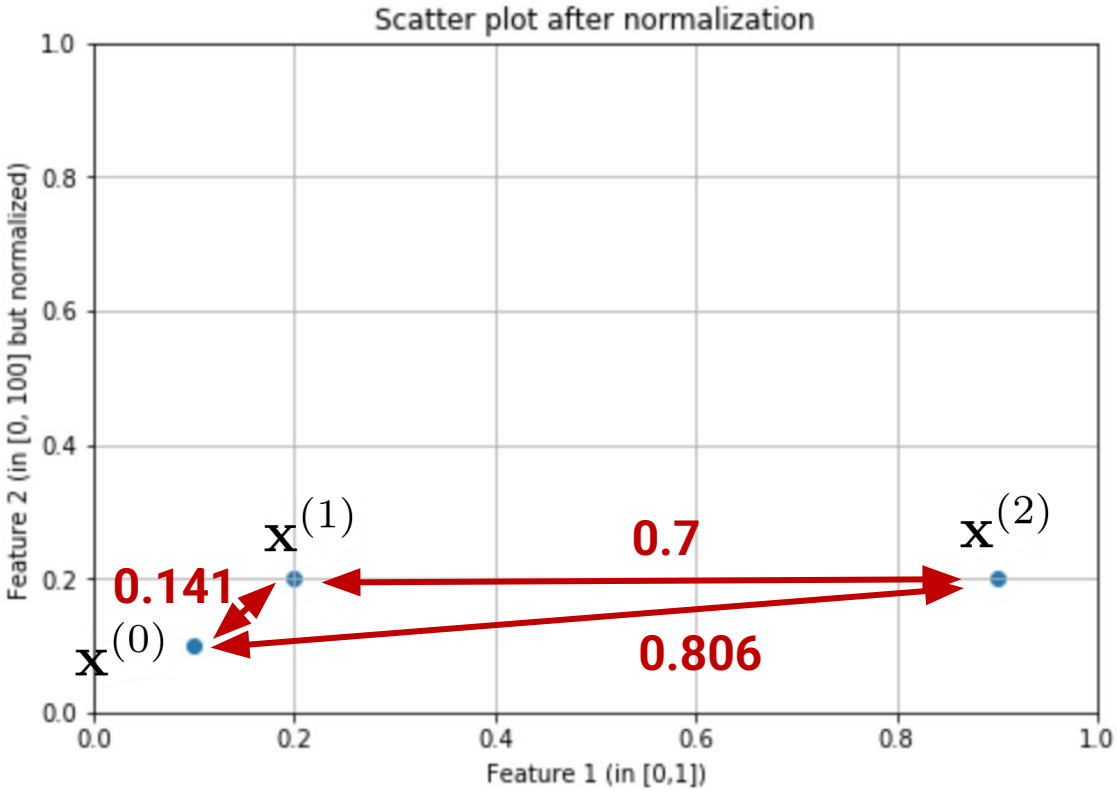
IMPORTANTE! Se recomienda siempre usar los valores máximo/mínimo teóricos de las features, o en su defecto estimarlos a partir de un conjunto de entrenamiento grande.

Más info: Joel Grus, “Data Science from Scratch: First Principles with Python”. Capítulo 10.

Escalado / Normalización

$$\mathbf{x}^{(0)} = [0.1, 10] \longrightarrow \mathbf{x}^{(0)} = [0.1, 0.1]$$
$$\mathbf{x}^{(1)} = [0.2, 20] \longrightarrow \mathbf{x}^{(1)} = [0.2, 0.2]$$
$$\mathbf{x}^{(2)} = [0.9, 20] \longrightarrow \mathbf{x}^{(2)} = [0.9, 0.2]$$

Al escalar las features, ahora las distancias tienen más sentido!

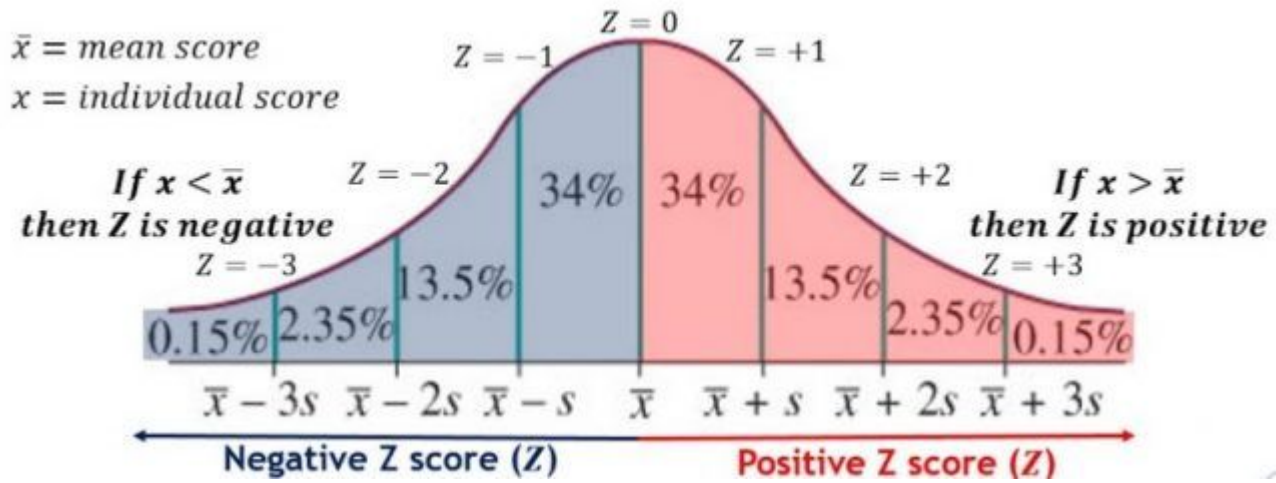


Escalado / Estandarización

La estandarización es una operación para transformar los datos de manera de tener una media de 0 y una desviación estándar de 1

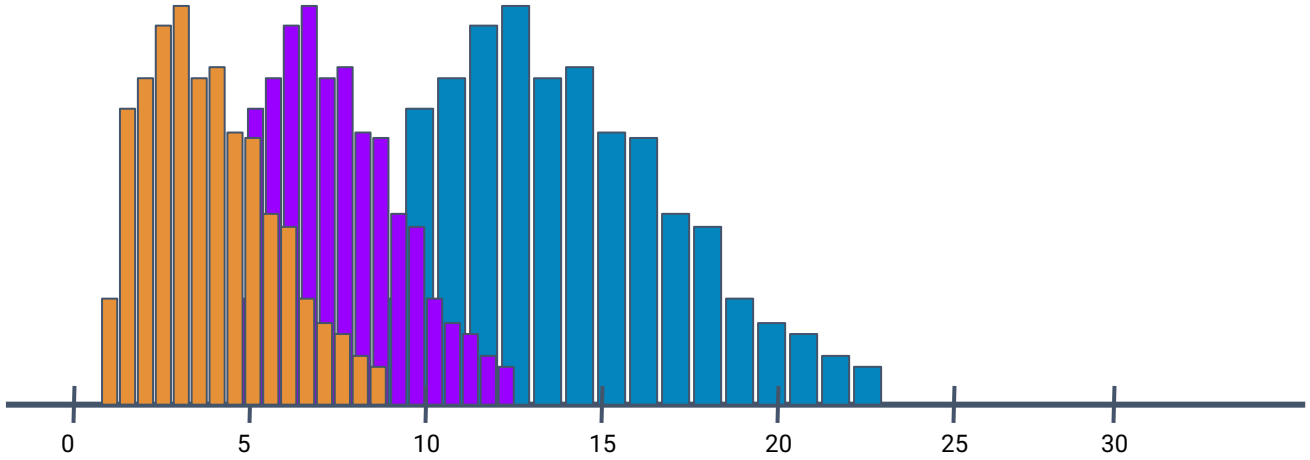
La estandarización también se conoce como normalización Z-score

$$x' = \frac{x - \overline{x}}{s}$$



Escalado / Estandarización

Otras estandarizaciones (custom)



estandarización

$$x' = \frac{x}{2}$$

estandarización y desplazamiento

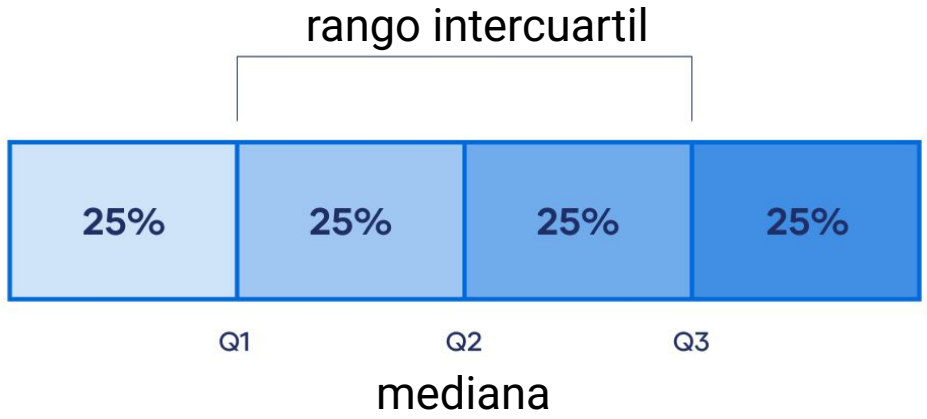
$$x' = \frac{x - 7}{2}$$

Escalado / Estandarización

La estandarización robusta considera la mediana y el rango intercuartiles

$$x' = \frac{x - mediana(x)}{IRQ(x)}$$

Se define como la diferencia entre el tercer cuartil (Q_3) y el primer cuartil (Q_1), es decir: IRQ = Q_3 - Q_1



Escalado / Estandarización

La estandarización robusta considera la mediana y el rango intercuartiles

$$x' = \frac{x - mediana(x)}{IRQ(x)}$$

Q_2 = 87
Q_1 = 31 (mediana 1 a 6)
Q_3 = 119 (mediana 8 a 13)
IQR = 119 - 31 = 88

Orden	Valor
1	7
2	7
3	31
4	31
5	47
6	75
7	87
8	115
9	116
10	119
11	119
12	155
13	177

Análisis Exploratorio de Datos (EDA)

Transformación / Escalado

Cómo elegimos la forma de escalado más apropiada?

Estandarización

- Útil cuando podemos asumir que los datos siguen una distribución normal
- Ajusta los datos a una distribución normal estándar, con media 0 y desvío 1, sin rango
- 99.73% de los datos caen dentro de +/-3 desviaciones estándar

Normalización

- Útil cuando no queremos hacer ninguna suposición acerca de la distribución de los datos
- Los datos estarán estrictamente en el rango [0,1]

Otras transformaciones (“estandarización robusta”)

- Útil cuando los datos tienen valores extremos o muchos outliers

Transformación / Escalado

Ventajas

- Mejor comparación de las características, tienen la misma importancia
- Otras ventajas en algoritmos de ML (convergencia más rápida, facilita la interpretación de coeficientes, etc.)

Desventajas

- Pérdida de interpretabilidad de las características (por ej. edad negativa)
- Pérdida de información, cuando se escalan características que ya están en la escala correcta
- La elección de la forma de escalado necesita ser entendida

Análisis Exploratorio de Datos (EDA)

Datos Faltantes

Los datos pueden estar incompletos:

- Muchas filas pueden no tener registrado valores para uno o más atributos

Razones:

- Mal funcionamiento de equipos/sensores
- Fueron borrados por inconsistencias con otros datos registrados
- No fueron registraron o no fueron considerados importantes al momento de la recolección
- Una entidad simplemente no tiene un cierto atributo (por ej. una persona sin dirección fija)
- No hay historial de los datos

Entender por qué son son faltantes!

Datos Faltantes

- **Mecanismos de datos faltantes**: describen cómo la probabilidad de que un valor faltante en *Y* se relaciona con otras variables o con los posibles valores del propio *Y* (Rubin, 1976)
  - Missing Completely At Random (MCAR): faltante totalmente al azar
  - Missing At Random (MAR): faltante al azar
  - Missing Not At Random (MNAR): faltante no al azar

Análisis Exploratorio de Datos (EDA)

Datos Faltantes

Missing Completely At Random (MCAR): La probabilidad de que falten datos en una variable Y no está relacionada con otras variables medidas y no está relacionada con los posibles valores de Y

Nombre	Genero	Valor
Juan	Hombre	5
Pedro	Hombre	7
José	Hombre	3
Ernesto	Hombre	7
Pablo	Hombre	3
Ana	Mujer	5
María	Mujer	7
Josefina	Mujer	3
Juana	Mujer	7
Mariela	Mujer	1

promedio = 5

promedio = 4.6

Análisis Exploratorio de Datos (EDA)

Datos Faltantes

Missing Completely At Random (MCAR): La probabilidad de que falten datos en una variable Y no está relacionada con otras variables medidas y no está relacionada con los posibles valores de Y

Nombre	Genero	Valor
Juan	Hombre	5
Pedro	Hombre	N/A
José	Hombre	3
Ernesto	Hombre	7
Pablo	Hombre	N/A
Ana	Mujer	5
María	Mujer	N/A
Josefina	Mujer	N/A
Juana	Mujer	7
Mariela	Mujer	1

promedio = 3.6

promedio = 7

Ejemplo: encuesta, un 5% no dió esa información

Datos Faltantes

Missing At Random (MAR): La probabilidad de que falten datos sobre *Y* está relacionada con otras variables medidas, pero no está relacionada con los posibles valores de *Y*

Nombre	Genero	Valor
Juan	Hombre	5
Pedro	Hombre	N/A
José	Hombre	3
Ernesto	Hombre	N/A
Pablo	Hombre	3
Ana	Mujer	N/A
María	Mujer	7
Josefina	Mujer	N/A
Juana	Mujer	7
Mariela	Mujer	N/A

Datos Faltantes

Missing At Random (MAR): La probabilidad de que falten datos sobre *Y* está relacionada con otras variables medidas, pero no está relacionada con los posibles valores de *Y*

Nombre	Genero	Valor	Residencia
Juan	Hombre	5	Urbana
Pedro	Hombre	N/A	Rural
José	Hombre	3	Urbana
Ernesto	Hombre	N/A	Rural
Pablo	Hombre	3	Urbana
Ana	Mujer	N/A	Rural
María	Mujer	7	Urbana
Josefina	Mujer	N/A	Rural
Juana	Mujer	7	Urbana
Mariela	Mujer	N/A	Rural

promedio = 3.6

promedio = 7

Análisis Exploratorio de Datos (EDA)

Datos Faltantes

Missing Not At Random (MNAR): Existe una relación entre la propensión a que falte un dato y sus valores, razones desconocidas o datos no colectados

Nombre	Genero	Ingresos
Juan	Hombre	100.000
Pedro	Hombre	N/A
José	Hombre	70.000
Ernesto	Hombre	N/A
Pablo	Hombre	99.000
Ana	Mujer	N/A
María	Mujer	123.000
Josefina	Mujer	77.000
Juana	Mujer	43.000
Mariela	Mujer	N/A

Análisis Exploratorio de Datos (EDA)

Datos Faltantes

Missing Not At Random (MNAR): Existe una relación entre la propensión a que falte un dato y sus valores

Nombre	Genero	Ingresos	Edad
Juan	Hombre	100.000	33
Pedro	Hombre	N/A	35
José	Hombre	70.000	15
Ernesto	Hombre	N/A	55
Pablo	Hombre	99.000	47
Ana	Mujer	N/A	22
María	Mujer	123.000	N/A
Josefina	Mujer	77.000	15
Juana	Mujer	43.000	N/A
Mariela	Mujer	N/A	N/A

Datos Faltantes

Cómo tratar los valores faltantes?

- Eliminar filas completas (debido a valores faltantes) da como resultado una muestra
  - Esa muestra no es aleatoria, por lo que la inferencia estadística es inapropiada
  - La muestra a menudo estará sesgada y no será representativa de la población (que pasa con MCAR?)
- Reemplazar valores faltantes (imputación) tiene consecuencias para el análisis
  - Reemplazar los valores faltantes con el valor verdadero que se eliminó si fuera posible (en la mayoría de los casos impracticable)
  - Si se infieren valores, documentar el cambio y considerar sus efectos (por ej., reemplazar los valores faltantes con la media disminuirá la varianza)

Análisis Exploratorio de Datos (EDA)

Datos Faltantes / Imputación

Eliminación de filas

Nombre	Genero	Valor
Juan	Hombre	5
Pedro	Hombre	N/A
José	Hombre	3
Ernesto	Hombre	N/A
Pablo	Hombre	3
Ana	Mujer	N/A
N/A	Mujer	7
Josefina	Mujer	N/A
Juana	Mujer	7
Mariela	Mujer	N/A

- Método simple
- Implica pérdida de información
- Solo es seguro en caso de MCAR

Análisis Exploratorio de Datos (EDA)

Datos Faltantes / Imputación

Eliminación de filas con faltantes en uno o varios atributos

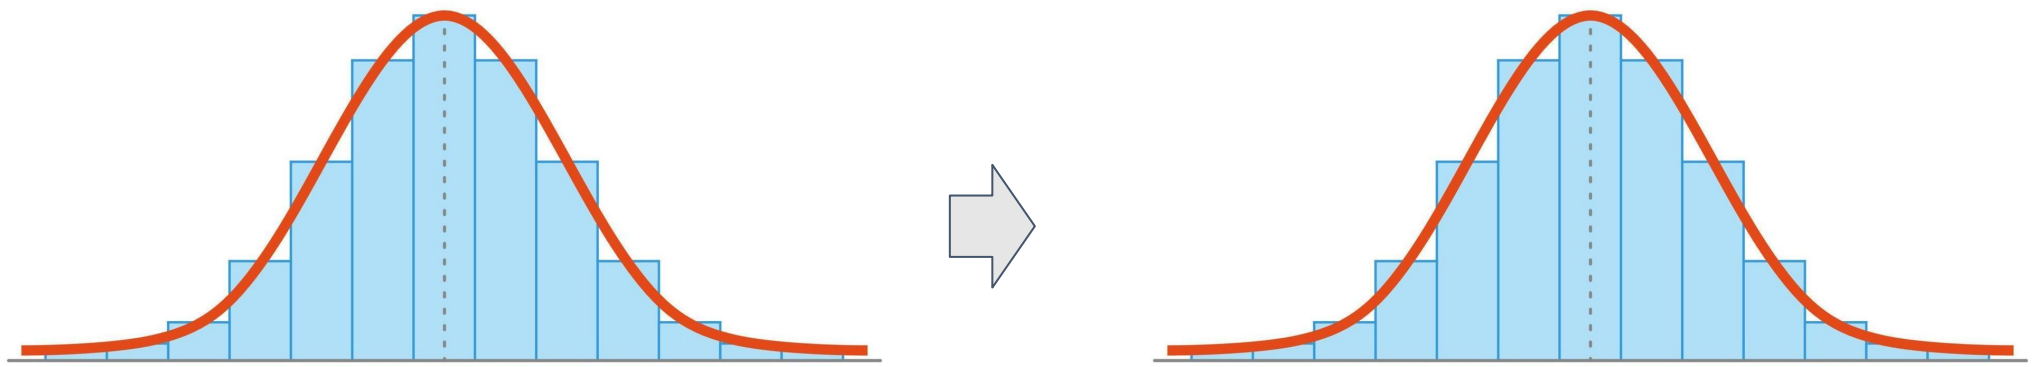
Nombre	Genero	Valor
Juan	Hombre	5
Pedro	Hombre	N/A
José	Hombre	3
Ernesto	Hombre	N/A
Pablo	Hombre	3
Ana	Mujer	N/A
N/A	Mujer	7
Josefina	Mujer	N/A
Juana	Mujer	7
Mariela	Mujer	N/A

- Método simple
- Implica pérdida de información
- Solo es seguro en caso de MCAR

Datos Faltantes / Imputación

Imputación de valores faltantes: busca alcanzar un dataset completo que luego pueda ser utilizado para modelar

La imputación puede ser simple o múltiple



Antes de la imputación

Después de la imputación

Idealmente la imputación no debería cambiar la distribución de los datos

Datos Faltantes / Imputación

Imputación por la media, mediana, moda:

- Reemplaza (imputa) los valores faltantes con el promedio de los valores disponibles
- La variabilidad y las correlaciones se atenúan porque las imputaciones son constantes
- La imputación de la media es la peor opción posible

Ideal: datos completos

V1	V2	V3
25	1	50
27	3	80
29	5	110
31	7	140
33	9	170
35	11	200

datos por imputar

V1	V2	V3
25	?	50
27	3	?
29	5	110
31	7	140
33	9	170
?	11	200

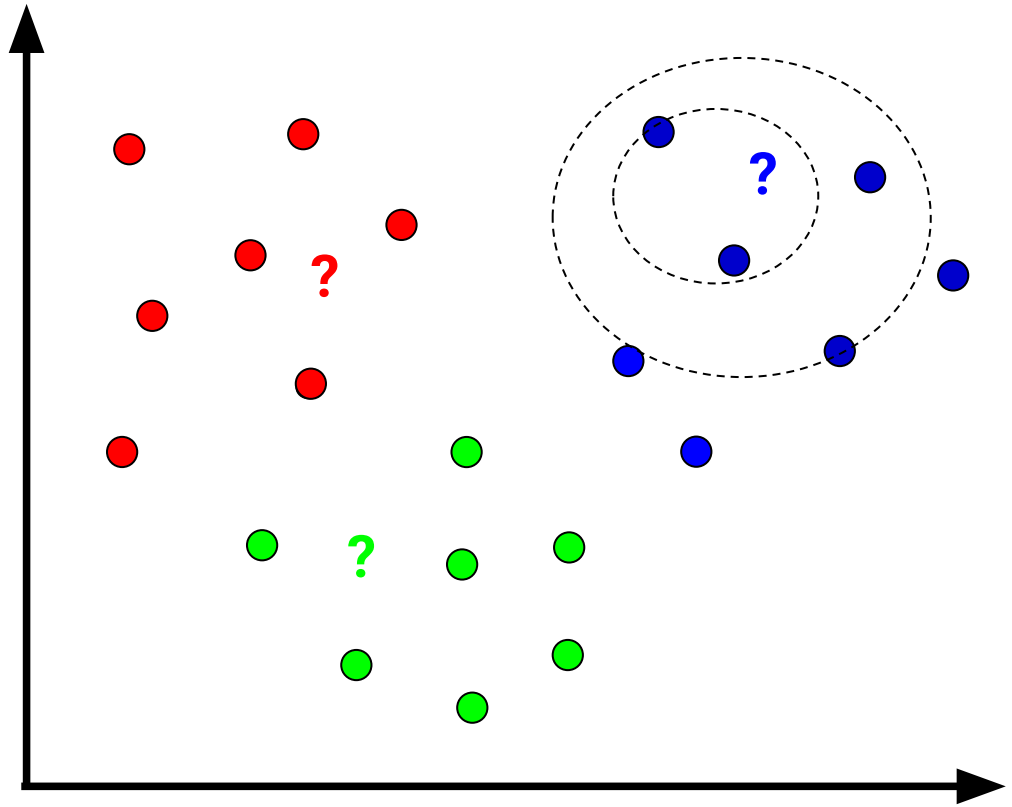
media=7

resultado imputación

V1	V2	V3
25	7	50
27	3	134
29	5	110
31	7	140
33	9	170
29	11	200

Datos Faltantes / Imputación

Imputación hot-deck: kNN (vecinos más cercanos)



Datos Faltantes / Imputación

Imputación hot-deck: kNN

- cada valor faltante se reemplaza por el valor medio de los *n* vecinos más cercanos

datos completos

V1	V2	V3
25	1	50
27	3	80
29	5	110
31	7	140
33	9	170
35	11	200

datos por imputar

V1	V2	V3	
25	?	50	
27	3	?	
29	5	110	
31	7	140	k=2
33	9	170	k=1
?	11	200	

=(31+33)/2

datos por imputar

V1	V2	V3	
25	?	50	k=1
27	3	?	
29	5	110	k=2
31	7	140	
33	9	170	
?	11	200	

=(50+110)/2

resultado imputación

V1	V2	V3
25	4	50
27	3	80
29	5	110
31	7	140
33	9	170
32	11	200

¿Qué vimos hoy?

Análisis de Datos Exploratorio (EDA)

a. Transformaciones
    i. Escalado
    ii. Normalización
b. Datos Faltantes
    i. Mecanismos
    ii. Inputación