

FACULTAD DE CIENCIAS EXACTAS UNICEN

Acceso y análisis de datos (parte II)

Fundamentos de la Ciencia de Datos

Roadmap

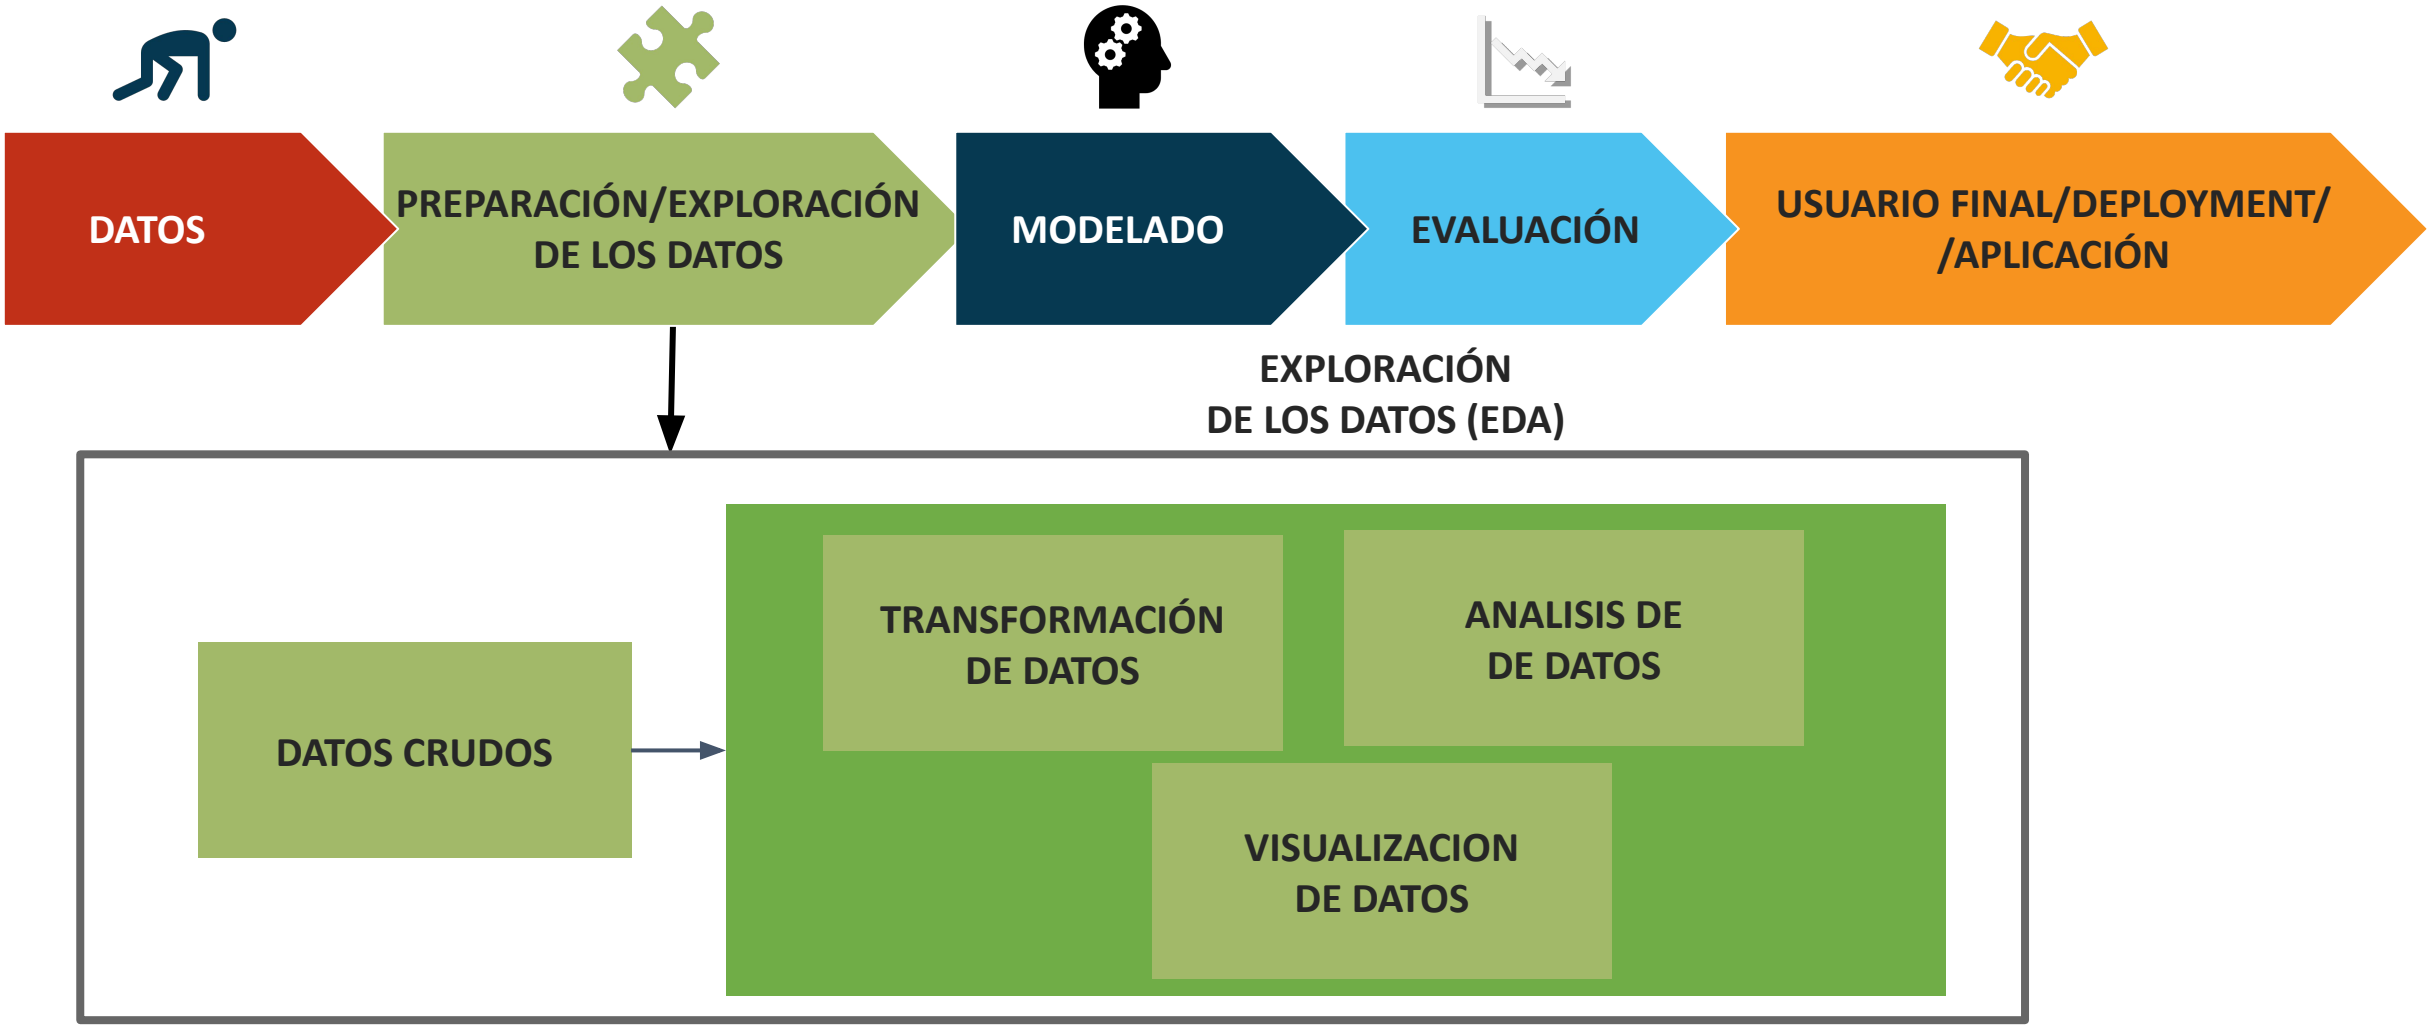






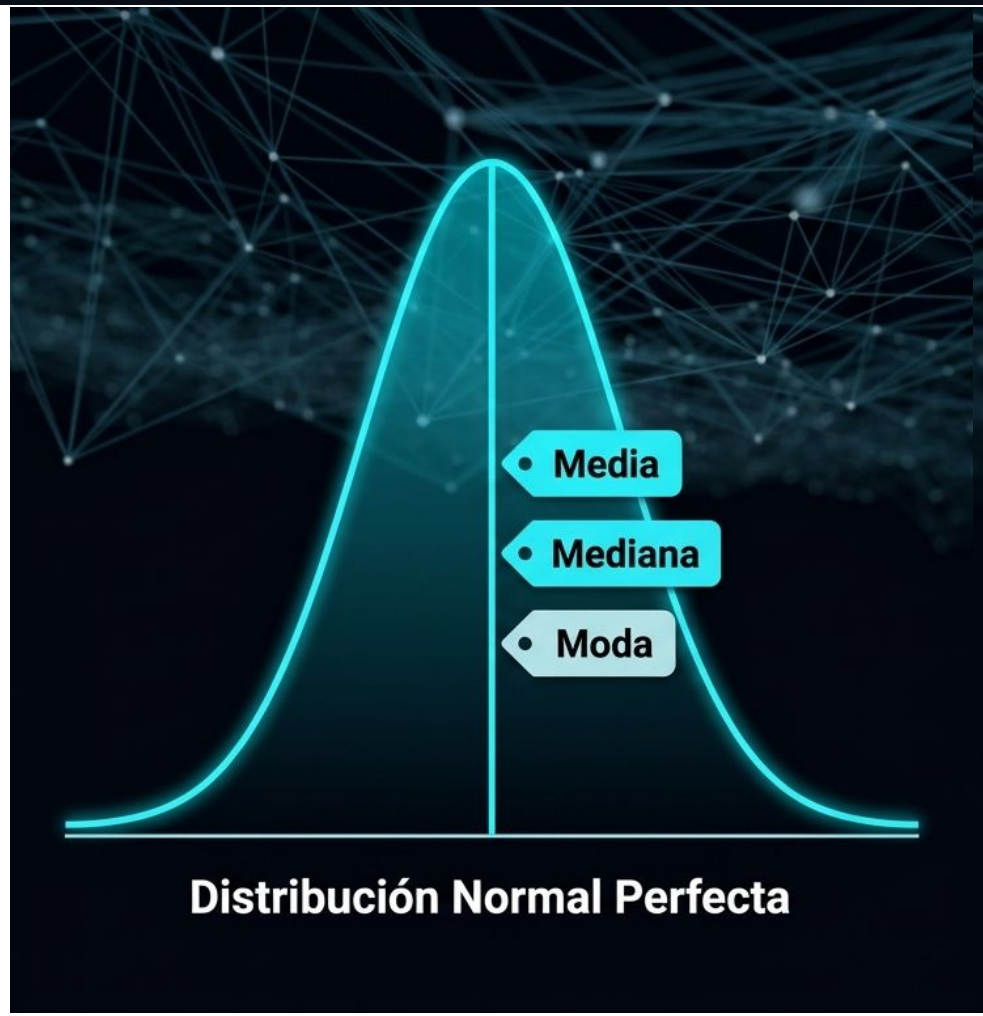
DATOS → PREPARACIÓN/EXPLORACIÓN DE LOS DATOS → MODELADO → EVALUACIÓN → USUARIO FINAL/DEPLOYMENT/ /APLICACIÓN

Roadmap


DATOS
PREPARACIÓN/EXPLORACIÓN DE LOS DATOS
MODELADO
EVALUACIÓN
USUARIO FINAL/DEPLOYMENT/ /APLICACIÓN
EXPLORACIÓN DE LOS DATOS (EDA)
DATOS CRUDOS
TRANSFORMACIÓN DE DATOS
ANALISIS DE DE DATOS
VISUALIZACION DE DATOS

EDA: Explorative Data Analysis

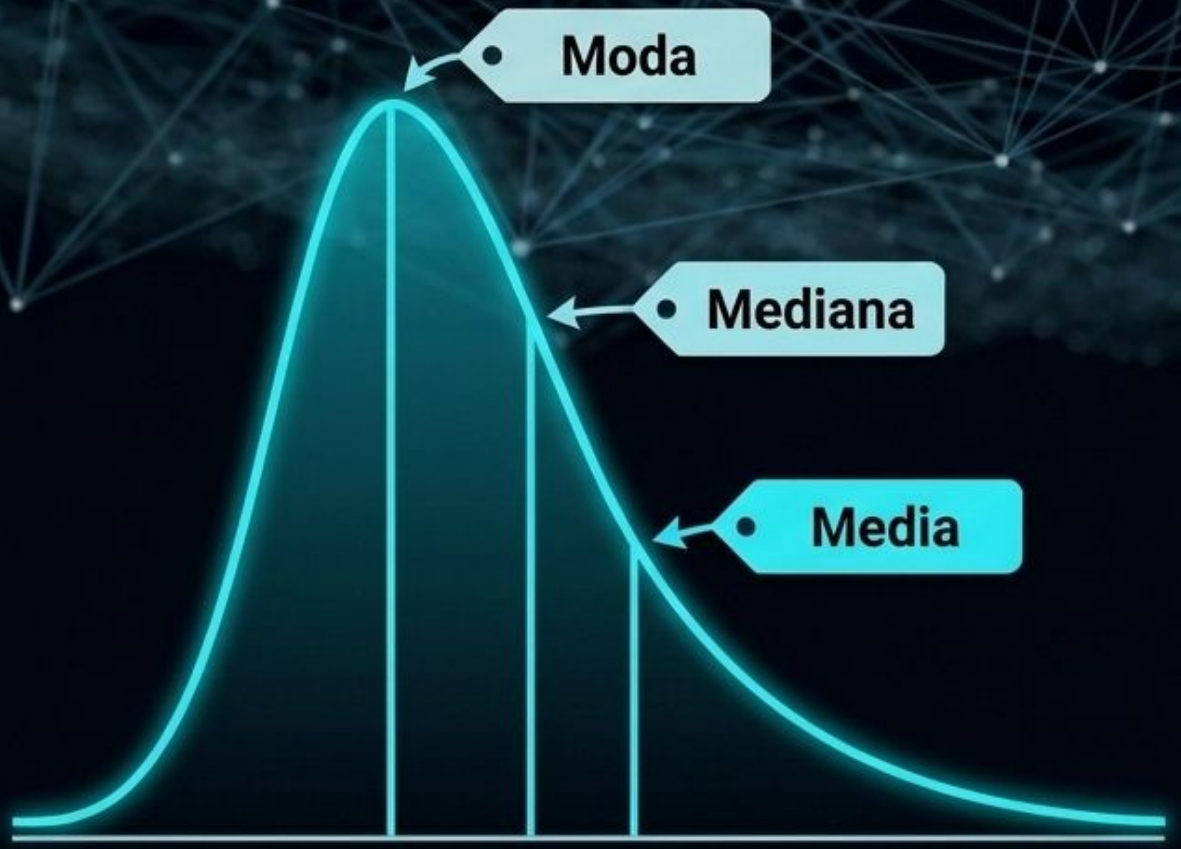
Medidas de tendencia central



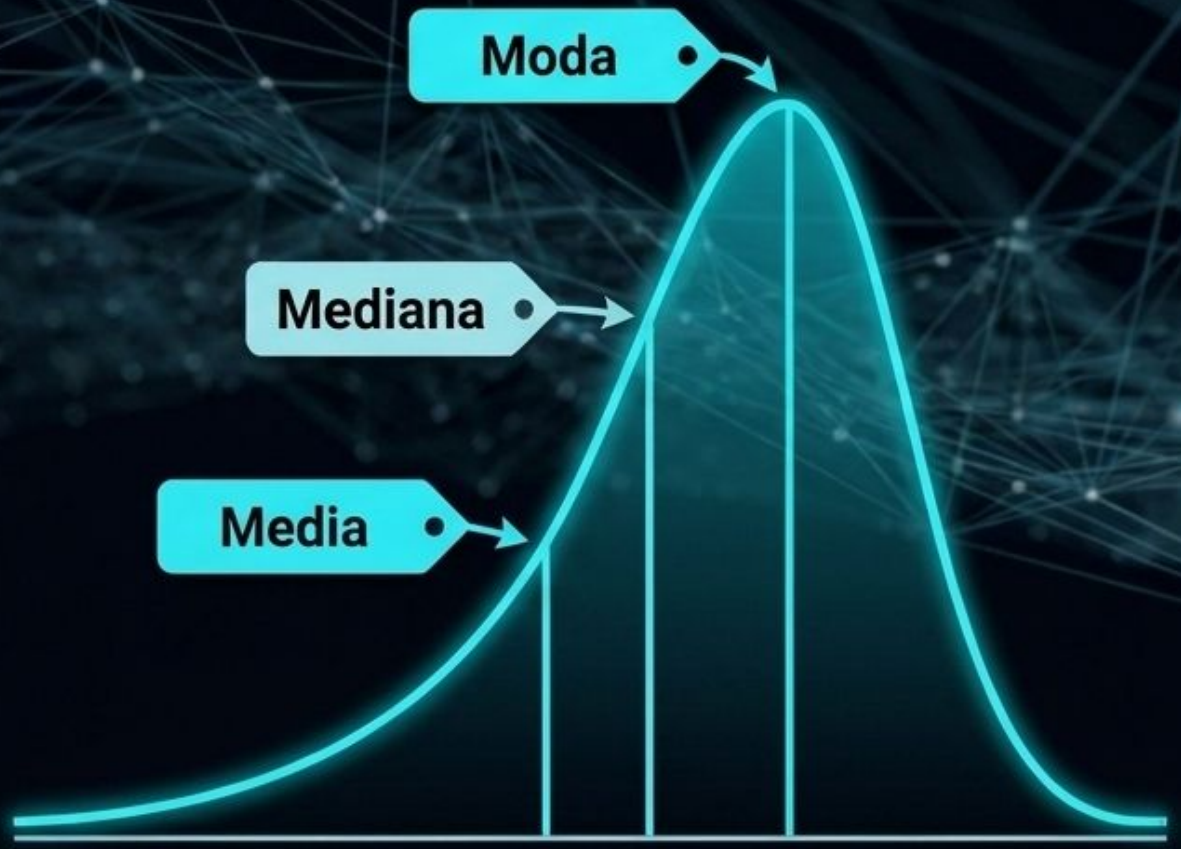
Diagnóstico de Centralidad

Media (Promedio) Centro de masa (equilibrio).	Sensibilidad a Outliers: ALTA
Mediana (50%) Valor central ordenado.	Sensibilidad a Outliers: BAJA
Moda Valor de mayor frecuencia.	Ideal para: Categóricos

Diagnóstico de Centralidad: Sesgo



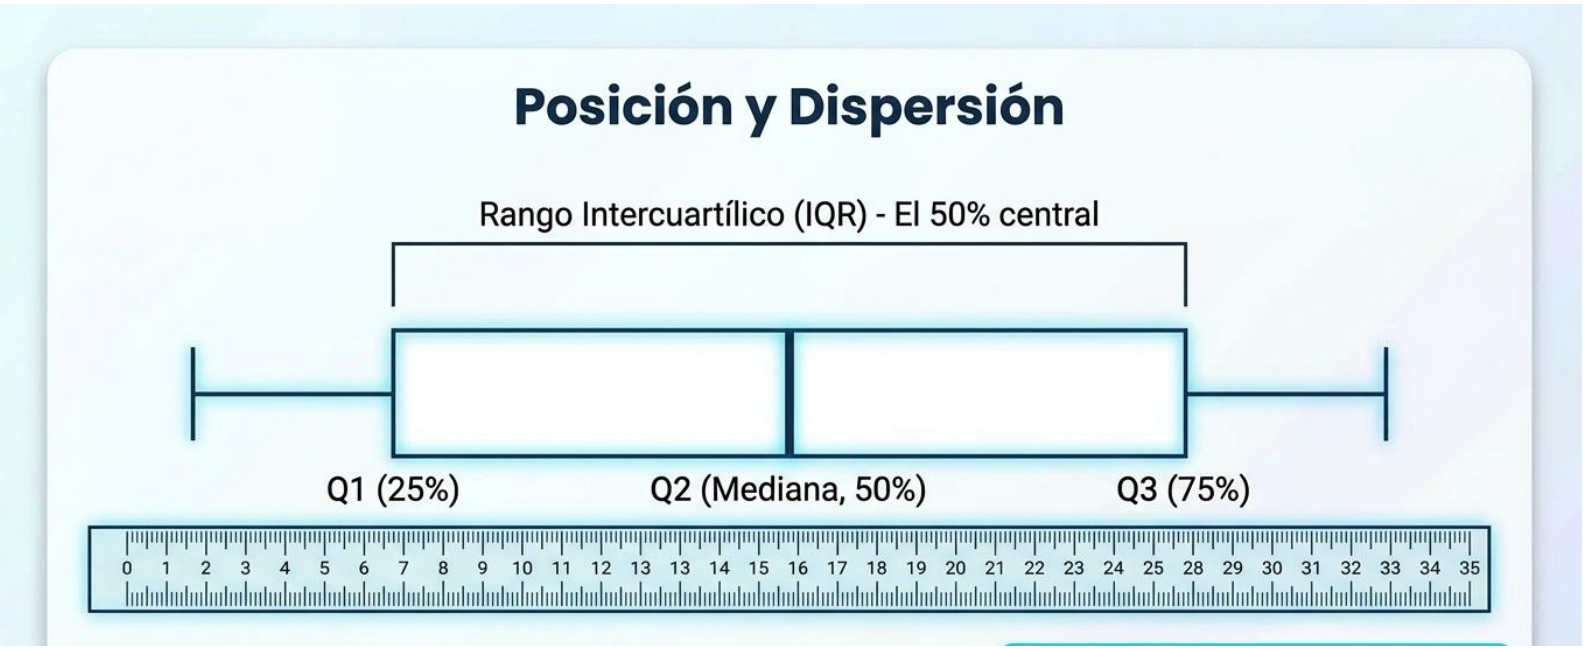
Sesgo Positivo (A la derecha)



Sesgo Negativo (A la izquierda)

Gemini Notebook

Medidas de posición

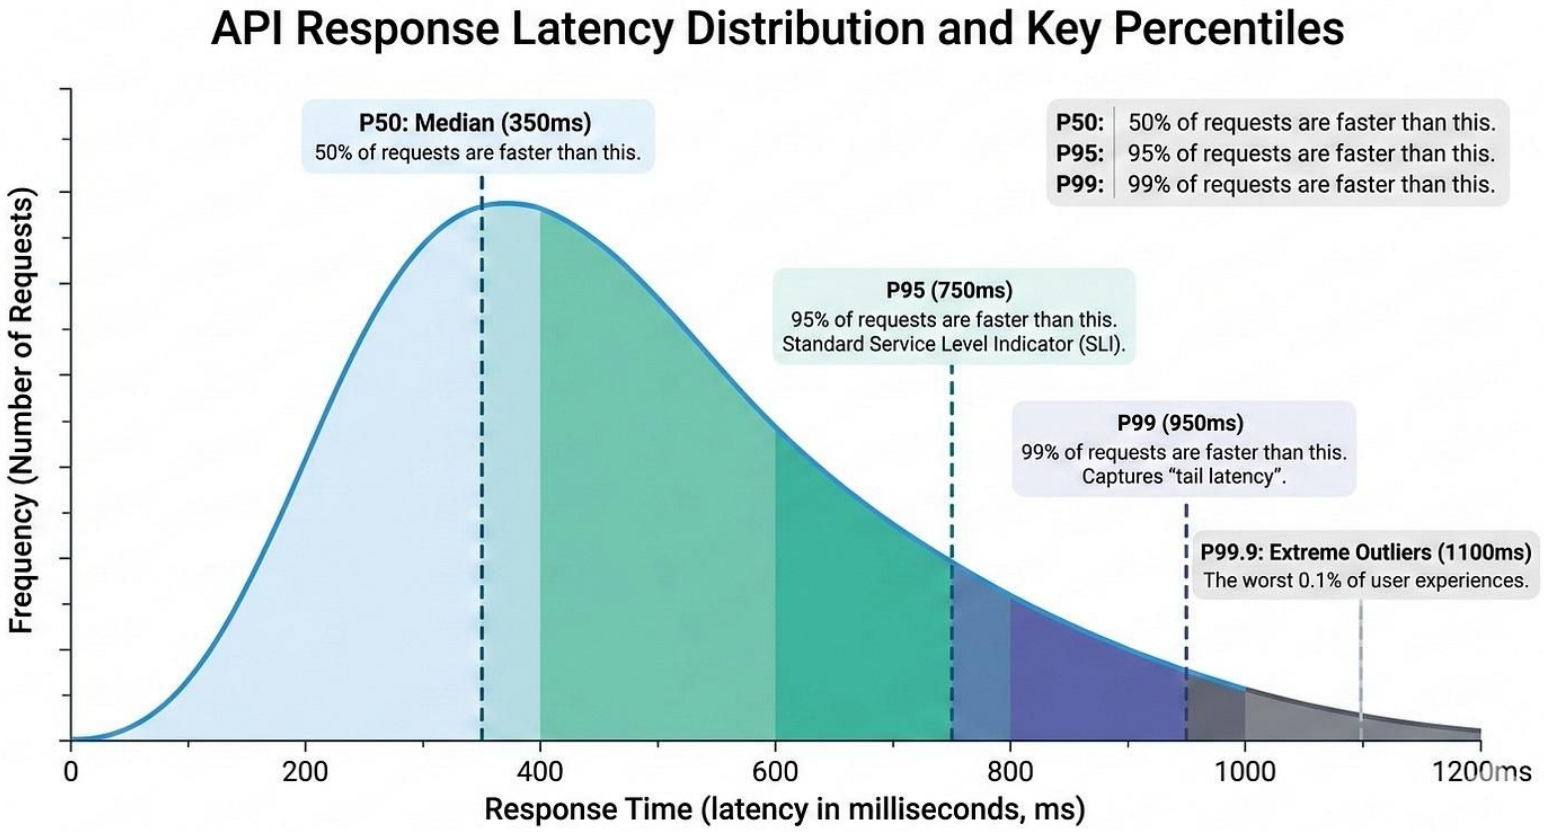


I- Cuartiles – divide a la distribución en cuartos

II- Deciles – divide a la distribución en 10 partes

III- Percentiles – divide a la distribución en 100 partes

Medidas de posición



I- Cuartiles – divide a la distribución en cuartos

II- Deciles – divide a la distribución en 10 partes

III- Percentiles – divide a la distribución en 100 partes

Medidas de dispersión

Son medidas asociadas a la variación que presentan los datos, o equivalentemente a la concentración por ejemplo alrededor de un valor característico como la media

- **Rango o amplitud = R= máximo- mínimo** (medida de dispersión)
- **Varianza:** es el promedio de los desvíos (diferencias) de los valores respecto de la media, al cuadrado

$$S^2 = \frac{\sum_{i=1}^{n} (x_i - \bar{x})^2 f_i}{n-1}$$

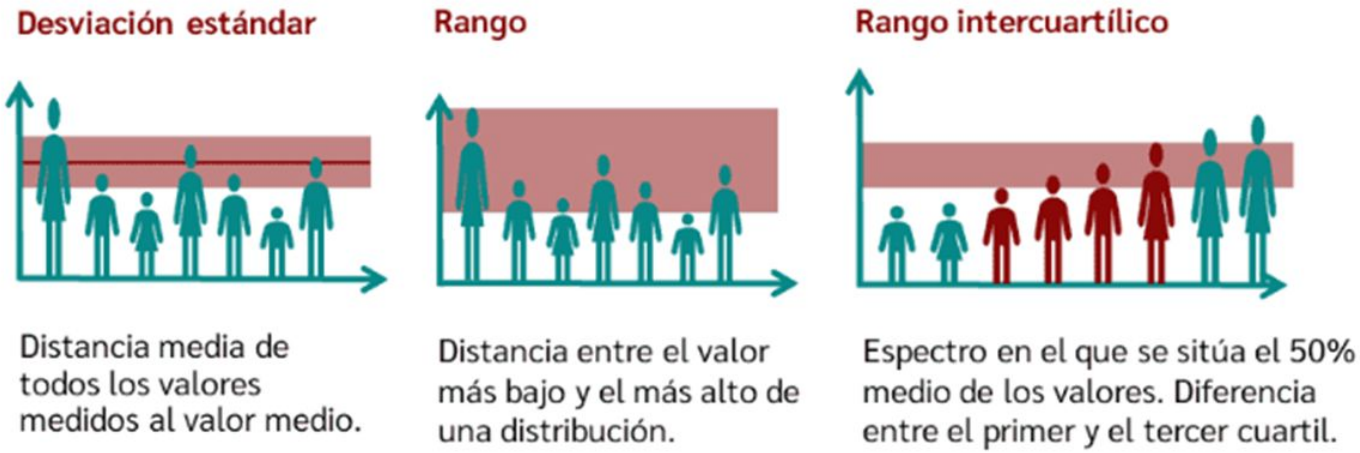
- **Desvío estándar:** es la raíz de la varianza, por lo tanto tiene la misma unidad de la variable, **S:**

$$S = \sqrt{\frac{\sum_{i=1}^{n} (x_i - \bar{x})^2 f_i}{n-1}}$$

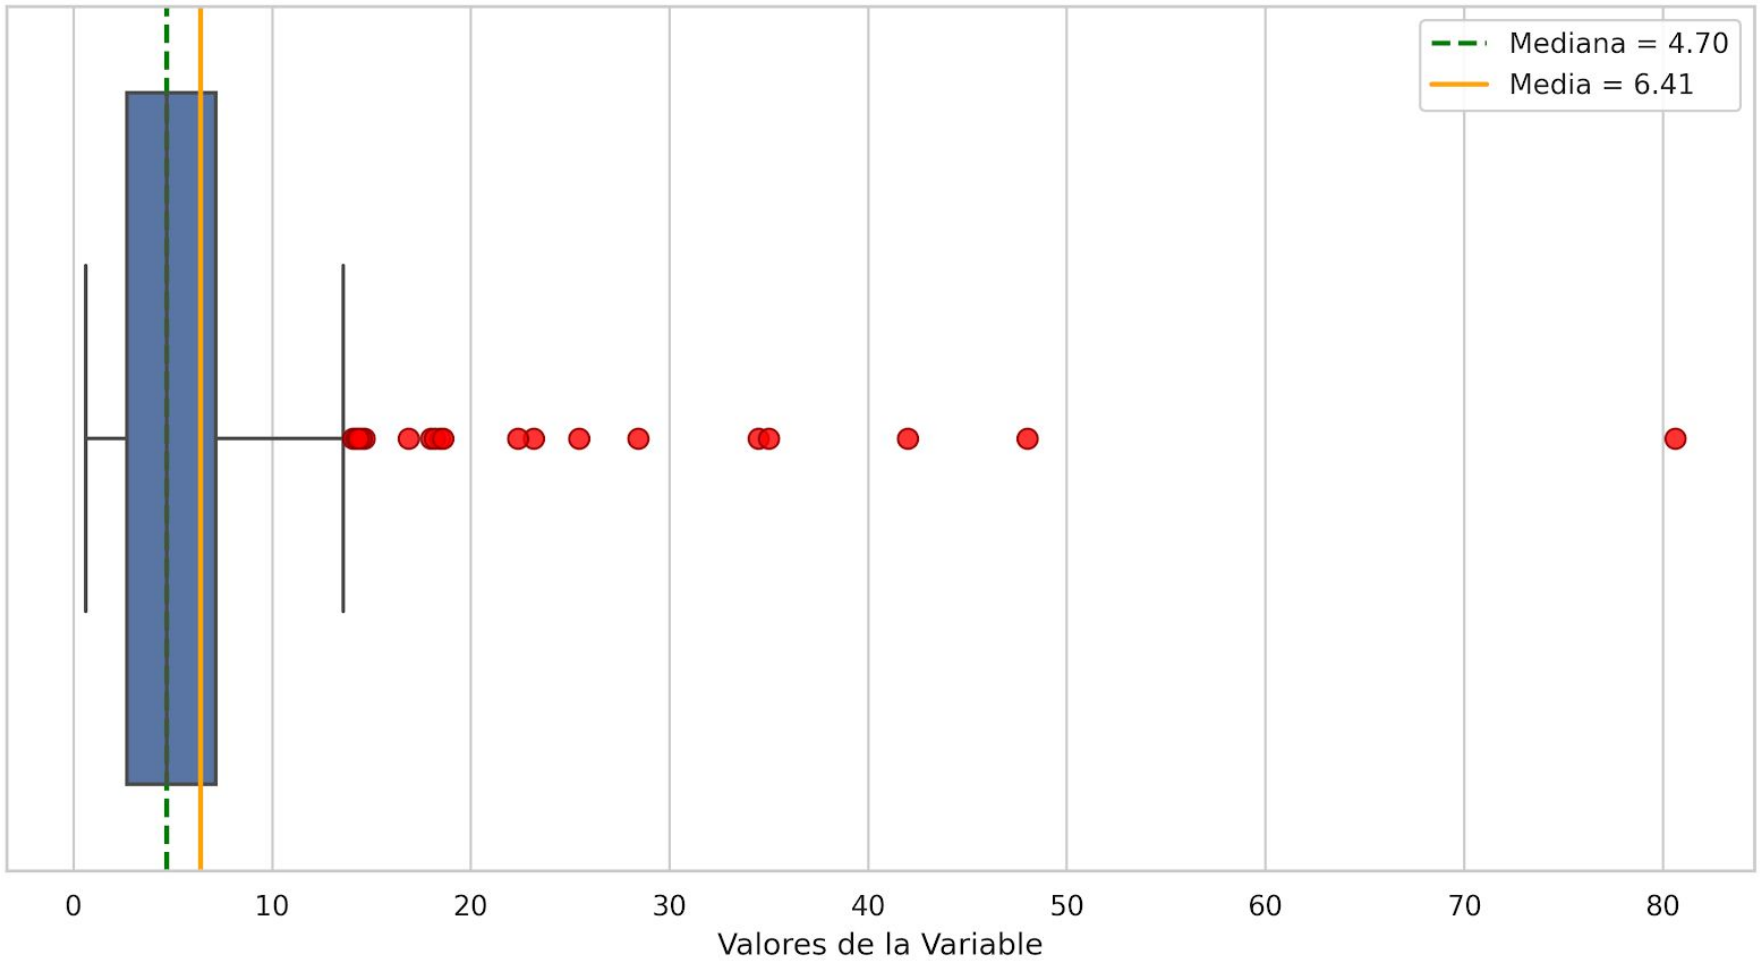
Resumen de datos

Medidas de dispersión

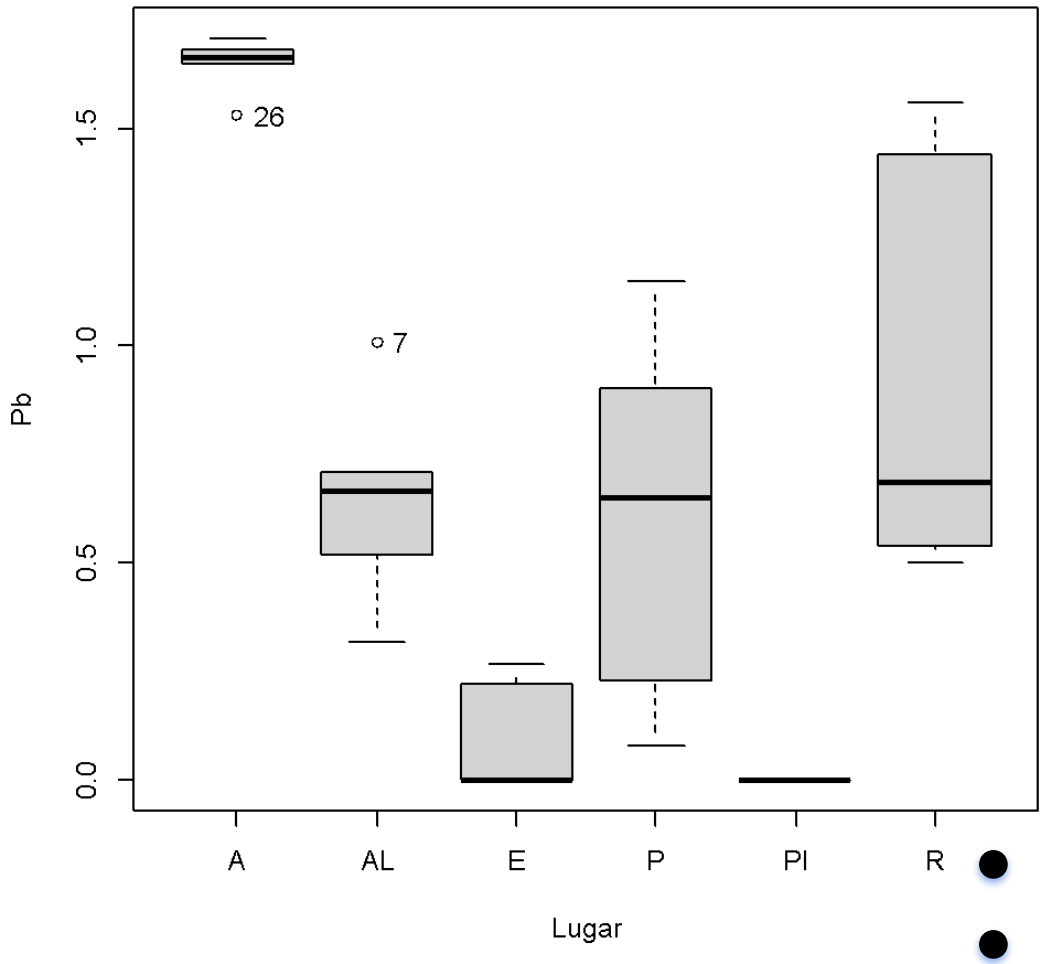
- **Recorrido o rango intercuartílico**: Q3-Q1, El 50% de los datos está dentro de este rango
- **Coeficiente de variación**: sin unidades, útil para comparar grupos. $CV = \frac{S}{\bar{x}}.100$
- **Error estandar:** medida de dispersión de la media $EE = \frac{S}{\sqrt{n}}$

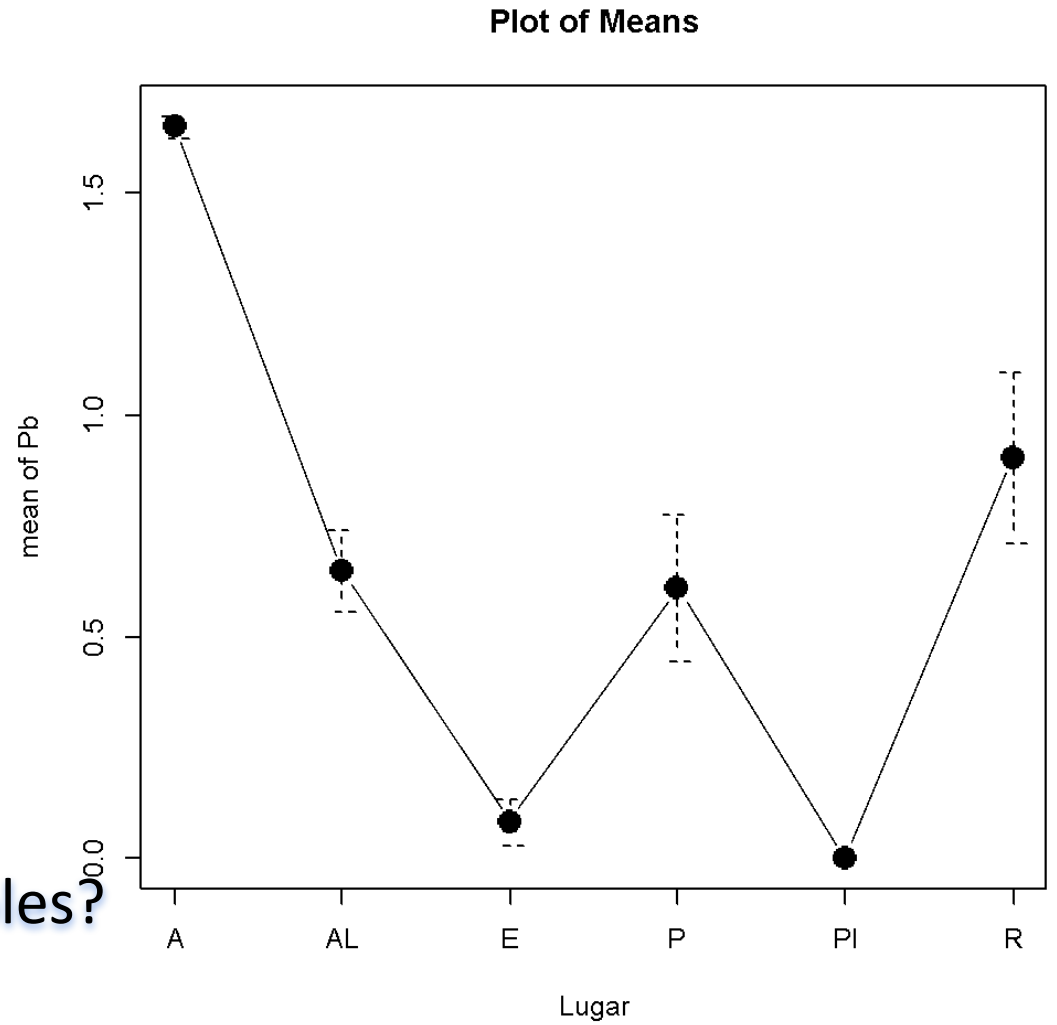


Visualización: Box plot



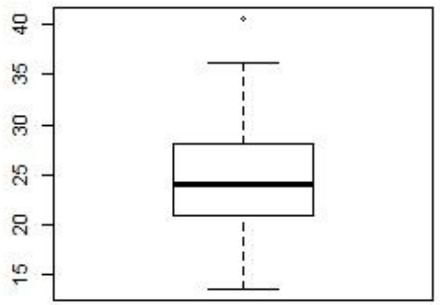
Visualización: comparativos

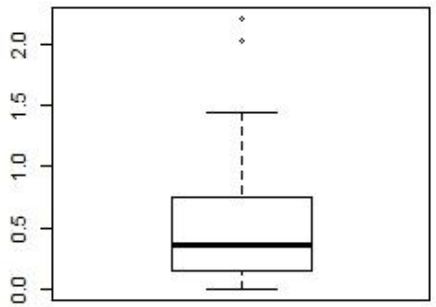


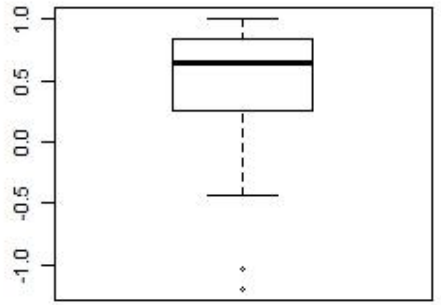


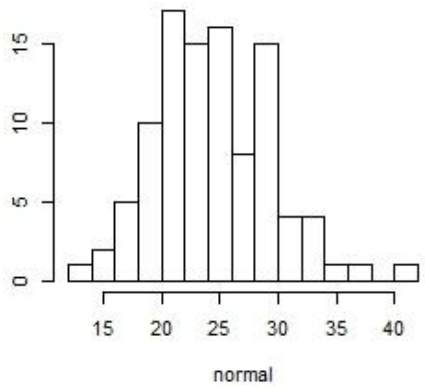
- Cuantas variables?
- de que tipo?

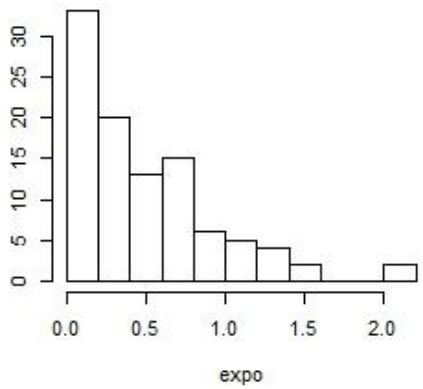
Visualización: Box plot vs Histograma

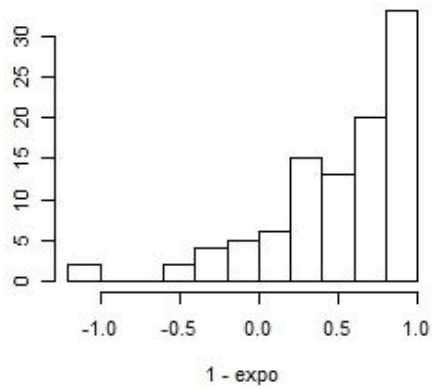










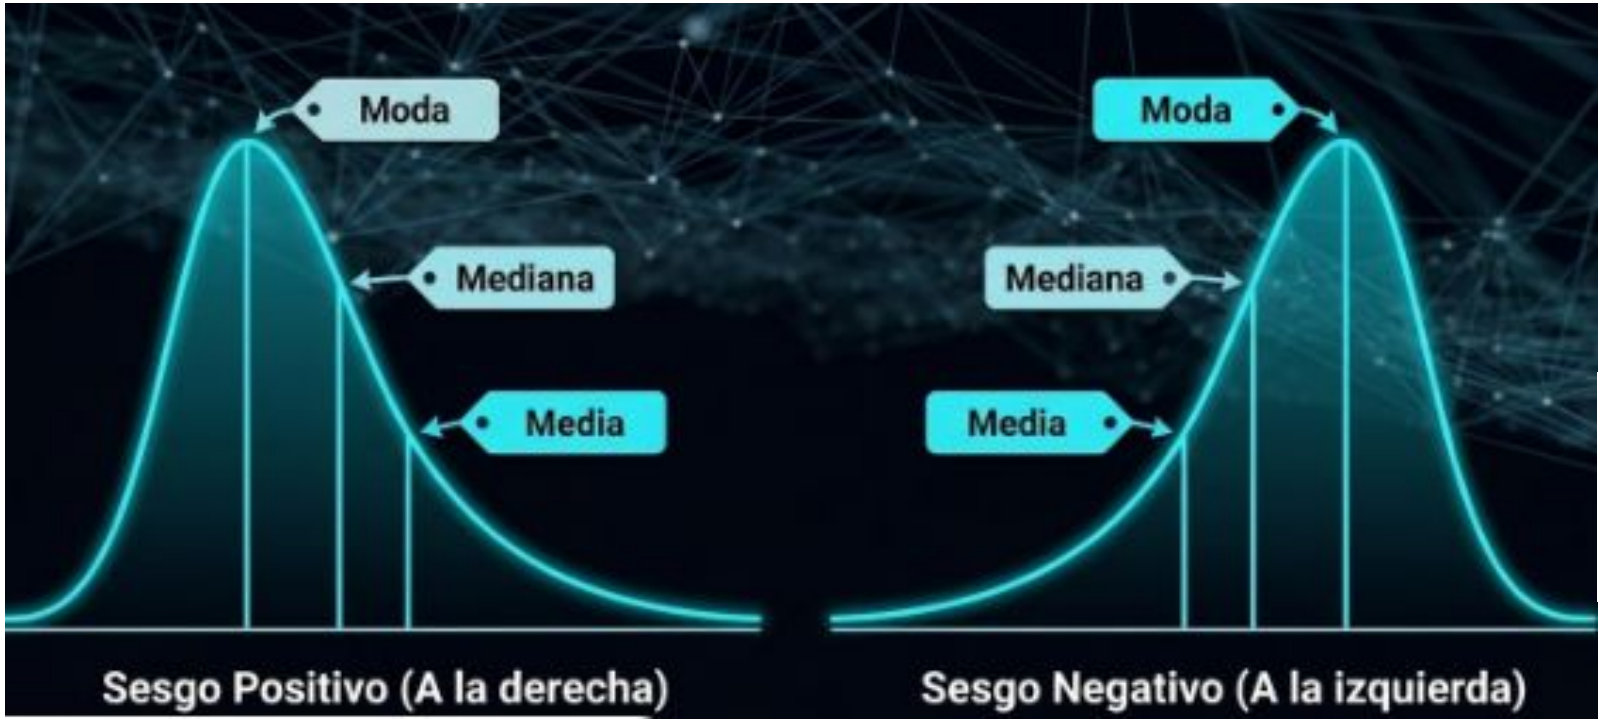


Simétrica

Sesgada

Sesgada

Distribución sesgada o insesgada (cola)

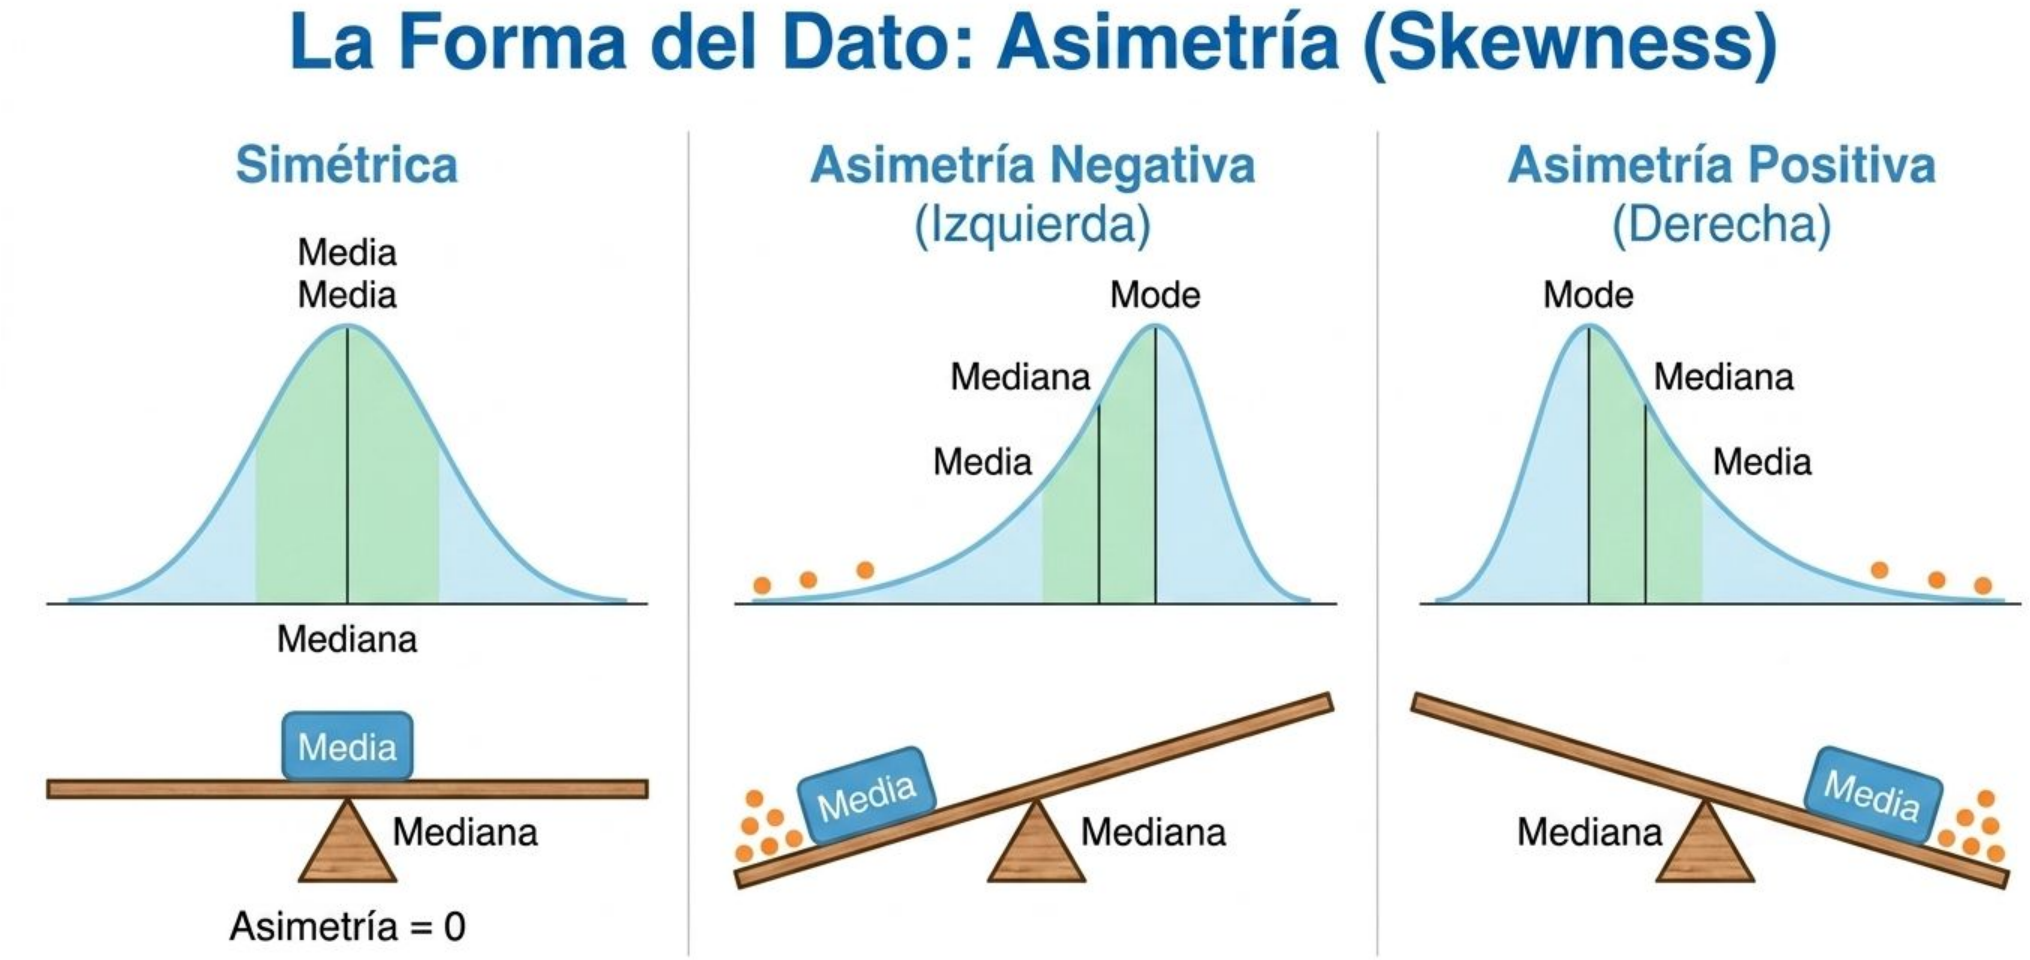


CUANTIFICAR ASIMETRIA

$$SCoef = \frac{\sum_{i=1}^{n}(x_i - \bar{x})^3}{nS^3}$$

Coeficiente de asimetría de Fisher-Pearson

Distribución sesgada o insesgada (cola)



Cuantificando la asimetría

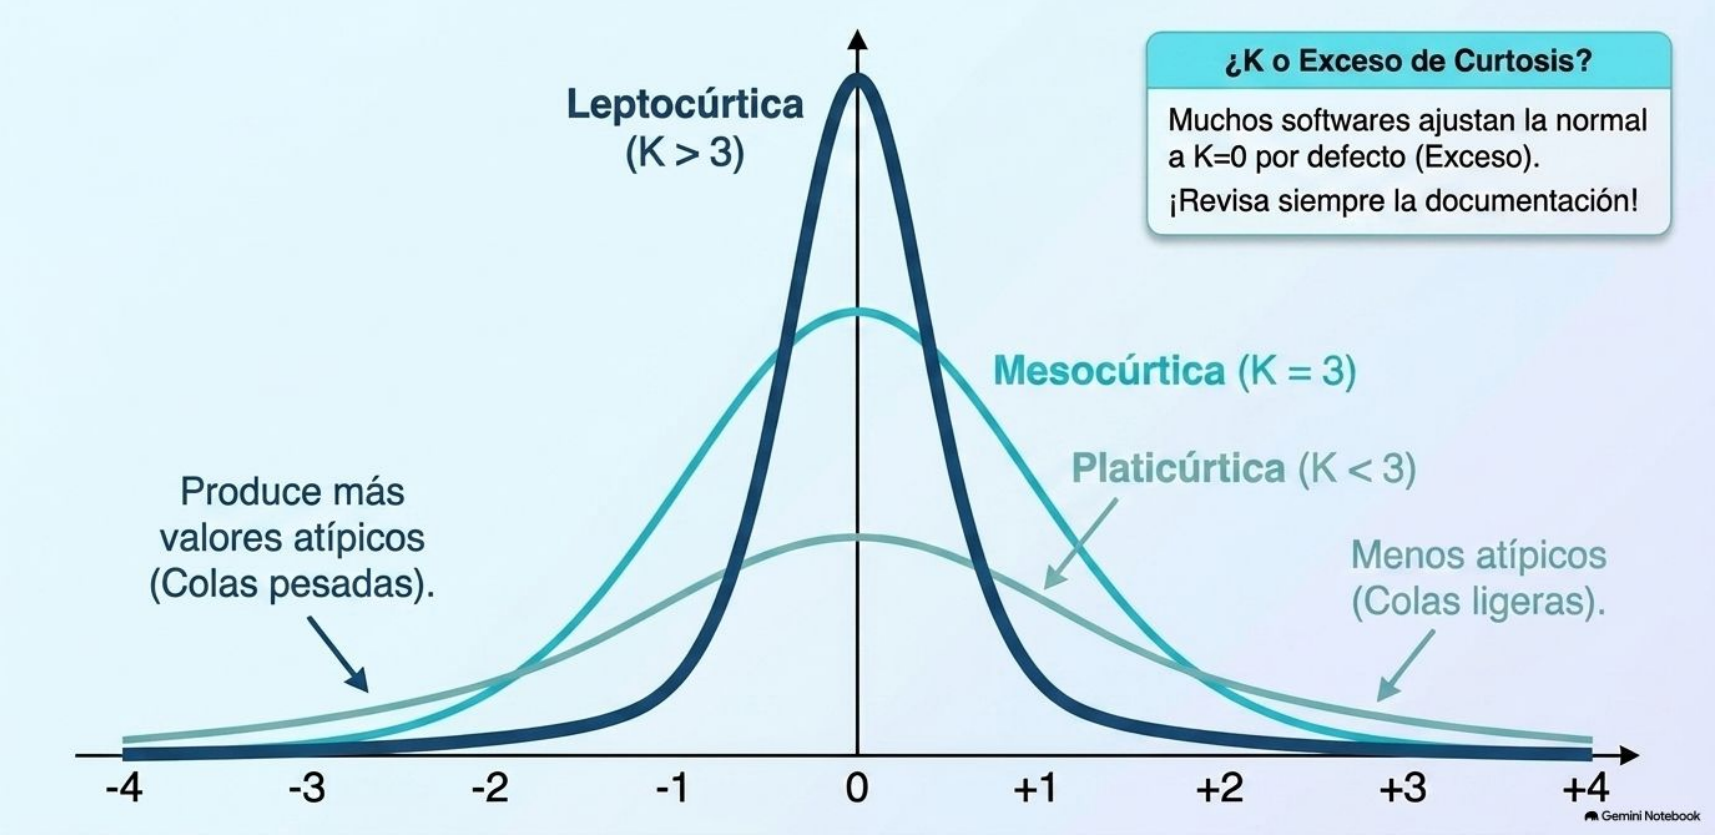
- Asimetría = 0: la distribución es simétrica
- Asimetría > 0 (+): Asimétrica hacia la derecha, cola más larga a la derecha (extremos a derecha de la media)
- Asimetría < 0 (-): Asimétrica hacia la izquierda, cola más larga a la izquierda (extremos a izquierda de la media)

Si los datos son multimodales, puede afectar el signo de la asimetría!!!

La forma de los datos: Kurtosis

La **Kurtosis** es una medida de si los datos tienen colas pesadas o colas ligeras en relación con una distribución normal.

$$K = \frac{\sum_{i=1}^{n}(x_i - \bar{x})^4}{nS^4}$$



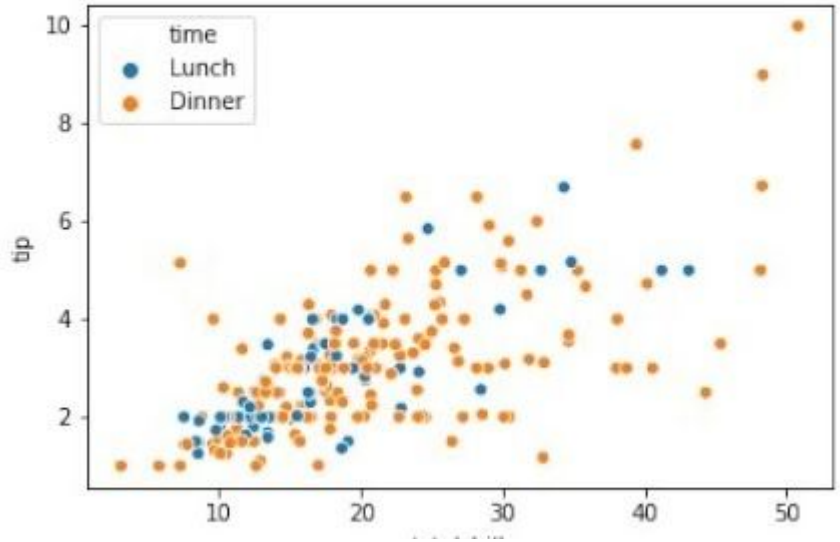
La forma de los datos: Kurtosis

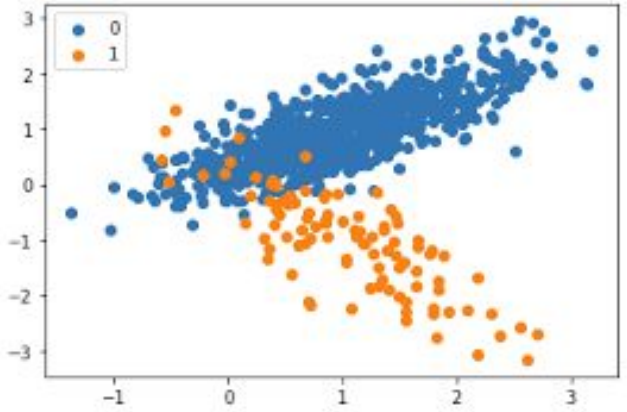
La kurtosis anterior, se suele denominar excesiva, pero se puede modificar para que se ajuste a K=0, la distribución normal como :

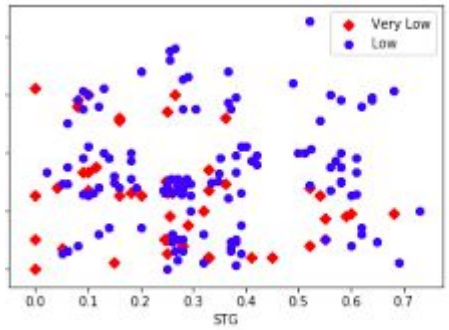
$$K = \frac{\sum_{i=1}^{n}(x_i - \bar{x})^4}{nS^4} - 3$$

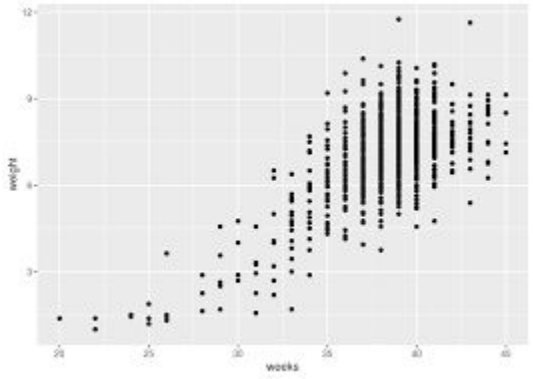
Con esta definición, la curtosis positiva indica una distribución de "cola pesada" y la curtosis negativa indica una distribución de "cola ligera".

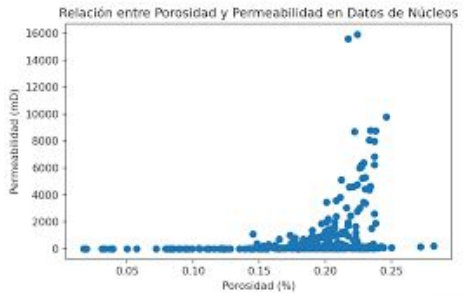
Independencia: caso I- variables cuanti

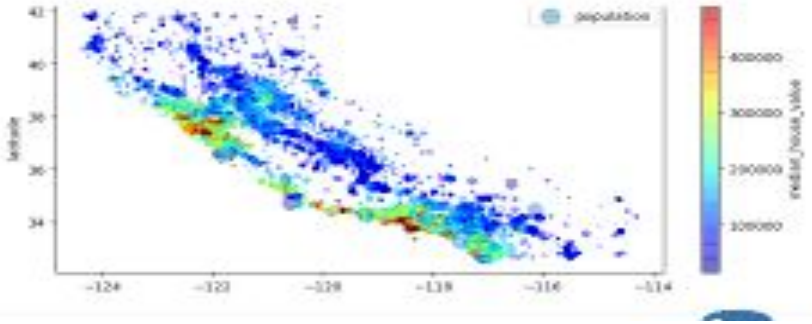


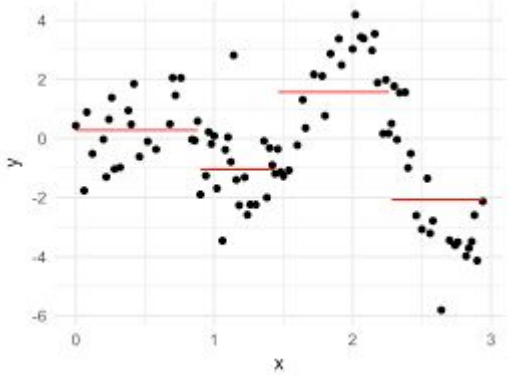












Independencia: caso I- variables cuanti

Covarianza: medida de la asociación/ dependencia entre dos variables cuantitativas

$$Cov(X,Y) = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{n}$$

Correlación: es una medida de asociación (relación) lineal entre dos variables cuantitativas.Surge como un escalado de la covarianza:

$$r = \frac{Cov(X,Y)}{S_X S_y}$$

- Varía entre -1 y 1.
- El signo determina la relación directa o inversa entre las variables.
- Independiente de unidades

y si es cero?

Independencia: caso I- variables cuanti

Es **positiva** cuando la **tendencia general** presente en los datos es:

- **valores altos** de X con **valores altos** de Y (ó viceversa) y **valores bajos** de X con **valores bajos** de Y (ó viceversa)

Es **negativa** cuando la tendencia general presente en los datos es:

- **valores altos** de x con **valores bajos** de y (y viceversa) y **valores bajos** de x con **valores altos** de y (y viceversa)

- Un valor cercano a **0 INDICA AUSENCIA de asociación lineal**
- **NO DA** información precisa sobre **causa y efecto**
- **NO ES ÚTIL** si la **relación entre las variables NO ES LINEAL**
- Puede testearse su **significación** (correlación no nula) bajo **normalidad**

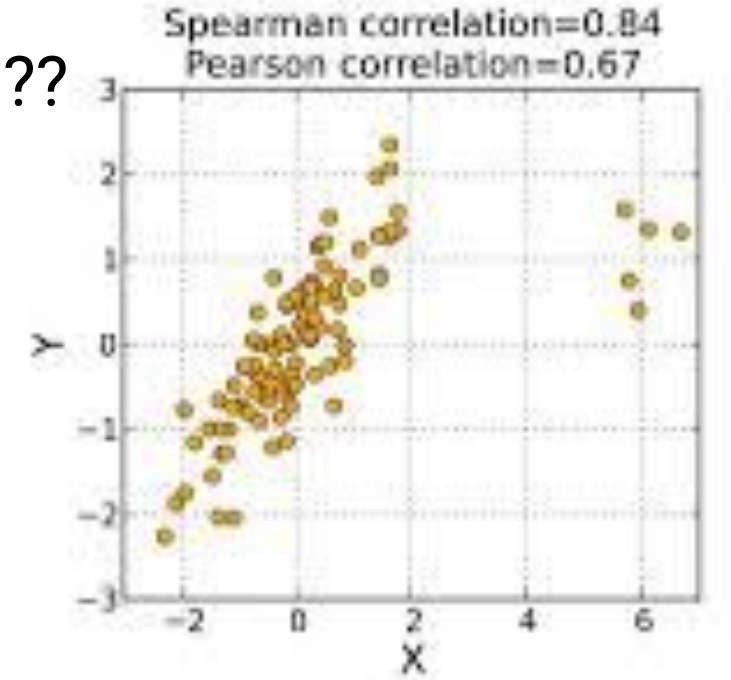
Independencia: caso I- variables cuanti

Existen diversos tipos:

- *correlación de Pearson*
- *correlación por rangos (Spearman- Kendall)*
- *Otros*

Y que tiene que ver la correlación con la independencia??





Independencia: caso I- variables cuanti

Serie 1		Serie 2		Serie 3		Serie 4	
X	y	X	y	X	y	X	y
10	8,04	10	9,14	10	7,46	8	6,58
8	6,95	8	8,14	8	6,77	8	5,76
13	7,58	13	8,74	13	12,74	8	7,71
9	8,81	9	8,77	9	7,11	8	8,84
11	8,33	11	9,26	11	7,81	8	8,47
14	9,96	14	8,1	14	8,84	8	7,04
6	7,24	6	6,13	6	6,08	8	5,25
4	4,26	4	3,1	4	5,39	19	12,5
12	10,84	12	9,13	12	8,15	8	5,56
7	4,82	7	7,26	7	6,42	8	7,91
5	5,68	5	4,74	5	5,73	8	6,89

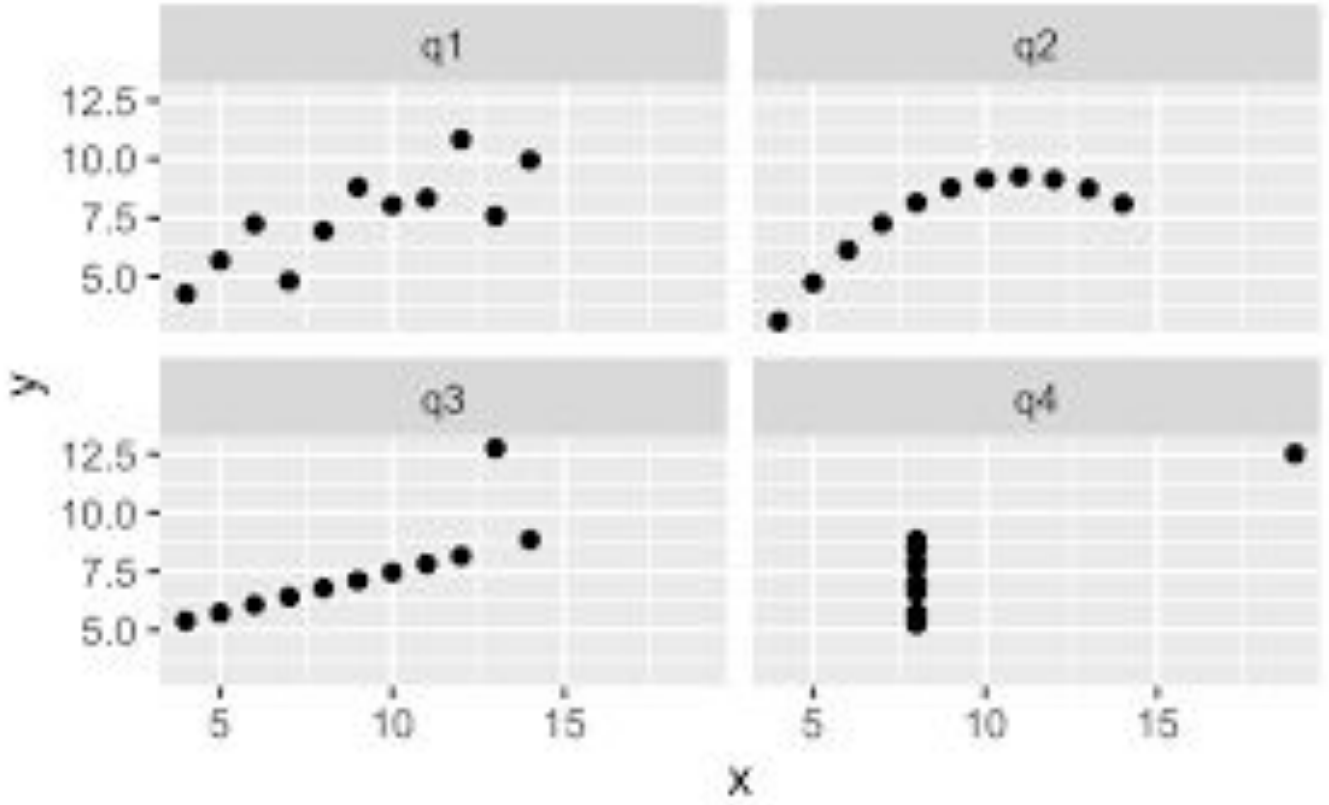
$$\bar{x} = 9 \quad \bar{y} = 7{,}5$$

$$S_x = S_y = 11$$

$$r = 0.816$$

Independencia: caso I- variables cuanti

"*CUARTETO DE ANSCOMBE (1973)* ": r=0.816



Moraleja: GRAFICAR los datos es VITAL!!!

Independencia: caso II- variables cuali

La Prueba Chi-cuadrado χ^2

Existen tres tipos de pruebas chi-cuadrado:

- Bondad de ajuste
- **Prueba de independencia**
- Prueba de homogeneidad

De manera general, es una prueba **no paramétrica** que se utiliza para evaluar la divergencia entre puntuaciones observadas y unas puntuaciones esperadas.

Prueba o test No paramétrico: son pruebas cuyas hipótesis n**o especifican condiciones sobre un parámetro de la población, sino propiedades**

Independencia: caso II- variables cuali

Una tabla de contingencia es una herramienta que permite poner a prueba si ***dos criterios de clasificación de una misma muestra*** **son independientes o no.** Contiene las frecuencias observadas.

Si X e Y son dos variables aleatorias cualitativas con r y c categorías respectivamente. La tabla de contingencia resume las frecuencias n_{ij} observadas de X_i e Y_j en una muestra de tamaño n.

X/Y	Nivel 1	Nivel 2	....	Nivel c	Marginal X
Nivel 1	n_{11}	n_{12}		n_{1c}	$n_{1.}$
Nivel 2	n_{21}	n_{22}		n_{2c}	$n_{2.}$
...					
Nivel i	n_{i1}		n_{ij}		
Nivel r	n_{r1}	n_{r2}	n_{rj}	n_{rc}	$n_{r.}$
Marginal Y	$n_{.1}$	$n_{.2}$	$n_{.j}$	$n_{.c}$	n

Independencia: caso II- variables cuali

Pregunta: Son X e Y son independientes?

Hipótesis: X e Y son independientes

$$H_0: P(XY = X_i Y_j) = P(X = X_i)P(Y = Y_j)$$
$$H_1: P(XY = X_i Y_j) \neq P(X = X_i)P(Y = Y_j)$$

Si X e Y son independientes cuantos individuos caerían en la celda ij de la tabla de contingencia??

Veamos un ejemplo sencillo:

supongamos que desea clasificar los defectos de los muebles producidos por una planta de fabricación en función del tipo de defectos y del turno de producción. Se registró un total de **390 muebles defectuosos**, y los defectos se clasificaron como uno de los cuatro tipos A, B, C y D. Al mismo tiempo, cada mueble defectuoso se identificó según el turno de producción

Shift	Type of defect			
	A	B	C	D
1	15	21	45	13
2	26	31	34	5
3	33	17	49	20

Independencia: caso II- variables cuali

Frecuencias observadas f_{oij}

Shift	Type of defect			
	A	B	C	D
1	15	21	45	13
2	26	31	34	5
3	33	17	49	20

Shift/Defect	A	B	C	D	Marginal de X
1	15	21	45	13	94
2	26	31	34	5	96
3	33	17	49	20	119
Marginal Y	74	69	128	38	309

Que podemos hipotetizar de acuerdo a los marginales?

La probabilidad de que un producto se encuentre en la celda ij bajo la H_0 es:

Frecuencia esperadas f_{eij} para la celda ij, bajo independencia

$$p_{ij} = \frac{n_{i.}}{n}\frac{n_{.j}}{n} \qquad f_{e_{ij}} = nP_{ij} = \frac{n_{i.}\, n_{.j}}{n}$$

Independencia: caso II- variables cuali

Shift/Defect	A	B	C	D	Marginal de X
1	15	21	45	13	94
2	26	31	34	5	96
3	33	17	49	20	119
Marginal Y	74	69	128	38	309

Shift/Defect	A	B	C	D	Marginal de X
1	94.74/309=22.51	20.99	38.94	11.55	94
2	22.99	21.44	39.77	11.80	96
3	28.49	26.57	49.29	14.63	119
Marginal Y	**74**	**69**	**128**	**38**	309

Estadístico de prueba propuesto: $$\chi^2 = \sum \frac{(O-E)^2}{E}$$

$$\chi^2 = \sum_{j=1}^{c} \sum_{i=1}^{r} \frac{\left(f_{o_{ij}} - f_{e_{ij}}\right)^2}{f_{e_{ij}}}$$

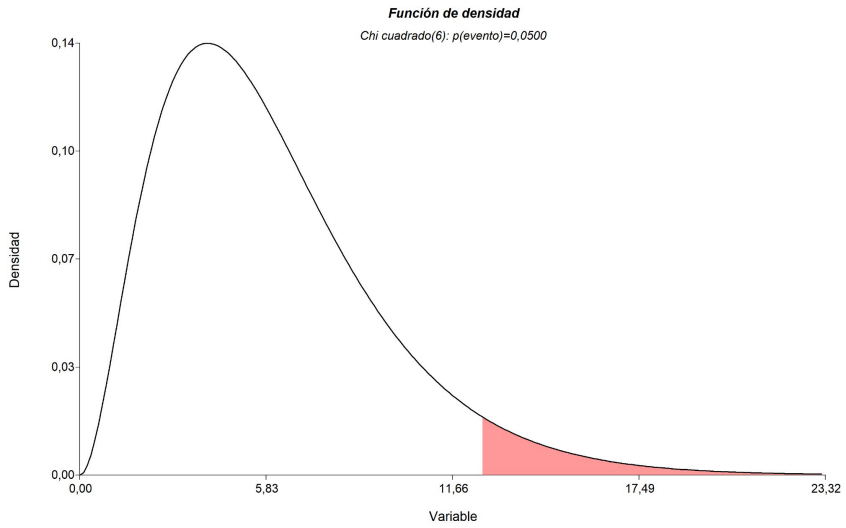
Este estadístico tiene una distribución **χ^2 con (r-1)(c-1) grados de libertad**

Independencia: caso II- variables cuali

Por lo tanto, la Hipótesis de independencia se rechaza si el estadístico de prueba supera al valor crítico.

Es decir:

$$Si\ \chi^2_{obs} > \chi^2_{(r-1)(c-1),1-\alpha}$$



SIEMPRE ES UNA PRUEBA UNILATERAL DERECHA

Independencia: caso II - variables cuali

Shift/Defect	A	B	C	D
1	2.51	0.00	0.94	0.18
2	0.39	4.27	0.84	3.92
3	0.71	3.45	0.00	1.97

$$\chi^2_{6,0.95} = 12.54$$

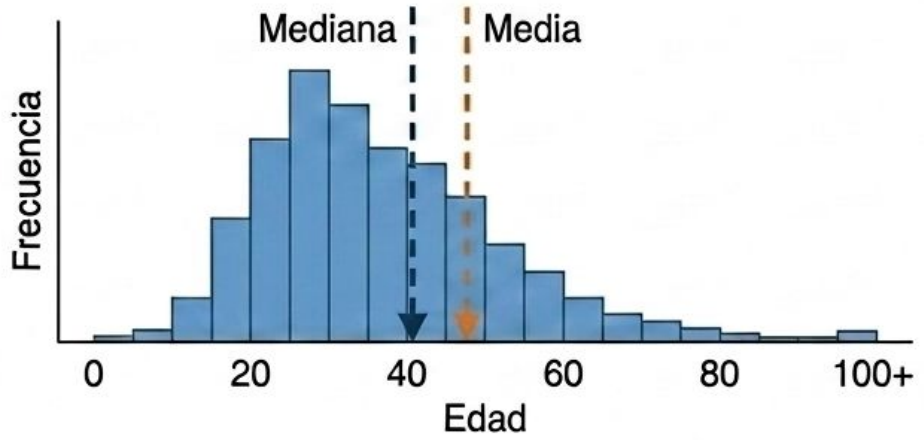
```
Pearson's Chi-squared test

X-squared = 19.178, df = 6, p-value = 0.003873
```

Es decir, existen evidencias para rechazar la hipótesis nula, las variables no pueden considerarse estadísticamente independientes, **hay una asociación significativa entre el número de defectos de producción y el turno.**

EDA

Distribución de Edad



Relación Edad vs. Ingresos

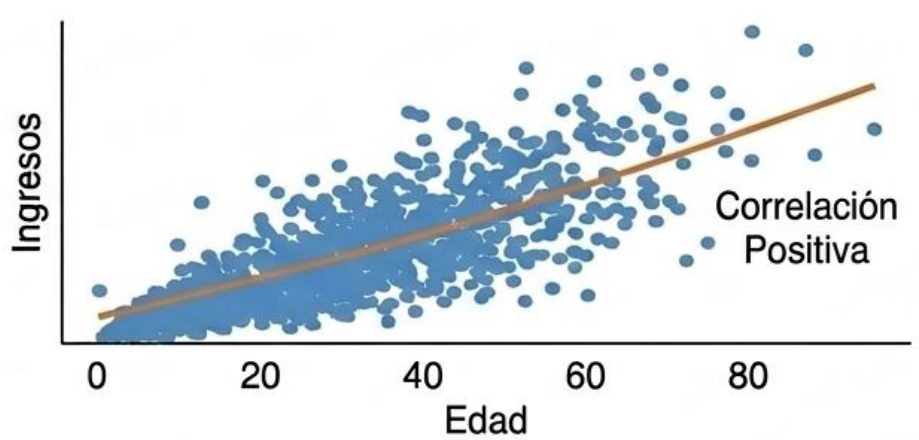
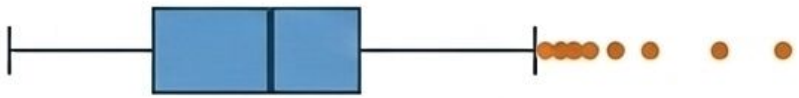


Diagrama de Caja y Bigotes



Relación entre Variables Categóricas



Prueba de Chi-cuadrado (χ^2)
Evalúa la independencia entre una o más variables categóricas. (Ej. Género vs. Preferencia)

El **EDA** no es aplicar fórmulas aisladas. Es usar **todas las** herramientas (centralidad, dispersión, asimetría y correlación, chi-cuadrado) en **conjunto** para **contar la historia completa** de una variable.

¿Qué vimos hoy?

Análisis de Datos Exploratorio (EDA)

a. Medidas de tendencia central
b. Medidas de posicion
c. Medidas de dispersión
d. Asociacion entre variables cuantitativas
e. Asociación entre variables cualitativas