

FACULTAD DE CIENCIAS EXACTAS UNICEN

Reducción de dimensionalidad

(Parte I)

¿Qué vamos a ver hoy?

- Datos multivariados
- Medidas de resumen de datos multivariados
- Tipos de técnicas del análisis multivariado
- Concepto de combinación lineal y proyeccion: interpretación gráfica- geométrica
- Concepto de independencia estadística y su interpretación gráfica
- Descomposición canónica
- Reducción de dimensionalidad bajo linealidad con PCA -
- Visualización del PCA- Gplot y Biplot

Tipos de estudios

1. Métodos de Interdependencia

Estructura general: (X)

No distinguen entre variables dependientes e independientes.

•Objetivo: Identificar relaciones subyacentes, patrones y estructura conjunta de los atributos.

Ejemplos:
- Componentes Principales (PCA)
- Escalado Multidimensional (MDS)
- Análisis de Cluster / Agrupamiento

2. Métodos de Dependencia



Estructura general: (X → Y)

Dividen las variables en explicativas e independientes vs. respuesta.

• Objetivo: Determinar si el conjunto X afecta a Y y cuantificar la magnitud del efecto.

Ejemplos:
- Regresión Múltiple / Multivariada
- Discriminante Lineal de Fisher
- MANOVA

3. Métodos Estructurales

Estructura general: (X ~ Y)

Modelan dependencias simultáneas e interrelaciones en múltiples bloques.

• Objetivo: Analizar cómo influyen las explicativas y cómo se relacionan los grupos entre sí.

Ejemplos
- Correspondencia Canónica
- Mínimos Cuadrados Parciales (PLS)
- Ecuaciones Estructurales (SEM)

Técnicas multivariadas

Los métodos estadísticos multivariados se utilizan para analizar el comportamiento conjunto de varios atributos

Existe una amplia gama de técnicas multivariadas disponibles, vamos a ver solo algunas y para que se utilizan

🔽**REDUCIR**

🗂️ **CLASIFICAR**

👥 **AGRUPAR.**

🔮 **PREDECIR**

📊 **ORDENAR**



EN POCAS

DIMENSIONES!!

Objetivos

I- Reducción de la dimensión

- Múltiples variables correlacionadas, si se analizan por métodos tradicionales hay problemas de multicolinealidad
- La reducción de dimensión permite identificar grupos de individuos o muestras, describir esos grupos y de los individuos o muestras y generar nuevas variables que deben facilitar el problema
- El análisis va a depender del tipo de atributos o variables de estudio
- Puede asumir una relación lineal o no lineal, entre las multiples variables

II- Clasificación / Agrupamiento

Puede ser supervisado o no, dependiendo del objetivo, la naturaleza del problema o la información con la que se cuente, etc

Objetivos

Agrupamiento No supervisado

- De utilidad cuando no se tienen identificados grupos de forma precisa, se analizan las “distancias” entre los individuos/grupos
- Algunas de las técnicas para agrupar son conocidas como escalamiento métrico y no métrico, análisis de aglomeramientos **o clusters.**

Agrupamiento Supervisado

- Dada una variable de clasificación (cualitativa) se predice el valor de variable para un individuo dado a partir de un conjunto de variables cuantitativas o una combinación de ellas.
- Algunas de las técnicas que se utilizan para clasificar son el discriminante lineal o por alguna función discriminante de Fisher

Objetivos

III- Modelado- predicción

- Asume una dependencia de una o más variables de otras. El objetivo es explicar y cuantificar la relación de la/las variables dependientes de las independientes
- Permite describir patrones, predecir comportamientos y simplificar la información sin perder la información esencial

Fundamentos de la Ciencia de Datos

Análisis multivariado vs algebra

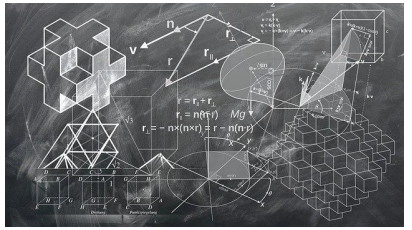
El Álgebra Lineal Proporciona el Lenguaje Formal de la Estadística Multivariada

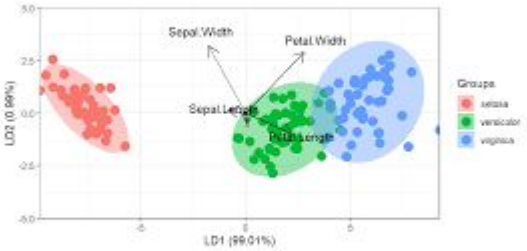
Concepto Algebraico	Interpretación Estadística Multivariada
Matriz X (n × p) / Vector v	Matriz de Diseño / Registro de Atributos e Individuos
Combinación Lineal	Asociación e Independencia entre Atributos
Proyección Ortogonal	Espacio de Representación Reducida (Subespacio Óptimo)
Descomposición Espectral (Q Λ Q')	Espacio Óptimo de Variabilidad Multivariada
Autovalores (λj)	Varianza Explicada por cada Eje Principal
Autovectores (qj)	Direcciones Principales de Variabilidad (Pesos / Loadings)

¿Por qué este Puente?

La Estadística Multivariada transforma problemas de alta dimensionalidad en operaciones geométricas de proyecciones y rotaciones en espacios vectoriales.

Cada propiedad matricial tiene un directo significado analítico sobre la información y variabilidad de los datos.





Fundamentos de la Ciencia de Datos

Medidas de Resumen Multivariado: Centroide, Covarianza y Correlación

$$X_{nxp} = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{bmatrix}$$

VECTOR DE MEDIAS- CENTROIDE
Tiene dimensión p y calcula las medias de cada una de las p variables.

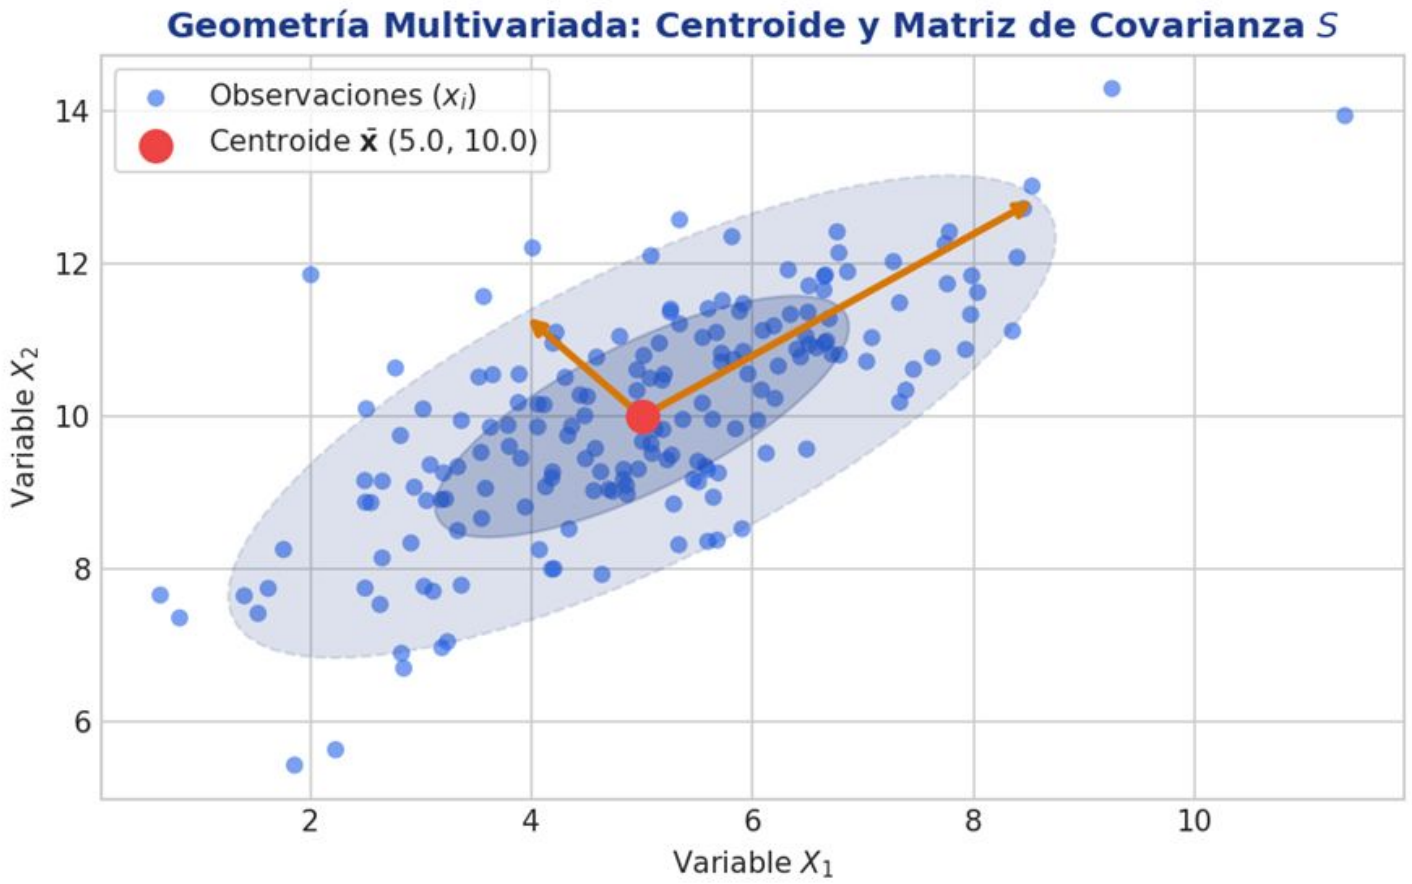
$$\bar{x} = \begin{bmatrix} \overline{x_1} \\ \cdots \\ \cdots \\ \cdots \\ \overline{x_p} \end{bmatrix} = \frac{1}{n}\mathbf{X}'\mathbf{1}$$

MATRIZ DE VARIANZAS Y COVARIANZAS:
resume la variabilidad de los datos y la información relativa a las relaciones lineales entre las variables
Esta matriz es cuadrada y simétrica de orden p, donde los términos diagonales son las varianzas y los no diagonales, las covarianzas entre las variables.
En cada lugar ij se encuentra una medida no acotada de la covariación conjunta de Xi con Xj.

$$S = \begin{bmatrix} s^2{}_1 & s_{12} \cdots & s^2_{1p} \\ \vdots & \ddots & \vdots \\ s^2_{p1} & s^2_{p2} \cdots & s^2_p \end{bmatrix}$$

Fundamentos de la Ciencia de Datos

Análisis multivariado vs algebra



$$S = \begin{bmatrix} \text{Var}(X_1) & \text{Cov}(X_1, X_2) \\ \text{Cov}(X_2, X_1) & \text{Var}(X_2) \end{bmatrix} = \begin{bmatrix} 4.0 & 2.5 \\ 2.5 & 9.0 \end{bmatrix}$$

- Var(X1)=4.0: indica que la dispersión de los datos en el eje horizontal es moderada.
- Var(X2)=9.0: muestra mayor variabilidad en el eje vertical.
- Cov(X1,X2)=2.5: refleja una correlación positiva entre ambas variables (cuando X1 aumenta, X2 tiende a aumentar).

Este tipo de matriz genera una **elipse inclinada**, porque la covarianza positiva hace que los ejes principales de la elipse estén rotados respecto de los ejes X1 y X2.

Medidas de resumen multivariado

A partir de la matriz S, podemos definir la matriz R de correlaciones como:

$$R = [r_{ij}] = D^{-1/2} S D^{-1/2} = \left[\frac{s_{ij}}{\sqrt{s_{ii}}\sqrt{s_{jj}}} \right]$$

$$D^{1/2} = \begin{bmatrix} \sqrt{s_{11}} & 0 & \cdots & 0 \\ 0 & \sqrt{s_{22}} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \sqrt{s_{pp}} \end{bmatrix}$$

- La *covarianza* y la *correlación* son medidas de *asociación lineal* entre las variables, sus valores son poco informativos para otros tipos de asociación.
- R es una matriz cuadrada y simétrica, que en la diagonal tiene unos y fuera de ella tiene las correlaciones de las variables dos a dos, estos números están entre -1 y 1, es decir todos los valores están acotados, **son comparables e interpretables!**

Fundamentos de la Ciencia de Datos

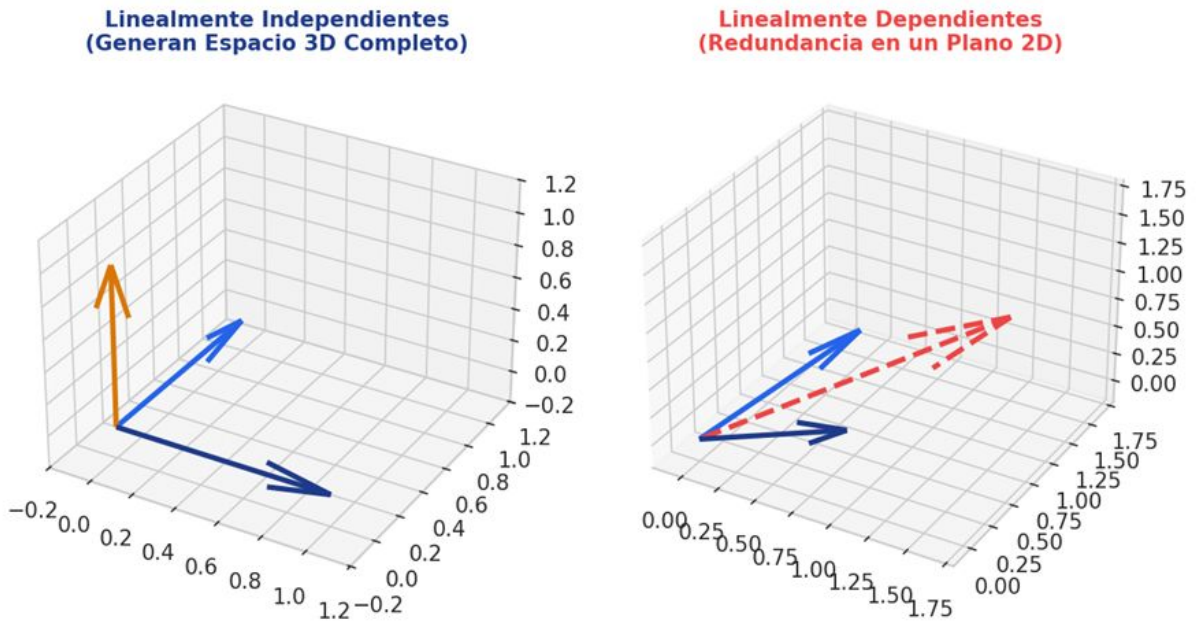
Independencia lineal

- Una COMBINACIÓN LINEAL es una operación algebraica entre vectores, **estadísticamente hablando sobre atributos o variables**.

- Si tenemos p vectores, **o atributos (variables, vectores columnas)**, una combinación lineal de ellos es una suma ponderada de los mismos. Deben coincidir en dimensión, es decir estar en un mismo espacio (R^p).

$$Y = a_1X_1 + a_2X_2 + \dots + a_pXp$$

Los coeficientes a_i, son los pesos, valores reales.



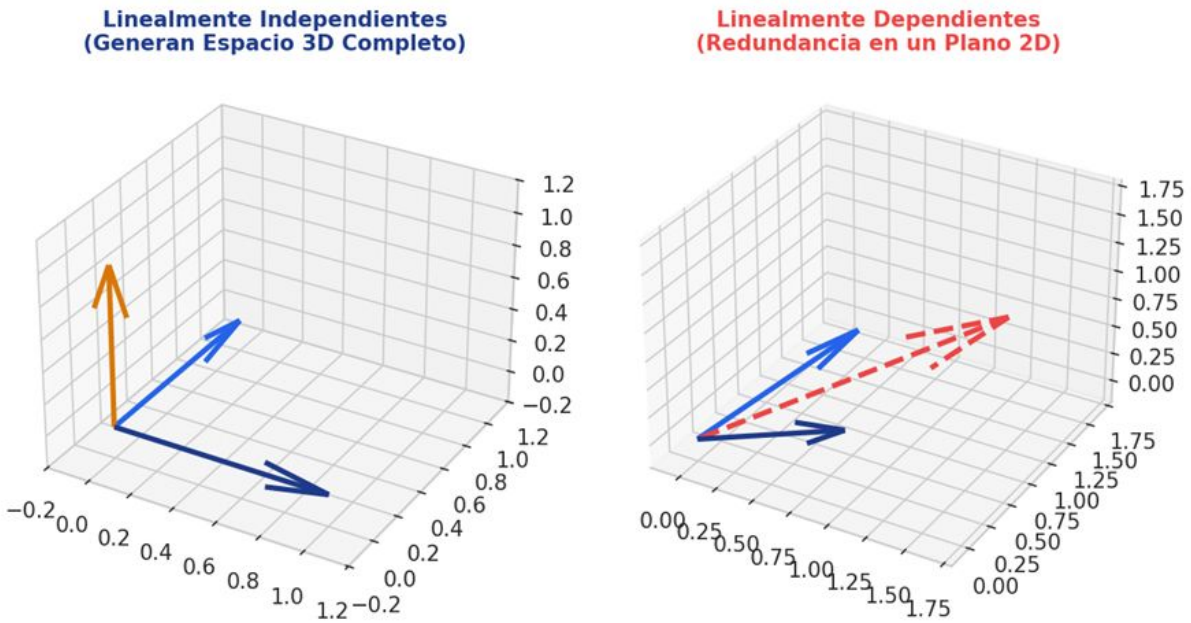
Fundamentos de la Ciencia de Datos

Independencia lineal

Un conjunto de vectores es **linealmente independiente (LI) si ninguno de ellos puede ser escrito como combinación lineal de los restantes.**

En estadística si dos vectores (variables) son LI, es equivalente a pensar, las variables que representan esos vectores ***son estadísticamente independientes.***

ES decir ninguna variable aporta información totalmente redundante de otra variable

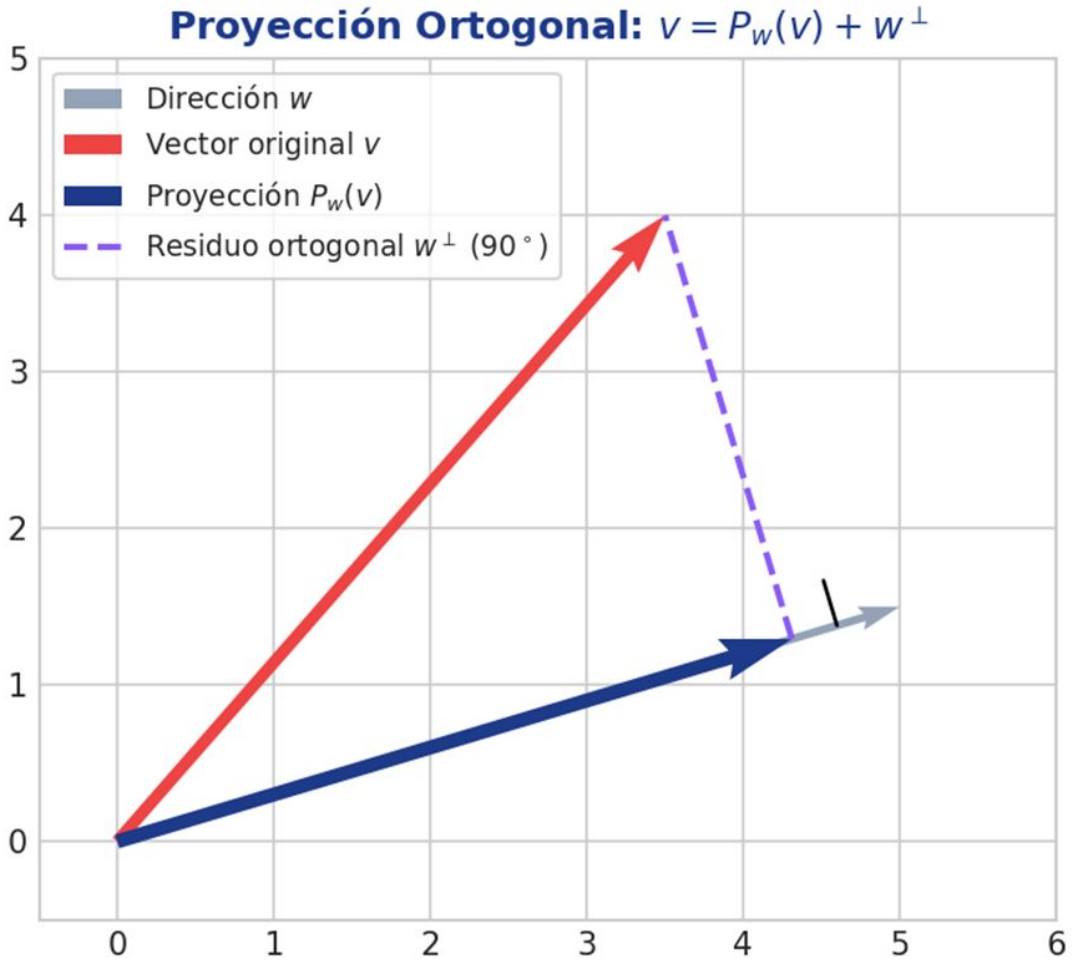


Proyección ortogonal

Proyección ortogonal: para proyectar v en un plano, proyectamos v sobre w, un vector en el plano de interés, algebraicamente:

$$P_w(v) = \frac{(v' w)}{\|w\|^2} w$$

Descomposición Ortogonal: Todo vector se descompone de forma única en $v = P_w(v) + w^{\perp}$ (componente explicada + residuo).



Ortogonalidad entre vectores

- Dos vectores u y v son **ortogonales** cuando el producto escalar entre ellos es cero: u´.v=0. La ortogonalidad entre vectores implica geométricamente un ángulo entre ellos de 90°

$$u´v=\|u\|.\|v\| \cdot \cos(\theta)=0 \leftrightarrow \cos(\theta)=0 \leftrightarrow \theta=90°$$

Estadisticamente:
Cov(X1,X2)=0

- Dos vectores u y v son **ortonormales** cuando son ortogonales entre sí y cada uno de norma 1

Descomposición espectral

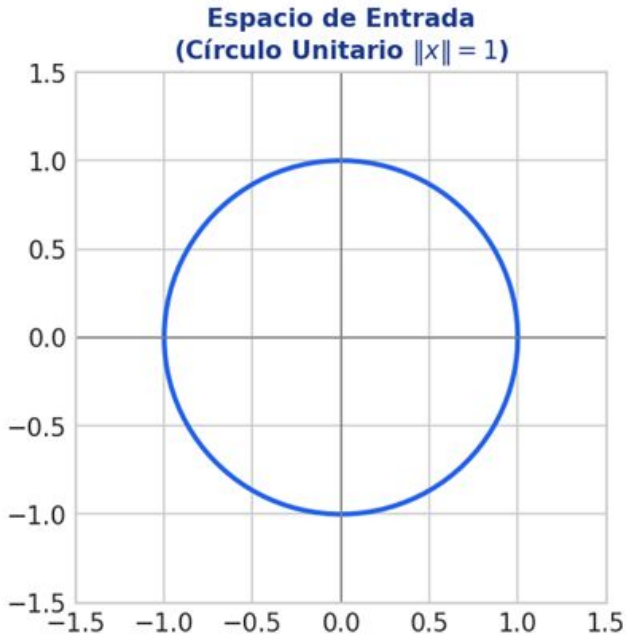
¿Qué es? y ¿para qué sirve?¿cuando se usa?

- Es una descomposición especial de **matrices simétricas**
- Sirve para detectar direcciones y dimensiones de **mayor variación** o dominantes de un conjunto de datos
- Sirve para para disminuir la dimensión de un problema
- Puede aplicarse en toda matriz cuadrada y simétrica
- Otras aplicaciones: En **análisis de redes**: centralidad en grafos. En **dinámica de sistemas**: para resolver ecuaciones diferenciales lineales, en **procesamiento de señales**

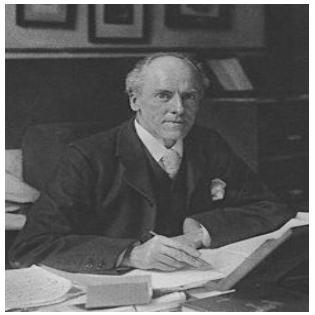
Descomposición espectral

Factorización de Matrices Simétricas

- **Factorización R = Q Λ Q':** Toda matriz simétrica y diagonalizable (S o R) admite esta descomposición canónica.
- **Matriz Q (Autovectores):** Q = [q1 q2 ... qp] contiene autovectores ortonormales que definen los nuevos ejes principales.
- **Matriz Λ (Autovalores):** Λ = diag(λ1, λ2, ..., λp) con λ1 ≥ λ2 ≥ ... ≥ λp ≥ 0 ordenados de mayor a menor variabilidad.
- **Utilidad Práctica:** Identifica las direcciones de máxima variación y fundamenta la reducción de dimensionalidad







Cauchy (1829)

Pearson (1901)

Descomposición canónica o espectral

AUTOVALORES (o valores propios)

- Hay tantos como el número de filas (ó columnas) de la matriz sobre la que se calcula
- Cada autovalor se asocia a un autovector
- Los autovalores pueden considerarse una medida de la VARIABILIDAD del autovector.
- Los autovalores de R y S, son no negativos y están ordenados de manera decreciente
- Si se descompone R, la suma de los autovalores coindice con el orden o dimensión del problema es decir con p

AUTOVECTORES (o vectores propios).....

- Hay tantos como el número de filas (ó columnas) de la matriz sobre la que se calcula.
- Cada autovector está asociado con un autovalor
- El autovector define una DIRECCIÓN de variabilidad
- Los autovectores definen direcciones ortogonales
- La primer dirección es la mas variable, y asi en orden descendiente

REDUCCIÓN DE LA DIMENSIONALIDAD

- PCA
- t-SNE
- UMAP



REDUCCIÓN DE LA DIMENSIÓN

Muchos problemas de ciencia de datos, involucran cientos de características, tener una cantidad tan grande de atributos trae consigo muchos problemas, algunos son:

- Hace que el análisis sea extremadamente lento.
- Hace que sea difícil encontrar una buena solución.

Por eso una estrategia consiste en **la reducción de la dimensionalidad**

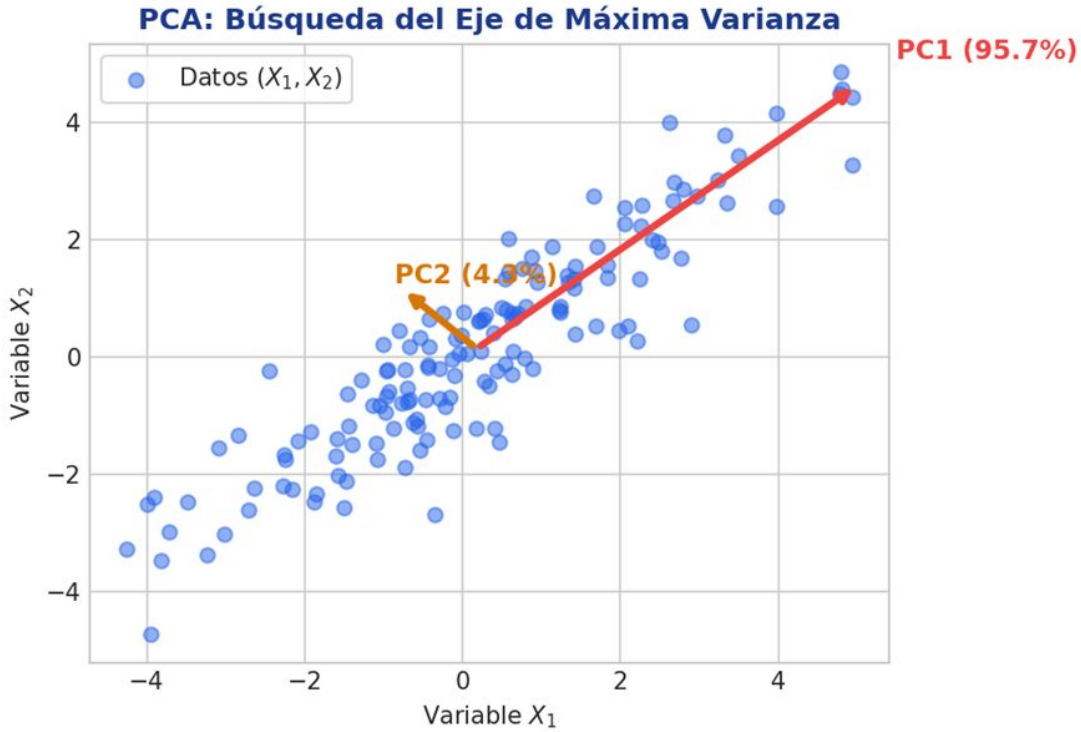
La mayoría de las aplicaciones de reducción de dimensionalidad se utilizan para:

- Comprensión/descripción de datos multivariados
- Reducción de ruido/ redundancia
- Visualización de datos
- Clasificación de datos

REDUCCIÓN DE LA DIMENSIÓN: ACP o PCA

Construcción de Componentes

- **Definición de C_j:** Nuevas variables $C_j = q_j' X$ (combinación lineal de las variables originales).
- **Maximización de Varianza:** C_1 captura la máxima variabilidad posible; C_2 la segunda máxima ortogonal a C_1.
- **Varianza Retenida:** $\text{Var}(C_j) = \lambda_j$. La varianza de cada componente es exactamente su autovalor asociado.
- **Incorrelación Total:** $\text{Cov}(C_i, C_j) = 0$ para $i \neq j$. Se elimina completamente la multicolinealidad.

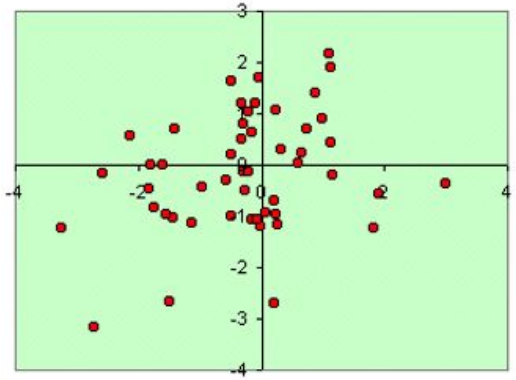


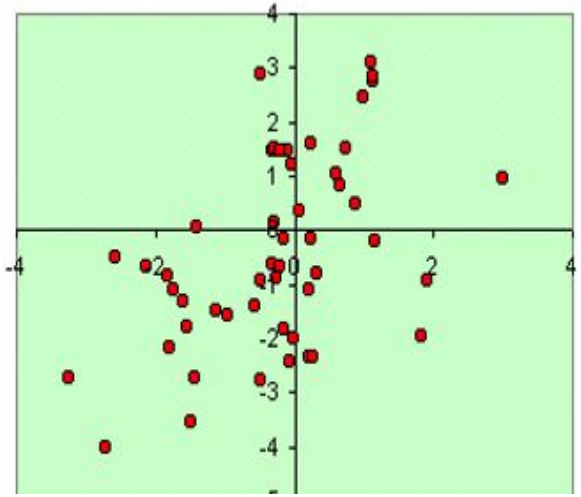
$$C_1 = q_{11}X_1 + q_{21}X_2 + \cdots + q_{p1}X_p$$

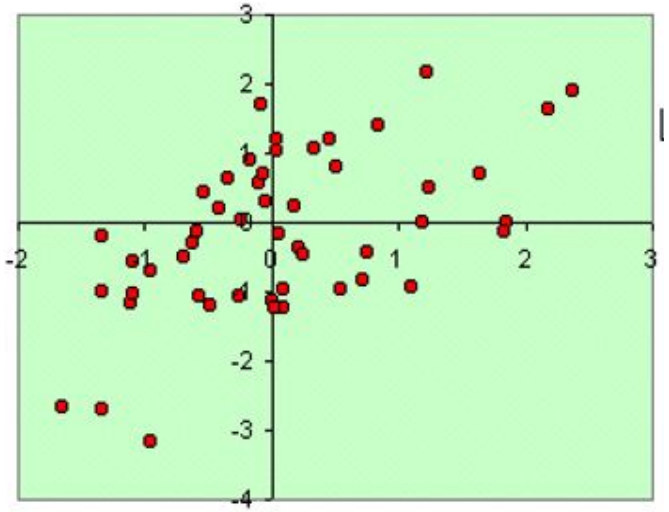
$$C_2 = q_{12}X_1 + q_{22}X_2 + \cdots + q_{p2}X_p$$

$$C_p = q_{1p}X_1 + q_{2p}X_2 + \cdots + q_{pp}X_p$$

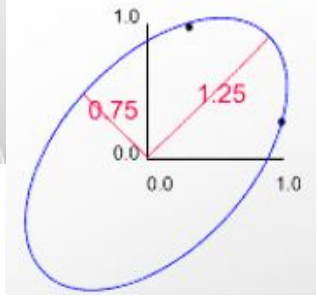
COMPONENTES PRINCIPALES



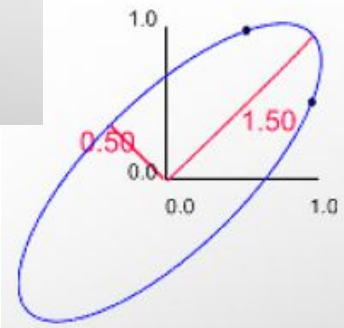




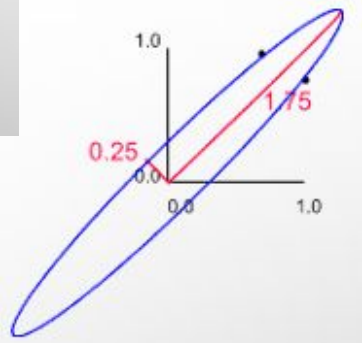
$$R = \begin{bmatrix} 1 & 0.25 \\ 0.25 & 1 \end{bmatrix}$$



$$R = \begin{bmatrix} 1 & 0.50 \\ 0.50 & 1 \end{bmatrix}$$



$$R = \begin{bmatrix} 1 & 0.75 \\ 0.75 & 1 \end{bmatrix}$$



EL MISMO PROCEDIMIENTO EN MUCHAS DIMENSIONES: PCA

COMPONENTES PRINCIPALES

¿Cuánta información presente en el set de datos original se pierde al proyectar las observaciones en un espacio de menor dimensión?

VARIANZA TOTAL=SUMA DE LAS VARIANZAS de las variables originales.

Var Total =Traza (S) con los *datos crudos* ó

Var Total =Ttraza(R) con los *datos estandarizados*.

Pero….

$$\text{Traza}(R)=\text{Traza}(\Lambda)= \lambda_1 +\lambda_2 + \ldots +\lambda_p = \text{Var}(C_1) + \ldots + \text{Var}(C_p) =p$$

COMPONENTES PRINCIPALES

Entonces,

en la primer dirección principal: % $Var(C_1) = \frac{\lambda_1}{p}$

en la segunda: % $Var(C_2) = \frac{\lambda_2}{p}$

Y en el primer plano principal: % $Var(C_1C_2) = \frac{\lambda_1 + \lambda_2}{p}$

y así sucesivamente…….. en p componentes se alcanza el 100% de varianza total

Buscamos un espacio óptimo de k dimensiones que recupere un % alto de variación

COMPONENTES PRINCIPALES

- Si este porcentaje es alto, se pueden reemplazar las p variables originales por un número mucho menor k de Componentes, con poca pérdida de información.

- No existe un método objetivo para determinar el número de componentes principales que son suficientes para un análisis

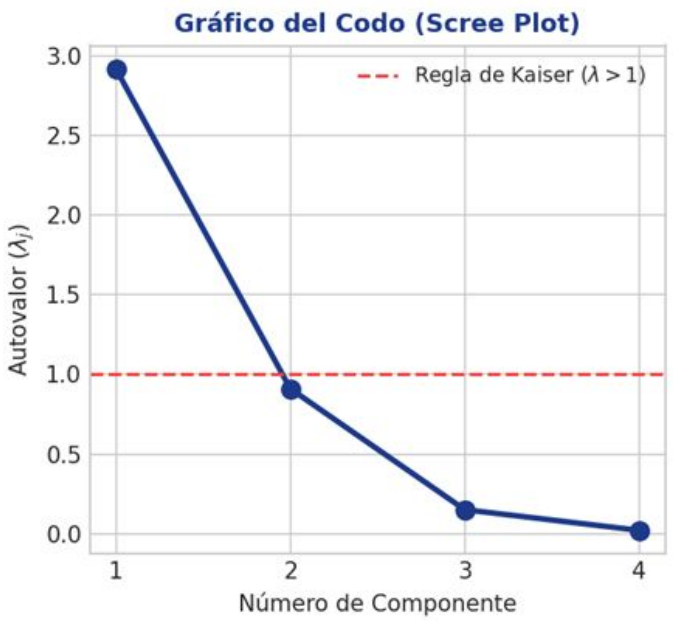
- Si explican suficiente variabilidad y el objetivo es la visualización de los datos, no se suelen considerar más de tres componentes principales

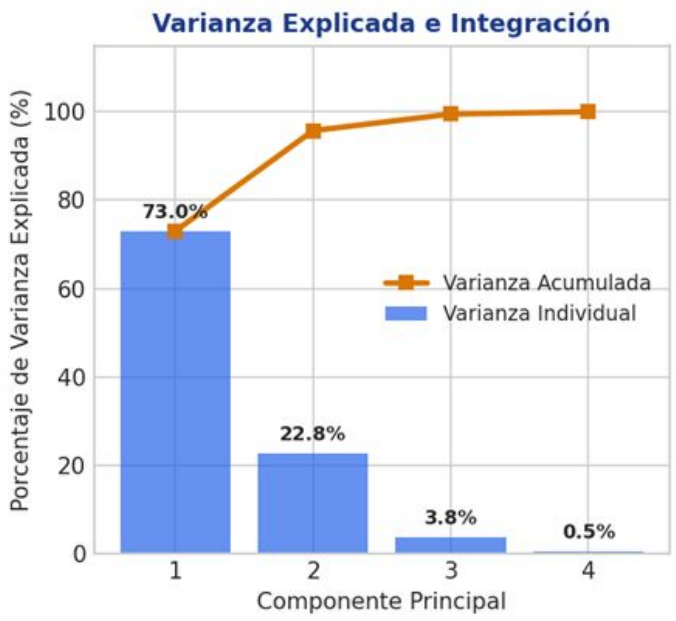
- El método de Kaiser es muy utilizado, y sugiere que se seleccionan tantas componentes **como aquellas tengan varianza de la componente mayor que 1.**

- Métodos gráficos (del Codo - Elbow)

COMPONENTES PRINCIPALES

Métodos Gráficos:





Reglas y Criterios

- **Varianza Total:** Traza(R) = p = ∑ λj = ∑ Var(Cj). La varianza total se conserva íntegramente.
- **Proporción Explicada:** La componente j explica (λj / p) % de la varianza total del dataset.
- **Criterio de Kaiser:** Conservar componentes con autovalor λ > 1 (aportan más información que 1 var individual).
- **Gráfico del Codo / Regla %:** Identificar el punto de inflexión en los autovalores o acumular >80% de varianza.

COMPONENTES PRINCIPALES

Razonamiento Lógico

EIGENVALUES

	DIM.1	DIM.2	DIM.3
VARIANCE	2.776	0.123	0.100
% OF VAR.	92.546	4.112	3.342
CUMULATIVE % OF VAR.	92.546	96.658	100.000

```
Autovalores en orden descendiente:
2.93035377559
0.927403621517
0.148342226482
0.0207460139956
```

Eigenvalues

	Dim.1	Dim.2	Dim.3	Dim.4	Dim.5
Variance	4.081	0.374	0.217	0.205	0.124
% of var.	81.623	7.477	4.331	4.096	2.473
Cumulative % of var.	81.623	89.100	93.431	97.527	100.000

```
print(eigenvalues)
```

```
[6.55895193 1.65279831 1.35157702 0.88829539 0.85258439 0.66131773
 0.53647102 0.40387475 0.27781262 0.25275696 0.21321162 0.18334985
 0.13427506 0.06044612]
```

COMPONENTES PRINCIPALES: ejemplo Iris

El conjunto de datos iris de Fisher es un conjunto de datos multivariados introducido por Ronald Fisher en su artículo de 1936. The use of multiple measurements in taxonomic problems.
Se midieron cuatro rasgos de cada muestra: el largo y ancho del sépalo y pétalo, en cm.



Iris Versicolor | Iris Setosa | Iris Virginica

Especie	Sepal length (cm)	Sepal width (cm)	Petal length (cm)	Petal width (cm)
Setosa	5.01 ± 0.05	3.43 ± 0.05	1.46 ± 0.02	0.25 ± 0.01
Versicolor	5.94 ± 0.07	2.77 ± 0.04	4.26 ± 0.07	1.33 ± 0.03
Virginica	6.59 ± 0.09	2.97 ± 0.05	5.55 ± 0.08	2.03 ± 0.04

COMPONENTES PRINCIPALES: ejemplo

dataset *Iris* se puede cargar el conjunto de datos desde la librería *seaborn*.

	sepal_length	sepal_width	petal_length	petal_width	species
0	5.1	3.5	1.4	0.2	setosa
1	4.9	3.0	1.4	0.2	setosa
2	4.7	3.2	1.3	0.2	setosa
3	4.6	3.1	1.5	0.2	setosa
4	5.0	3.6	1.4	0.2	setosa

```
iris.corr()
```

	sepal_length	sepal_width	petal_length	petal_width
sepal_length	1.000000	-0.117570	0.871754	0.817941
sepal_width	-0.117570	1.000000	-0.428440	-0.366126
petal_length	0.871754	-0.428440	1.000000	0.962865
petal_width	0.817941	-0.366126	0.962865	1.000000

Autovalores

Lambda	Proporción	Prop Acum
1	2,92	0,73	0,73
2	0,91	0,23	0,96
3	0,15	0,04	0,99
4	0,02	0,01	1,00

Λ

Autovectores

Variables	q1	q2	q3
SepalLen	0,52	0,38	0,72
SepalWid	-0,27	0,92	-0,24
PetalLen	0,58	0,02	-0,14
PetalWid	0,56	0,07	-0,63

Q

Correlaciones con las variables originales

Variables	CP 1	CP 2	CP 3
SepalLen	0,89	0,36	0,28
SepalWid	-0,46	0,88	-0,09
PetalLen	0,99	0,02	-0,05
PetalWid	0,96	0,06	-0,24

$Corr(CP_i, X_i)$

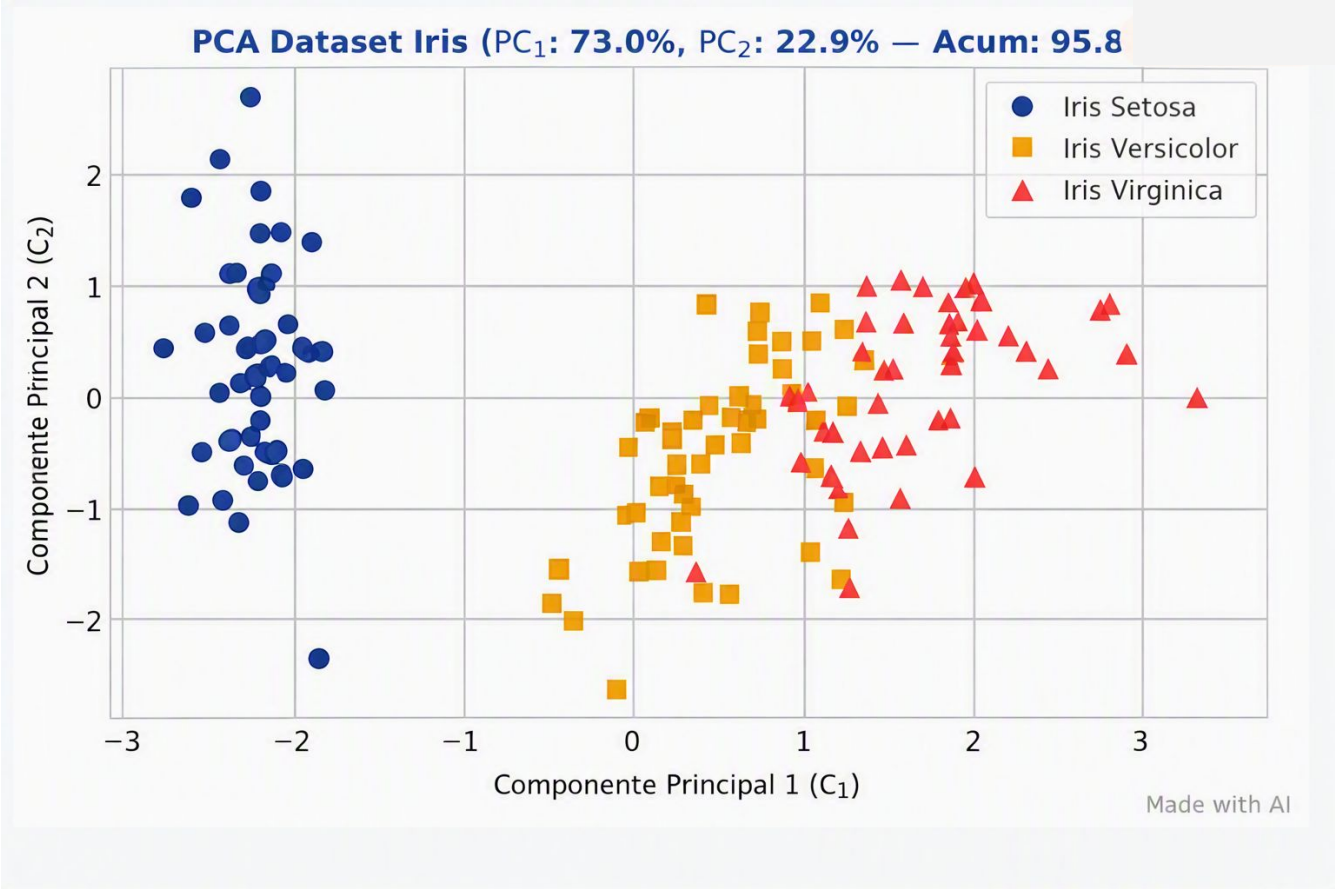
COMPONENTES PRINCIPALES: G-plot

Varianza explicada

Componente	Autovalor (λ)	Varianza Acumulada
CP 1	2.92	72.96%
CP 2	0.91	95.81%
CP 3	0.15	99.58%
CP 4	0.02	100.00%

El primer componente principal explica un 72.96% de la variación total de los datos originales, mientras que el segundo explica un 22.85%. Conjuntamente, los dos componentes principales explican alrededor del 95.81% de la variación total

Visualización



COMPONENTES PRINCIPALES

Autovalores

Lambda	Proporción	Prop Acum
1 2,92	0,73	0,73
2 0,91	0,23	0,96
3 0,15	0,04	0,99
4 0,02	0,01	1,00

Autovectores

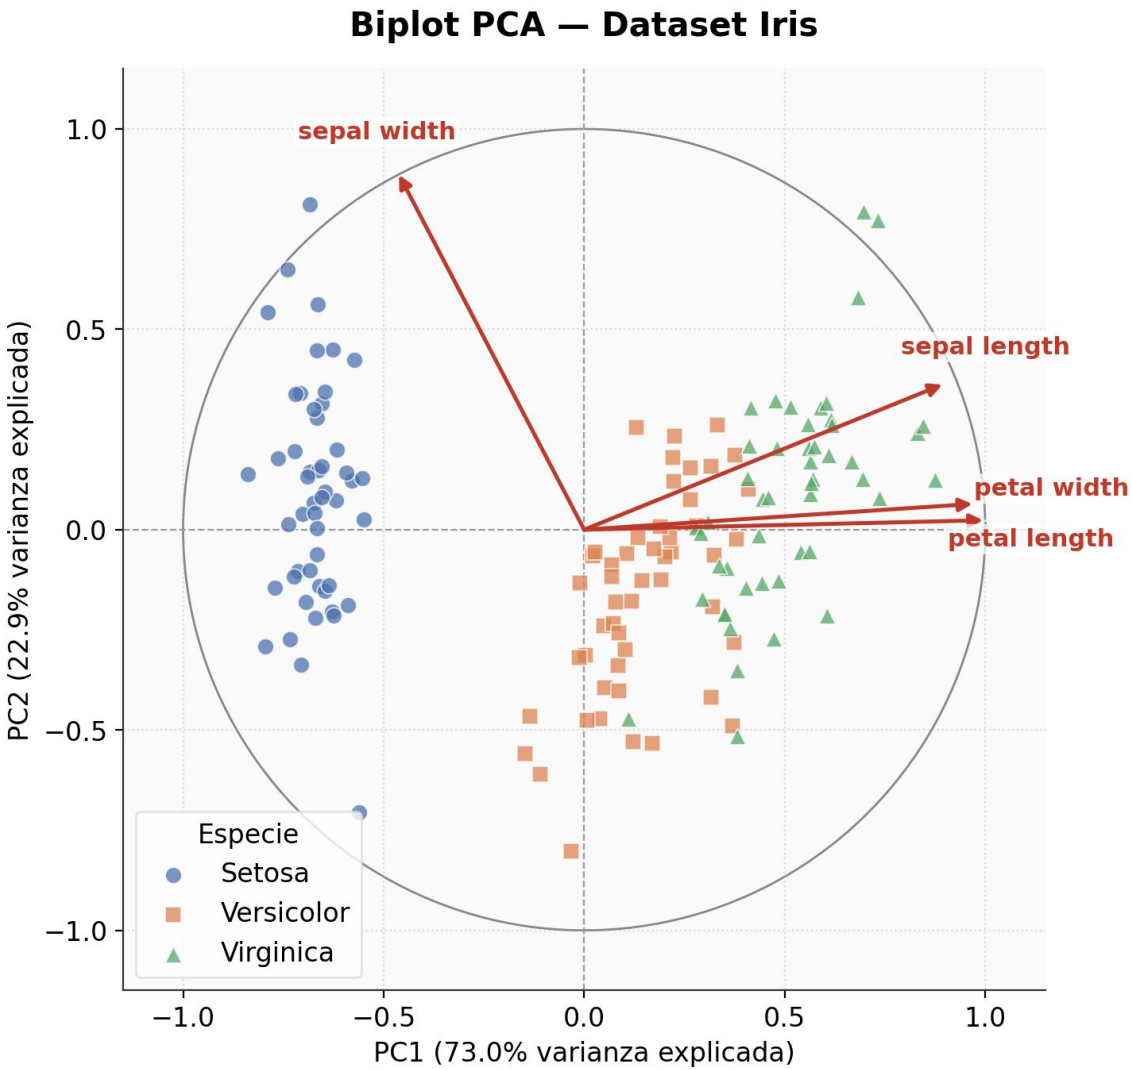
Variables	q1	q2	q3
SepalLen	0,52	0,38	0,72
SepalWid	-0,27	0,92	-0,24
PetalLen	0,58	0,02	-0,14
PetalWid	0,56	0,07	-0,63

Loadings

Correlaciones con las variables originales

Variables	CP 1	CP 2	CP 3
SepalLen	0,89	0,36	0,28
SepalWid	-0,46	0,88	-0,09
PetalLen	0,99	0,02	-0,05
PetalWid	0,96	0,06	-0,24

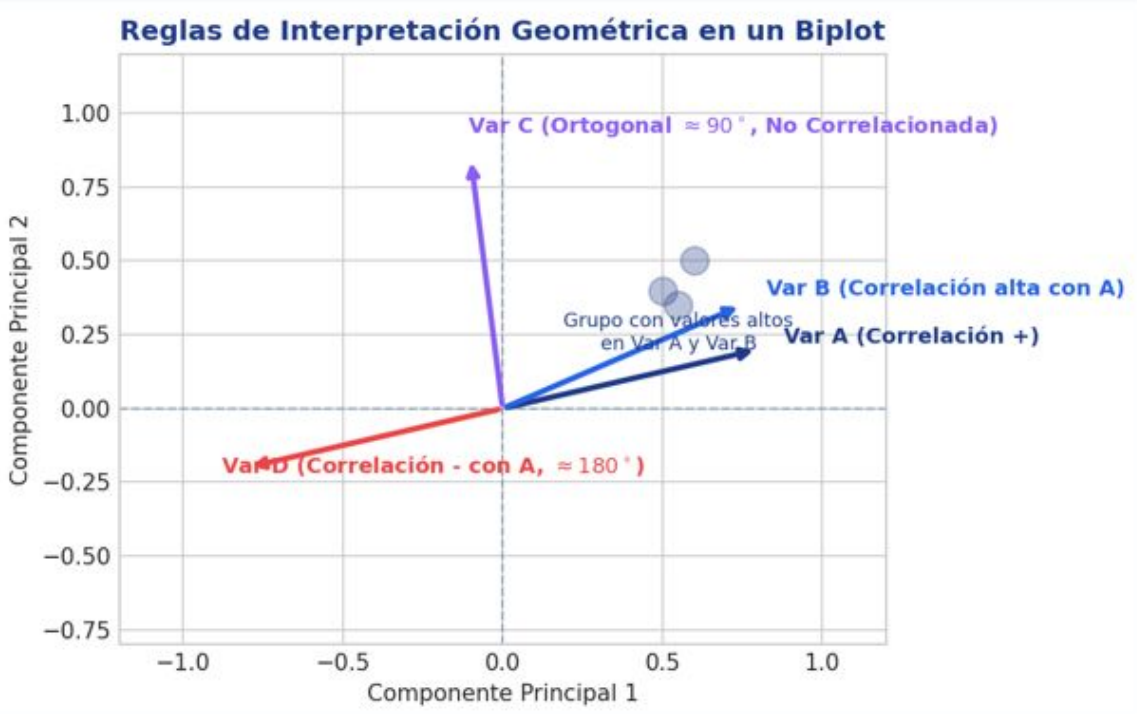
$$Cor(CP_j, X_i) = \lambda_j^{1/2} q_{ij}$$



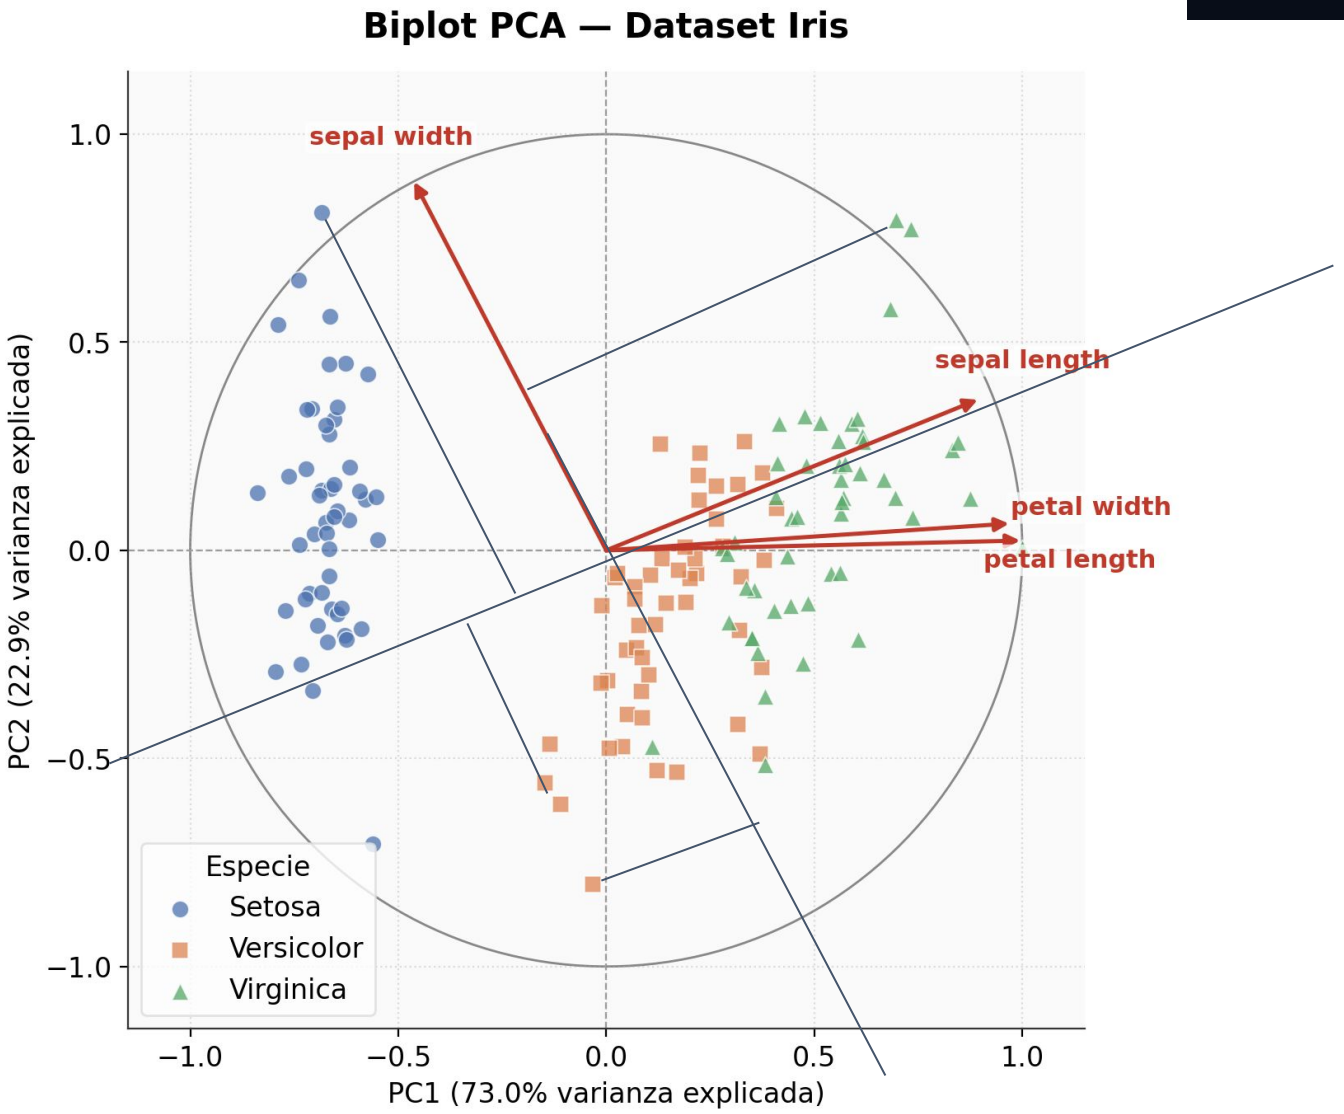
COMPONENTES PRINCIPALES

Reglas de Lectura

- **Vectores (Variables):** El ángulo entre vectores indica correlación (agudo = +, recto = 0, obtuso/180° = -).
- **Longitud del Vector:** Vectores más largos están mejor representados en el plano principal 2D.
- **Scores (Individuos):** Puntos cercanos representan observaciones con comportamiento multivariado similar.
- **Origen (0,0):** Puntos cerca del centro corresponden a individuos con valores cercanos a la media global.



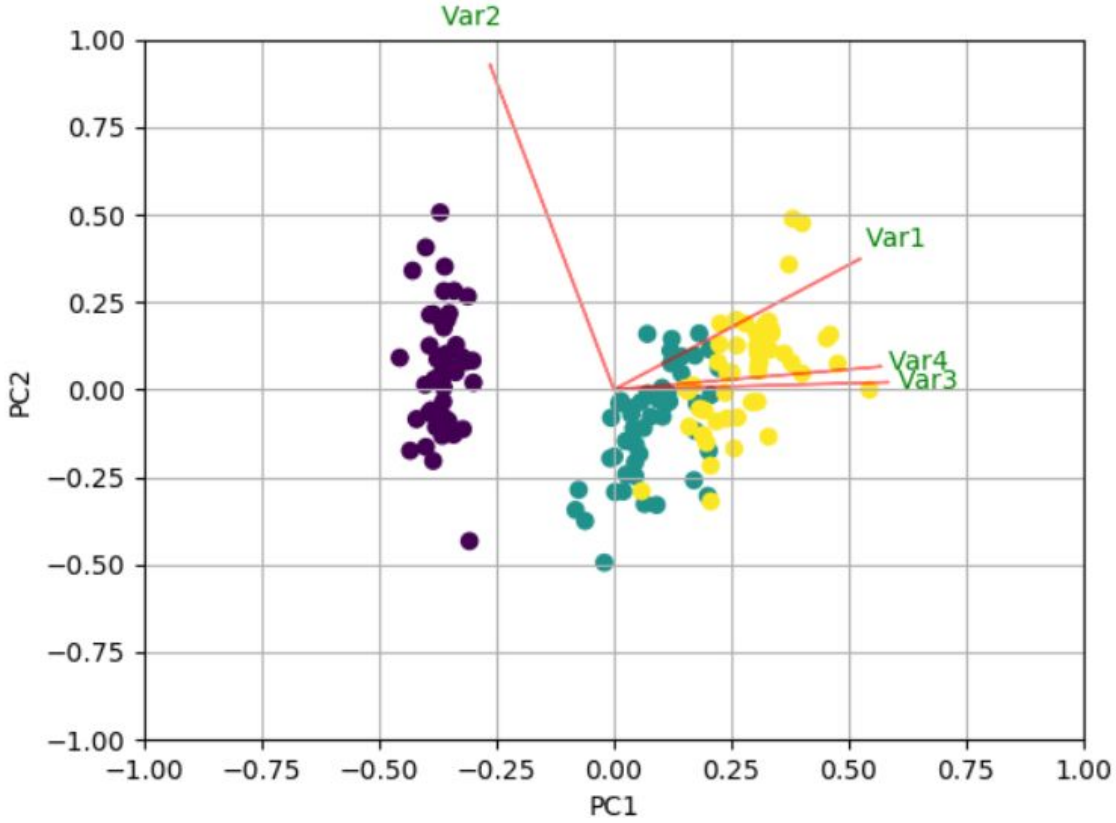
COMPONENTES PRINCIPALES

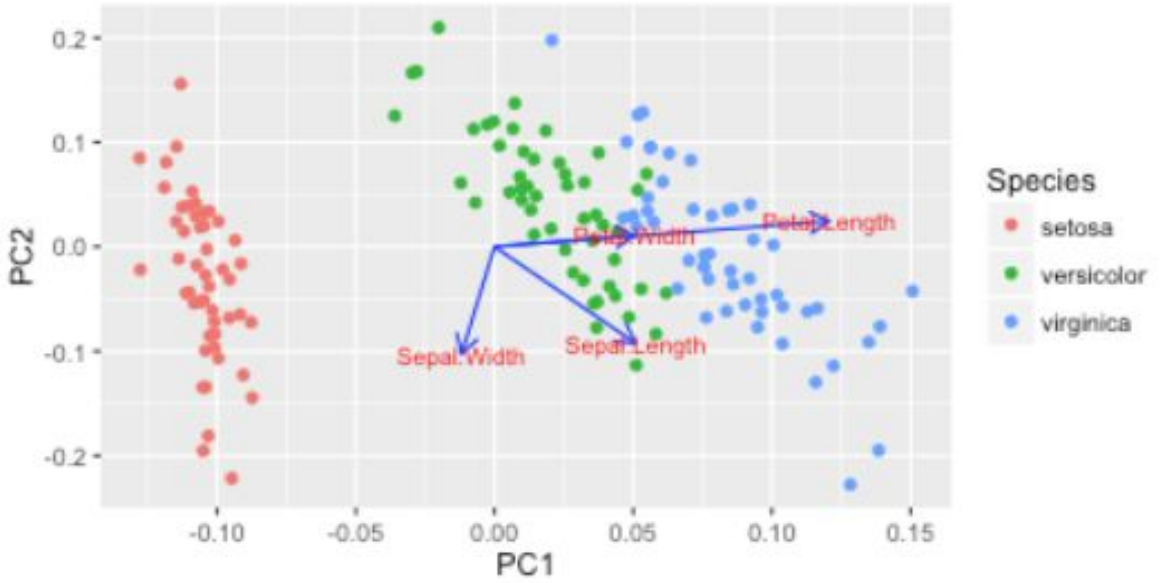


La relación de las observaciones con las variables se puede analizar **proyectando las observaciones sobre la dirección de los vectores.**

COMPONENTES PRINCIPALES

CUIDADO!





COMPONENTES PRINCIPALES

Ejemplo Práctico 2: Dataset Boston Housing (p = 13)

Autovalores

	Lambda	Proporción	Prop Acum
1	6,44	0,50	0,50
2	1,57	0,12	0,62
3	1,35	0,10	0,72
4	0,87	0,07	0,79
5	0,70	0,05	0,84
6	0,43	0,03	0,87
7	0,38	0,03	0,90
8	0,35	0,03	0,93
9	0,26	0,02	0,95
10	0,23	0,02	0,97
11	0,20	0,02	0,98
12	0,16	0,01	1,00
13	0,06	4,6E-03	1,00

Autovectores

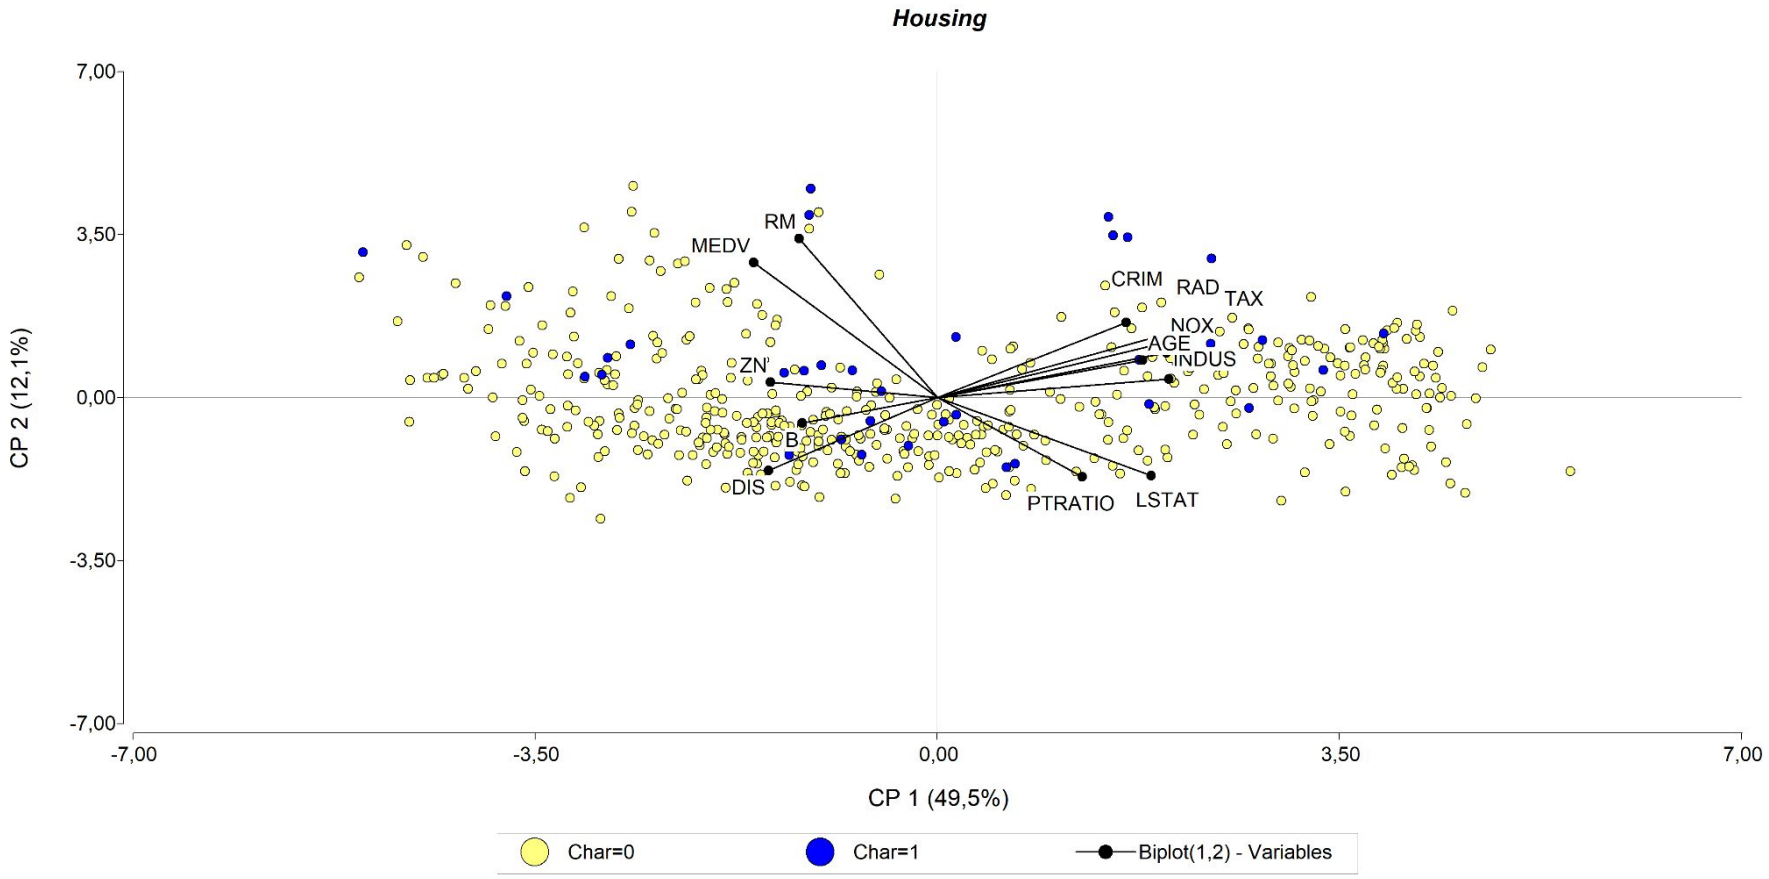
Variables	e1	e2	e3	
CRIM	0,27	0,27		0,33
ZN	-0,24	0,06		0,40
INDUS	0,34	0,07		-0,10
NOX	0,33	0,20		-0,18
RM	-0,20	0,57		0,05
AGE	0,30	0,13		-0,36
DIS	-0,24	-0,26		0,43
RAD	0,31	0,21		0,37
TAX	0,33	0,16		0,32
PTRATIO	0,21	-0,28		0,25
B	-0,20	-0,09		-0,24
LSTAT	0,31	-0,28		-0,09
MEDV	-0,27	0,48		-0,09

Correlaciones con las variables

Variables	CP 1	CP 2	CP 3
CRIM	0,69	0,34	0,38
ZN	-0,61	0,07	0,46
INDUS	0,85	0,08	-0,12
NOX	0,84	0,25	-0,21
RM	-0,51	0,71	0,06
AGE	0,76	0,17	-0,42
DIS	-0,62	-0,33	0,50
RAD	0,79	0,27	0,43
TAX	0,84	0,20	0,37
PTRATIO	0,53	-0,35	0,29
B	-0,50	-0,11	-0,28
LSTAT	0,79	-0,35	-0,10
MEDV	-0,68	0,61	-0,10

COMPONENTES PRINCIPALES: Ejemplo casas Boston

Ejemplo Práctico 2: Dataset Boston Housing (p = 13)



Síntesis y Hacia Dónde Vamos

- **Síntesis de la Parte I:** Matriz de Datos → Geometría de Proyección → Descomposición Espectral → PCA / Biplot.
- **Limitación del PCA:** PCA asume relaciones estrictamente lineales en subespacios planos.
- **Próximo Paso (Parte II):** Introducción a métodos de reducción no lineal para estructuras curvilíneas complejas.
- **Técnicas No Lineales:** t-SNE (t-Distributed Stochastic Neighbor Embedding) y UMAP (Uniform Manifold Approximation).

