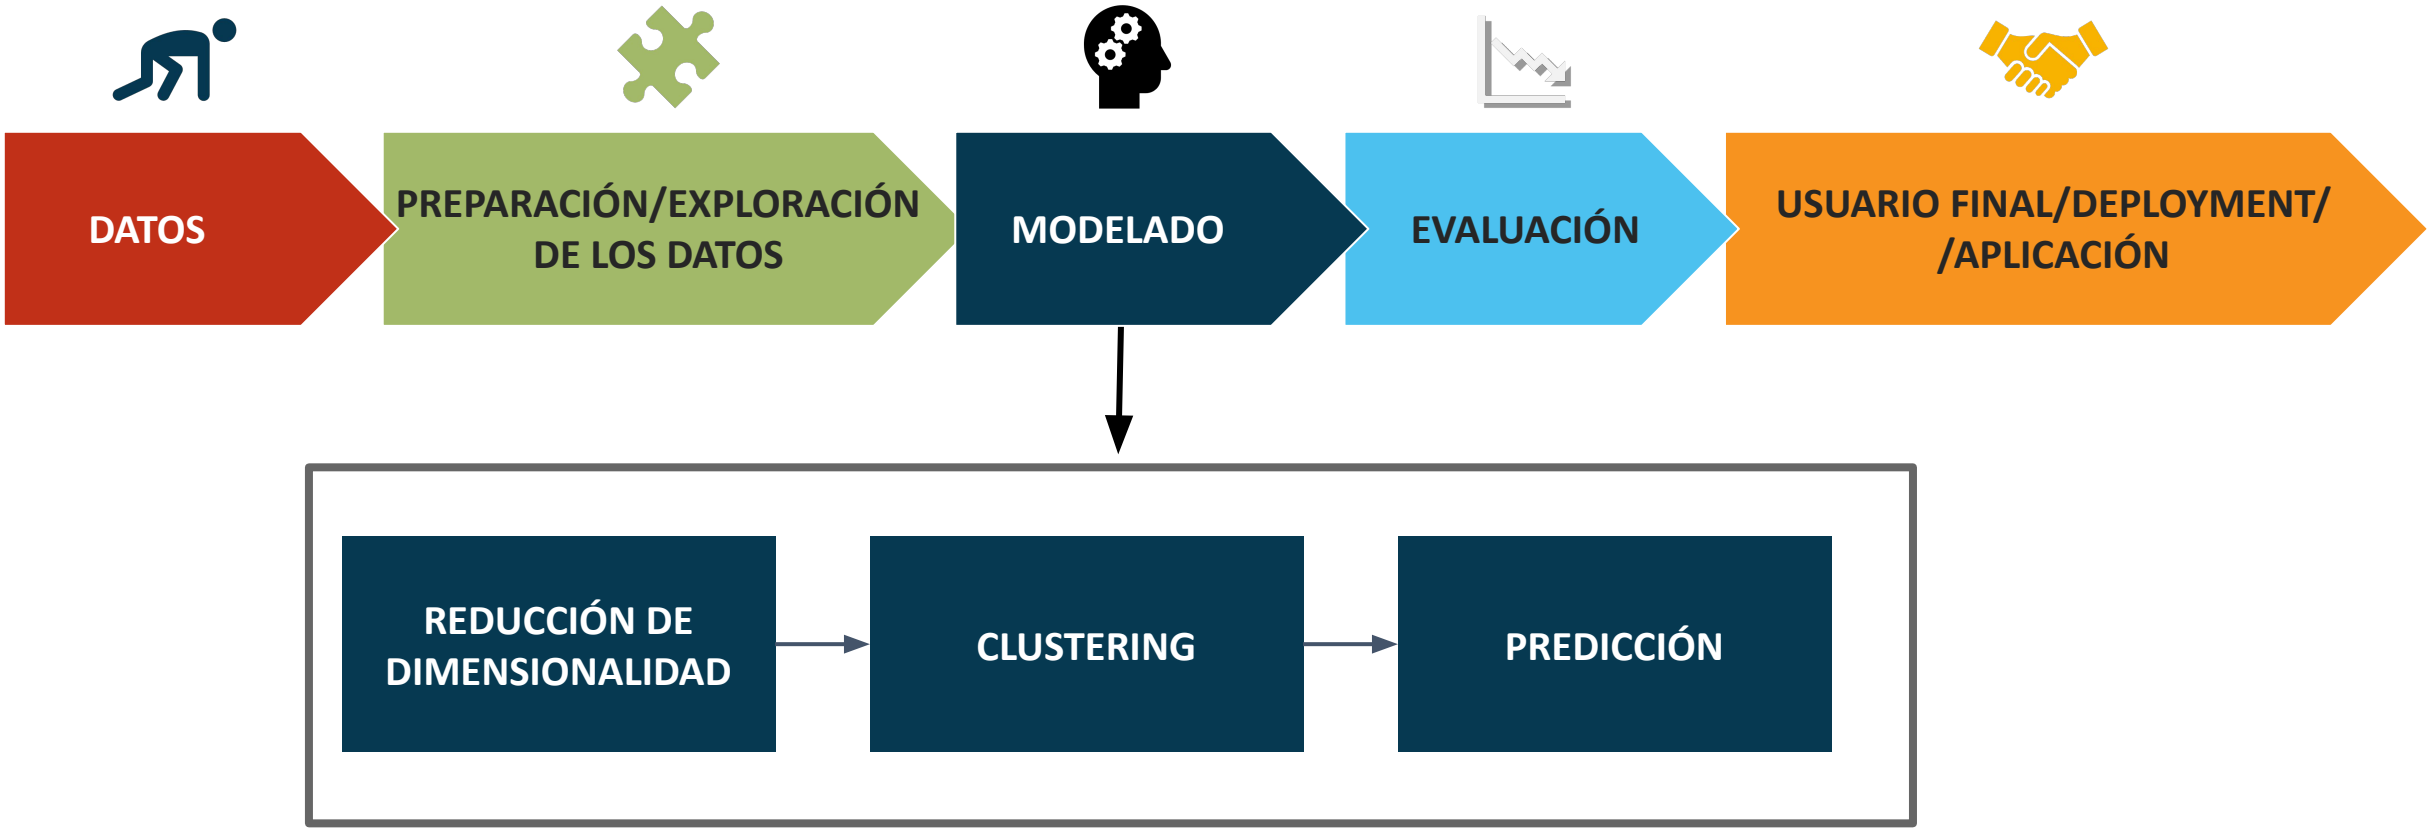


FACULTAD DE CIENCIAS EXACTAS UNICEN

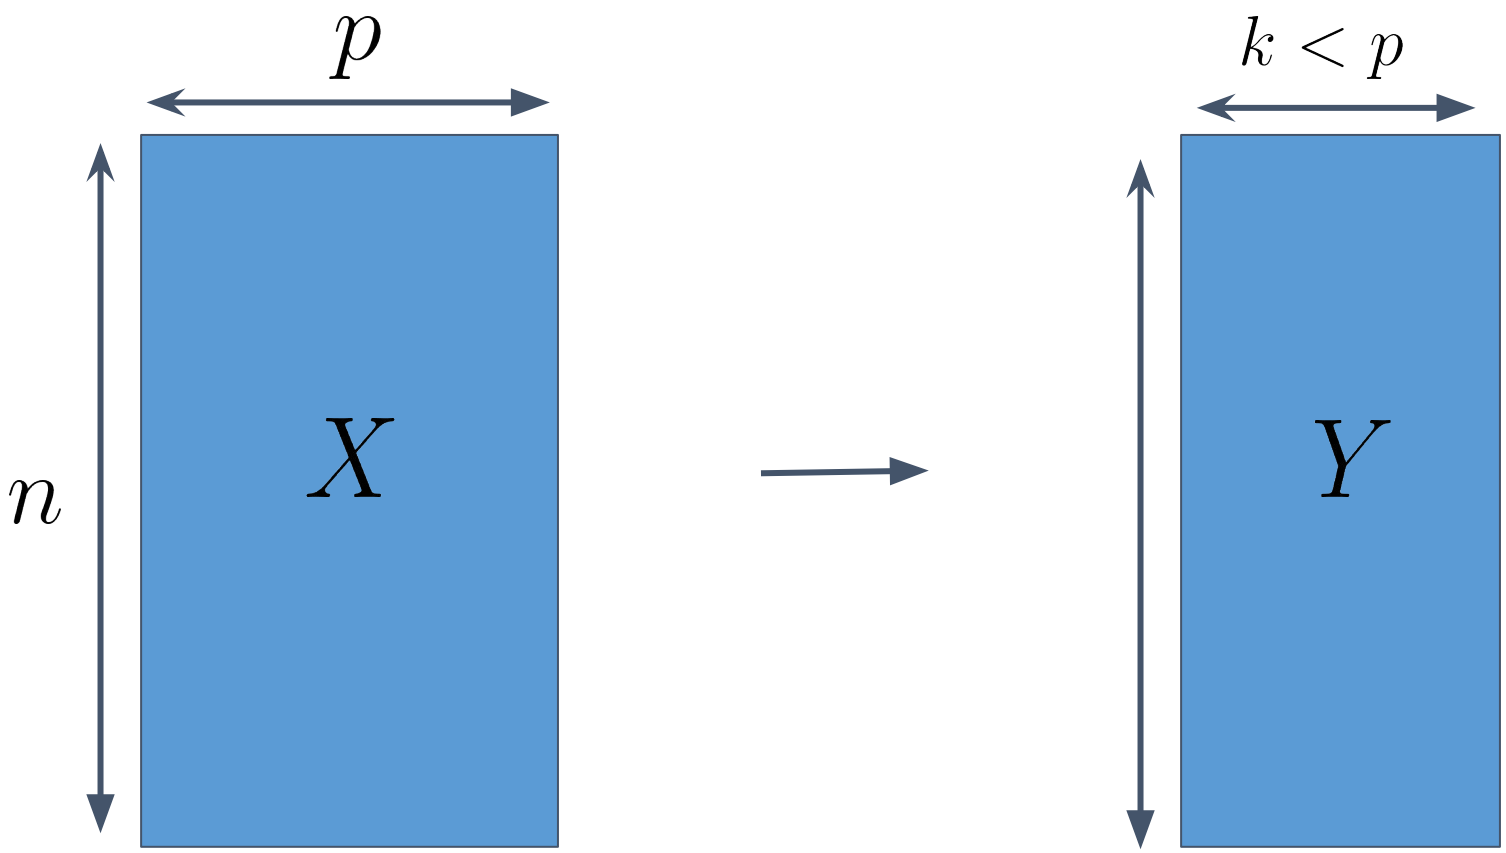
Reducción de dimensionalidad

(Parte II)

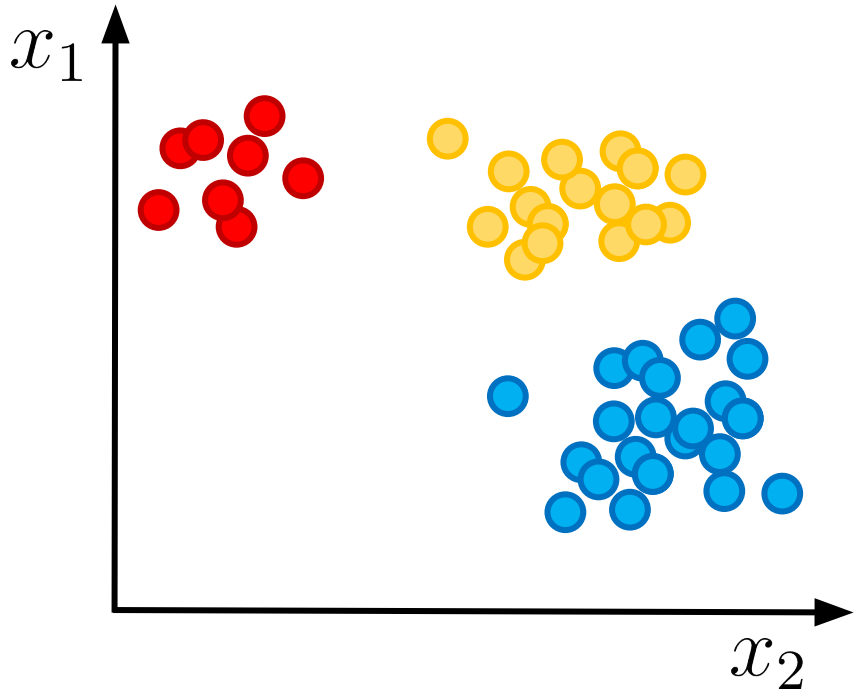
Roadmap


DATOS
PREPARACIÓN/EXPLORACIÓN DE LOS DATOS
MODELADO
EVALUACIÓN
USUARIO FINAL/DEPLOYMENT/ /APLICACIÓN
REDUCCIÓN DE DIMENSIONALIDAD
CLUSTERING
PREDICCIÓN

Reducción de dimensionalidad

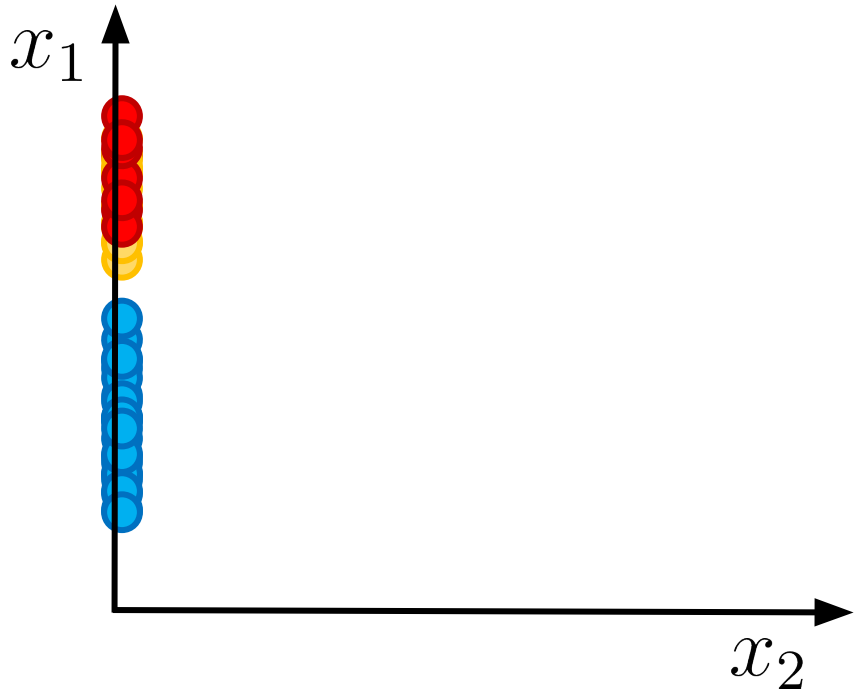


Reducción de dimensionalidad



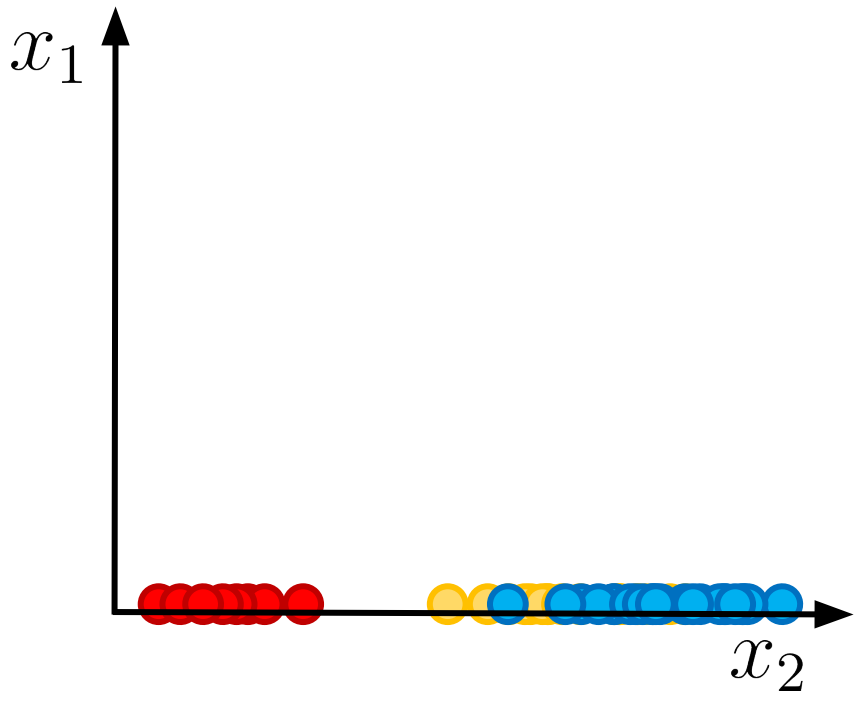
x1	x2
0.9	1.2
1.6	1.8
0.4	0.5
2.4	3.1
…	…

Reducción de dimensionalidad



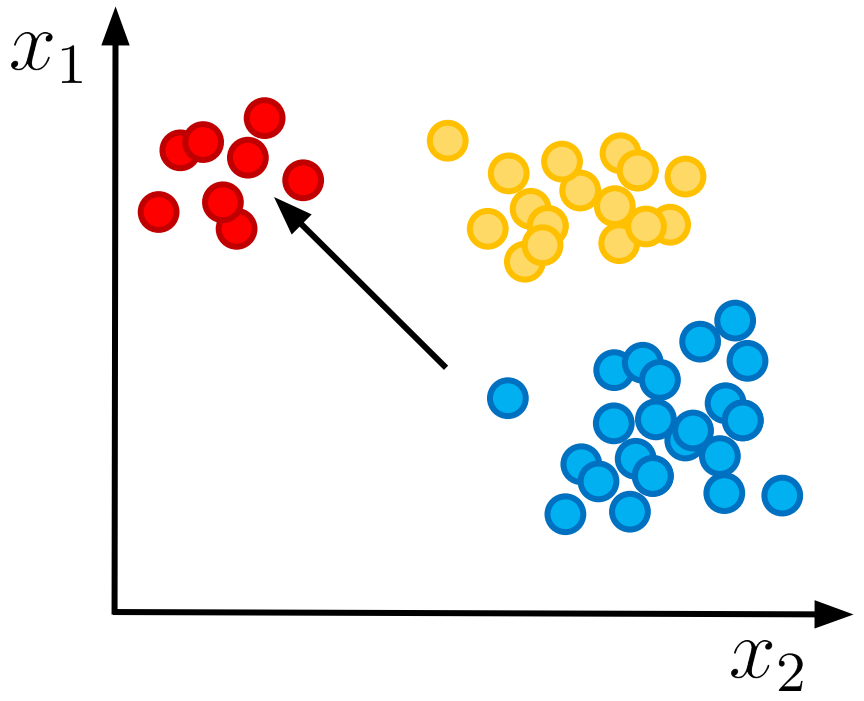
x1	x2
0.9	1.2
1.6	1.8
0.4	0.5
2.4	3.1
…	…

Reducción de dimensionalidad



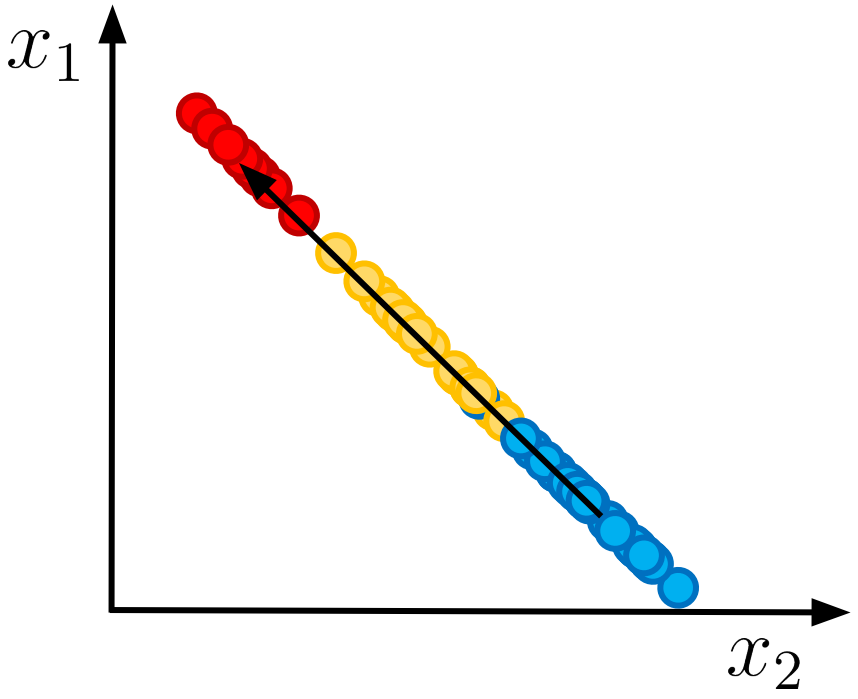
x1	x2
0.9	1.2
1.6	1.8
0.4	0.5
2.4	3.1
…	…

Reducción de dimensionalidad



x1	x2
0.9	1.2
1.6	1.8
0.4	0.5
2.4	3.1
…	…

Reducción de dimensionalidad

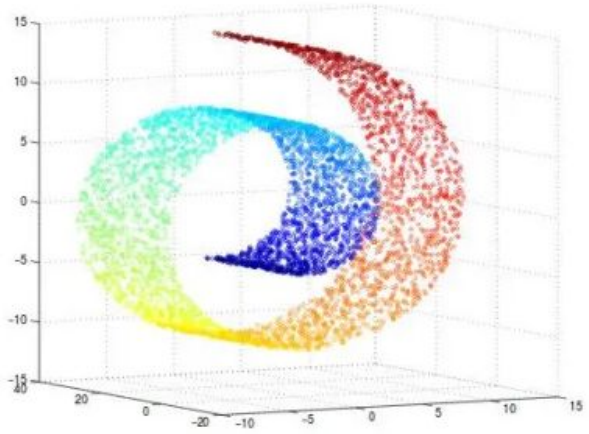


x1	x2
0.9	1.2
1.6	1.8
0.4	0.5
2.4	3.1
…	…

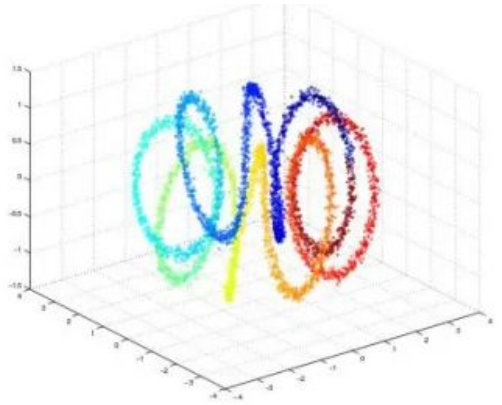


PC1
0.9
1.6
0.3
2.1
…

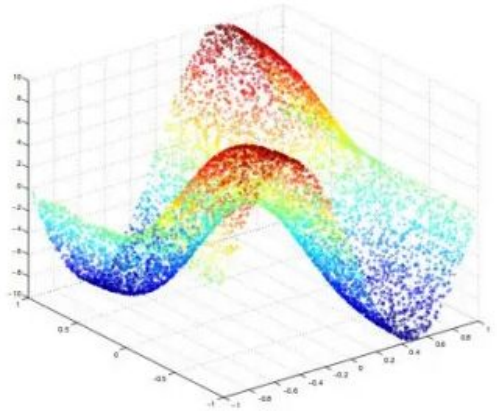
Reducción de dimensionalidad



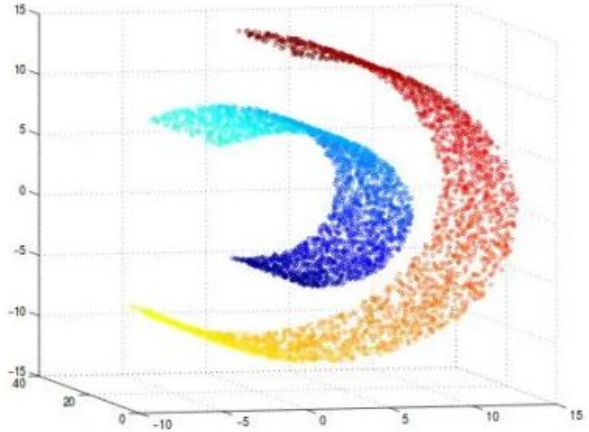
(a) Swiss roll dataset.



(b) Helix dataset.



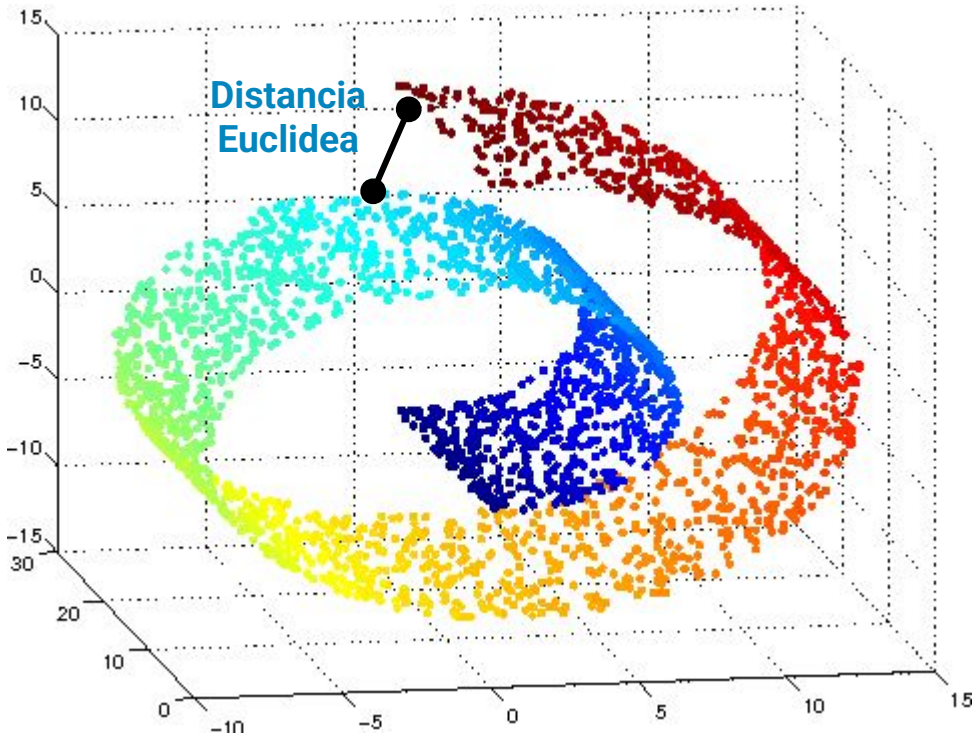
(c) Twinpeaks dataset.



(d) Broken Swiss roll dataset.

Reducción de dimensionalidad

- PCA es lineal de manera que no puede representar relaciones complejas entre las características
- PCA busca preservar distancias entre pares (maximizar covarianzas)
- Qué tan confiable es esa distancia?



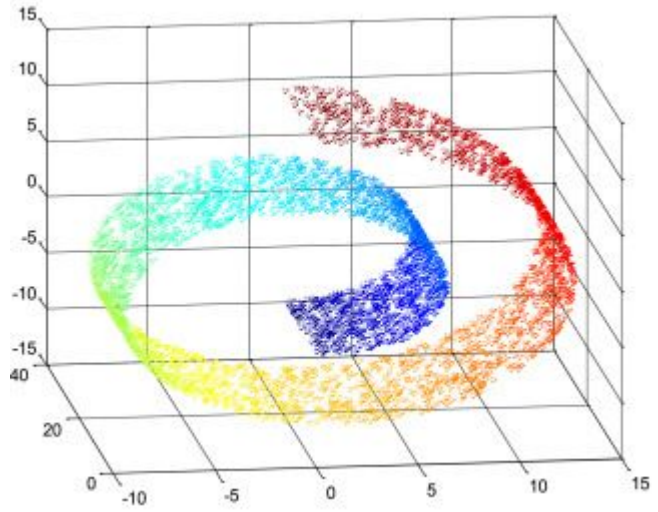
Reducción de dimensionalidad

Dos enfoques generales de reducción:

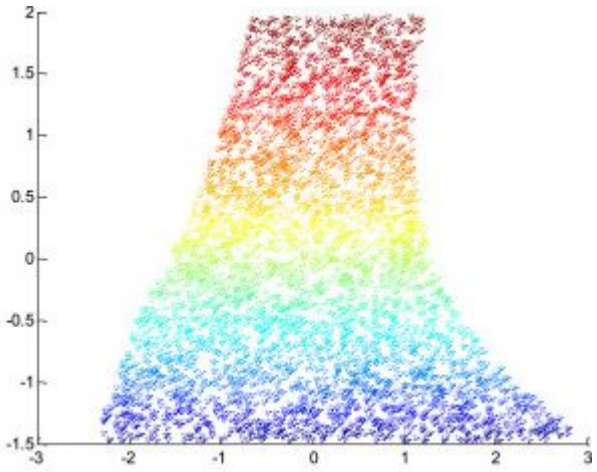
- **Proyección**: proyecta un espacio de alta dimensión en otro de menor dimensión
  - Mapeo lineal
  - Ejemplo: PCA
- **Manifold learning**: modelar el manifold (variedad) en el que están los datos
  - Mapeo no lineal
  - Ejemplo: t-SNE, UMAP

Manifold learning

Manifold hypothesis (hipótesis de la variedad) supone que a pesar de que los datos estén representados en un espacio euclidiano de alta dimensión, existe una variedad con dimensión intrínseca mucho menor donde podemos representarlos

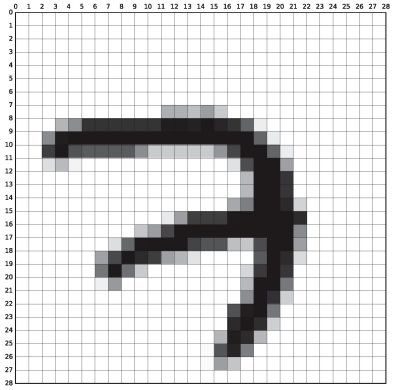


Dado un conjunto de *n* datos en *p* dimensiones estos representan un manifold de *k* dimensiones embebido en el espacio original, con *k<p*



Reducción de Dimensionalidad

SNE y t-SNE

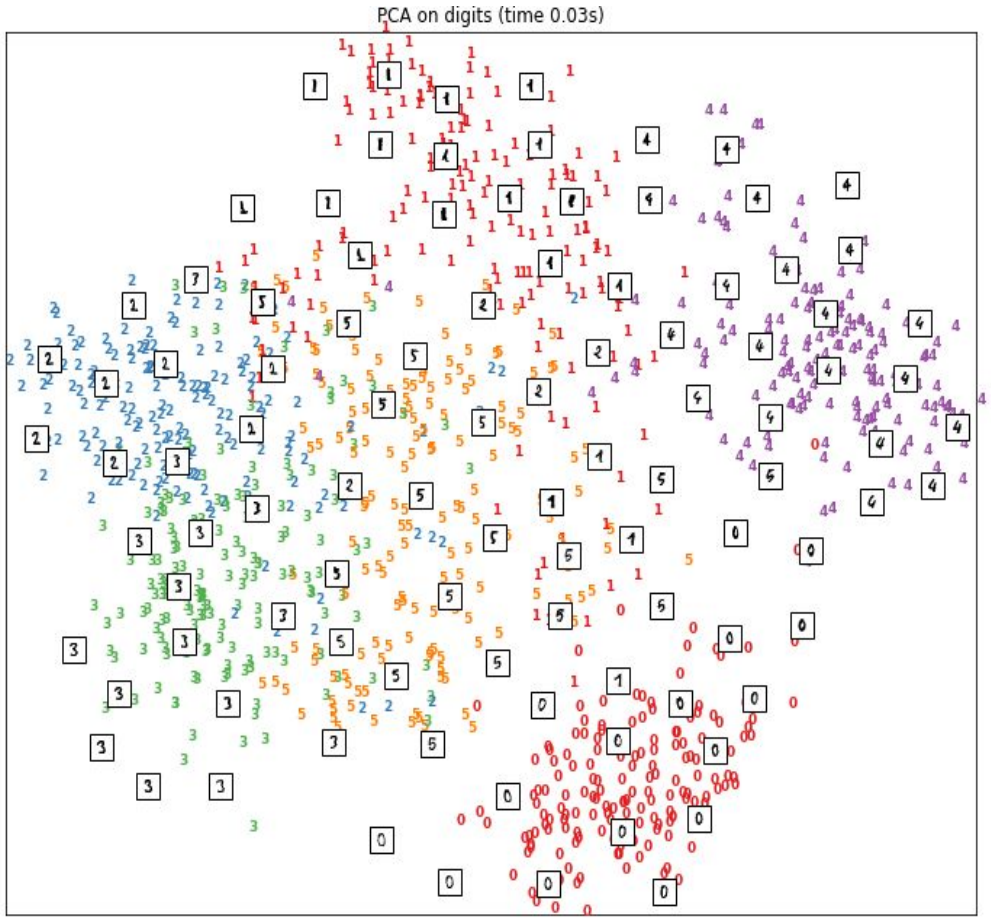


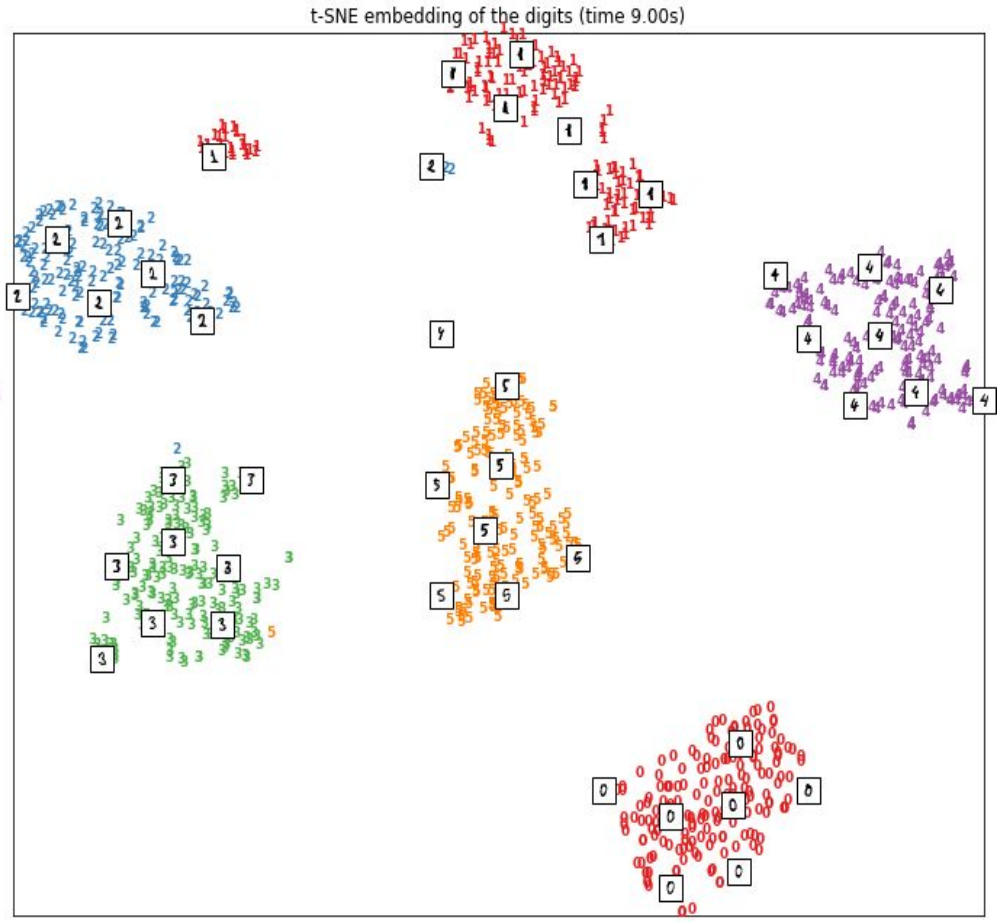
(**a**) MNIST sample belonging to the digit '7'.



(**b**) 100 samples from the MNIST training set.

28x28 píxeles





SNE y t-SNE

Stochastic Neighbor Embedding (SNE) (Hinton & Roweis, 2002)

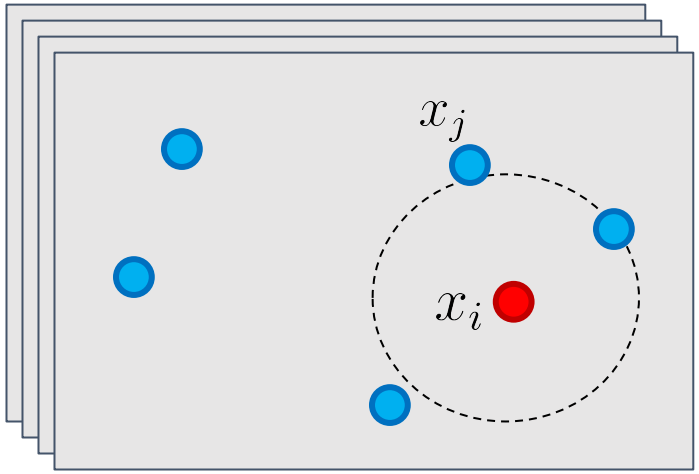
t-SNE (t-distributed Stochastic Neighbor Embedding)

Técnica no supervisada de reducción **no lineal** de la dimensionalidad para la exploración de datos y la visualización de datos de alta dimensión

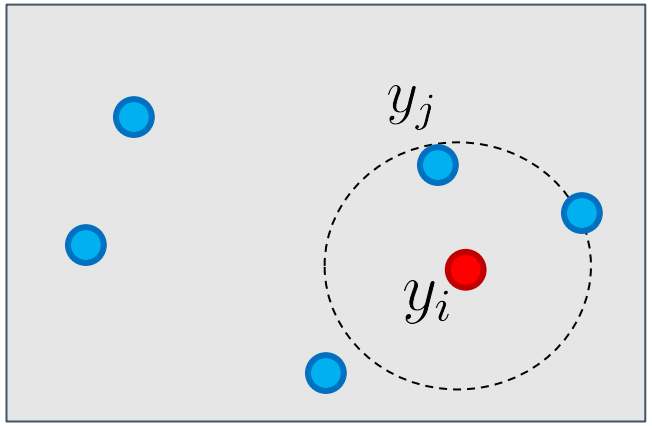
Reducción de Dimensionalidad

SNE y t-SNE

- Cada observación en el espacio de alta dimensional está representado por una observación en el espacio de menor dimensión
- La reducción busca **conservar el vecindario** en el espacio de menores dimensiones
- Similitudes por pares (pairwise similarities) entre las observaciones en ambos espacios



Alta dimensión

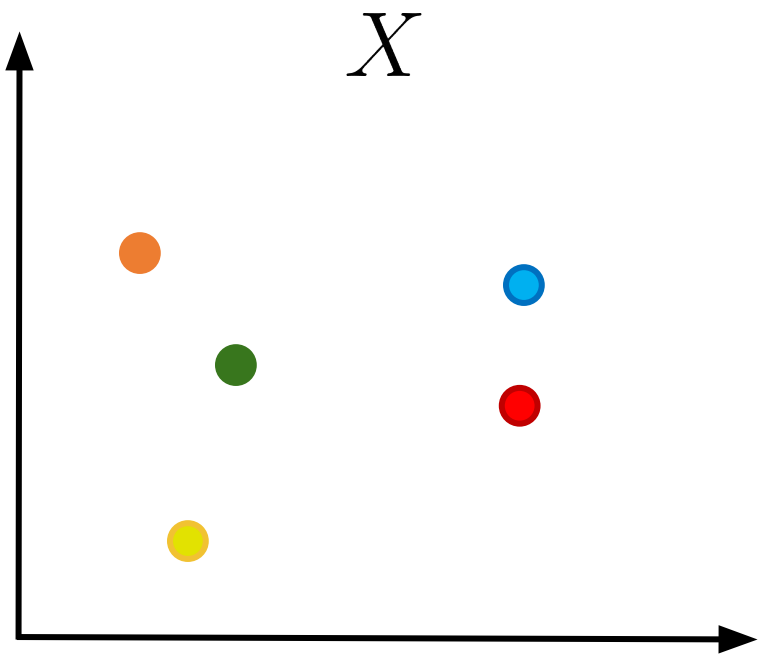


Baja dimensión

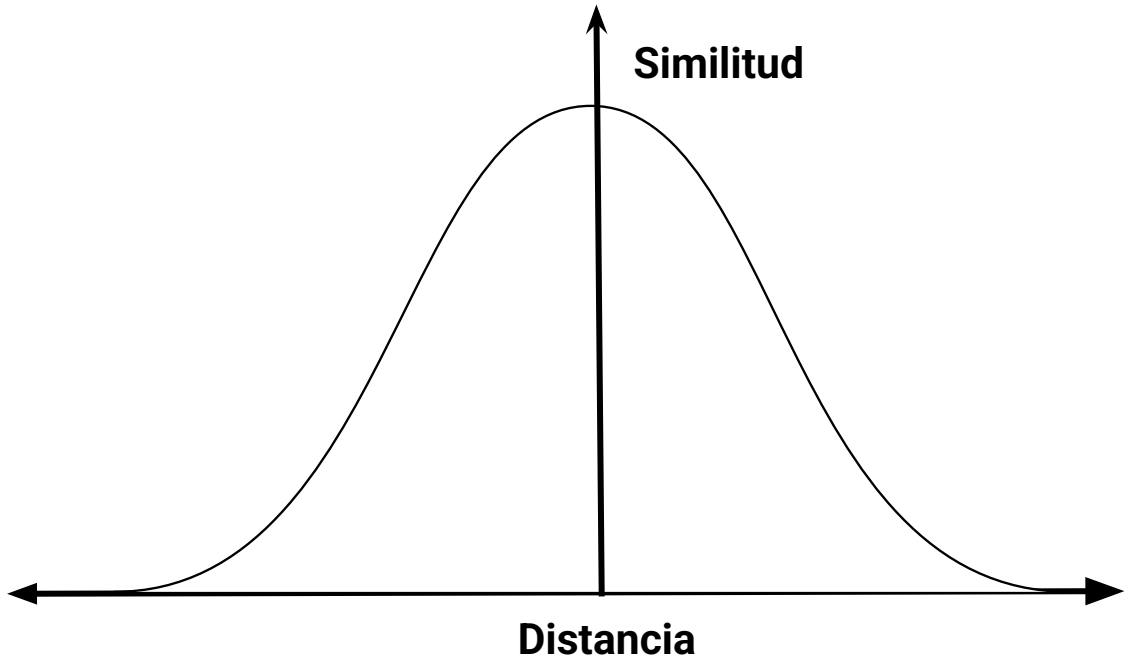
Reducción de Dimensionalidad

SNE y t-SNE

Las distancias euclidianas en el espacio altamente dimensional se convierten en **probabilidades condicionales** que representan similitudes



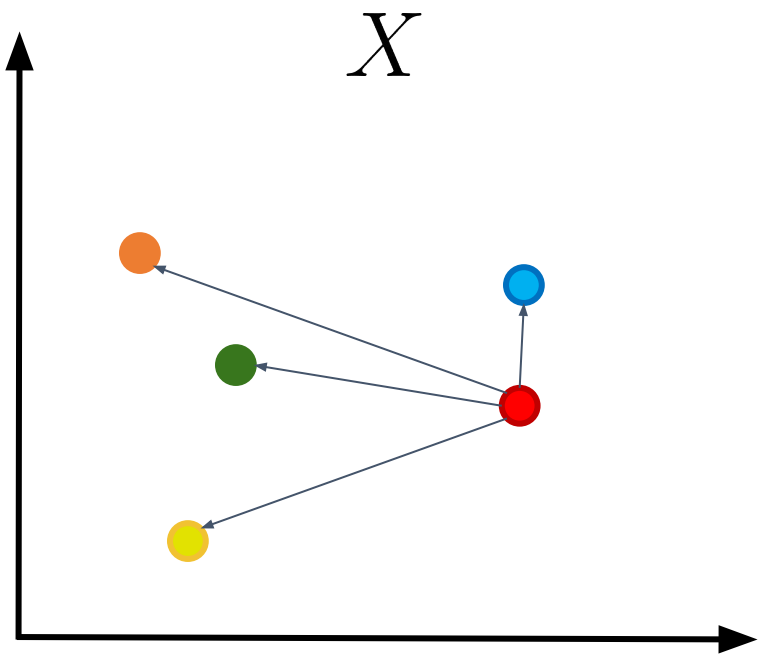
Vista de distancias



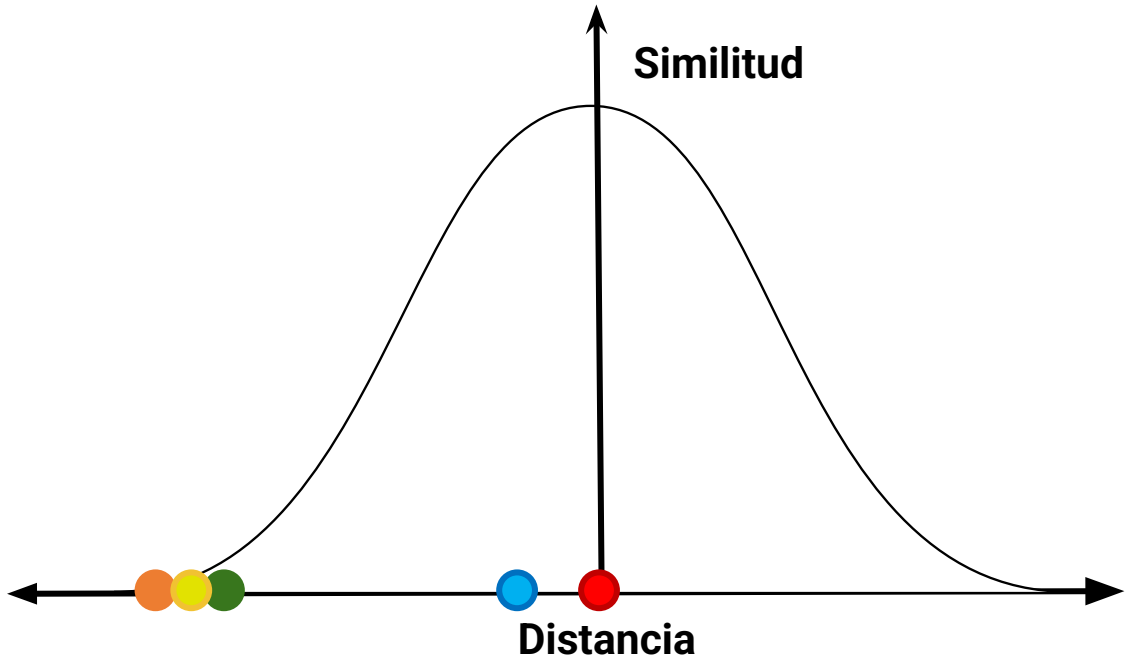
Vista de probabilidades

SNE y t-SNE

Las distancias euclidianas en el espacio altamente dimensional se convierten en **probabilidades condicionales** que representan similitudes

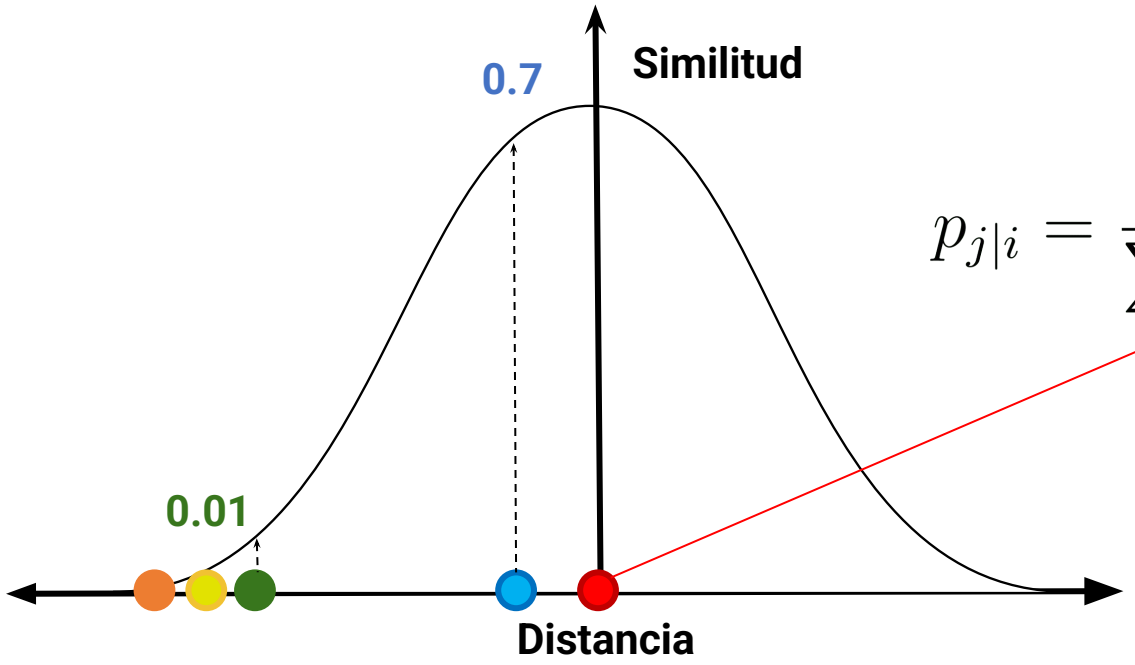


Vista de distancias



Vista de probabilidades

SNE y t-SNE



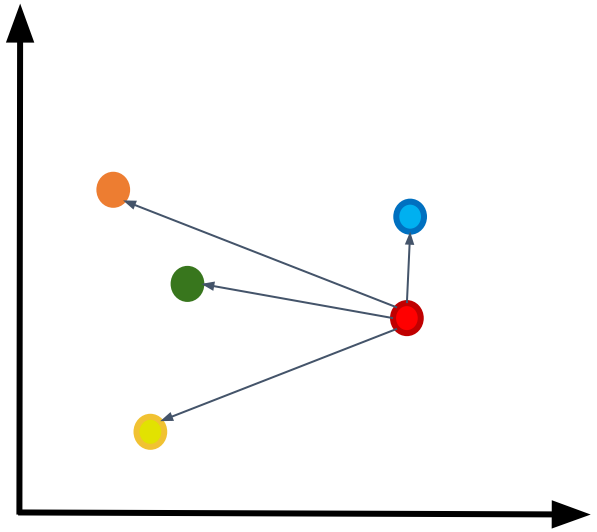
distancia euclidiana

varianza

$$p_{j|i} = \frac{\exp\left(-\|x_i - x_j\|^2 / 2\sigma_i^2\right)}{\sum_{k \neq i} \exp\left(-\|x_i - x_k\|^2 / 2\sigma_i^2\right)}$$

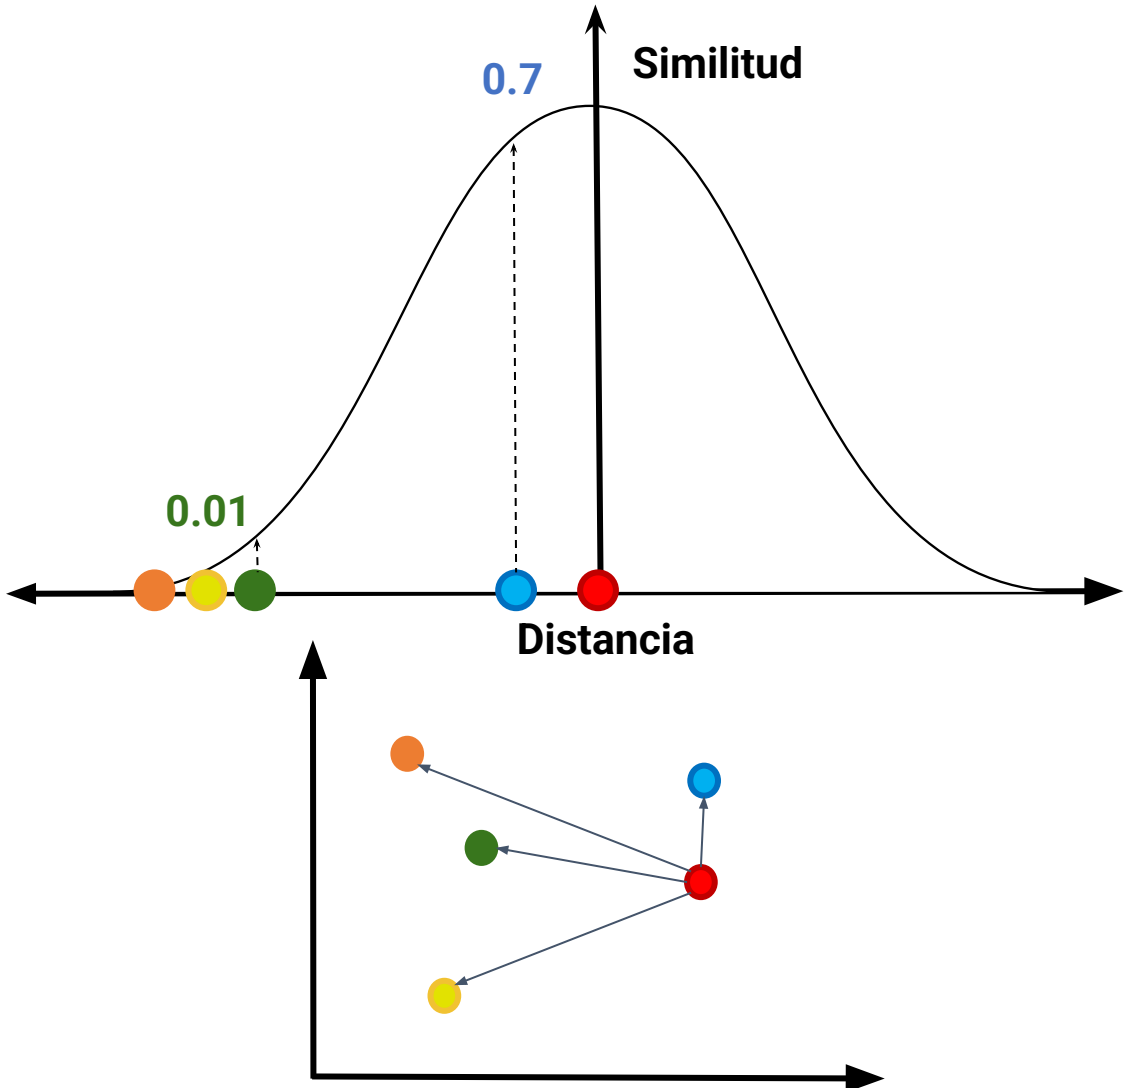
probabilidad condicional

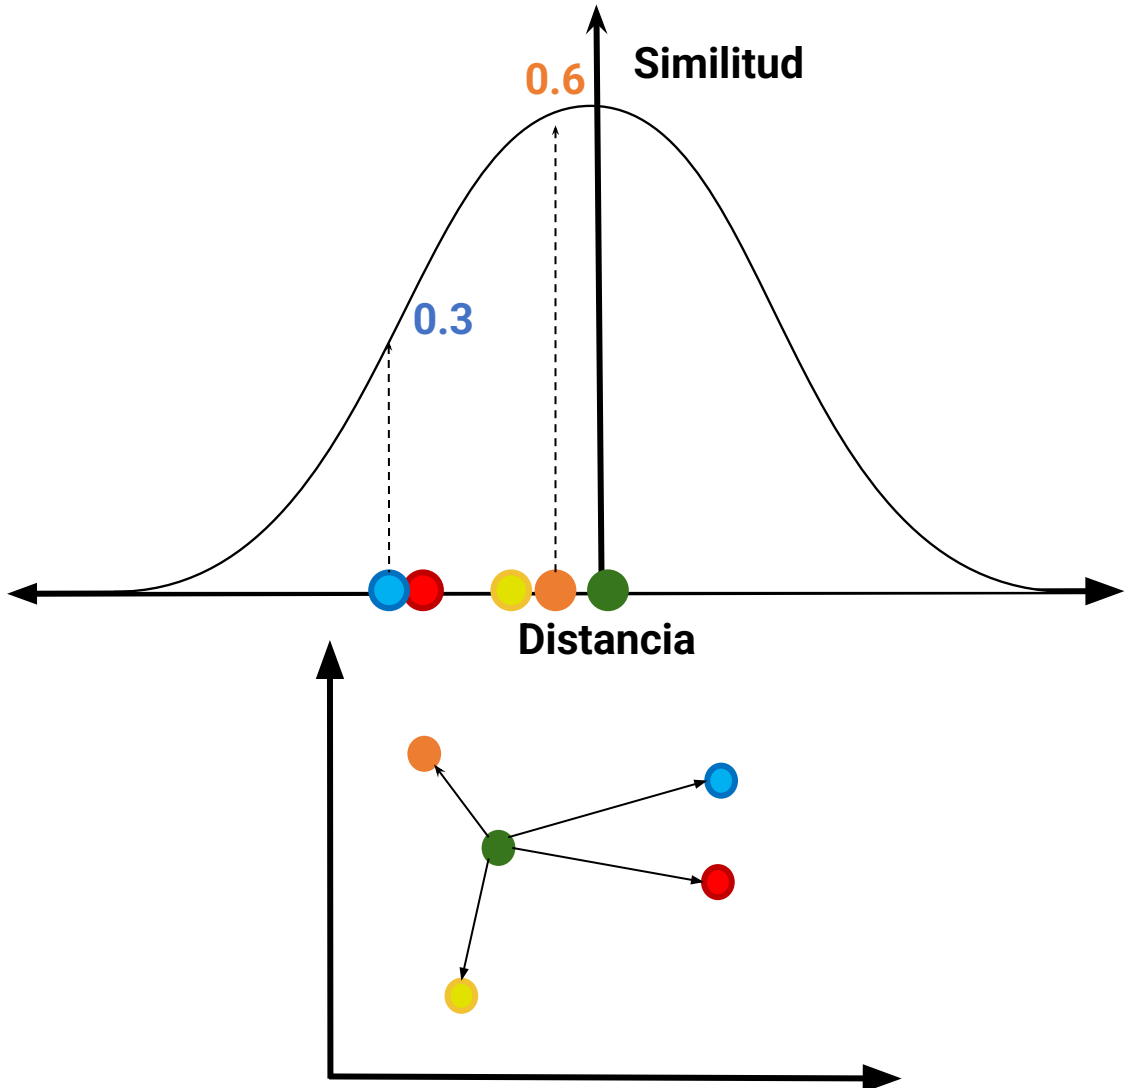
$p_{j|i}$ mide la probabilidad condicional que un punto *i* elija al punto *j* como su vecino más cercano



Reducción de Dimensionalidad

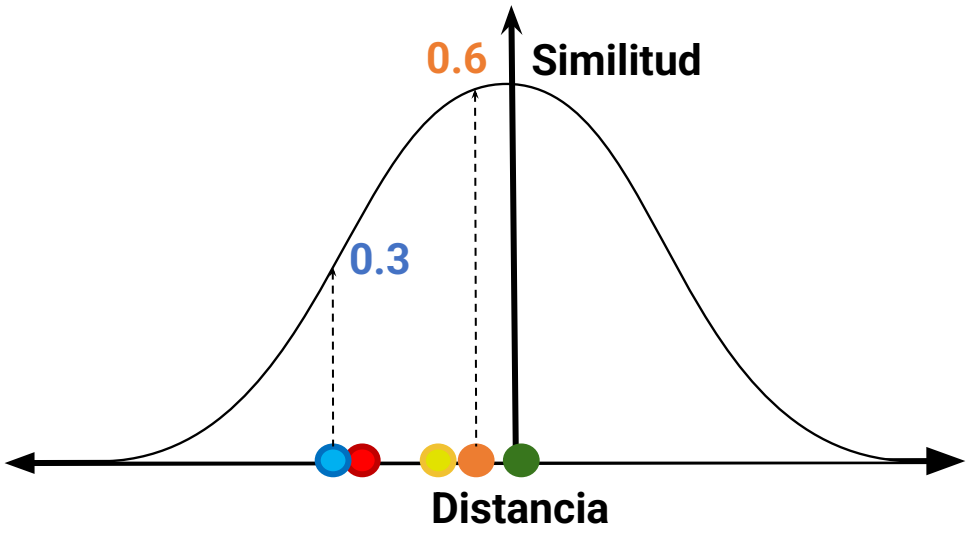
SNE y t-SNE

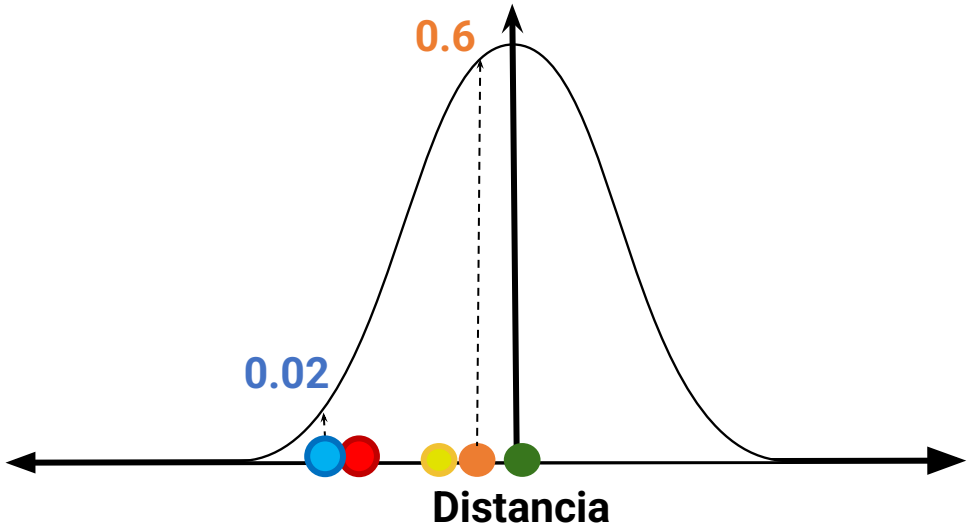


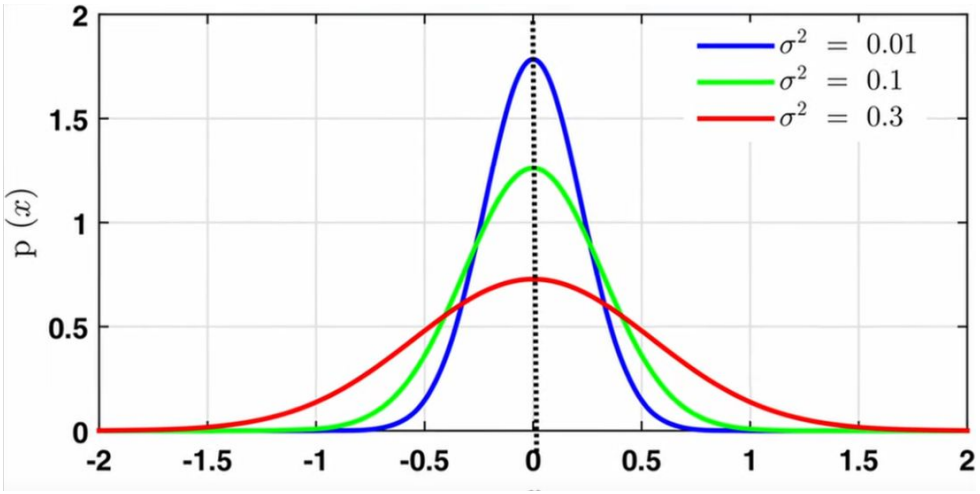


Reducción de Dimensionalidad

SNE y t-SNE

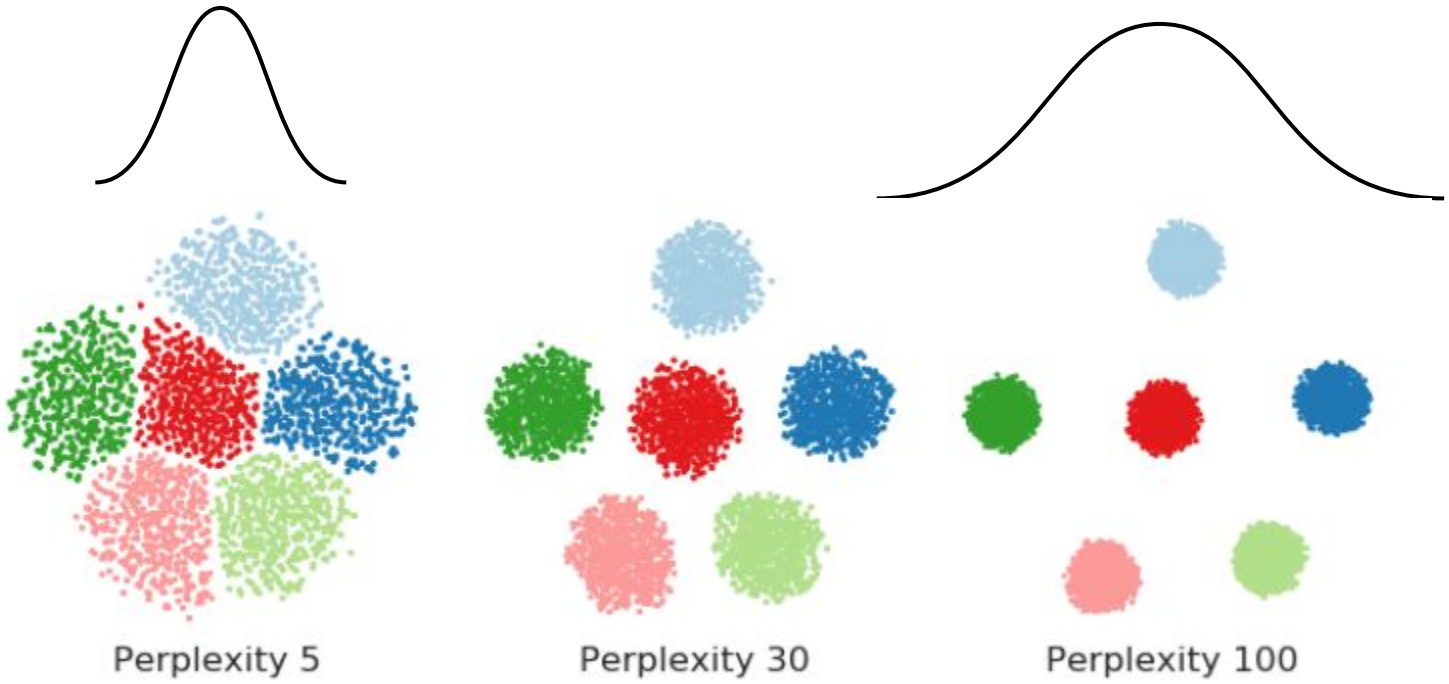






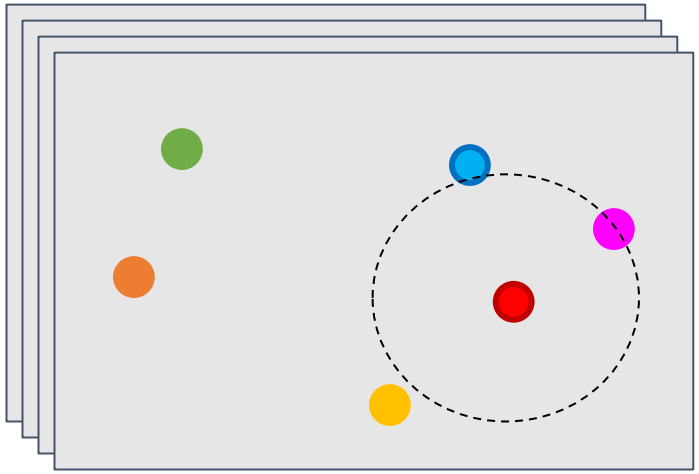
SNE y t-SNE

Perplexity: puede interpretarse como una medida del número efectivo de vecinos de una observación

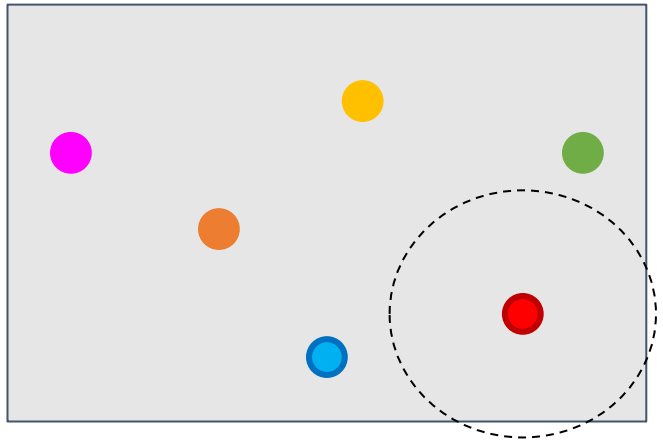


SNE y t-SNE

Para cada observación hay dos distribuciones de probabilidades, una en el espacio de alta dimensión $p_{j|i}$ y otra en el de menor dimensión $q_{j|i}$



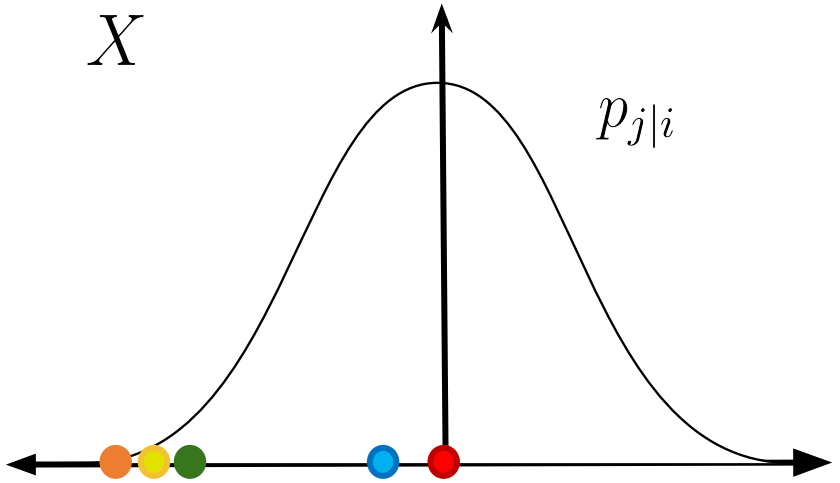
Alta dimensión



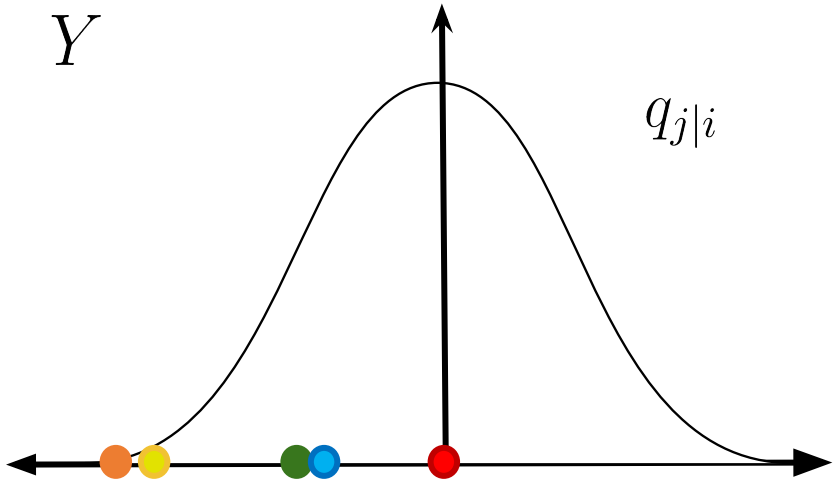
Baja dimensión

SNE y t-SNE

Para cada observación hay dos distribuciones de probabilidades, una en el espacio de alta dimensión $p_{j|i}$ y otra en el de menor dimensión $q_{j|i}$



Alta dimensión

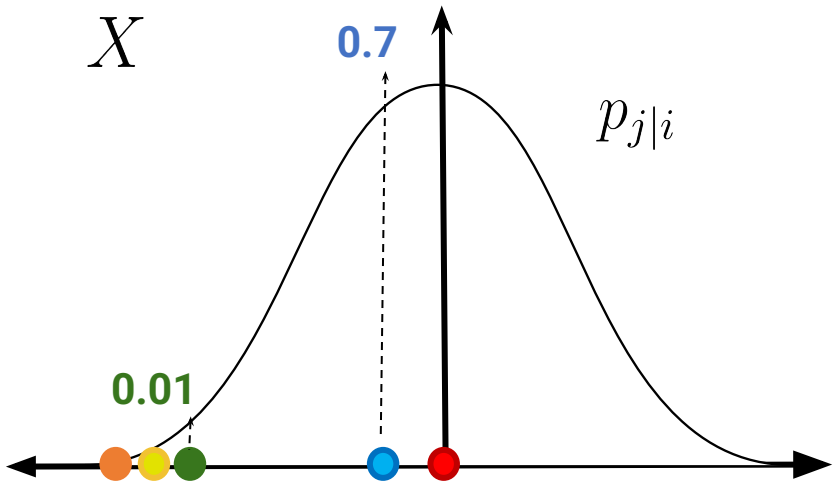


Baja dimensión

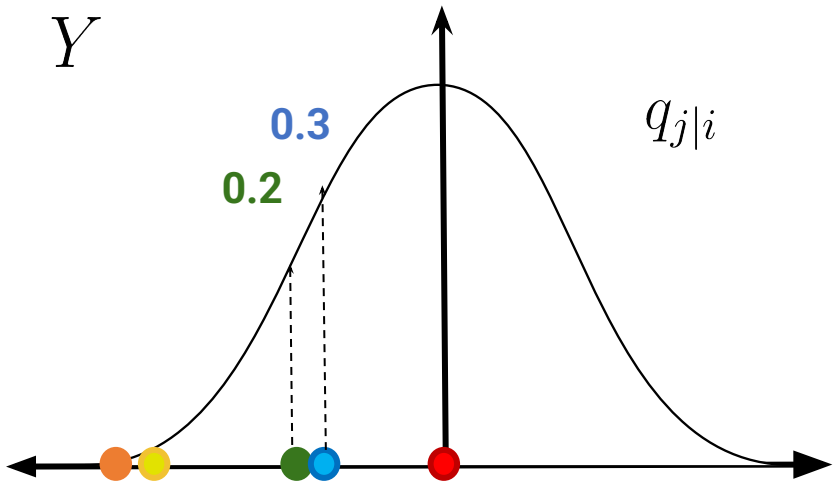
$$q_{j|i} = \frac{\exp\left(-\|y_i - y_j\|^2\right)}{\sum_{k \neq i} \exp\left(-\|y_i - y_k\|^2\right)}$$

SNE y t-SNE

Para cada observación hay dos distribuciones de probabilidades, una en el espacio de alta dimensión $p_{j|i}$ y otra en el de menor dimensión $q_{j|i}$



Alta dimensión



Baja dimensión

Kullback-Leibler Divergence

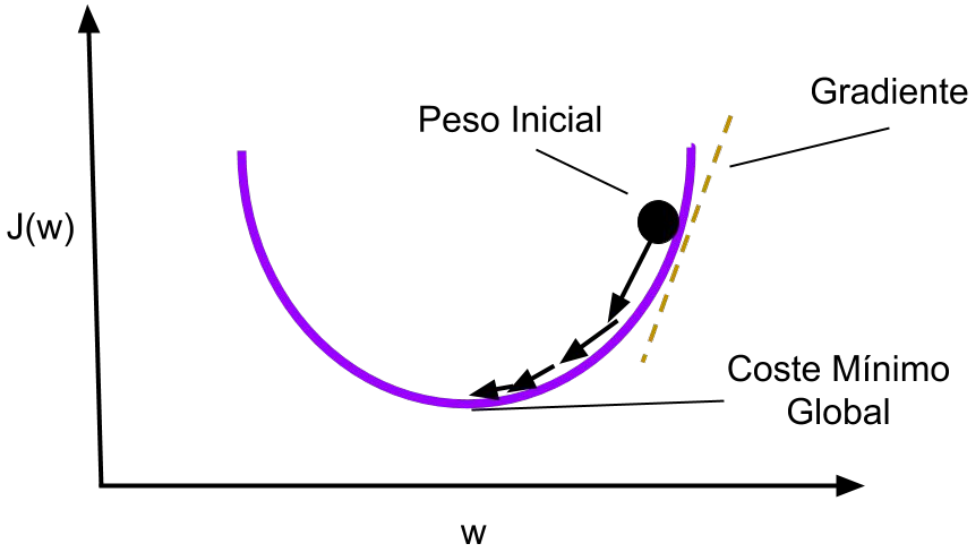
$$KL\left(P_i \| Q_j\right) = \sum_i \sum_j p_{j|i} \log \frac{p_{j|i}}{q_{j|i}}$$

Minimizar

SNE y t-SNE

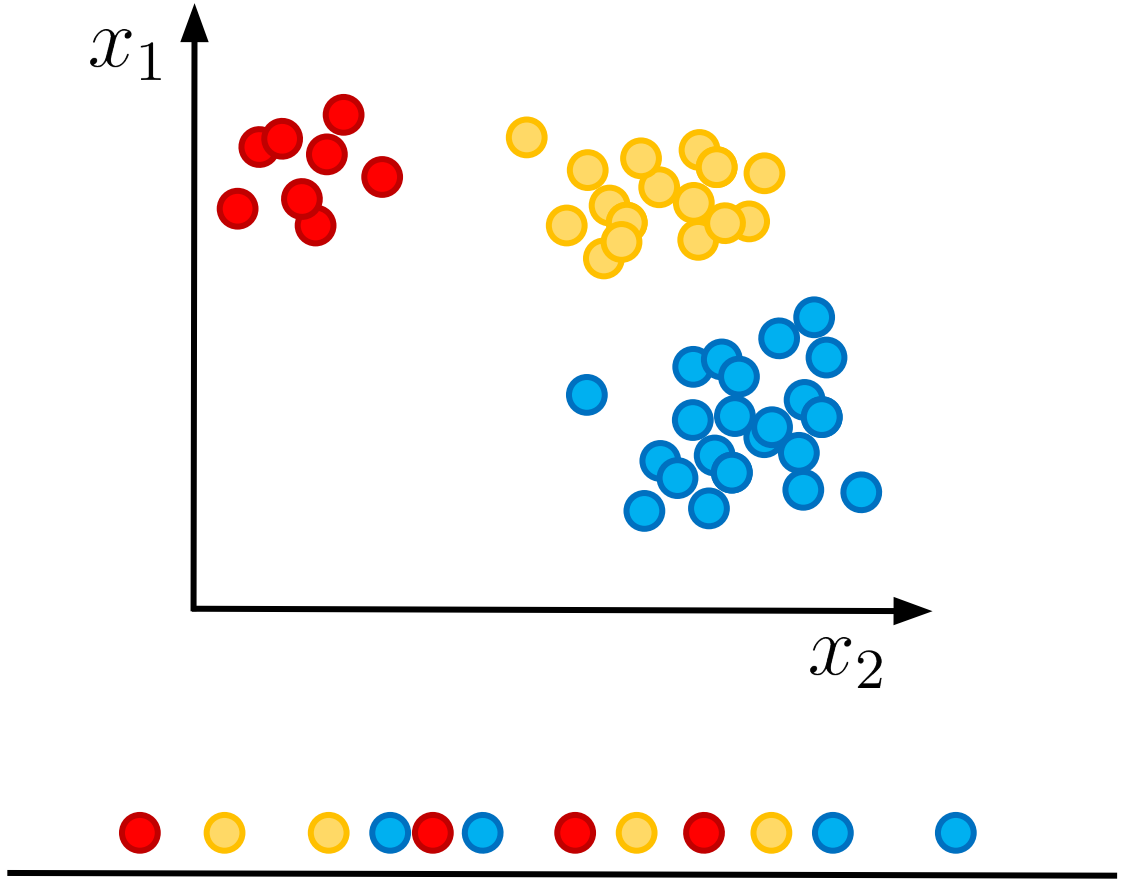
La minimización de la función de costo KL mediante el descenso por el gradiente asume la forma:

$$\frac{\partial KL\left(P_i \| Q_j\right)}{\partial y_i} = 2 \sum_j \underbrace{\left(p_{j|i} - q_{i|j} + p_{i|j} - q_{j|i}\right)}_{\text{medida de coincidencia}} \underbrace{\left(y_i - y_j\right)}_{\text{fuerza}}$$



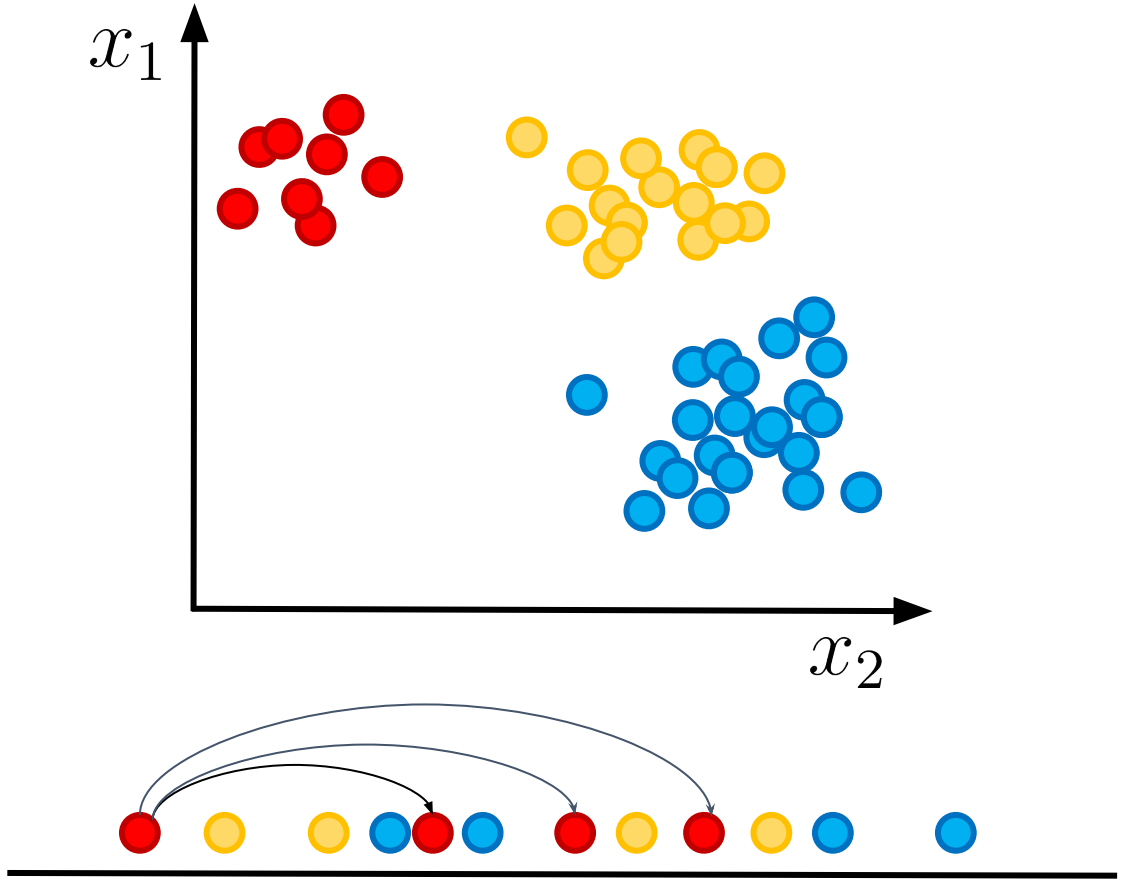
Reducción de Dimensionalidad

SNE y t-SNE



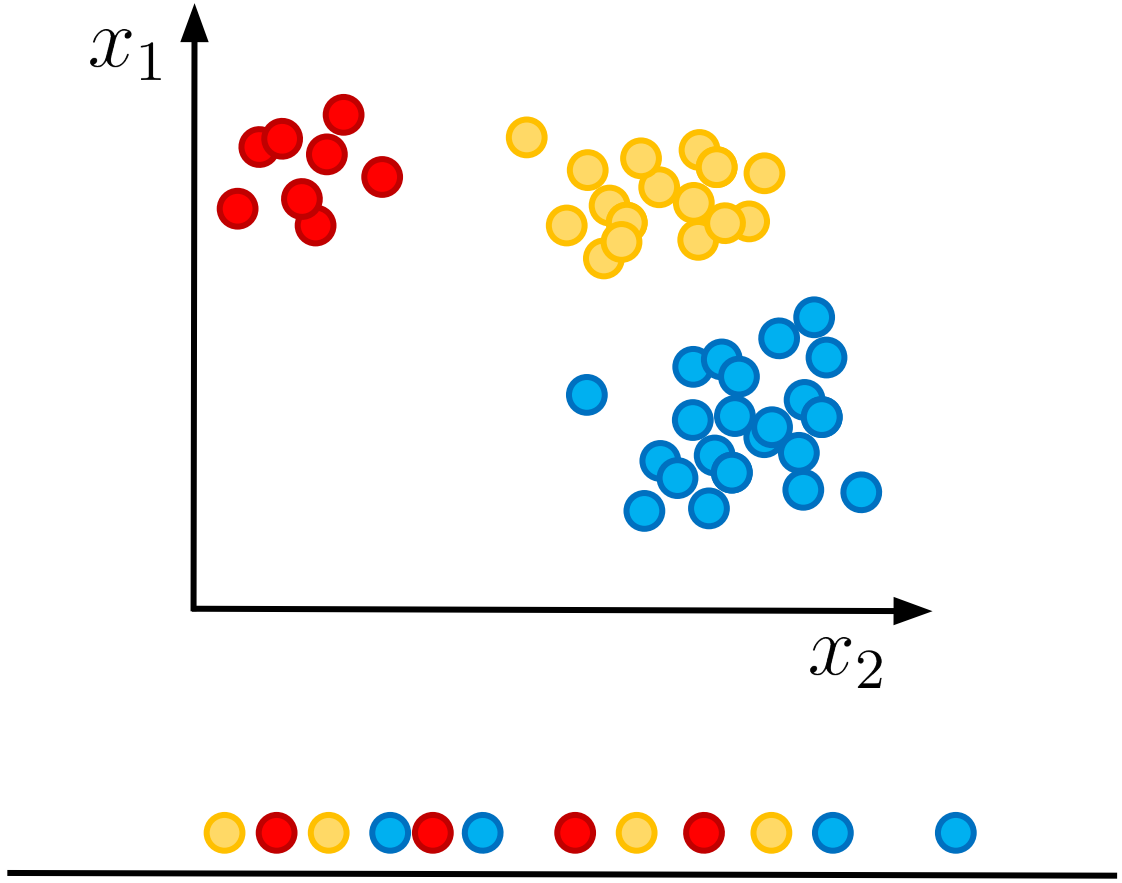
Reducción de Dimensionalidad

SNE y t-SNE



Reducción de Dimensionalidad

SNE y t-SNE



SNE y t-SNE

t-SNE reemplaza la distribución Gaussiana por una t-Student para calcular la similitud el espacio de baja dimensión

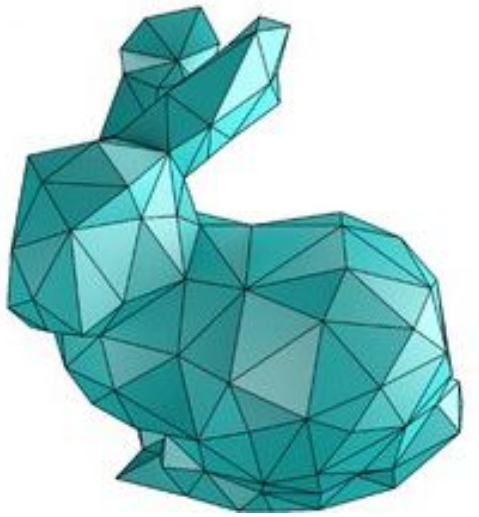
t-SNE reduce la dimensionalidad preservando al mismo tiempo similitud local (PCA preserva la varianza de los datos)

t-SNE puede resultar costoso desde el punto de vista computacional, especialmente para conjuntos de datos de alta dimensión con una gran cantidad de observaciones

Reducción de Dimensionalidad

UMAP

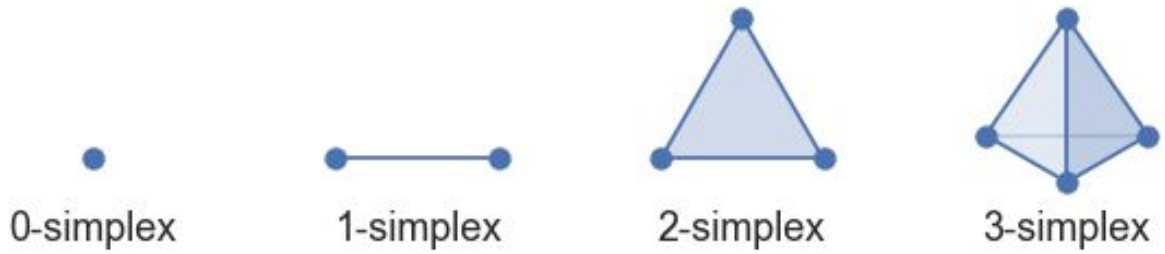
Uniform Manifold Approximation and Projection (UMAP) es un método de reducción de dimensionalidad cuyo objetivo es mapear datos de alta dimensión en un espacio de menor dimensión de manera que se preserve cierta **estructura de los datos** originales



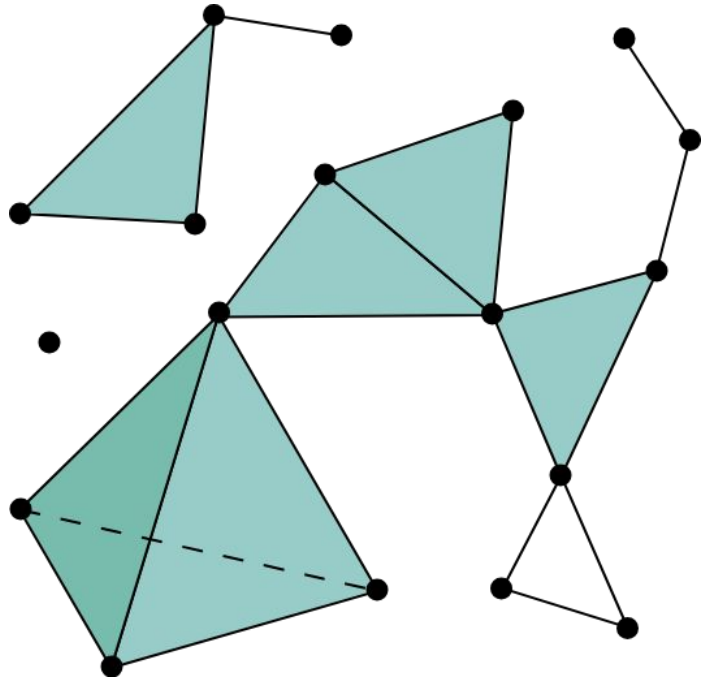
UMAP

UMAP busca combinar simplices para aproximar la geometría de los datos

Simplices



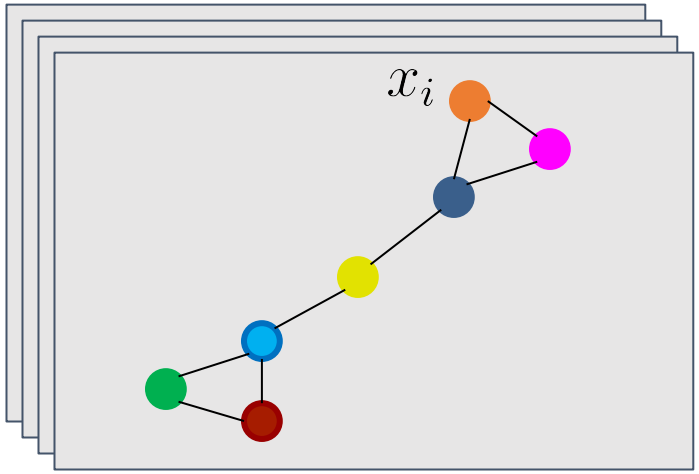
Complejo simplicial



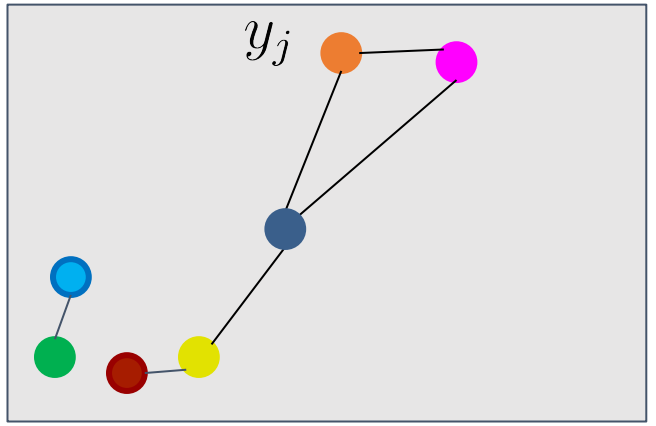
Reducción de Dimensionalidad

UMAP

- Cada observación en el espacio de alta dimensional está representado por una observación en el espacio de menor dimensión
- La reducción busca una estructura topológica similar en el espacio de menor dimensión



Alta dimensión



Baja dimensión

Reducción de Dimensionalidad

UMAP

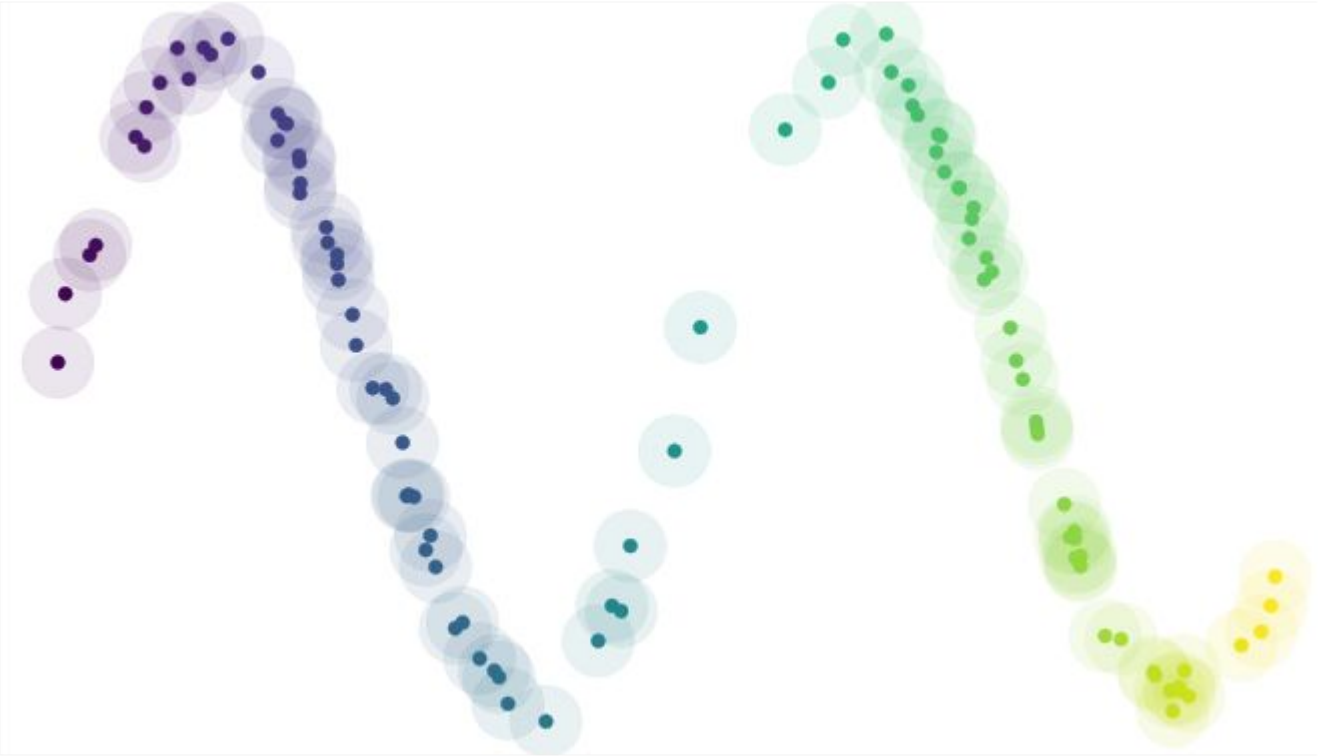
Construcción del grafo en el espacio de alta dimensión



Reducción de Dimensionalidad

UMAP

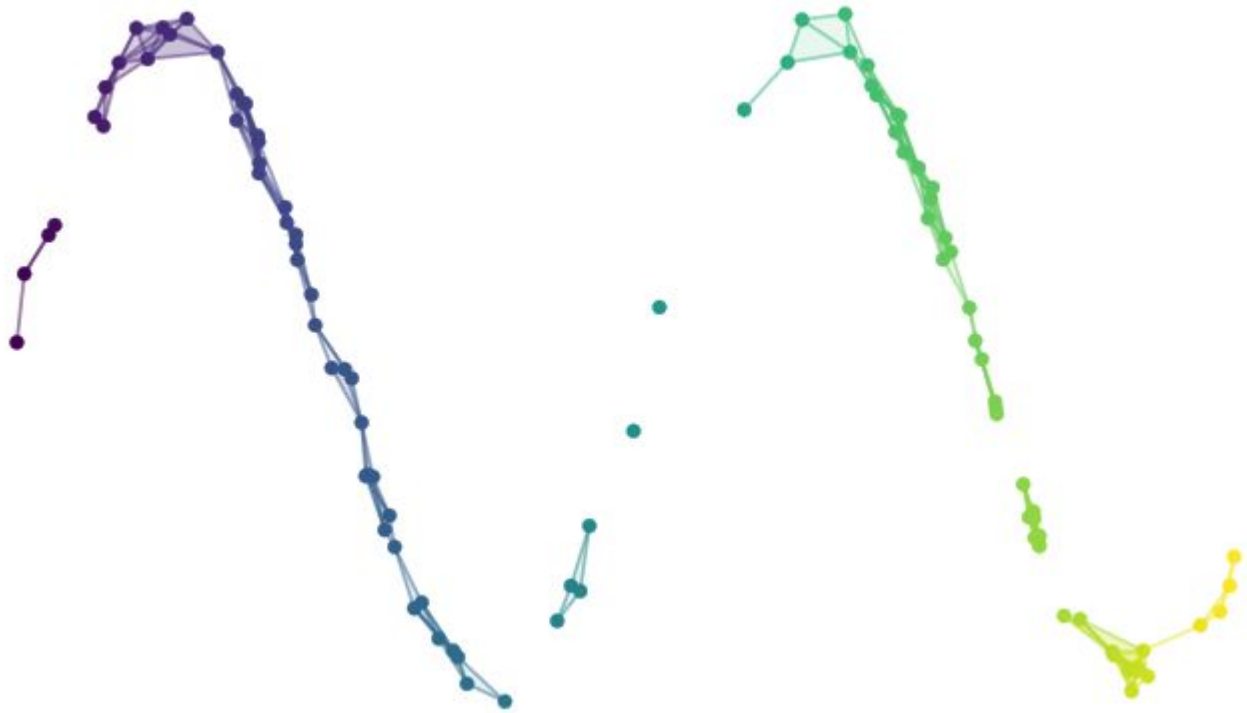
Se crean conjuntos con cada 0-simplex, se crea un 1-simplex entre dos de esos conjuntos si tienen una intersección no vacía, etc.



Reducción de Dimensionalidad

UMAP

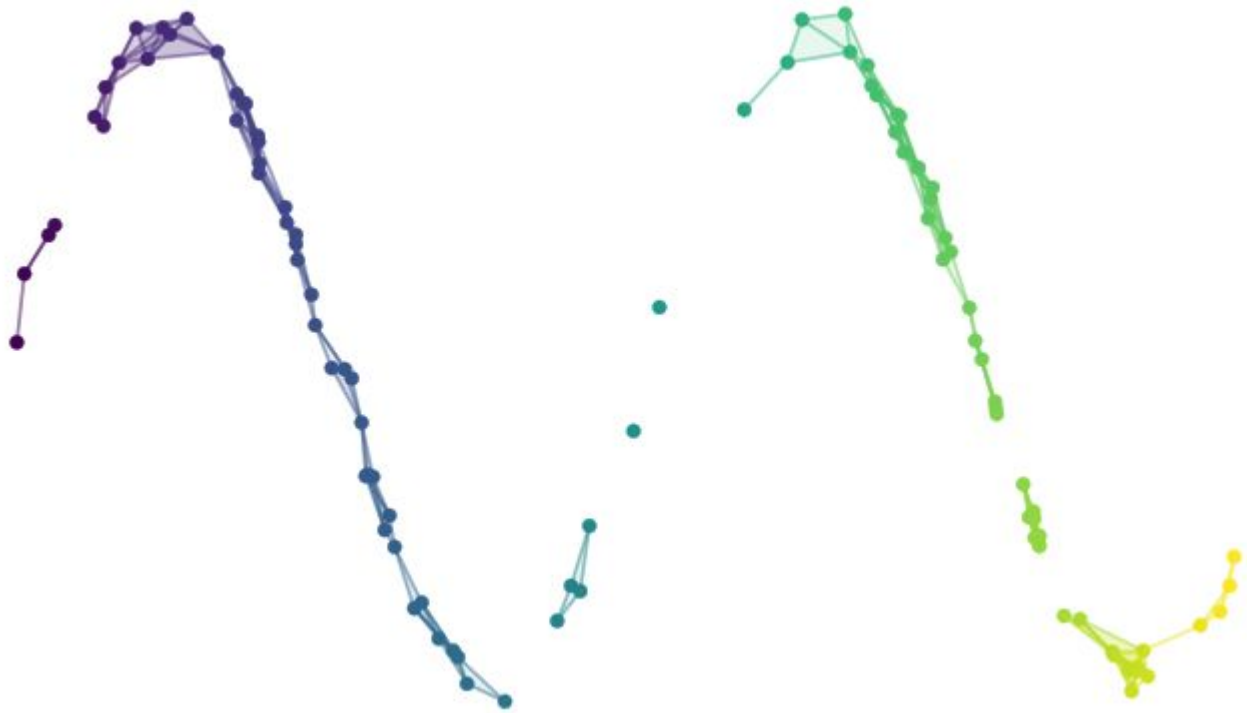
Luego podemos representar el complejo simplicial de 0, 1 y 2 simplices como puntos, líneas y triángulos



Reducción de Dimensionalidad

UMAP

Luego podemos representar el complejo simplicial de 0, 1 y 2 simplices como puntos, líneas y triángulos



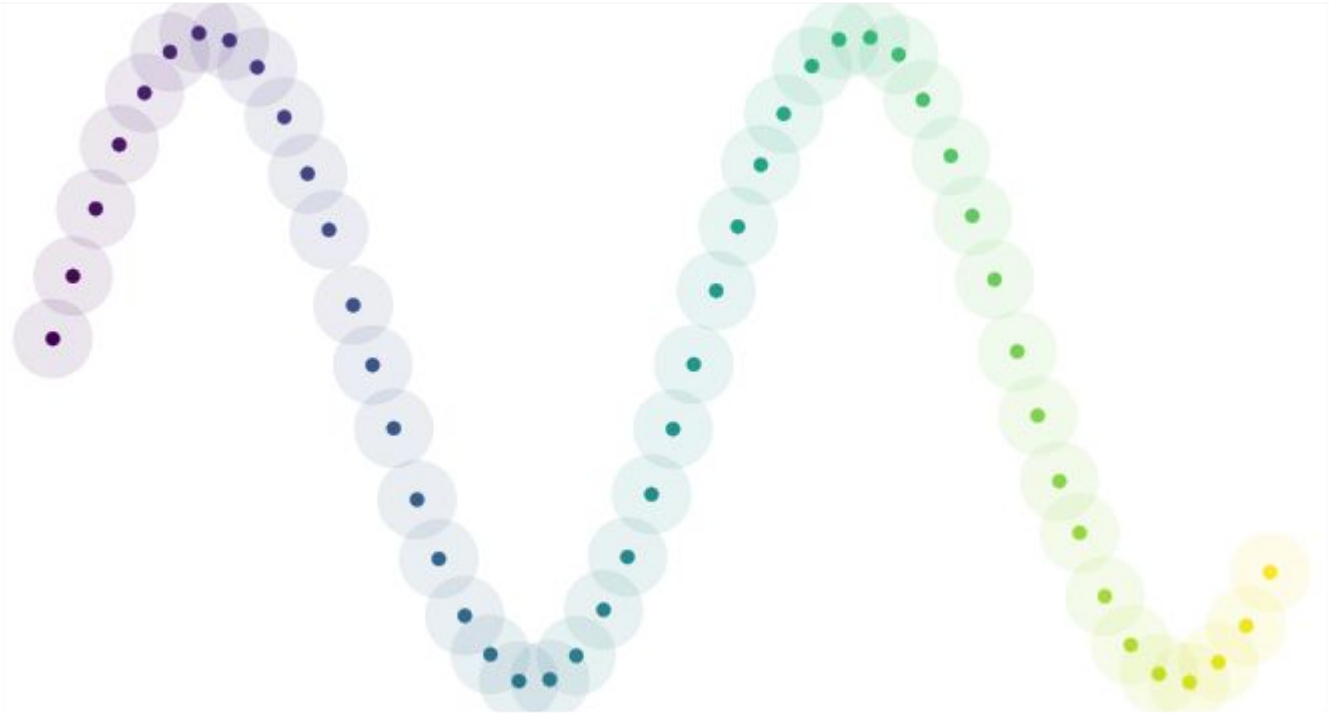
Reducción de Dimensionalidad

UMAP

- Adoptando este enfoque para obtener una representación topológica, se puede construir un algoritmo de reducción de dimensiones encontrando una representación de baja dimensión de los datos que tenga una representación topológica similar
- Si solo usamos 0 y 1 simplices, entonces la representación topológica es un grafo, y encontrar una representación de baja dimensión puede describirse como un problema de diseño del grafo

UMAP

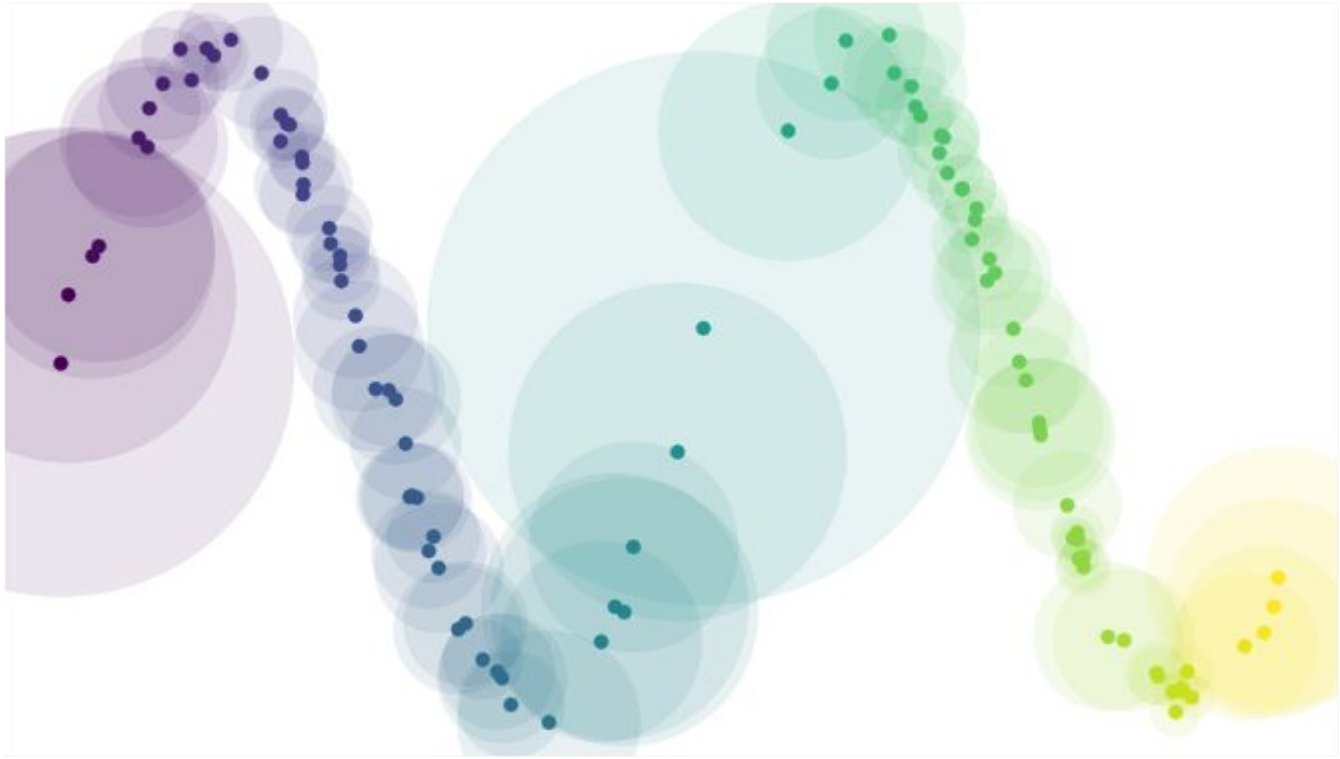
Si los datos estuvieran distribuidos uniformemente en el manifold, podríamos seleccionar un radio adecuado (por ej., la distancia promedio entre puntos)



Reducción de Dimensionalidad

UMAP

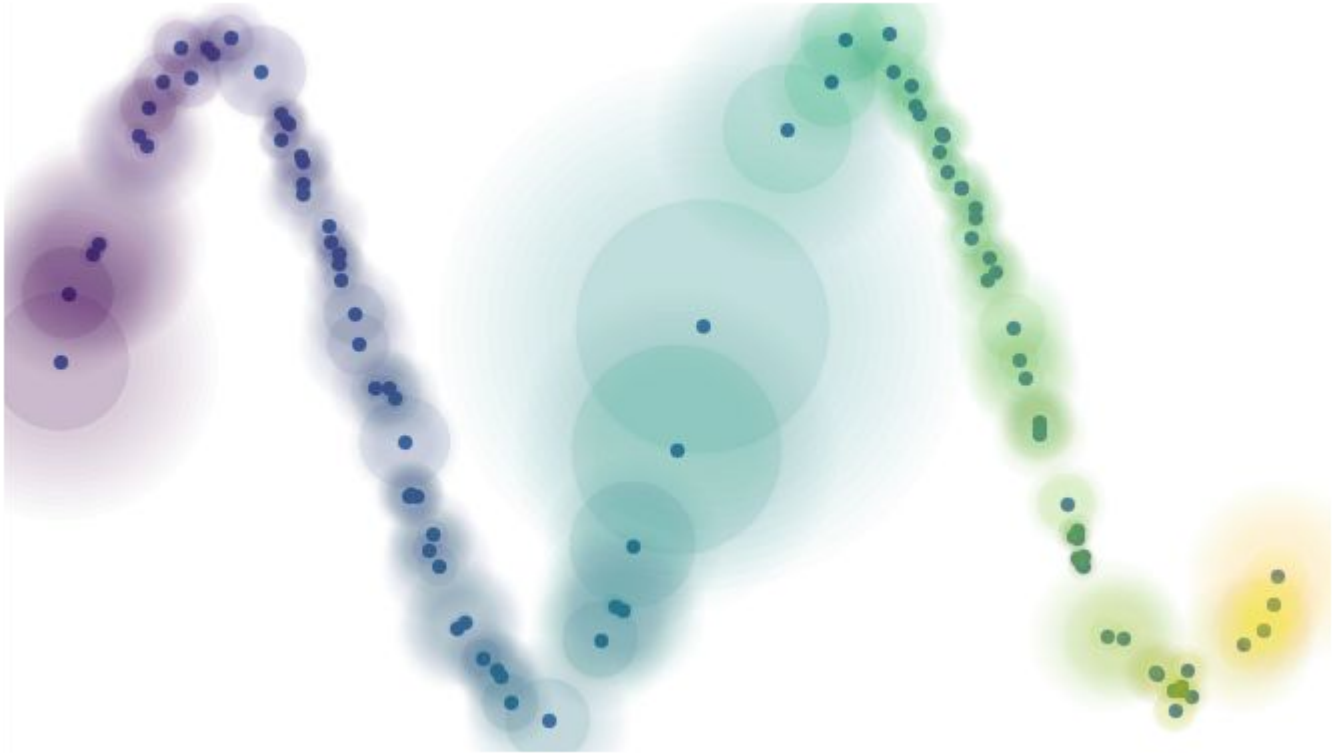
k-Nearest neighbors se utiliza para fijar radios variables



Reducción de Dimensionalidad

UMAP

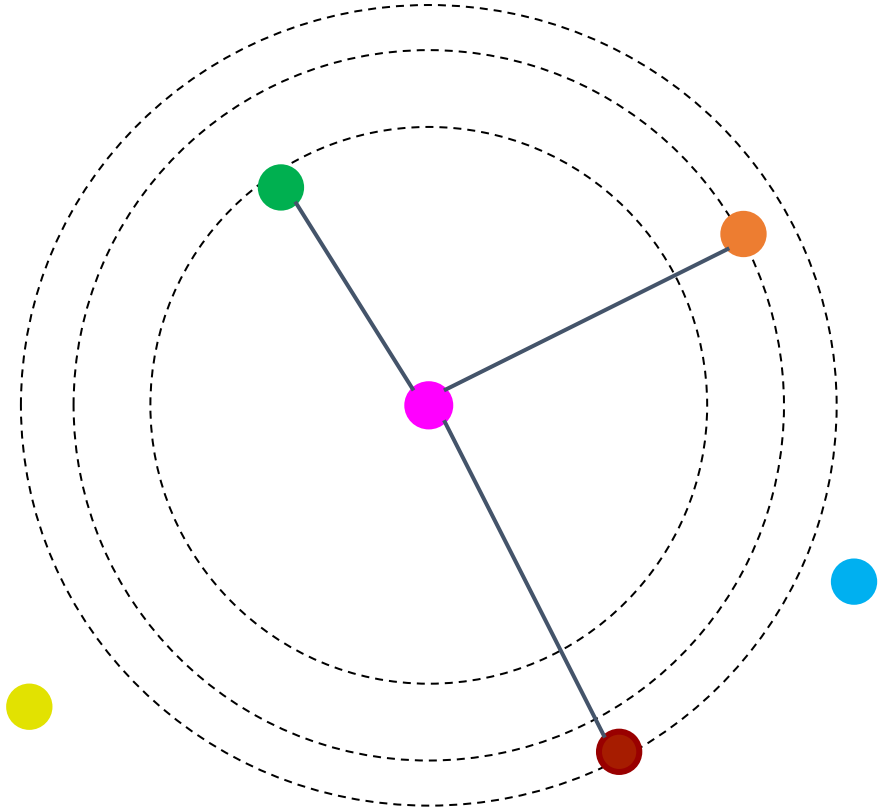
La certeza de ser vecino disminuye a medida que nos alejemos del centro



Reducción de Dimensionalidad

UMAP

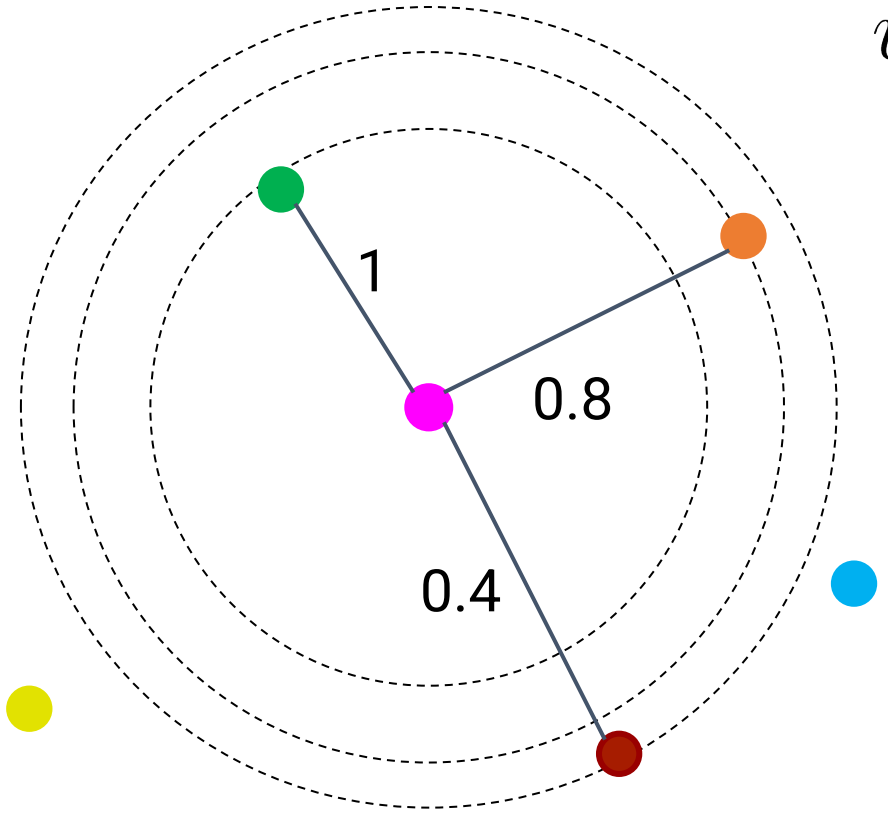
k-Nearest Neighbors (k=3)



Reducción de Dimensionalidad

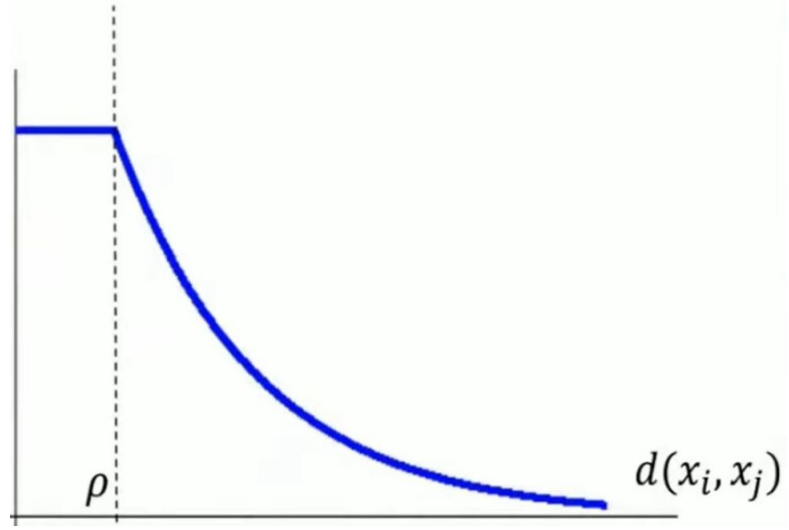
UMAP

k-Nearest Neighbors (k=3)



$$v_{i,j} = e^{-\frac{\max(0, d(x_i, x_j) - \rho_i)}{\sigma^2}}$$

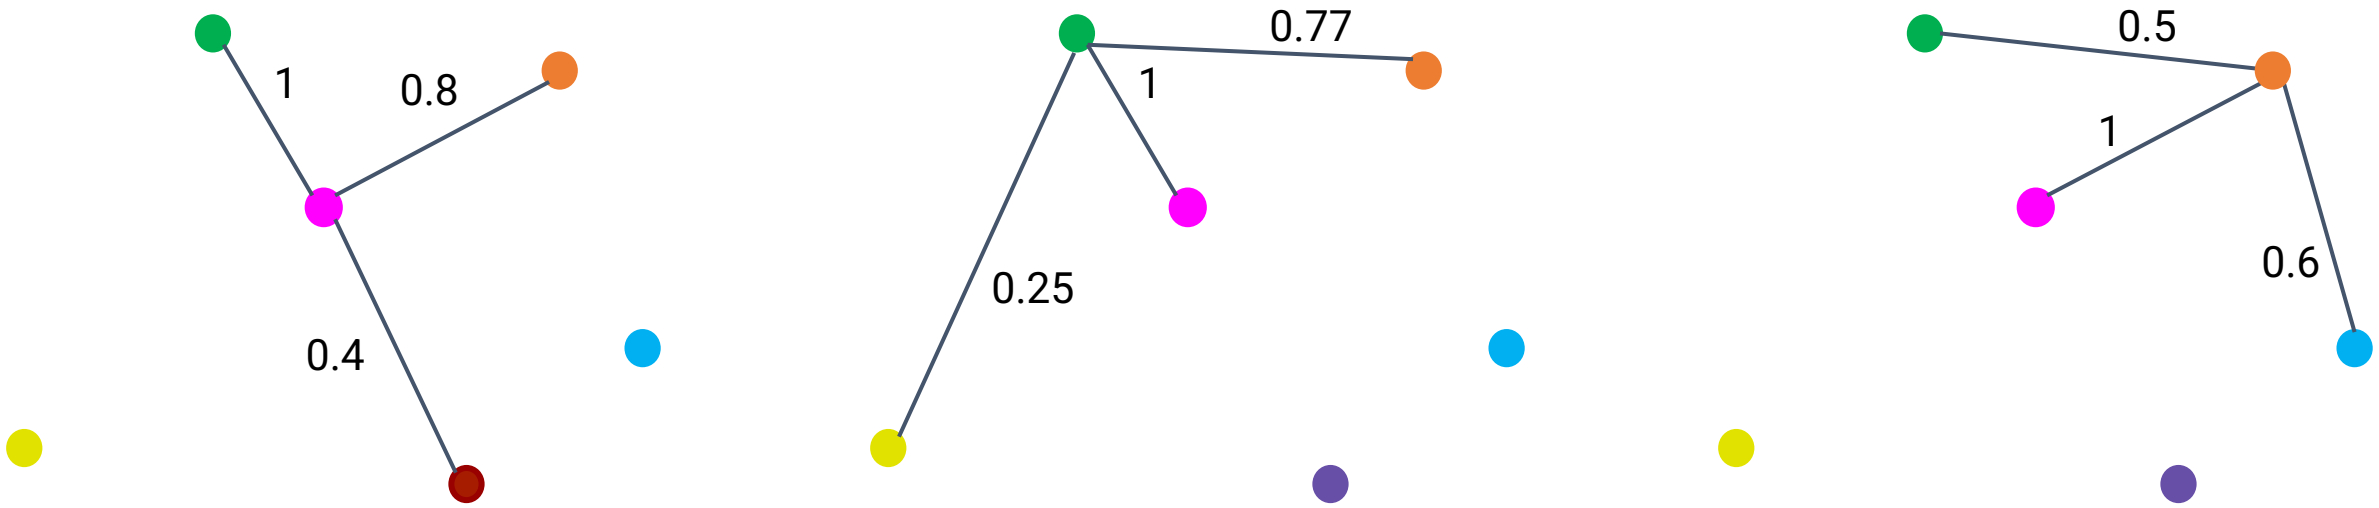
$$\rho_i = \min\{d(x_i, x_{i_j})\} 1 \leq j \leq k$$



Reducción de Dimensionalidad

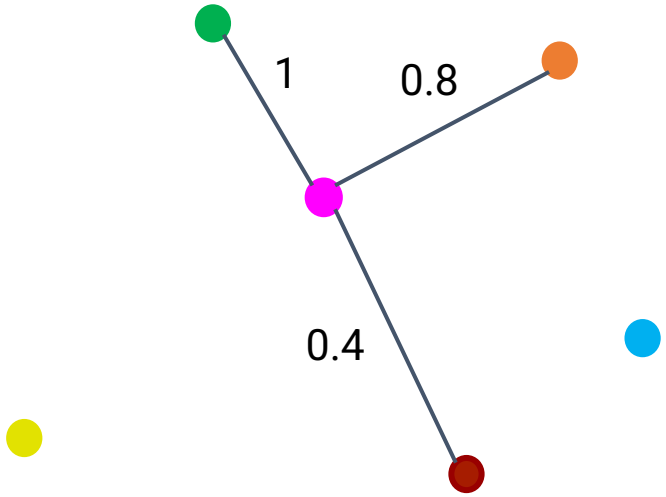
UMAP

Combinar las grafos pesados en un solo complejo simplicial

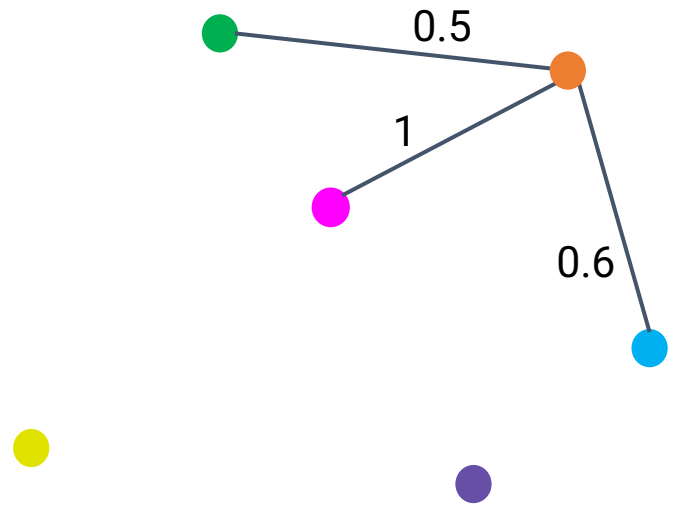


UMAP

Construcción del grafo en el espacio de alta dimensión

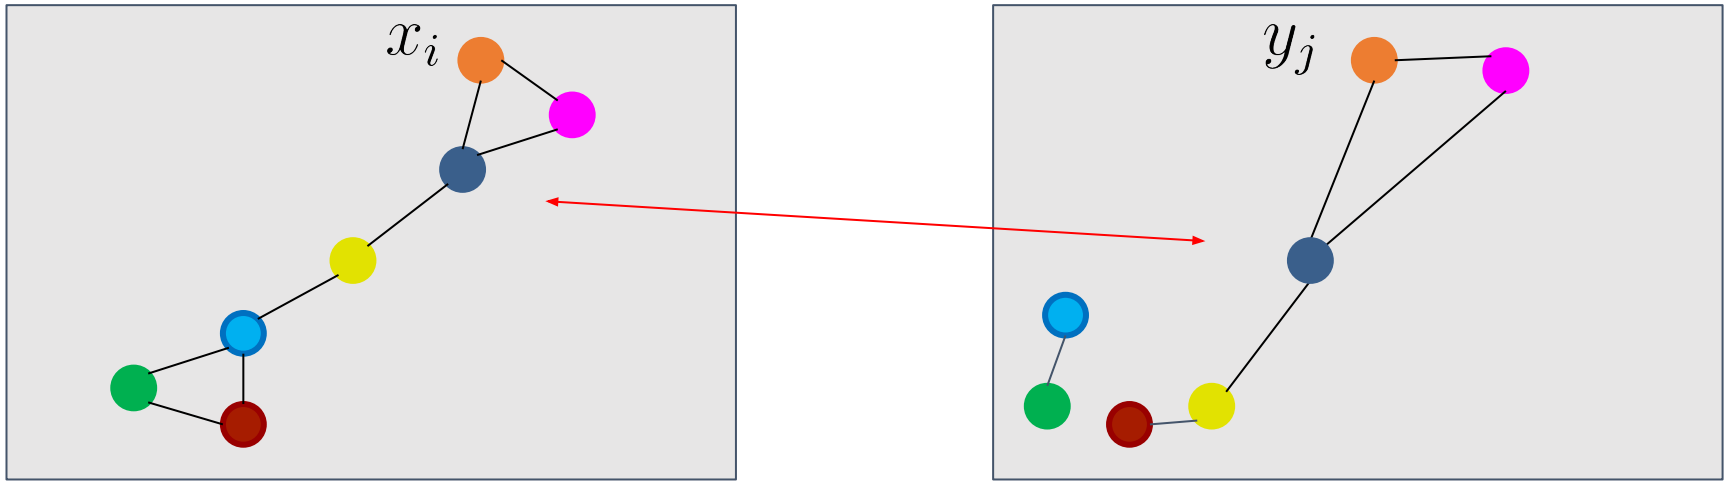


$$w_{ij} = v_{i,j} + v_{j,i} - v_{i,j} \cdot v_{j,i}$$



Reducción de Dimensionalidad

UMAP



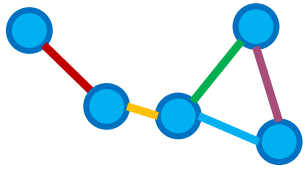
Alta dimensión

Baja dimensión

Reducción de Dimensionalidad

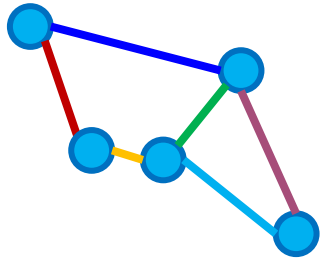
UMAP

Matrices de adyacencia



0	0.8	0	0	0
0.8	0	0.9	0	0
0	0.9	0	0.3	0.6
0	0	0.3	0	0.2
0	0	0.6	0.2	0

Alta dimensión



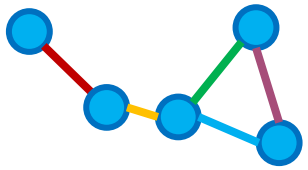
0	0.5	0	0.1	0
0.5	0	0.9	0	0
0	0.9	0	0.3	0.2
0.1	0	0.3	0	0.1
0	0	0.2	0.1	0

Baja dimensión

Reducción de Dimensionalidad

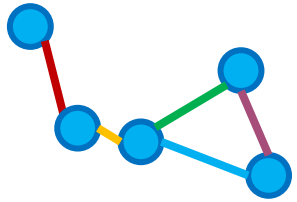
UMAP

Matrices de adyacencia



$$\begin{pmatrix} 0 & 0.8 & 0 & 0 & 0 \\ 0.8 & 0 & 0.9 & 0 & 0 \\ 0 & 0.9 & 0 & 0.3 & 0.6 \\ 0 & 0 & 0.3 & 0 & 0.2 \\ 0 & 0 & 0.6 & 0.2 & 0 \end{pmatrix}$$

Alta dimensión



$$\begin{pmatrix} 0 & 0.7 & 0 & 0 & 0 \\ 0.7 & 0 & 0.9 & 0 & 0 \\ 0 & 0.9 & 0 & 0.3 & 0.4 \\ 0 & 0 & 0.3 & 0 & 0.1 \\ 0 & 0 & 0.4 & 0.1 & 0 \end{pmatrix}$$

Baja dimensión

Reducción de Dimensionalidad

UMAP

Probabilidades de que un link exista y de que no, en alta dimensión (igual en baja dimensión)

$$\begin{pmatrix} 0 & 0.8 & 0 & 0 & 0 \\ 0.8 & 0 & 0.9 & 0 & 0 \\ 0 & 0.9 & 0 & 0.3 & 0.6 \\ 0 & 0 & 0.3 & 0 & 0.2 \\ 0 & 0 & 0.6 & 0.2 & 0 \end{pmatrix} \qquad \begin{pmatrix} 0 & 0.2 & 1 & 1 & 1 \\ 0.2 & 0 & 0.1 & 1 & 1 \\ 1 & 0.1 & 0 & 0.7 & 0.4 \\ 1 & 1 & 0.7 & 0 & 0.8 \\ 1 & 1 & 0.4 & 0.8 & 0 \end{pmatrix}$$

peso del 1-simplex en el espacio original

$$\sum_{i,j} w_{hd}(i,j) \log\left(\frac{w_{hd}(i,j)}{w_{ld}(i,j)}\right) + (1 - w_{hd}(i,j)) \log\left(\frac{1 - w_{hd}(i,j)}{1 - w_{ld}(i,j)}\right)$$

el conjunto de todos los 1-simplices

alta probabilidad los puntos deberían estar cerca

peso del 1-simplex en el espacio reducido

baja probabilidad los puntos deberían estar lejos

Cross-entropy

Reducción de Dimensionalidad

UMAP

- UMAP es más rápido que t-SNE
- Preserva más de la estructura global que t-SNE
- UMAP permite agregar nuevos datos

