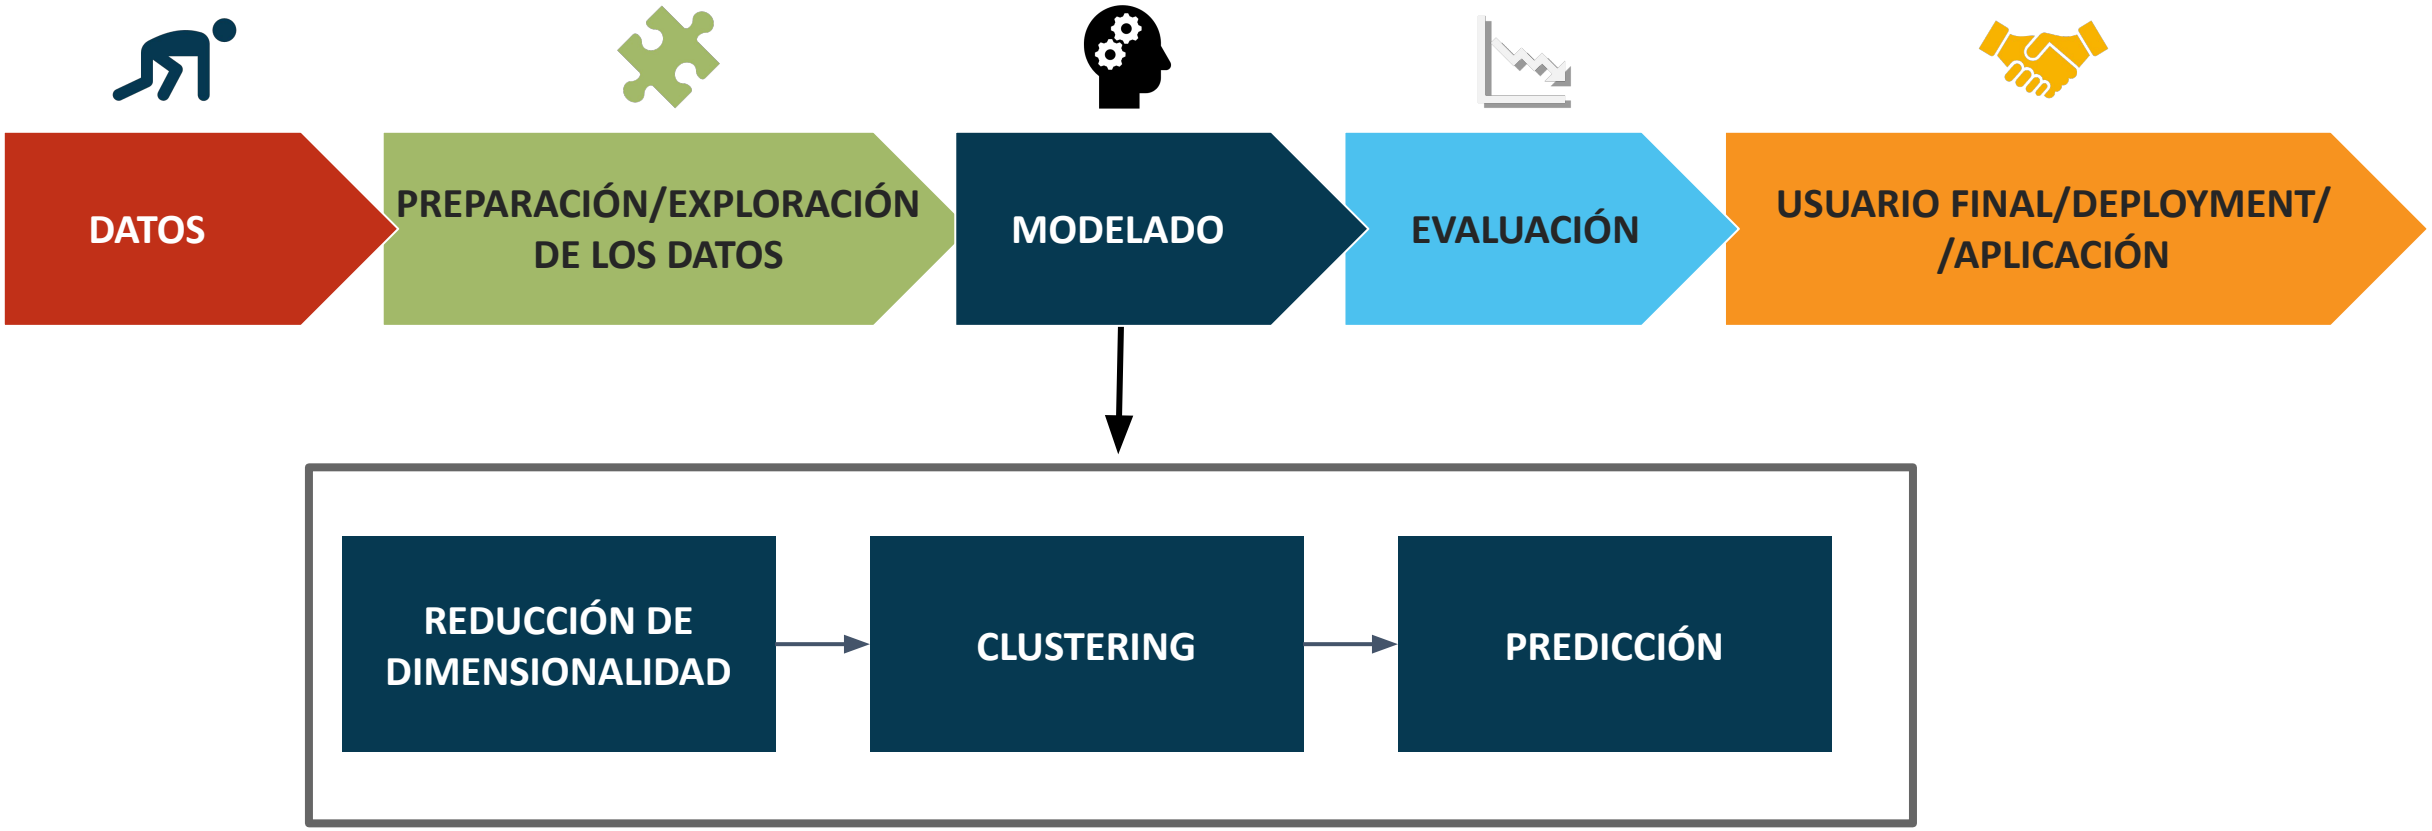


FACULTAD DE
CIENCIAS EXACTAS
UNICEN

Clustering

Roadmap


DATOS
PREPARACIÓN/EXPLORACIÓN DE LOS DATOS
MODELADO
EVALUACIÓN
USUARIO FINAL/DEPLOYMENT/ /APLICACIÓN
REDUCCIÓN DE DIMENSIONALIDAD
CLUSTERING
PREDICCIÓN

Problemas típicos de machine learning

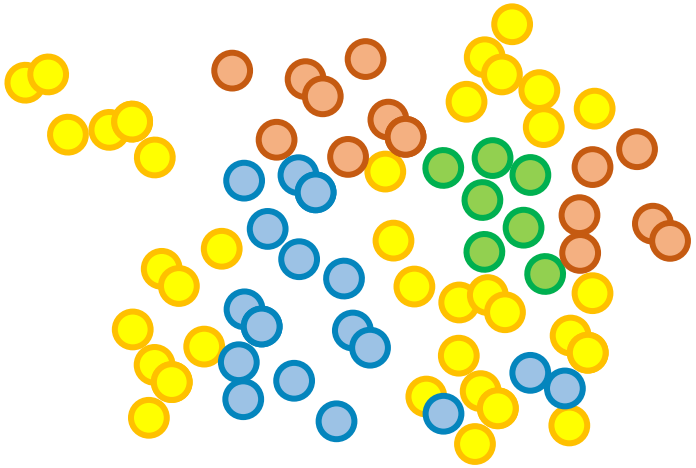
Clustering vs. Clasificación

Clasificación

Problema **supervisado**

Cada clase tiene una **semántica** asociada

Entrenamos con muestras de cada clase

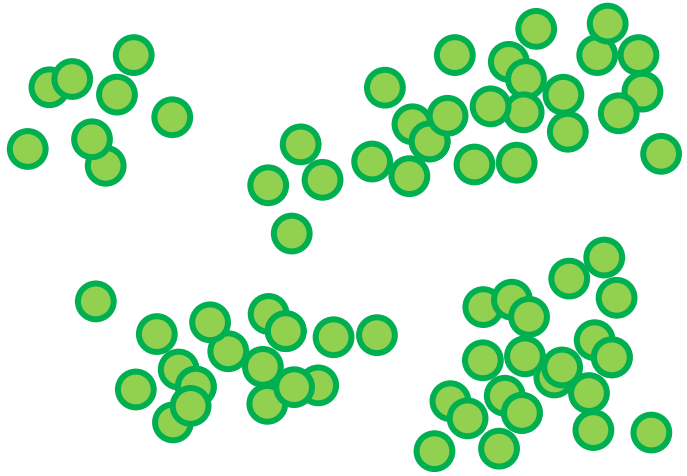


Clustering

Problema **no-supervisado**

Los **clusters no tienen semántica a priori**

Usamos todos los datos a la vez



Problemas típicos de machine learning

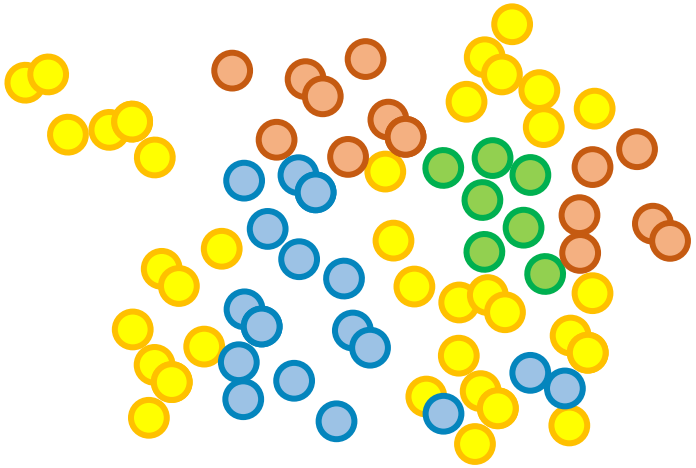
Clustering vs. Clasificación

Clasificación

Problema **supervisado**

Cada clase tiene una **semántica** asociada

Entrenamos con muestras de cada clase

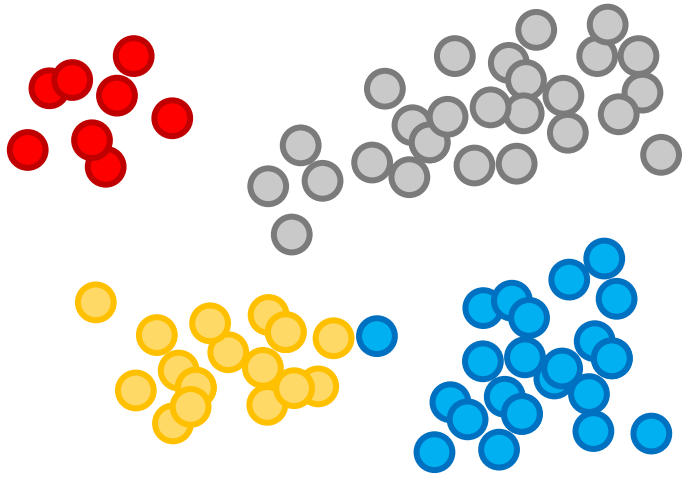


Clustering

Problema **no-supervisado**

Los **clusters no tienen semántica a priori**

Usamos todos los datos a la vez



Problemas típicos de machine learning

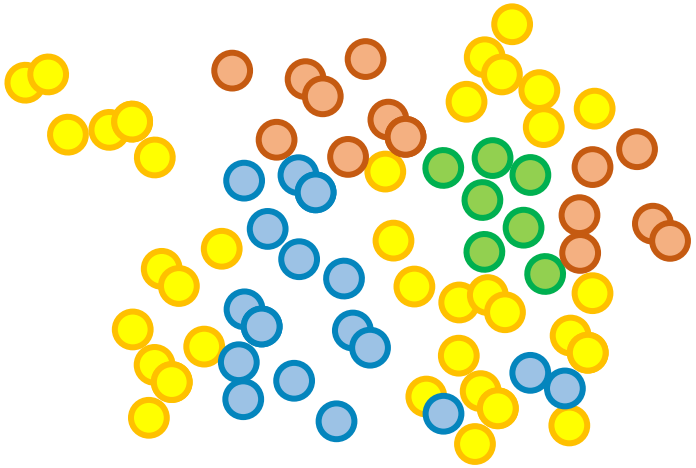
Clustering vs. Clasificación

Clasificación

Problema **supervisado**

Cada clase tiene una **semántica** asociada

Entrenamos con muestras de cada clase

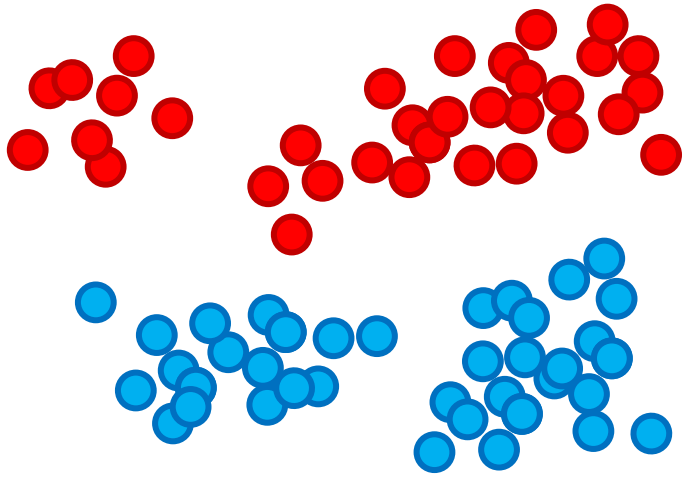


Clustering

Problema **no-supervisado**

Los **clusters no tienen semántica a priori**

Usamos todos los datos a la vez

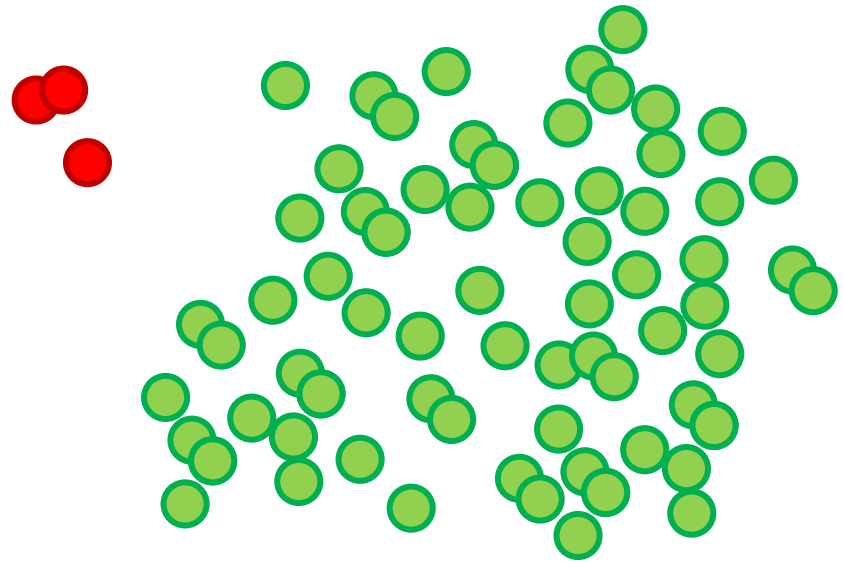


Exploración de Datos

Clustering

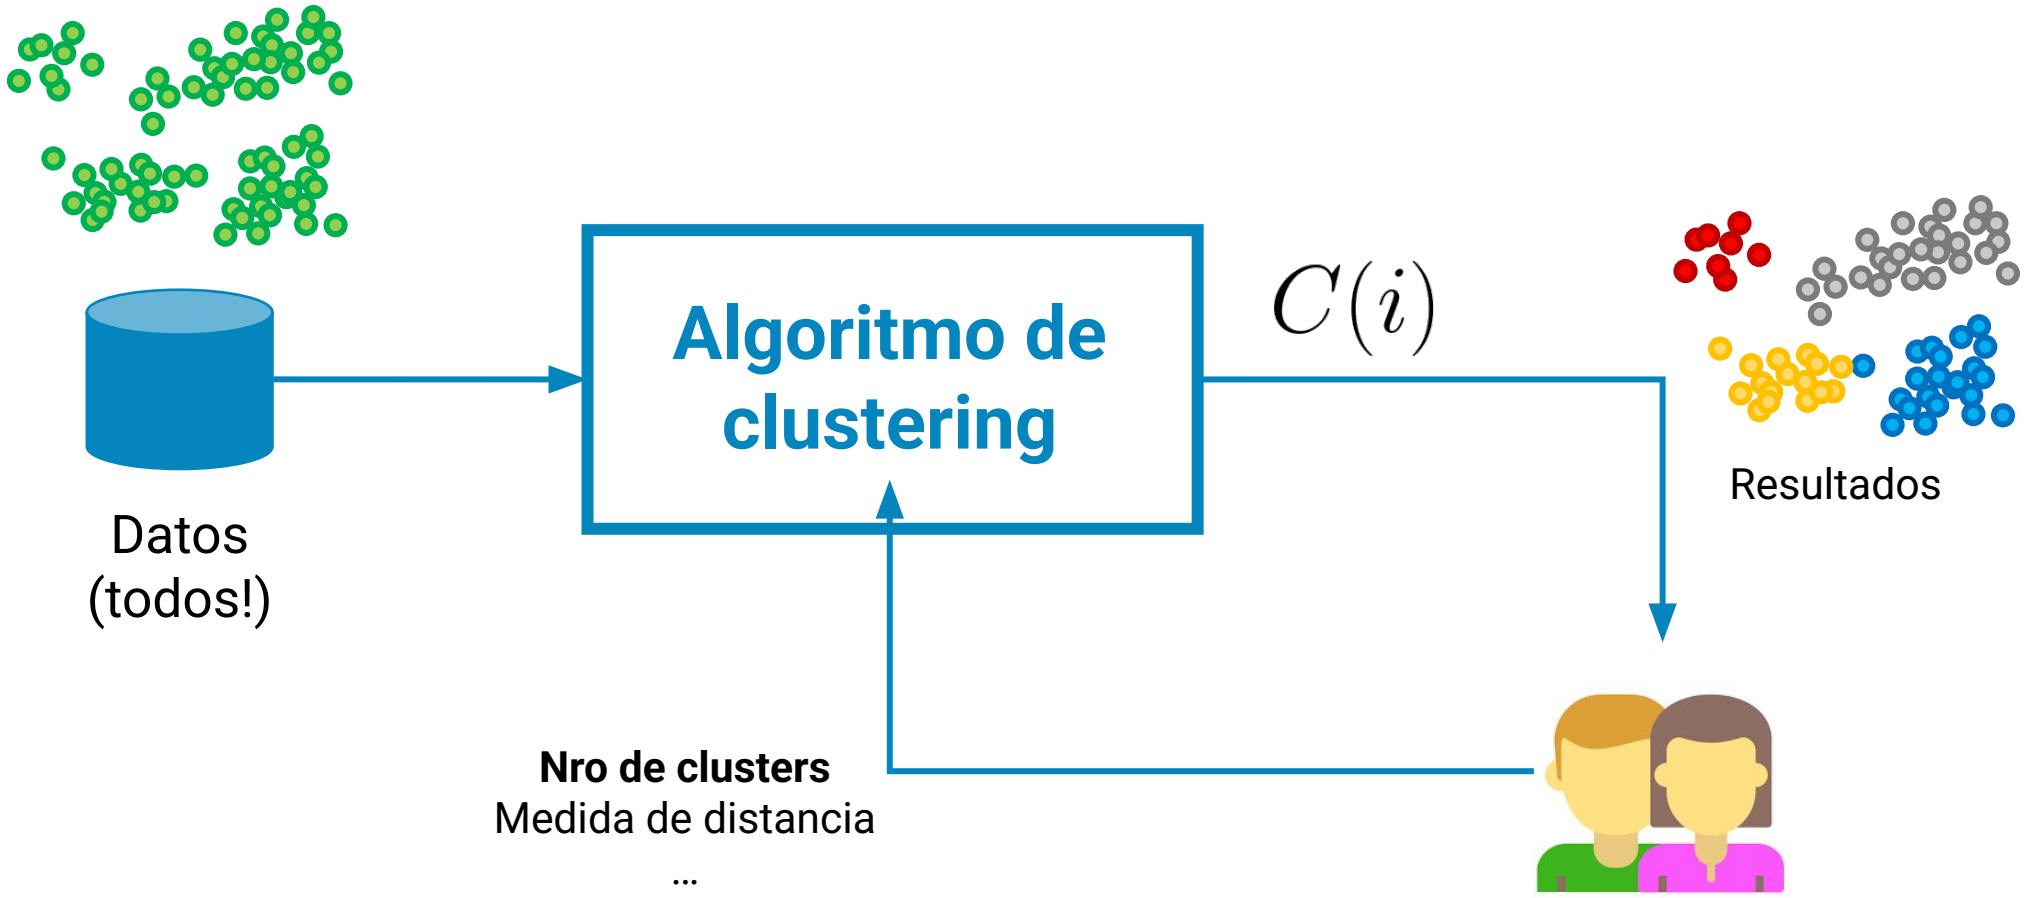
Clúster □ Agrupamiento de observaciones en el espacio de características

- No tienen semántica asociada (tenemos que asignársela una vez descubiertos)
- No conocemos tampoco la cantidad! (tenemos que explorar cuántos convienen)
- No hay forma de chequear si los clusters que hallamos están bien o no (solamente heurísticas)



Exploración de Datos

Clustering



Exploración de Datos

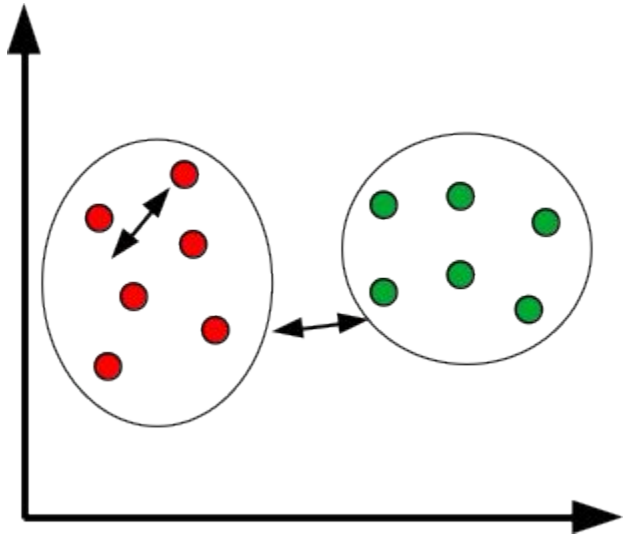
Clustering

Clustering es la organización de las observaciones en grupos o clusters, los algoritmos tratan de encontrar un agrupamiento natural de los datos

Un cluster es un subconjunto de los ejemplos que son similares entre sí, y disímiles a los ejemplos en otros clusters

Un buen agrupamiento es aquel que produce clusters con:

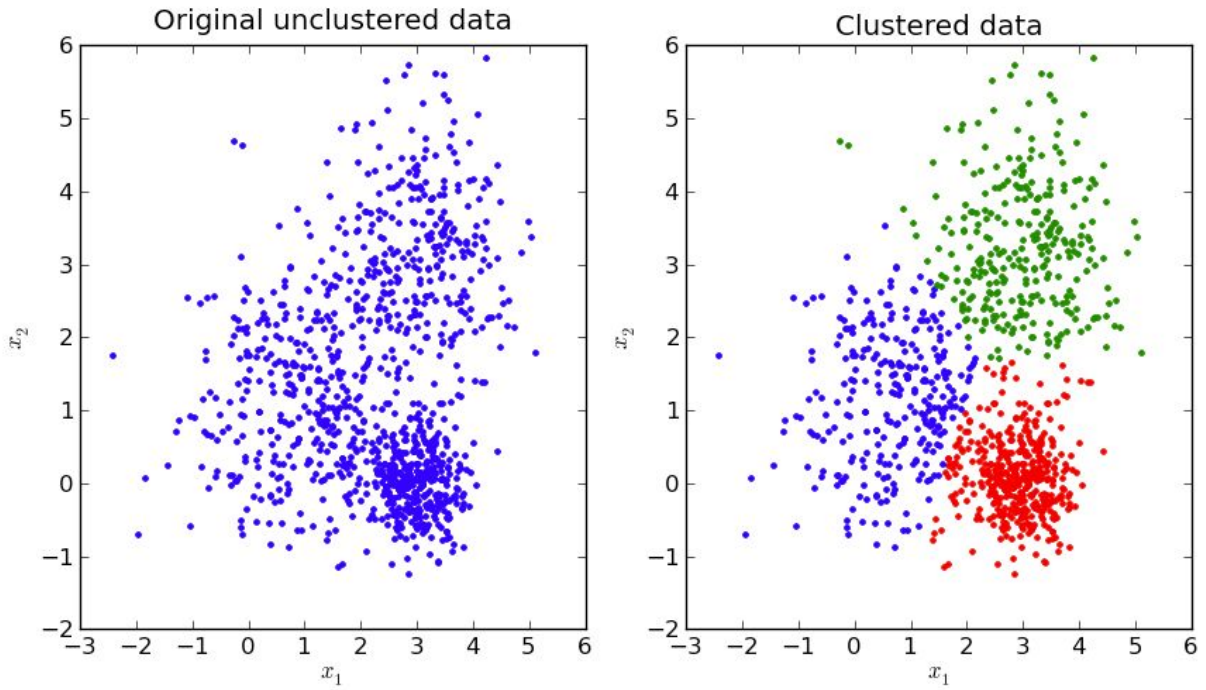
- alta similitud intra-cluster
- baja similitud inter-cluster



Exploración de Datos

Clustering

Busco encontrar particiones en un espacio de características que cumplan con ciertas condiciones:



1) Si 2 observaciones viven en un mismo cluster, deben estar cerca (poca varianza dentro de mi cluster)

2) Si 2 observaciones viven en distintos clusters, deben estar bien lejos (mucha distancia entre los clusters)

Clustering

Cómo se mide la similitud/distancia?

- La similitud depende de los datos y sus características
- Medidas comunes son la distancia Euclídea, Manhattan, Coseno y otras
- Características heterogéneas (por ejemplo, ingresos, edad, hábitos de consumo, nivel de educación, etc.) pueden requerir una definición ad-hoc de similitud

Exploración de Datos

Clustering

Euclídea

$$d(x_i, x_j) = \sqrt{\sum_{k=1}^{n} \left(x_i^k - x_j^k\right)^2}$$

Manhattan

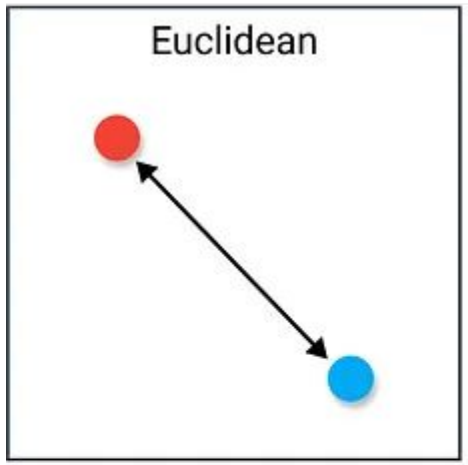
$$d(x_i, x_j) = \sum_{k=1}^{n} \mid x_i^k - x_j^k \mid$$

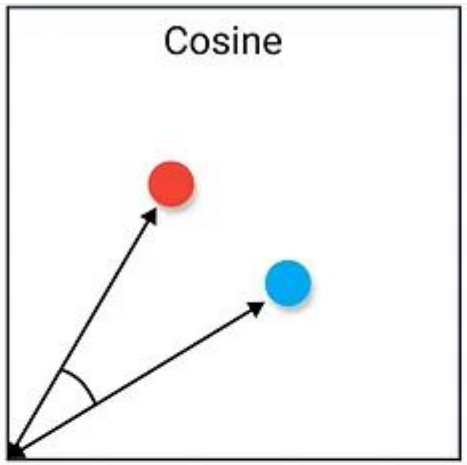
Coseno

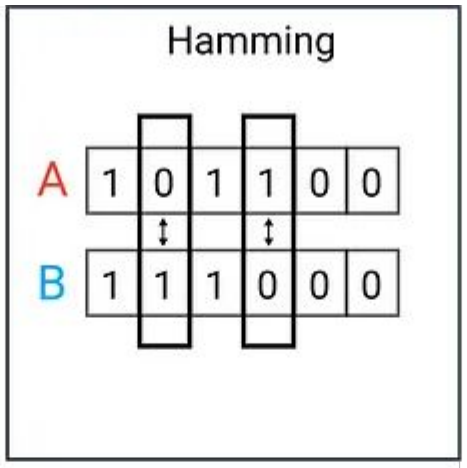
$$d(x_i, x_j) = \frac{\sum_{k=1}^{n} x_i^k \cdot x_j^k}{\sqrt{\sum_{k=1}^{n} (x_i^k)^2} \sqrt{\sum_{k=1}^{n} (x_j^k)^2}}$$

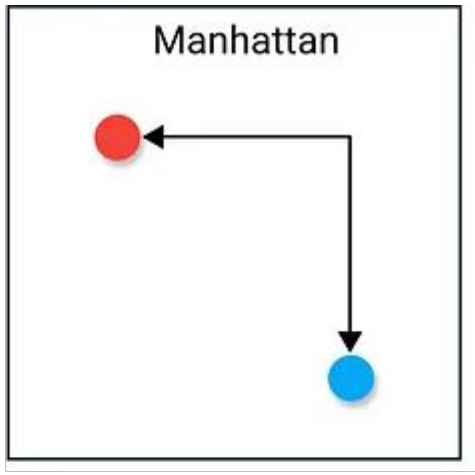
Exploración de Datos

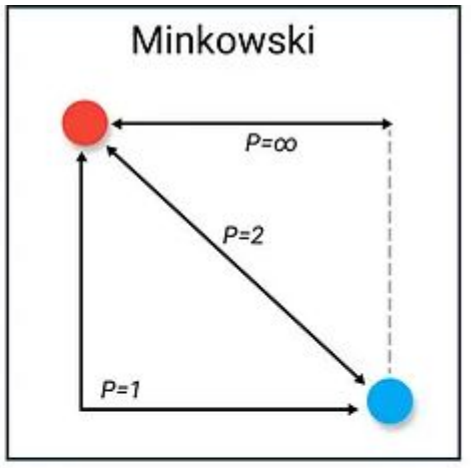
Clustering

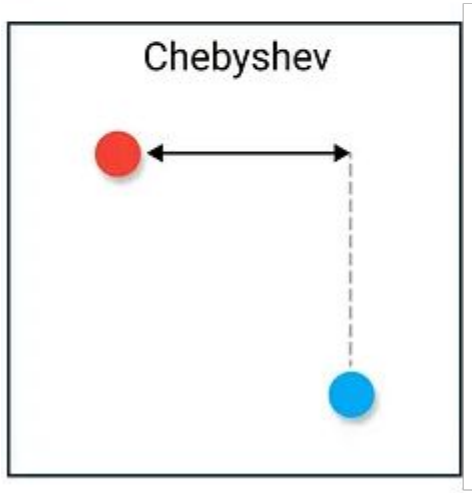


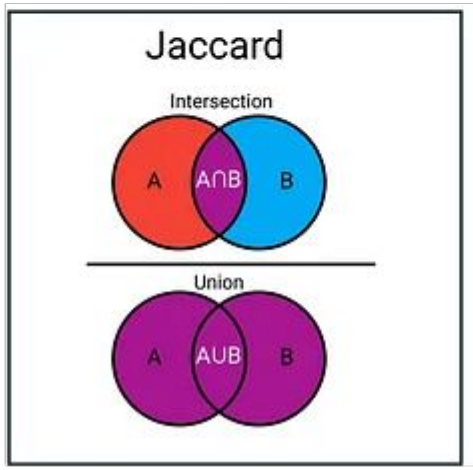


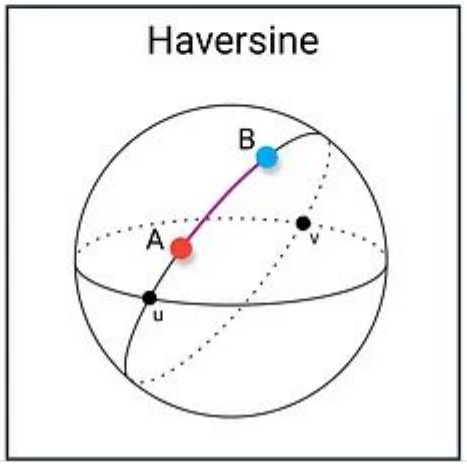


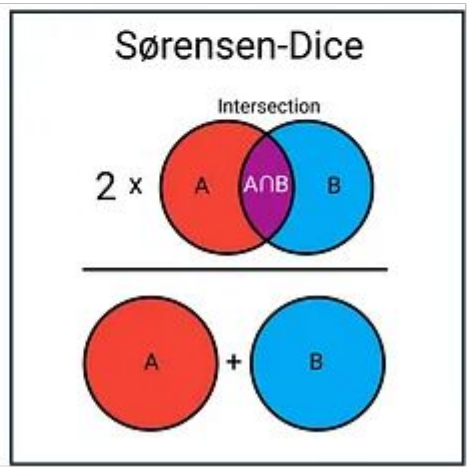












Exploración de Datos

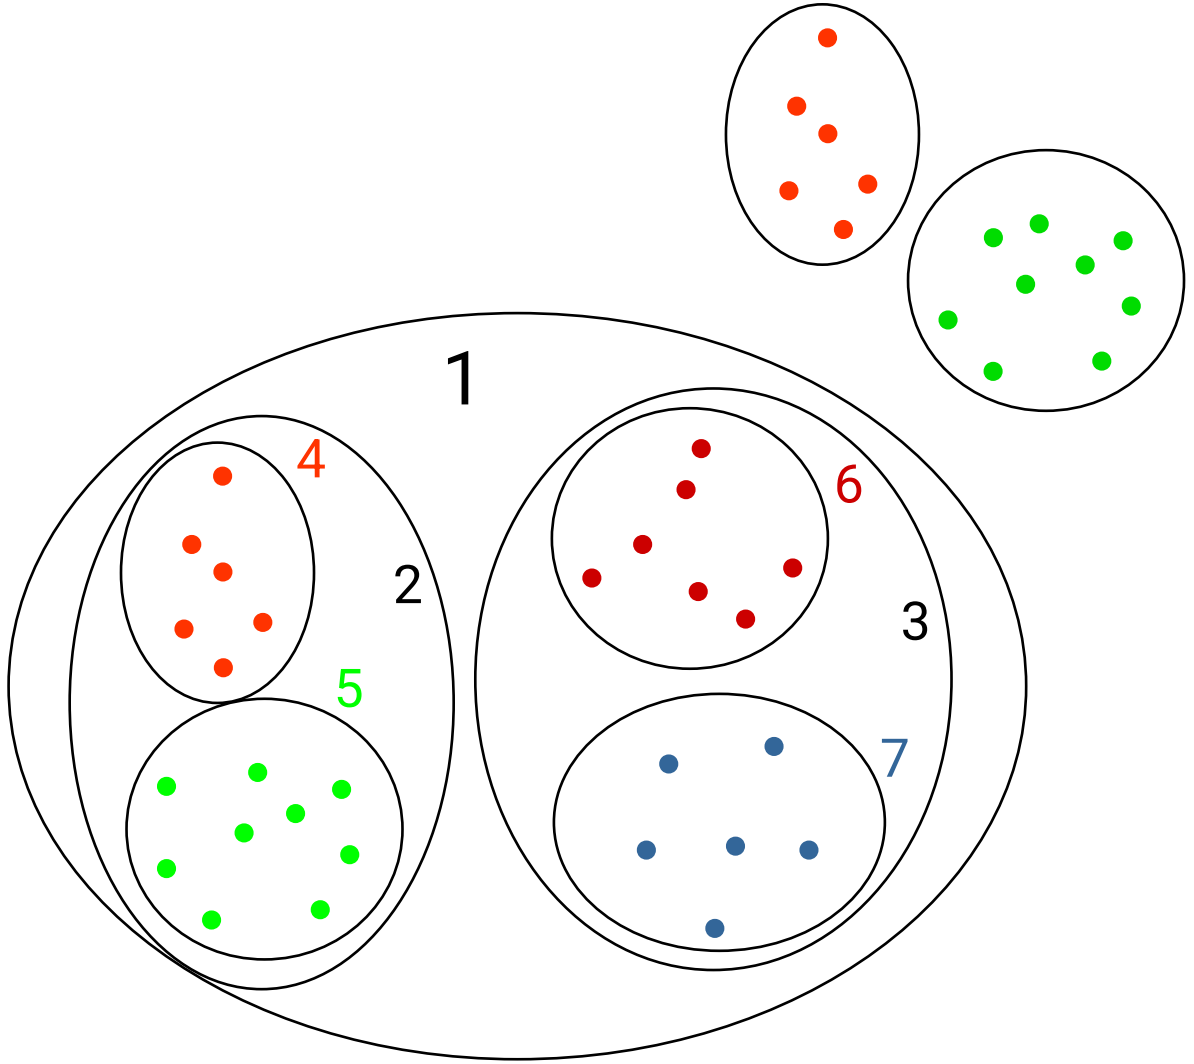
Clustering

Clustering basado en **particionamiento**

- Dividen los ejemplos en subconjuntos disjuntos tal que cada objeto pertenece exactamente a un cluster

Clustering **jerárquico**

- Generan un conjunto de clusters anidados en un árbol o jerarquía



Clustering / k-Means

Basado en particionamiento

- El objetivo es alcanzar una única partición de la colección de ejemplos en clusters
- Usualmente se basan en optimizar iterativamente un criterio o función objetivo que refleja el consenso entre las observaciones y las particiones

***k*-Means**: ejemplo de clustering basado en particionamiento

Clustering / k-Means

k-Means agrupa *n* observaciones en *k* particiones (*k*<*n*) en base a sus atributos

- Cada cluster está representado por su **centroide** o centro de gravedad:

$$\vec{\mu}(c) = \frac{1}{|\ c\ |} \sum_{\vec{x} \in C} \vec{x}$$

- Se optimiza la función:

$$\arg\min_{C} = \sum_{i=1}^{k} \sum_{x_j \in C_i} |\ x_j - \mu_i\ |^2$$

Clustering / k-Means

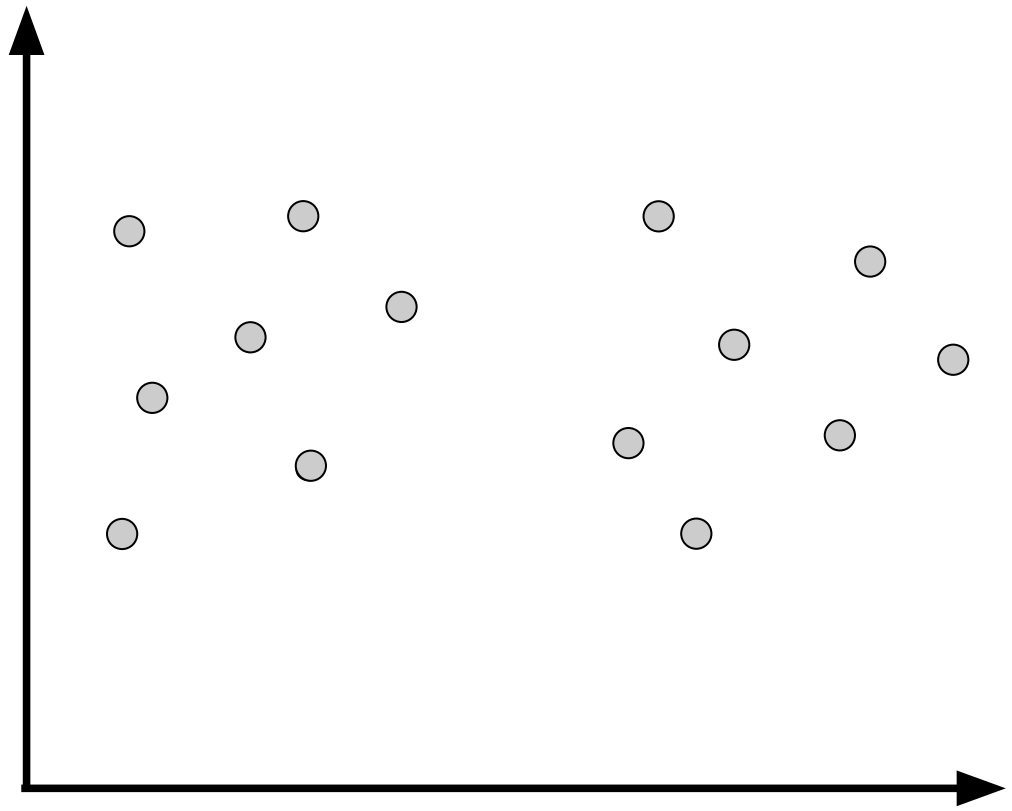
Dado un número de clusters *k*, el algoritmo *k*-Means ejecuta tres pasos después de la inicialización:

Inicialización: seleccionar aleatoriamente *k* ejemplos (semillas) para ser centroides de los clusters

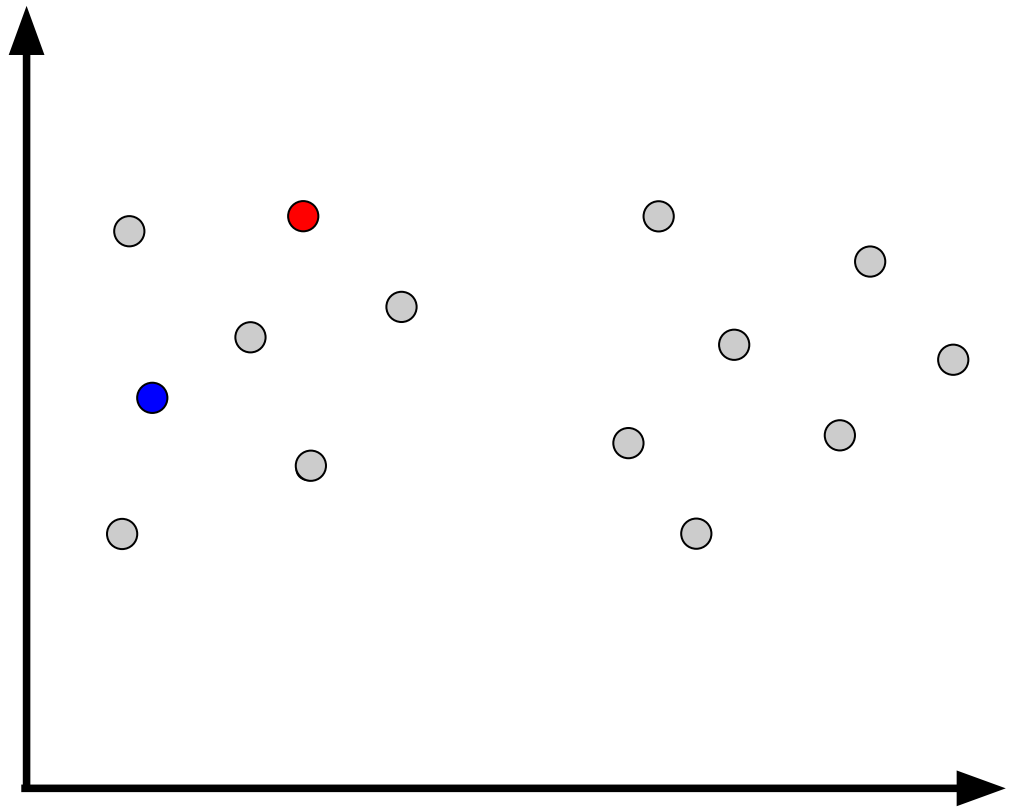
1. Asignar cada ejemplo al centroide con el que tenga mayor similitud
2. Calcular nuevos centroides de los clusters de la participación
3. Si no se satisface el criterio de terminación (no hay cambios en los clusters), volver al paso 1

Exploración de Datos

Clustering / k-Means

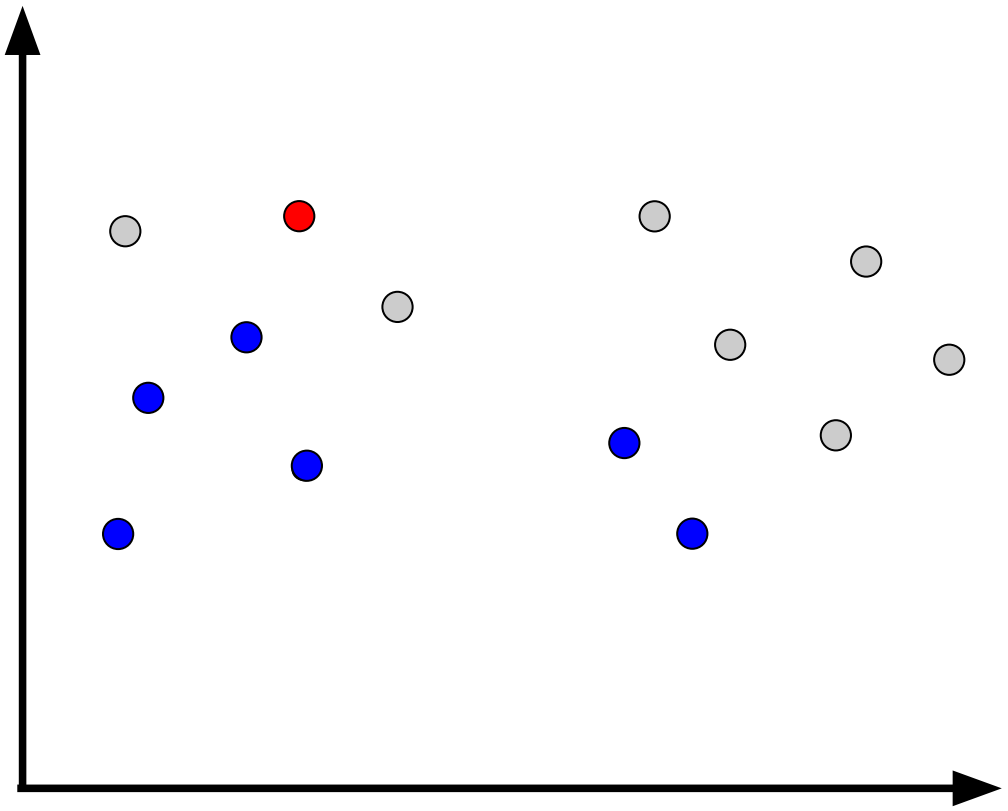


Clustering / k-Means



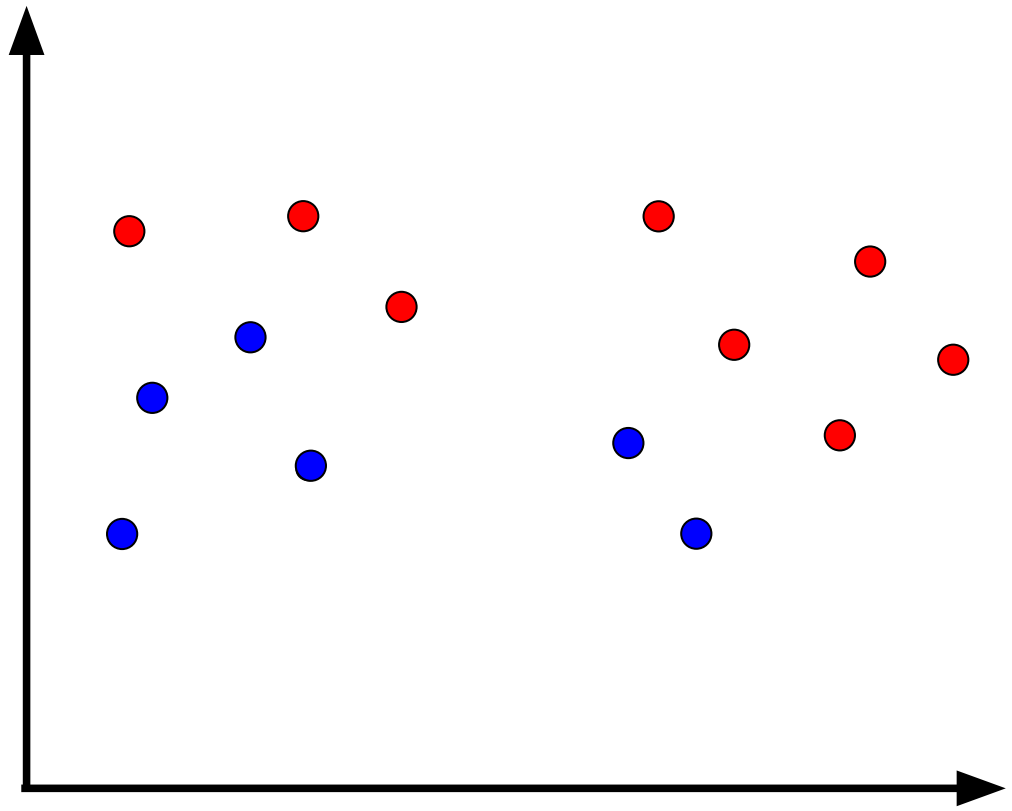
Para *k*=2, elegir aleatoriamente dos semillas entre los ejemplos

Clustering / k-Means



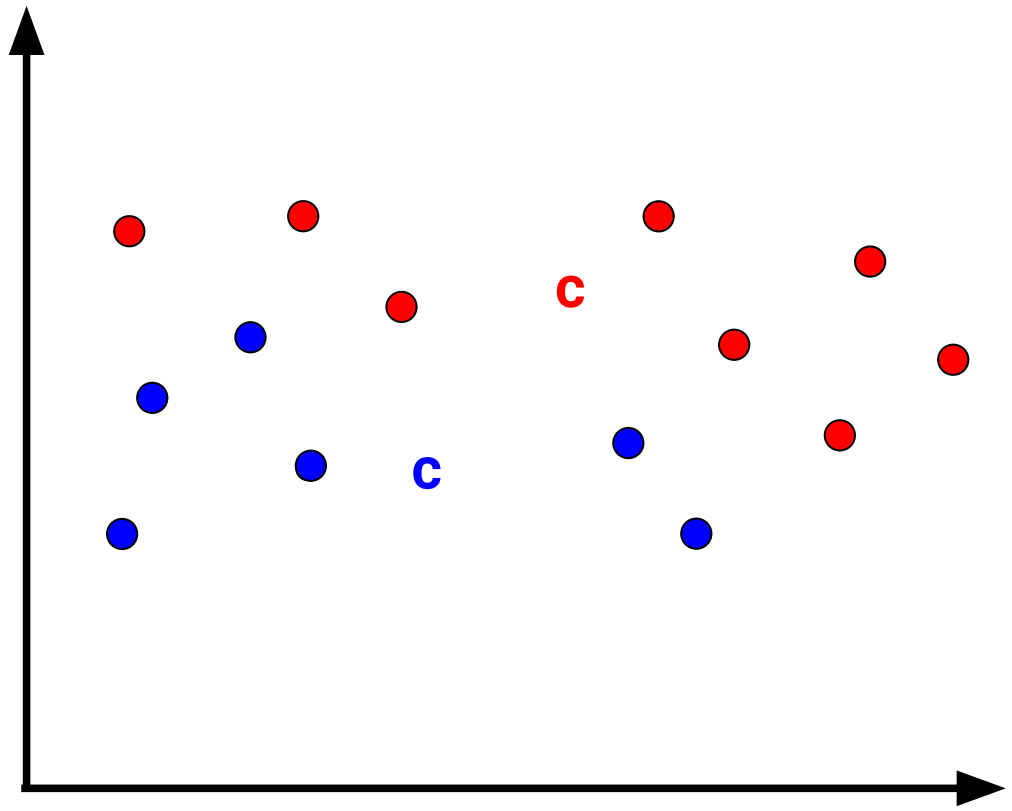
Asignar los ejemplos al centroide más cercano

Clustering / k-Means



Asignar los ejemplos al centroide más cercano

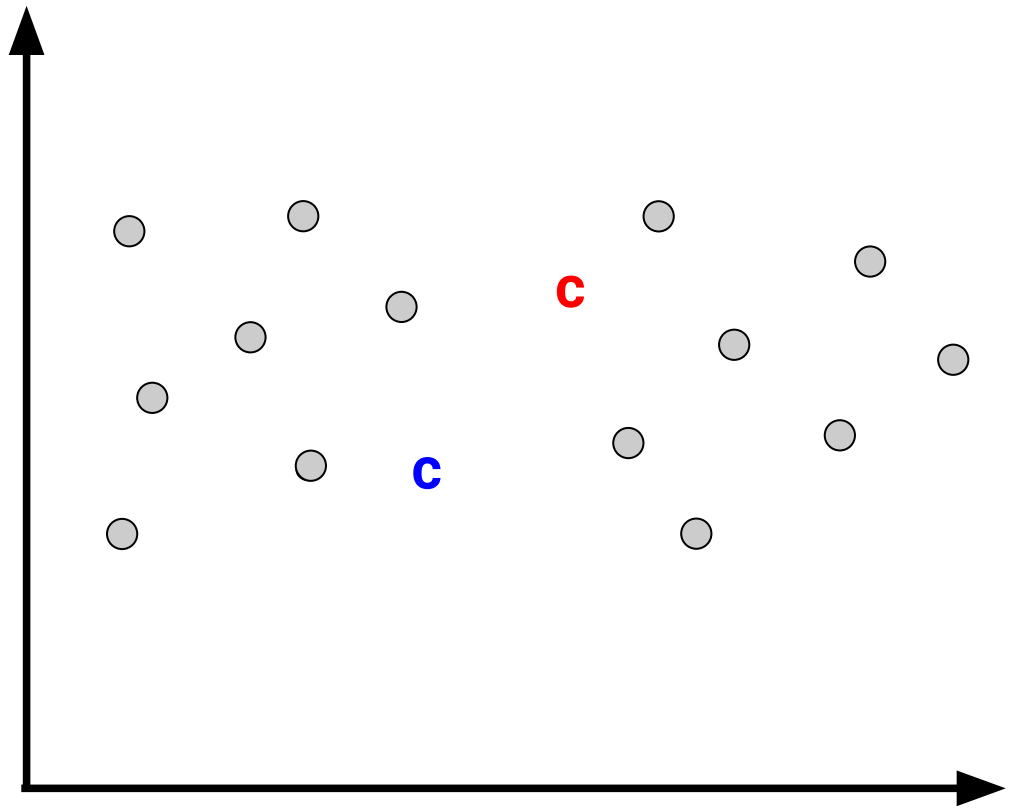
Clustering / k-Means



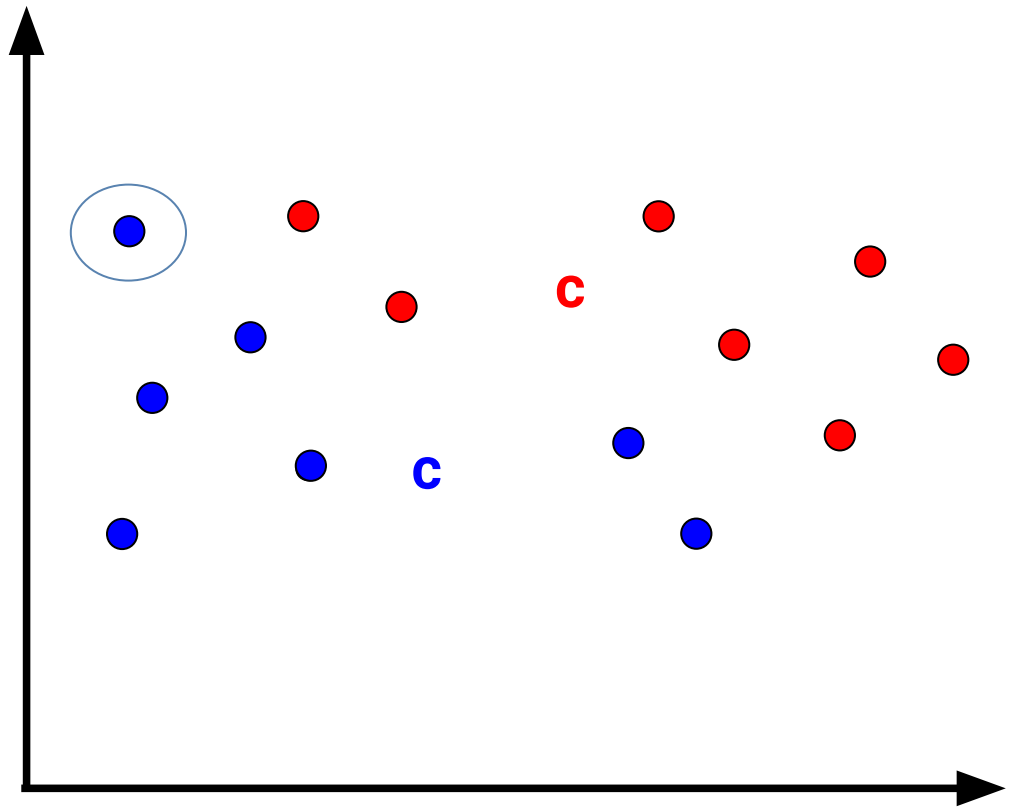
Calcular los nuevos centroides para el actual particionamiento

Exploración de Datos

Clustering / k-Means

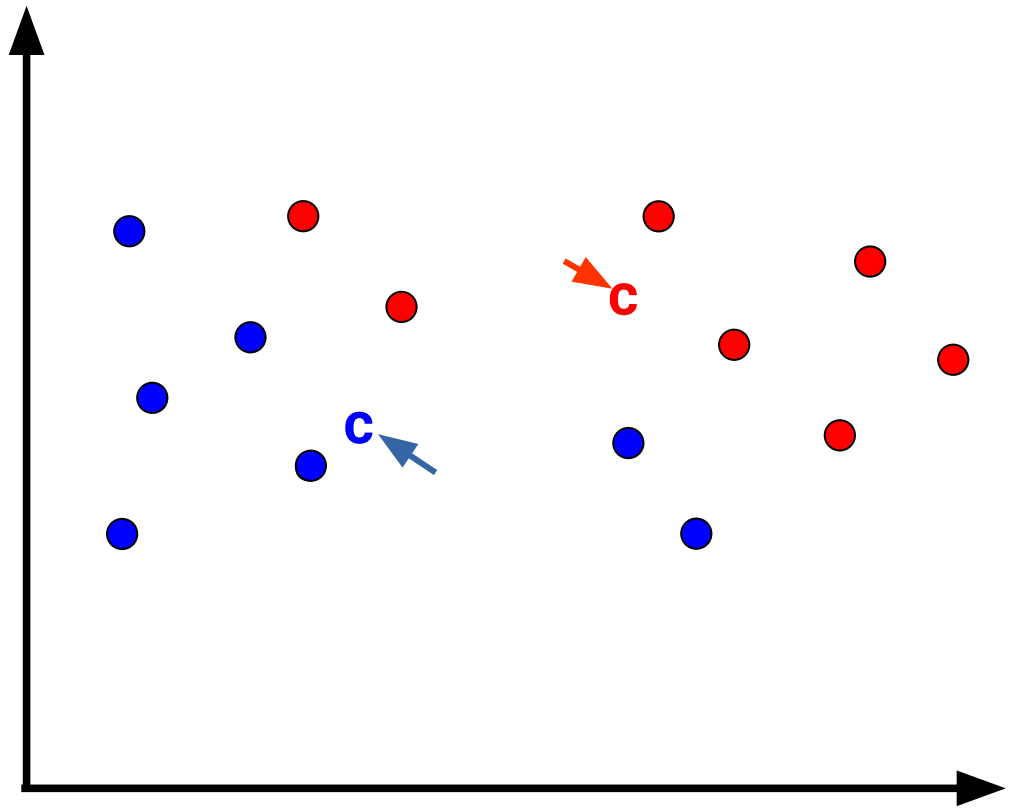


Clustering / k-Means



Asignar los ejemplos al centroide más cercano

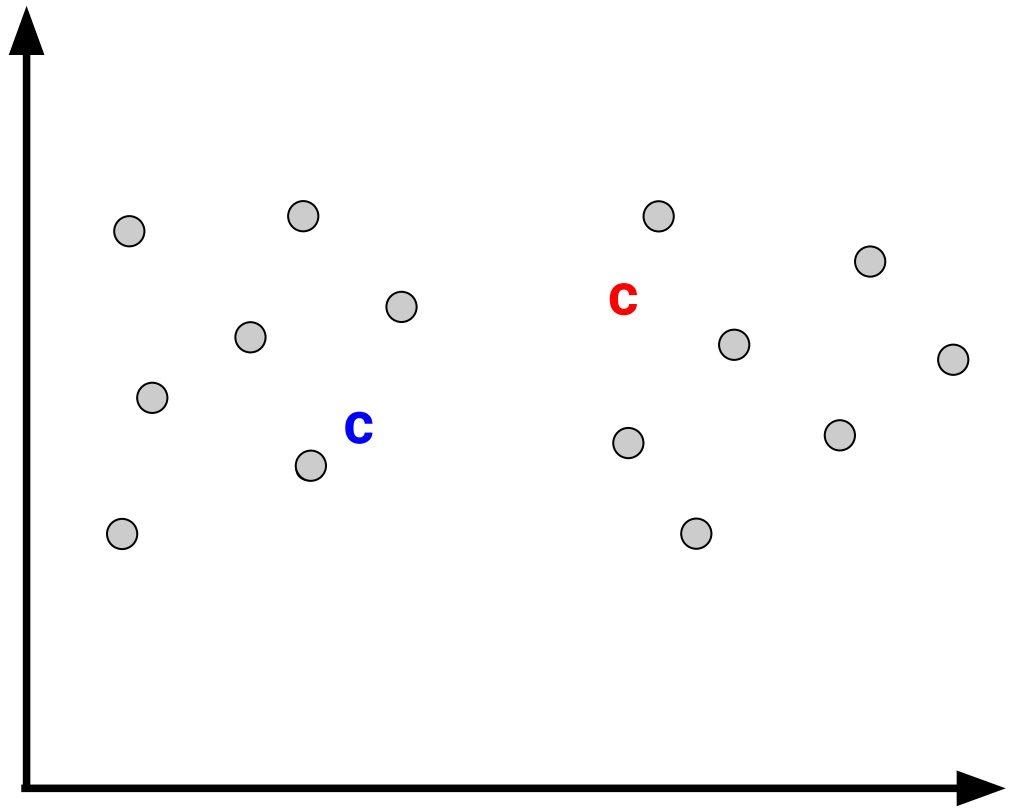
Clustering / k-Means



Calcular los nuevos centroides para el actual particionamiento

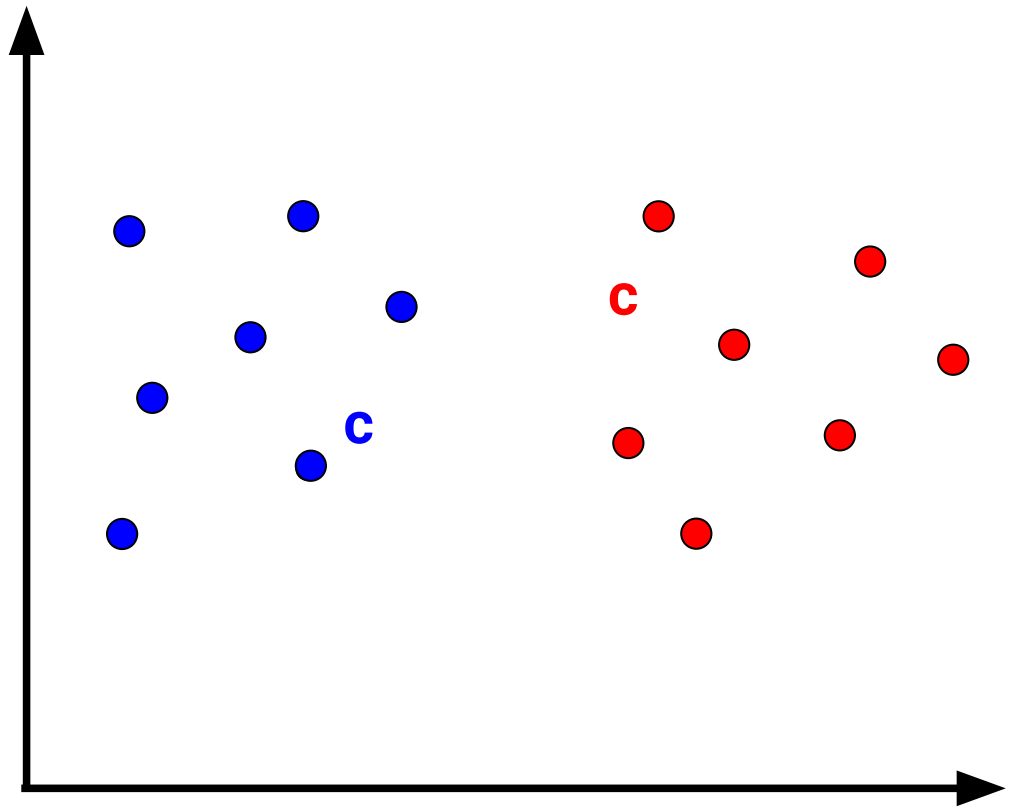
Exploración de Datos

Clustering / k-Means



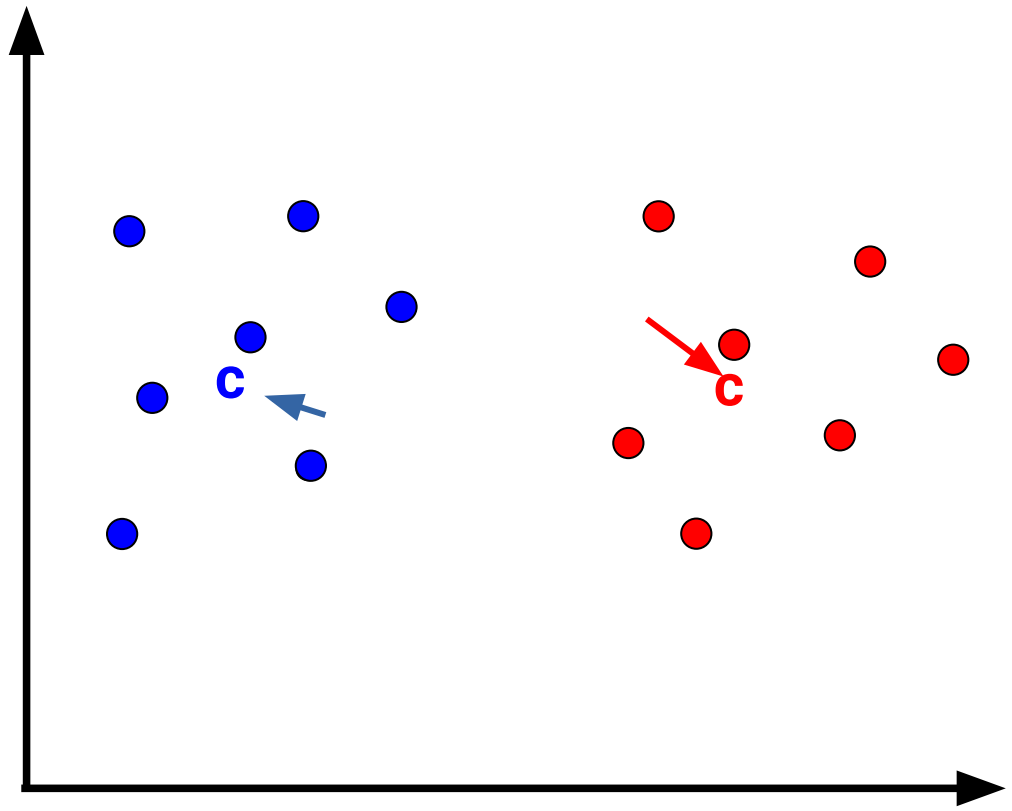
Exploración de Datos

Clustering / k-Means

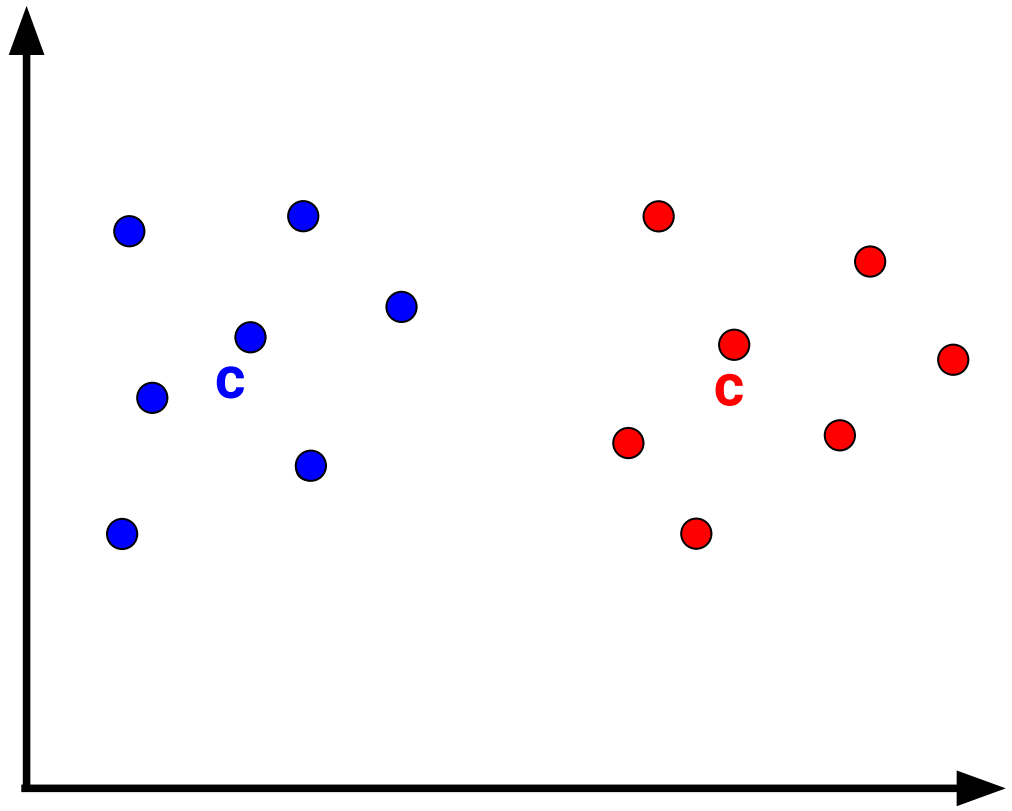


Exploración de Datos

Clustering / k-Means



Clustering / k-Means



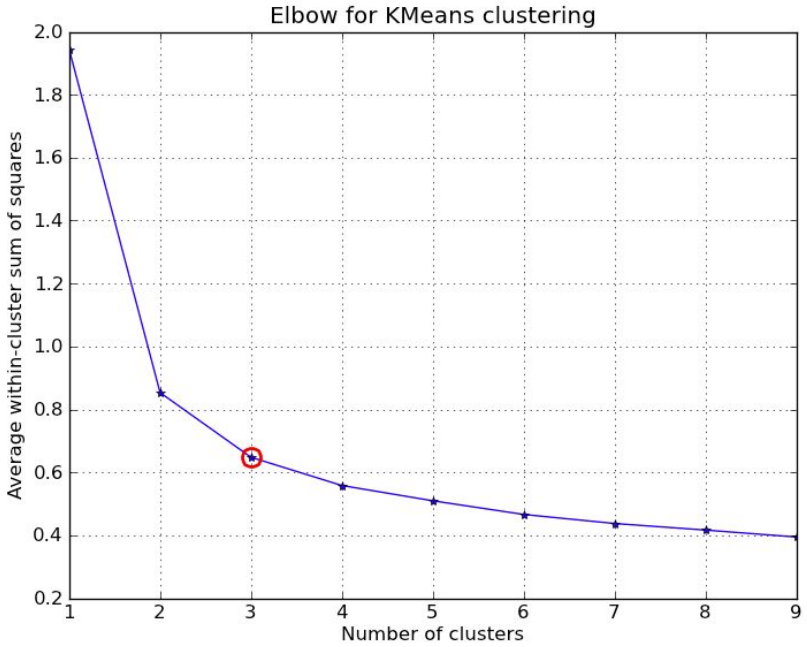
Los ejemplos no cambian de cluster, se satisface el criterio de terminación

Clustering / k-Means

Elbow plot

- Es una herramienta gráfica que nos permite elegir el valor óptimo de K para nuestros datos.
- Grafica el número de clusters (K) vs. la suma de distancias al cuadrado entre todas las observaciones y los centroides.
- Como en K-Means esa suma se reduce a medida que aumentamos K, tiene un perfil monótono decreciente
  - Si K = número de muestras, entonces la distancia entre cada muestra y el centroide (si misma) es 0.
- **Punto óptimo: el codo (donde cae el ritmo de decrecimiento!)**

$$\arg\min_{C} = \sum_{i=1}^{k} \sum_{x_j \in C_i} | \, x_j - \mu_i \, |^2$$



Clustering / k-Means

Pros

- Simple y eficiente dentro de los algoritmos de particionamiento

Cons

- Necesita establecer ***k* de antemano**
- Sensible a ruido y outliers, puede caer en mínimos locales
- Sensitivo a la elección de las semillas iniciales
  - según las semillas puede tener mejores tazas de convergencia
  - la selección de semillas puede basarse en heurísticas o resultados obtenidos con otros métodos
- Es aplicable cuando es posible calcular el centroide (*k*-Modes para atributos categóricos)

Clustering / Clustering jerárquico

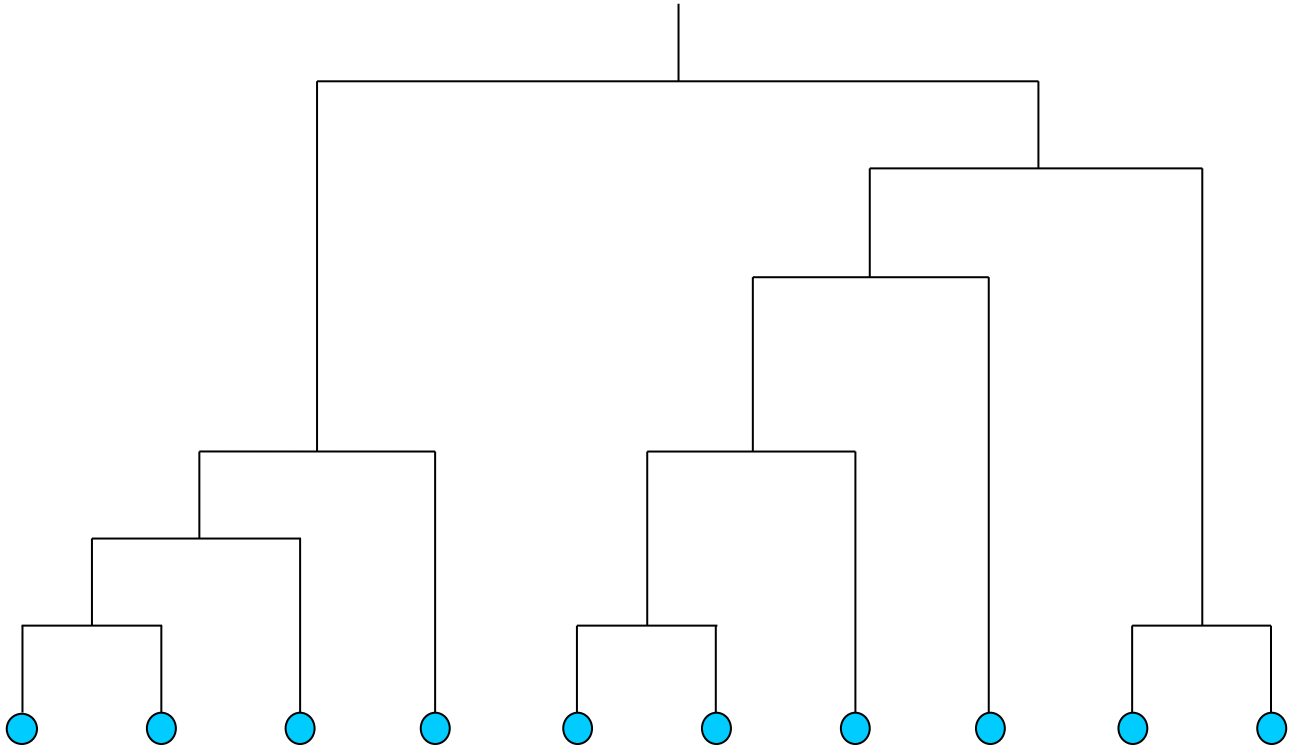
Métodos de clustering jerárquico:

Aglomerativo (bottom-up): métodos que comienzan con cada observación en un cluster diferente y combinan iterativamente los clusters en clusters de mayor tamaño

Divisivo (top-down): métodos que comienzan con todos las observación en un mismo cluster y los separan sucesivamente en clusters de menor tamaño

Clustering / Jerárquico aglomerativo

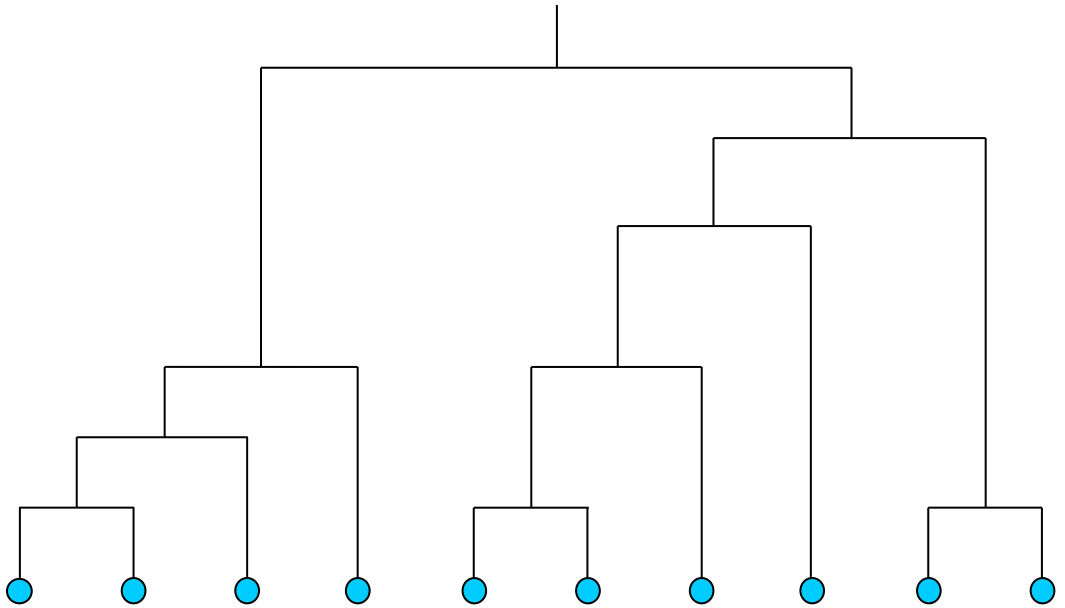
Los algoritmos jerárquicos aglomerativos construyen un árbol binario o **dendograma** a partir de un conjunto de ejemplos



Clustering / Jerárquico aglomerativo

Un dendograma muestra cómo se combinan los clusters

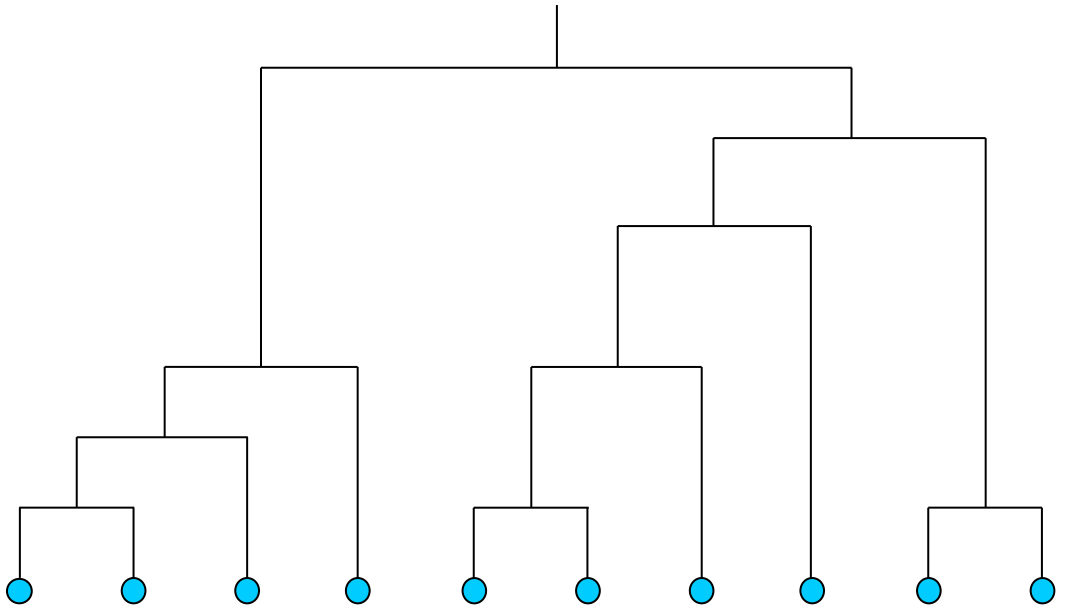
- La raíz contiene todas las observaciones y las hojas los ejemplos individuales
- Cortando en diferentes niveles se obtiene distinto número de clusters



Clustering / Jerárquico aglomerativo

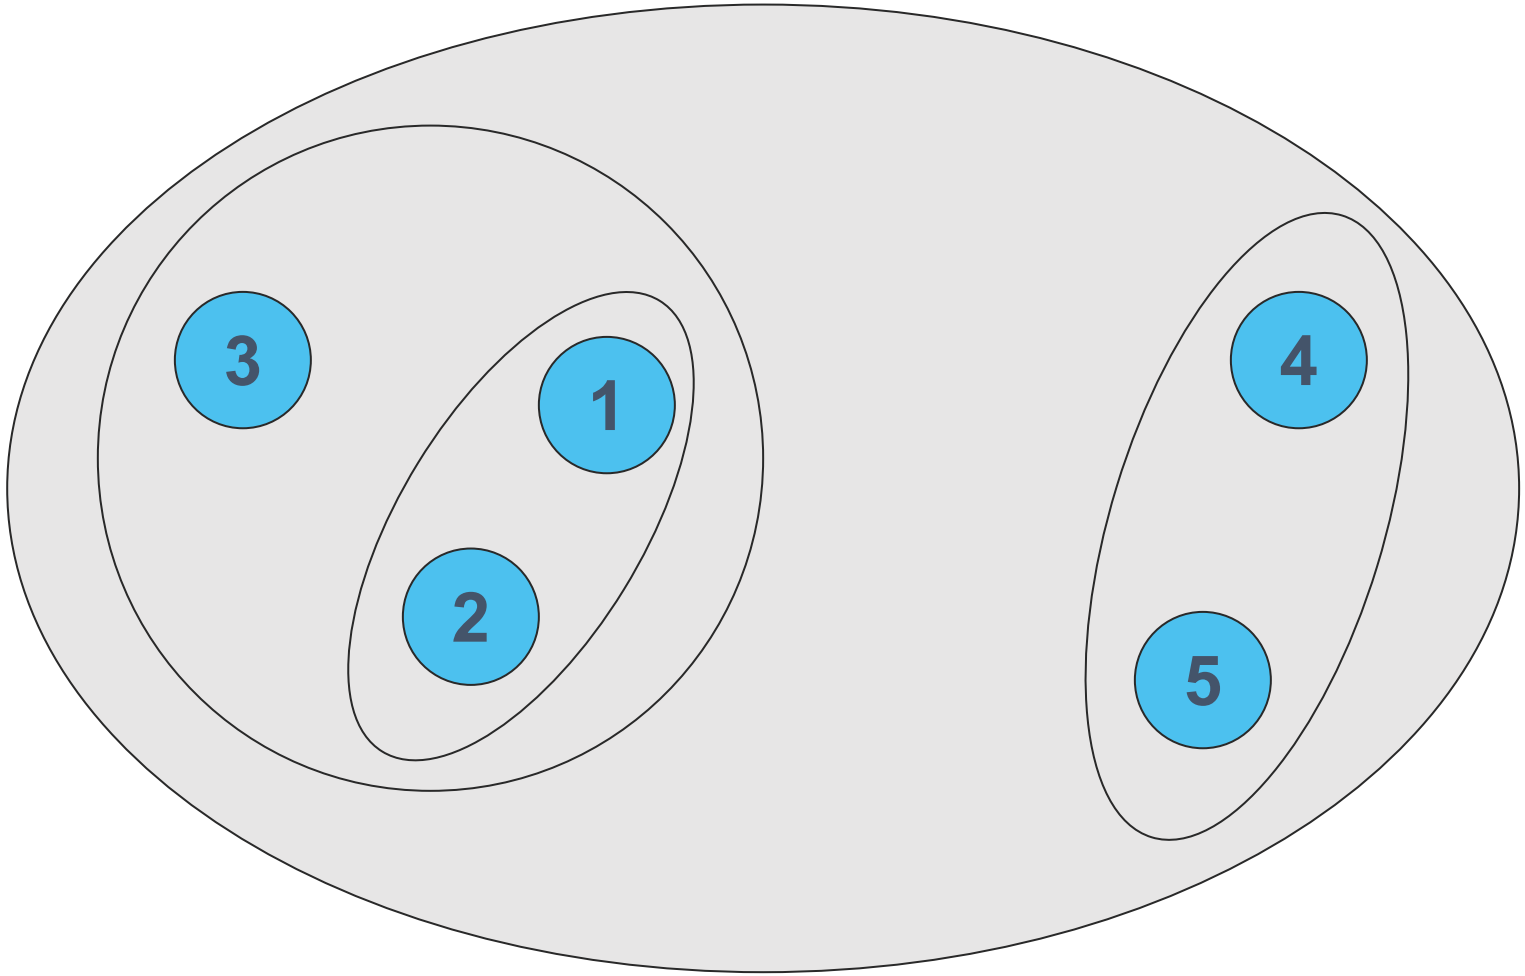
Un dendograma muestra cómo se combinan los clusters

- La raíz contiene todas las observaciones y las hojas los ejemplos individuales
- Cortando en diferentes niveles se obtiene distinto número de clusters



Exploración de Datos

Clustering / Jerárquico aglomerativo



Clustering / Jerárquico aglomerativo

El clustering aglomerativo jerárquico se desarrolla en los siguientes pasos:

1. Asignar cada ejemplo a un cluster diferente (*n* ejemplos, *n* clusters)
2. Encontrar el par de **clusters más similares** y combinarlos en uno único
3. Calcular las similitudes o distancias entre el nuevo cluster y los clusters restantes
4. Hasta que solo quede un cluster de tamaño *n*, volver a 2

Clustering / Jerárquico aglomerativo

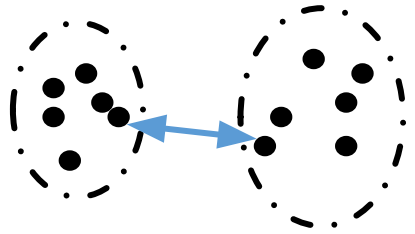
Función de similitud entre observaciones: determina la similitud/distancia entre dos observaciones individuales

Función de similitud entre clusters: determina la similitud de dos clusters conteniendo múltiples ejemplos

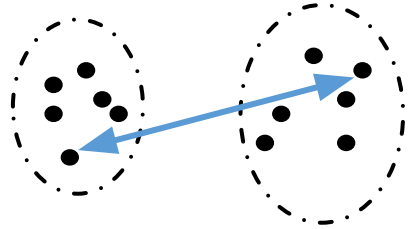
- Single link
- Complete link
- Group average

Clustering / Jerárquico aglomerativo

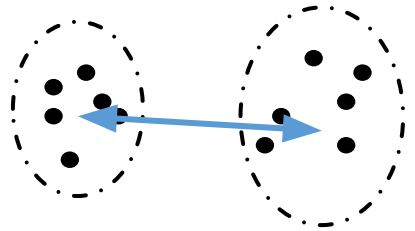
Single link: la similitud de los clusters está dada por los dos ejemplos más similares entre ambos



Complete link: la similitud de los clusters está dada por los dos ejemplos menos similares entre ambos



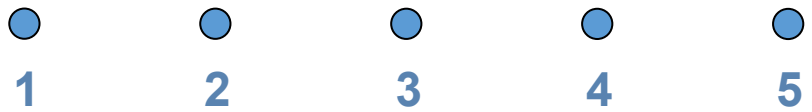
Group average: la similitud es el promedio las similitudes entre los ejemplos de ambos clusters



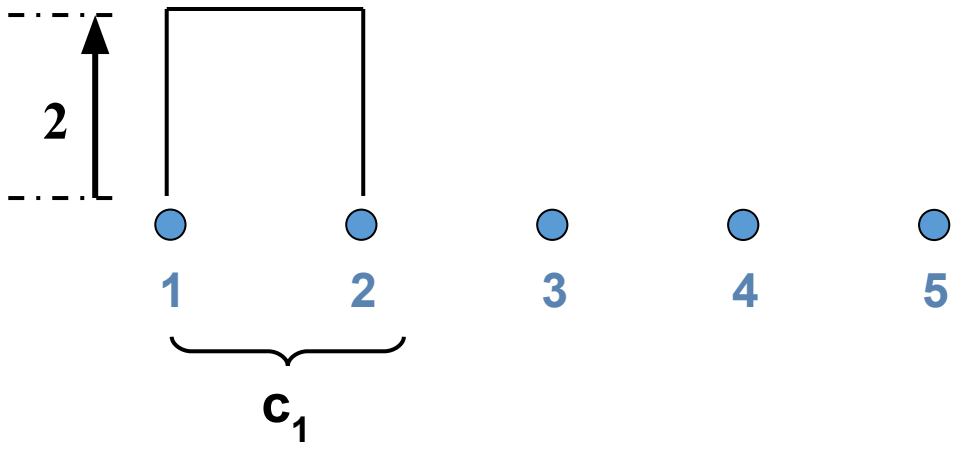
Exploración de Datos

Clustering / Jerárquico aglomerativo

	1	2	3	4	5
1	0				
2	2	0			
3	6	3	0		
4	10	9	7	0	
5	9	8	5	4	0

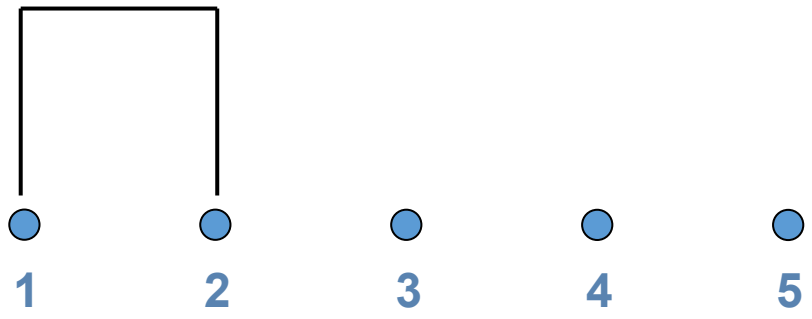


Clustering / Jerárquico aglomerativo



	1	2	3	4	5
1	0				
2	2	0			
3	6	3	0		
4	10	9	7	0	
5	9	8	5	4	0

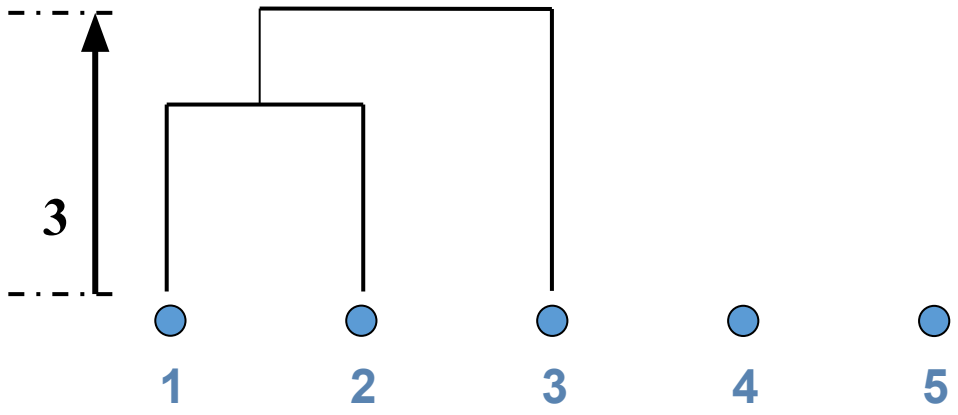
Jerárquico Aglomerativo



	1,2	3	4	5
1,2	0			
3	3	0		
4	9	7	0	
5	8	5	4	0

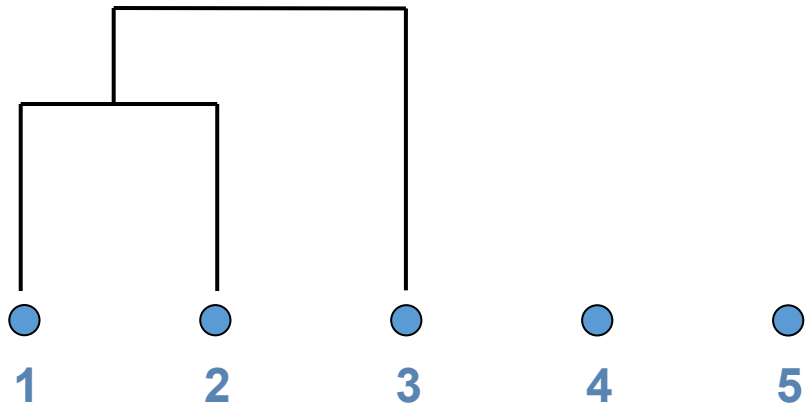
$$d_{(1,2),3} = \min\{d_{1,3}, d_{2,3}\} = \min\{6,3\} = 3$$
$$d_{(1,2),4} = \min\{d_{1,4}, d_{2,4}\} = \min\{10,9\} = 9$$
$$d_{(1,2),5} = \min\{d_{1,5}, d_{2,5}\} = \min\{9,8\} = 8$$

Clustering / Jerárquico aglomerativo



	1,2	3	4	5
1,2	0			
3	3	0		
4	9	7	0	
5	8	5	4	0

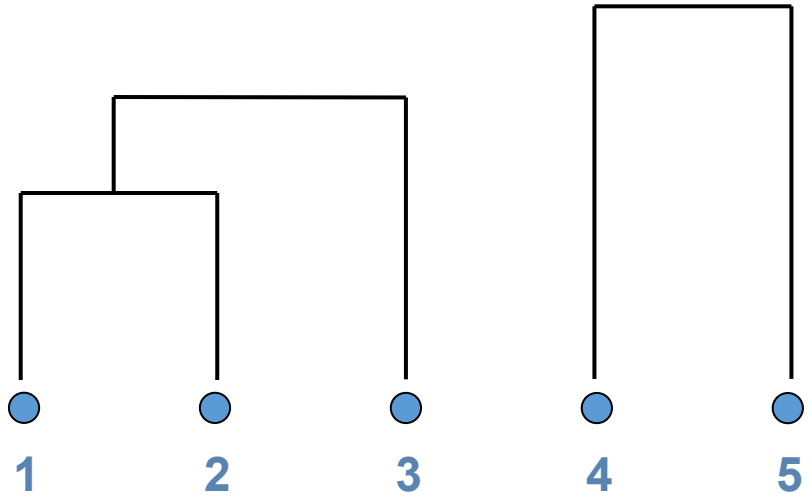
Clustering / Jerárquico aglomerativo



	1,2,3	4	5
1,2,3	0		
4	7	0	
5	5	4	0

$$d_{(1,2,3),4} = \min\{d_{(1,2),4}, d_{3,4}\} = \min\{9,7\} = 7$$
$$d_{(1,2,3),5} = \min\{d_{(1,2),5}, d_{3,5}\} = \min\{8,5\} = 5$$

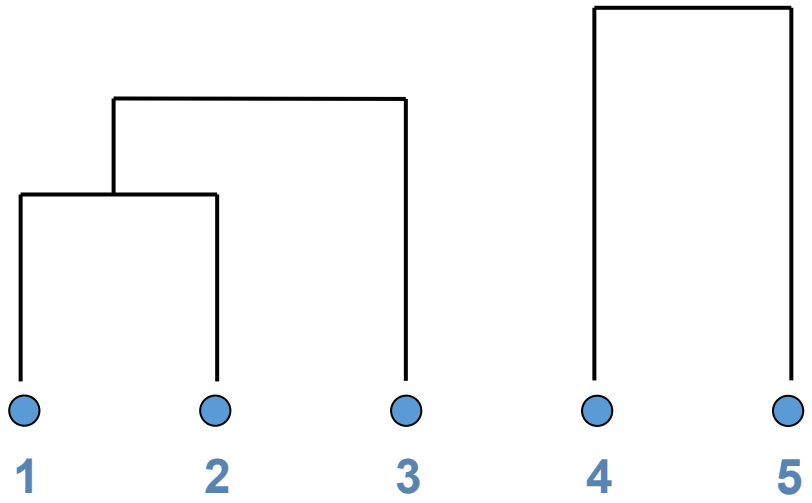
Clustering / Jerárquico aglomerativo



	1,2,3	4	5
1,2,3	0		
4	7	0	
5	5	4	0

Clustering / Jerárquico aglomerativo

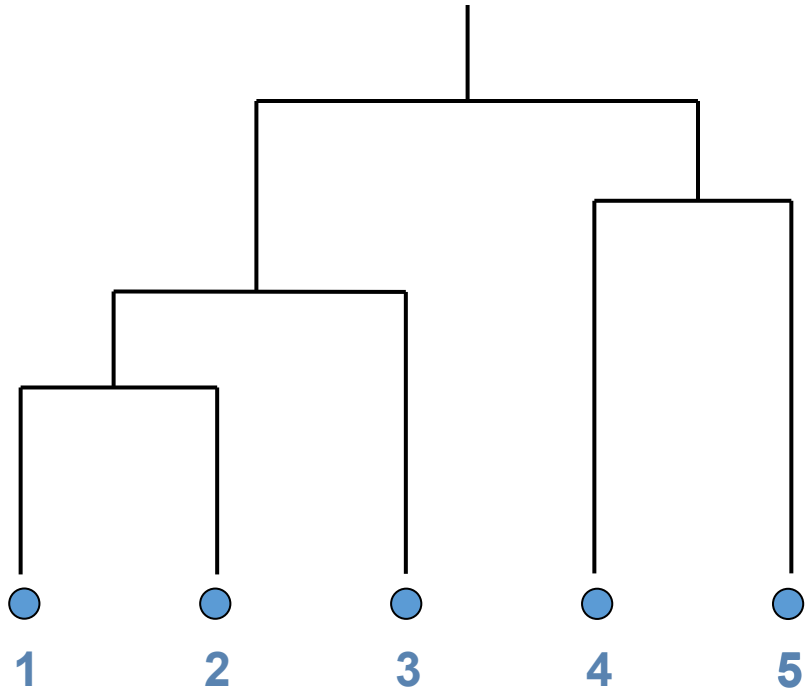
	1,2,3	4,5
1,2,3	0	
4,5	5	0



$$d_{(1,2,3),(4,5)} = \min\{d_{(1,2,3),4}, d_{(1,2,3),5}\} = 5$$

Exploración de Datos

Clustering / Jerárquico aglomerativo

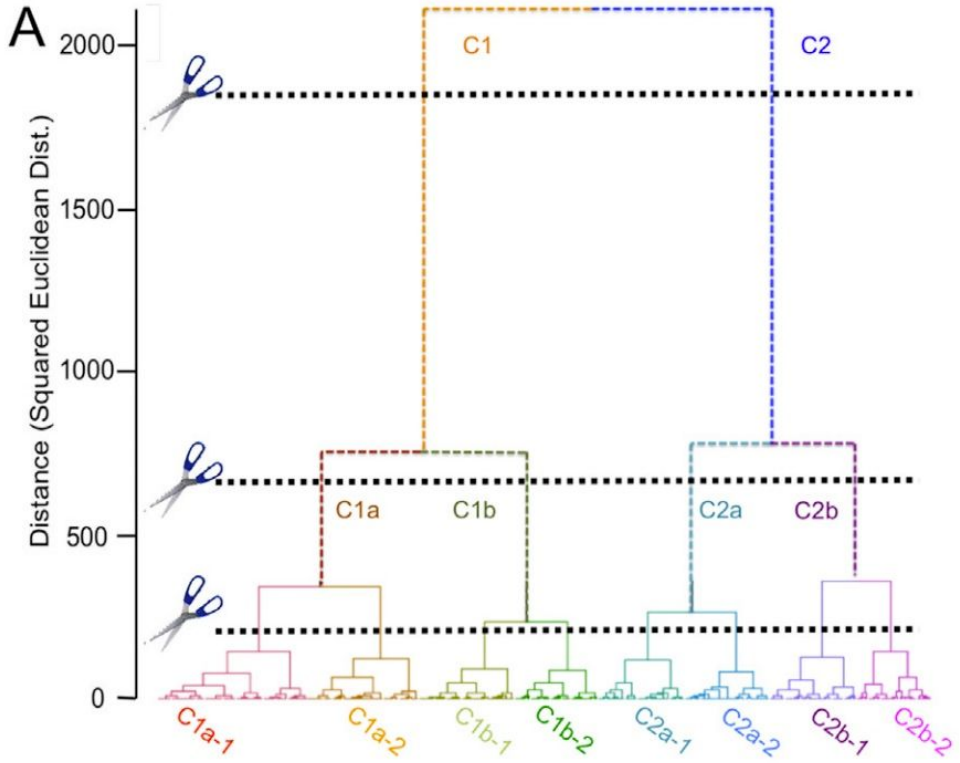


	1,2,3	4,5
1,2,3	0	
4,5	5	0

Exploración de Datos

Clustering / Jerárquico aglomerativo

- El dendrograma me permite estudiar muchas soluciones en un solo gráfico.
- Puedo elegir el número de clusters haciendo cortes verticales en el dendrograma
- Repito luego el clustering aglomerativo indicando ese número de clusters para obtener la respuesta final



Clustering / Jerárquico aglomerativo

Pros

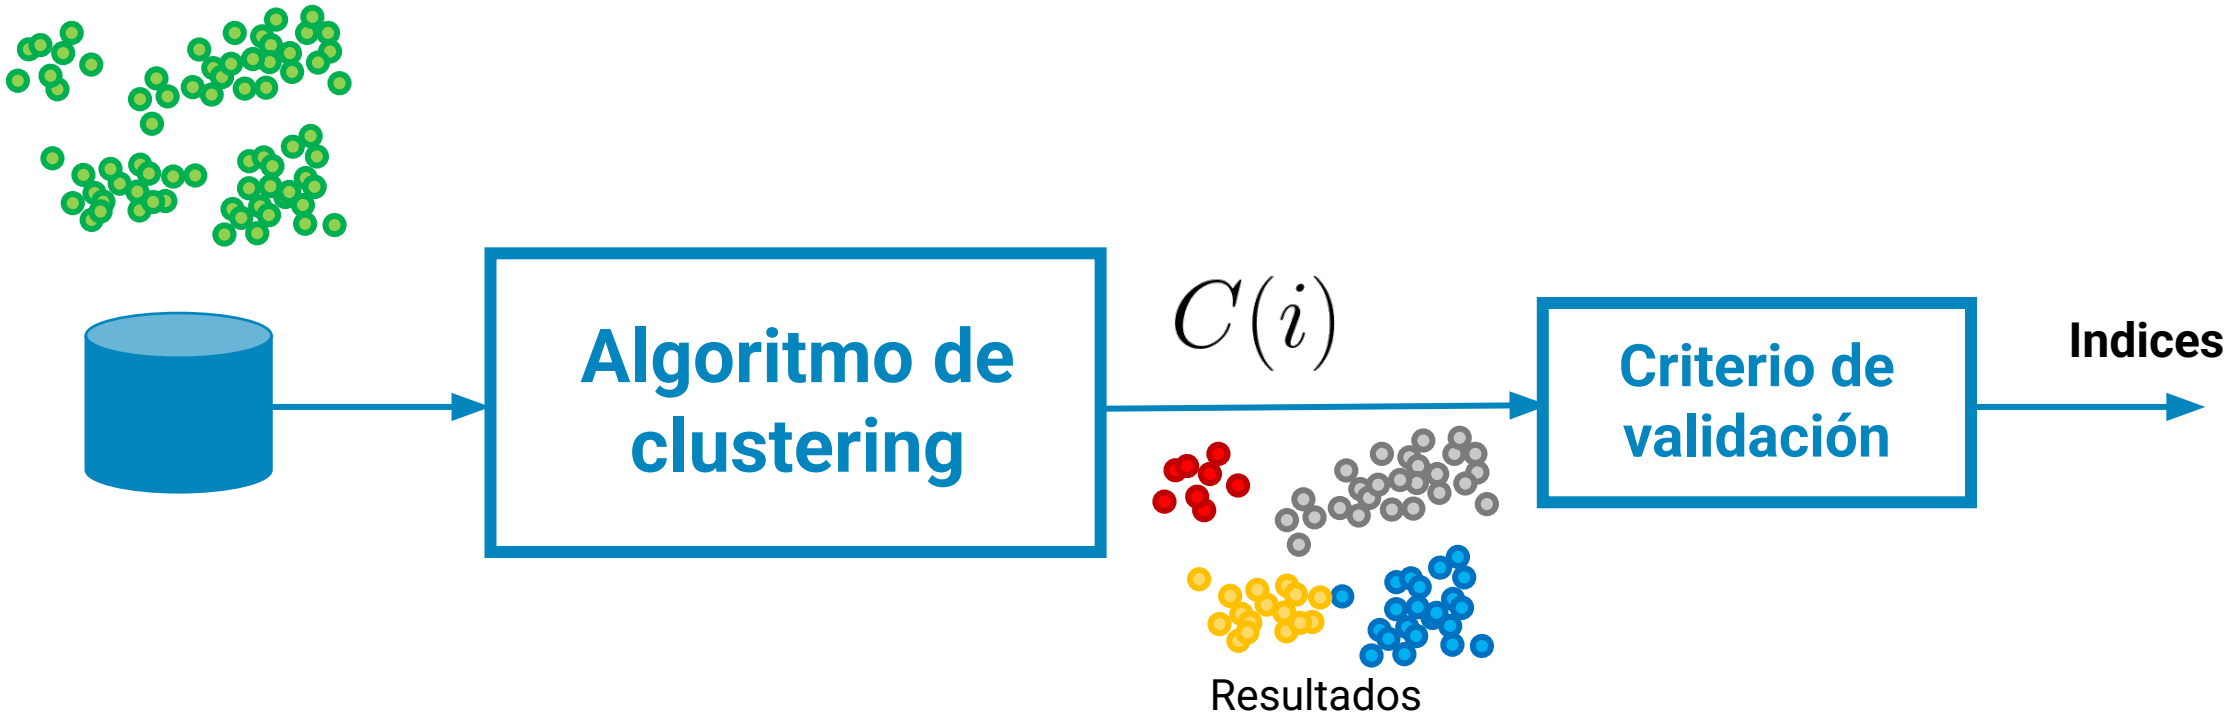
- No se necesita especificar el número de clusters de antemano
- La estructura jerárquica ofrece una forma natural de navegar los datos, más rico para análisis que el particionamiento

Cons

- No escala bien en el número de ejemplos, costoso computacionalmente
- No se recupera de decisiones incorrectas

Clustering / Validación

Validación de clustering: se refiere a la evaluación de los resultados de clustering de una forma cuantitativa y objetiva



Clustering / Validación

Criterios de validación: un criterio de validación es una estrategia que emplea una serie de índices o medidas numéricas para medir distintos aspectos del agrupamiento

- **Indices internos**: se usan para medir la bondad de un agrupamiento sin información externa
- **Indices externos**: se usan para medir el grado en que las etiquetas en los clusters coinciden con etiquetas de clases dadas

Clustering / Validación

Criterio interno: el **ground truth** (clases reales) rara vez está disponible, pero la validación debe realizarse de todos modos

Minimizar o maximizar un **índice interno**:

- Overall Similarity
- Sums of Squares (cohesión/separación)
- Silhouette Coefficient

Clustering / Validación

Overall Similarity: cuanto mayor es el valor mejor el agrupamiento

$$OS = \sum_{j=1}^{k} \frac{n_j}{n} \sum_{x \in C_j}^{n} \sum_{y \in C_j}^{n} \frac{sim(x,y)}{\mid n_j \mid^2}$$

siendo *k* el número de clusters y *n* el número de observaciones

Clustering / Validación

Davies-Bouldin Index

Nos da pistas respecto a:

- Qué tan separados están los clusters entre sí
- Qué tan densos son internamente

Promedio de las dispersiones y distancias entre los clusters

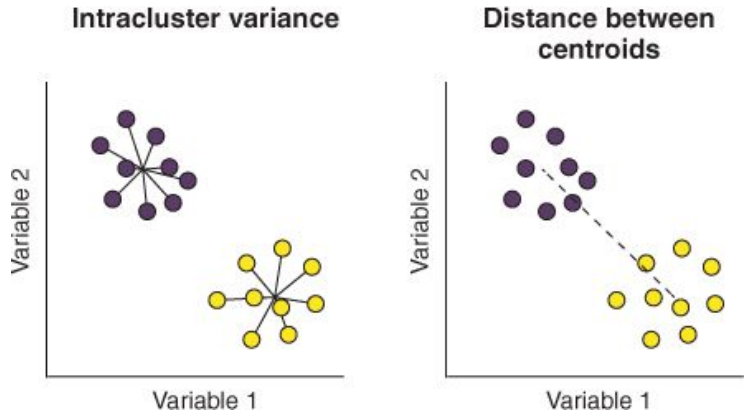
Cuanto más bajo, mejor

Cantidad de clusters

Desvíos de cada cluster respecto del centroide (intracluster)

$$DB = \frac{1}{k}\sum_{i=1}^{k} \max_{j \neq i} \left(\frac{\Delta(X_i) + \Delta(X_j)}{\delta(X_i, X_j)} \right)$$

Distancia entre centroides(intercluster)



Clustering / Validación

Dunn Index

Misma idea que el DB Index: mejora cuando los clusters están alejados entre sí y son densos

Cociente entre la distancia más chica entre centroides y el máximo de distancia interna en el cluster

Cuanto más alto, mejor

Si numerador es alto (la distancia más chica entre clusters es alta) y el denominador es bajo (las distancias dentro de un cluster son chicas)

Distancia entre centroides

$$DI_m = \frac{\min_{1 \leq i < j \leq m} \delta(C_i, C_j)}{\max_{1 \leq k \leq m} \Delta_k}$$

Distancia entre las muestras de un cluster

Clustering / Validación

Cohesión, mide qué tan cercanas están las observaciones en un cluster
Separación: mide qué tan distintos o bien separados están los clusters entre sí

WSS (Within Cluster Sums of Squares) donde la cohesión se mide por la suma de cuadrados dentro del cluster:

Minimizar

$$WSS = \sum_{j=1}^{k} \sum_{x \in C_j} d\left(x, \overline{x}_{C_j}\right)^2$$

k es el número de clusters
$\overline{x}_{C_j}$ el centroide del cluster C_j

La separación se mide por la suma de cuadrados entre clusters BSS (Between Cluster Sums of Squares):

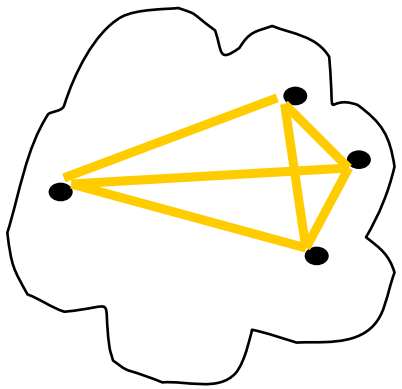
Máximizar

$$BSS = \sum_{j=1}^{k} \mid C_j \mid \cdot d\left(\overline{x}_{C_j}, \overline{x}\right)^2$$

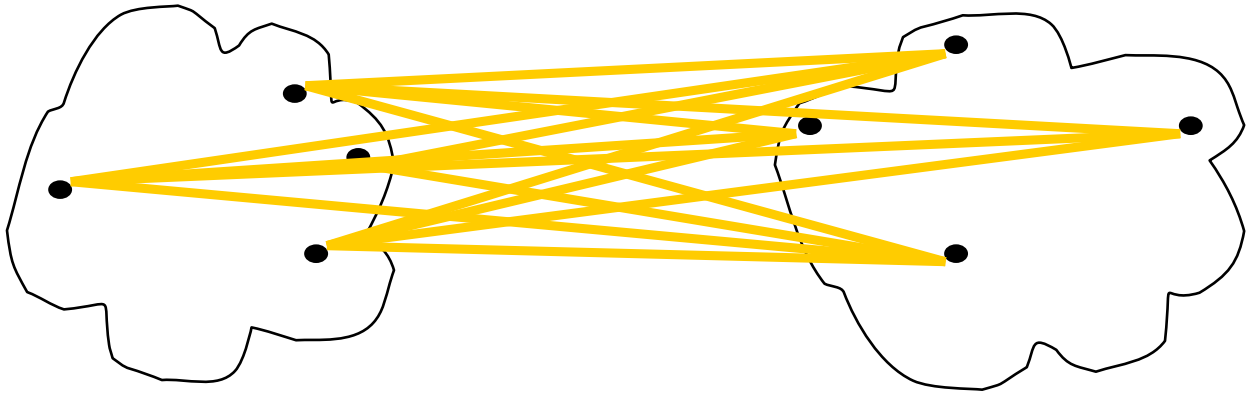
$\overline{x}$ centroide de la muestra

Clustering / Validación

Coeficiente de Silueta (Silhouette): combina las ideas de ambos cohesión y separación



cohesión



separación

Clustering / Validación

a(*i*): es la distancia promedio de *i* a todos los otros vectores en el mismo cluster
b(*i*): es la distancia promedio de *i* a los vectores en otros clusters

$$a(i) = \frac{1}{\mid C_i \mid -1} \sum_{j \in C_i, i \neq j} d(i,j)$$

$$b(i) = \min_{k \neq i} \frac{1}{\mid C_k \mid} \sum_{j \in C_k} d(i,j)$$

coeficiente de silueta, *s*(*i*):

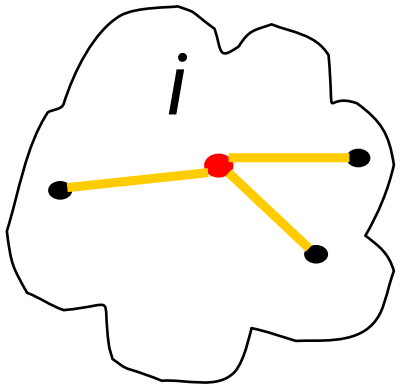
$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}}$$

s(*x*)=[-1,+1] cuanto más cerca de 1 mejor, negativo indicaría que a>b, por lo cuál sería deseable un valor positivo

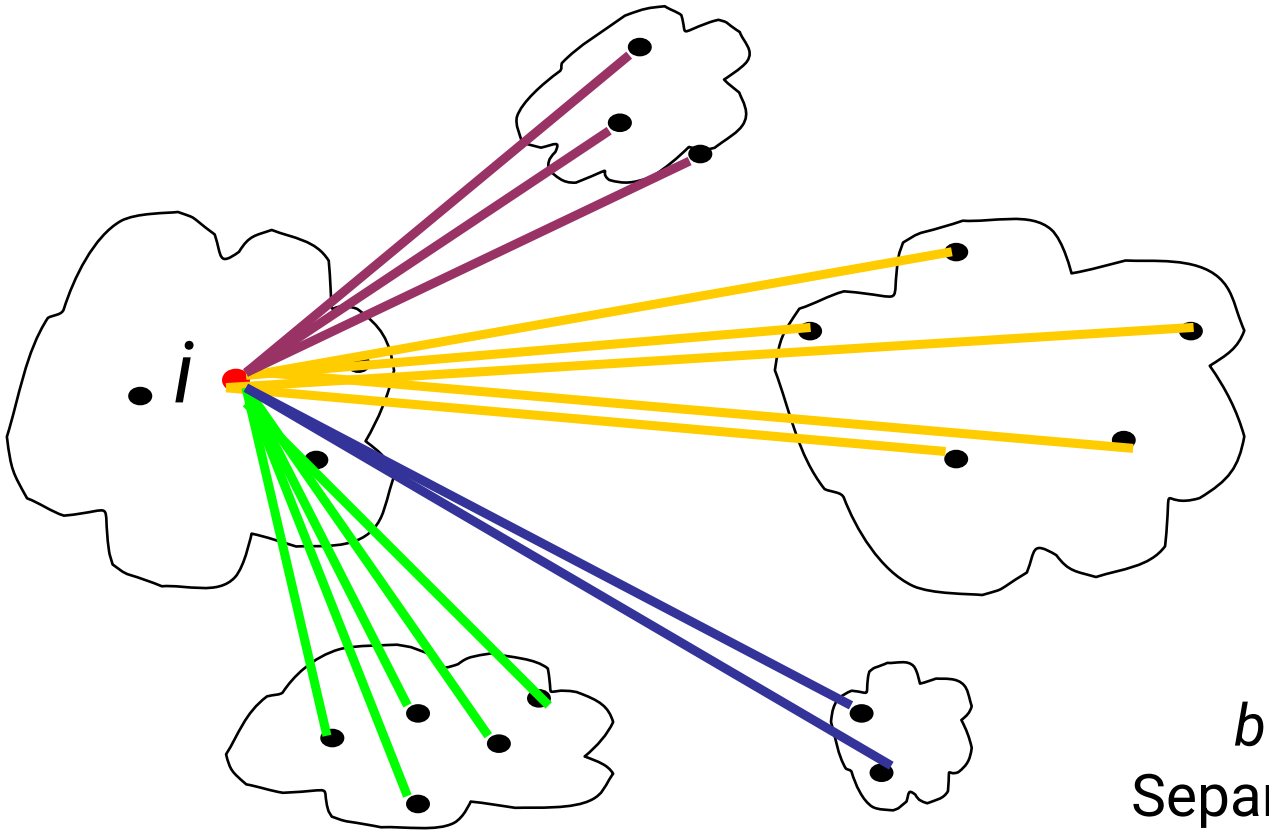
Clustering / Validación

Coeficiente de Silueta (Silhouette Coefficient, SC):

$$SC = \frac{1}{N}\sum_{i=1}^{N} s(i)$$



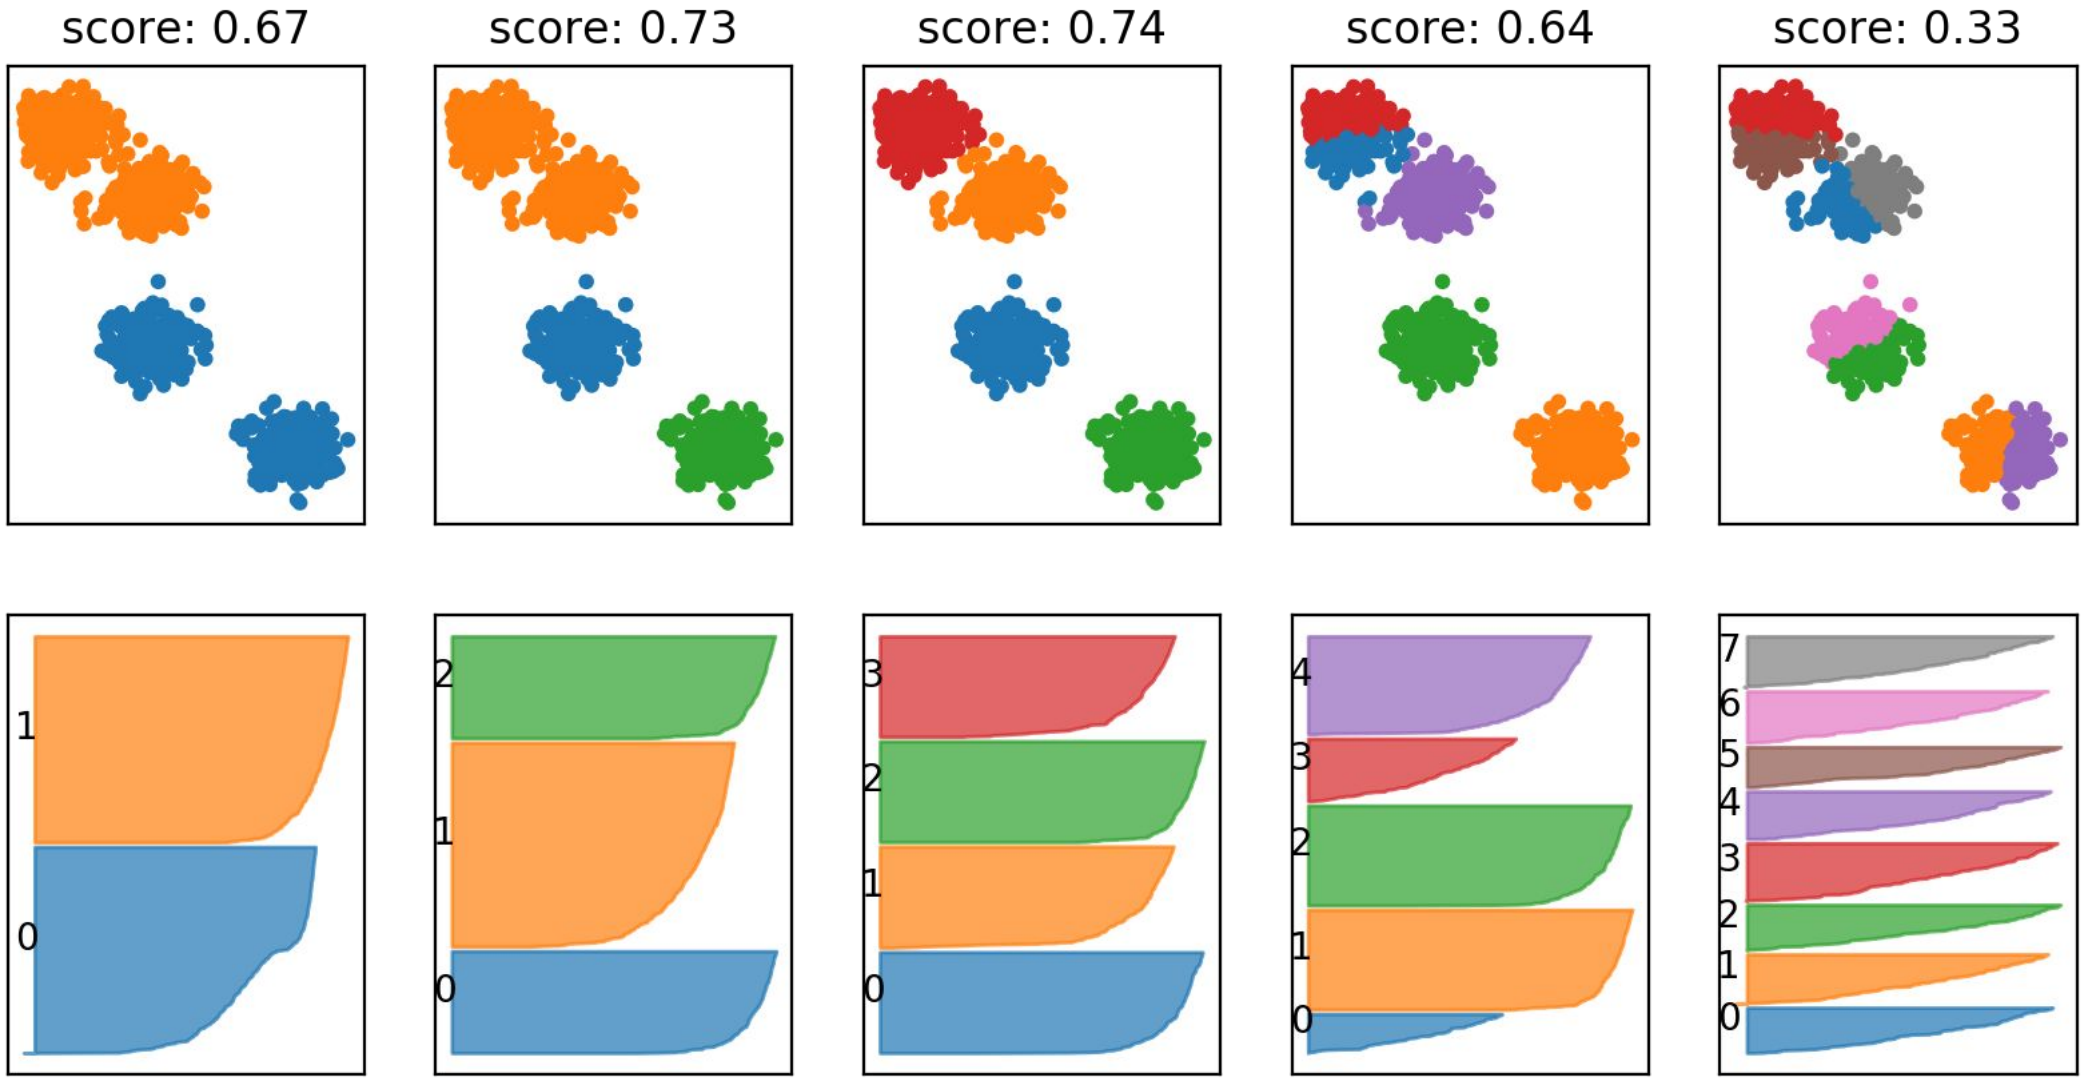
a(*i*)
Cohesión



b(*i*)
Separación

Exploración de Datos

Clustering / Validación



Clustering / Validación

Criterio externo: la calidad se mide por la capacidad de descubrir alguno o todos los patrones ocultos en los datos o clases latentes

Medir el clustering respecto de un **ground truth** requiere **datos etiquetados**

- Asume ejemplos pertenecientes a $C=\{c_1,\ldots,c_n\}$ clases, mientras que los algoritmos de clustering producen $K=\{k_1,\ldots,k_m\}$ clusters

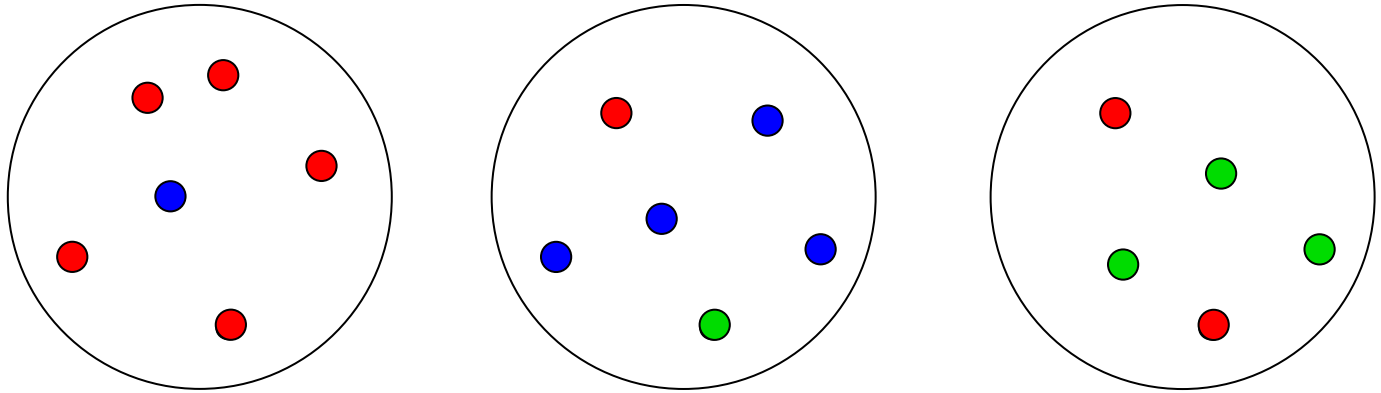
Minimizar o maximizar un **índice externo**:

- Purity
- Entropy
- Rand Index

Clustering / Validación

Purity: radio entre la clase dominante del cluster y su tamaño (sesgada porque más clusters maximizan la pureza)

$$Purity = \sum_{k=1}^{m} \max_{i} (n_{ki})$$



Cluster 1 Cluster 2 Cluster 3

Purity(cluster 1)= 1/6 * max{5,1,0}=5/6
Purity(cluster 2)= 1/6 * max{1,4,1}=4/6
Purity(cluster 3)= 1/5 * max{2,0,3}=3/5

Clustering / Validación

Entropy

Distribución de las clases: p_{ij} es la probabilidad que un miembro del cluster *j* pertenezca a la clase *i*

Entropía de un cluster *j*:

$$H_j = -\sum_{i=1}^{n} p_{ij} \log_2 p_{ij}$$

Entropy total:

$$H(C, K) = -\sum_{j=1}^{m} \frac{n_{ij}}{n} H_j$$

Clustering / Validación

Homogeneity: cada cluster contiene solo miembros de una clase

$$homogeneity = 1 - \frac{H(C|K)}{H(C)}$$

Completeness: todos los miembros de una misma clase están en el mismo cluster

$$completeness = 1 - \frac{H(K|C)}{H(K)}$$

V-Measure: media armónica de homogeneidad y completitud

$$V - measure = \frac{2 * homogeneity * completeness}{homogeneity + completeness}$$

Clustering / Validación

Medidas basadas en pares: estadísticas para cada par de items

- SS= misma clase, mismo cluster
- SD=mismo cluster, diferente clase
- DS=diferente cluster, misma clase
- DD= diferente cluster, diferente clase

Número de ejemplos	Mismo cluster en el agrupamiento	Clusters diferentes en el agrupamiento
Misma clase en el ground truth	20	24
Diferentes clases en el ground truth	20	72

Clustering / Validación

Rand Index

$$RandIndex = \frac{SS + DD}{SS + SD + DS + DD}$$

Rand Index = 0.68

Número de ejemplos	Mismo cluster en el agrupamiento	Clusters diferentes en el agrupamiento
Misma clase en el ground truth	20	24
Diferentes clases en el ground truth	20	72

Clustering / Validación

Validación del clustering:

- Es una tarea compleja, involucra cierta subjetividad
- Varios índices internos y externos para considerar en forma conjunta
- En casos donde el clustering no es la tarea primaria, es posible evaluarlo a través de la aplicación