Fundamentos de la Ciencia de Datos
Cursada 2026
Práctico 6: Tests de hipótesis

1. Utilizando el conjunto de datos “Life expectancy”, disponible en: https://raw.githubusercontent.com/ignaciorlando/duia-ml-datasets/master/LifeExpectancyWHO/Life_Expectancy_Data.csv:
    a. Realizar todo el preprocesamiento necesario sobre todas las columnas.
    b. Comprobar gráfica y estadísticamente si los países desarrollados tienen un producto per cápita mayor al de los en vías de desarrollo. Seleccionar el mejor test en función del objetivo y el cumplimiento de los supuestos.
    c. Comprobar gráfica y estadísticamente si los países en vías de desarrollo gastan un menor porcentaje de su producto bruto en salud que los países desarrollados. Seleccionar el mejor test en función del objetivo y el cumplimiento de los supuestos.
    d. Comprobar gráfica y estadísticamente si los países en vías de desarrollo tienen una expectativa de vida menor a los desarrollados.
    e. ¿Hay una relación entre la combinación de las variables producto per cápita y porcentaje del producto per cápita invertido en salud y la expectativa de vida? Seleccionar la mejor estrategia para aproximar esta conclusión.
2. Utilizando el conjunto de datos “Life expectancy”, disponible en https://ignaciorlando.github.io/datasets/data-science/Life-Expectancy-Data-Updated.csv y cuya descripción está disponible en el sitio de Kaggle:
    a. Plantear al menos 6 hipótesis bivariadas y probarlas utilizando alguna metodología gráfica y un test de hipótesis. Validar previamente los supuestos.
    b. Agrupar los países por continente y establecer hipótesis según los resultados obtenidos y validarlas estadísticamente empleando los test que mejor se ajusten.
3. Utilizando el conjunto de datos “Health and sleep statistics”, disponible en https://www.kaggle.com/datasets/hanaksoy/health-and-sleep-statistics
    a. Evaluar si hay una diferencia significativa en la calidad del sueño entre hombres y mujeres.
    b. Examinar si el nivel de actividad física (alta vs. baja) afecta significativamente la calidad del sueño.
    c. Comparar la cantidad de pasos diarios entre personas con hábitos alimenticios saludables y no saludables.
    d. Plantear nuevas hipótesis y verificarlas usando herramientas vistas en la materia.

A continuación incluimos algunos ejercicios tipo parcial para que puedan hacer con papel y lápiz para prepararse mejor para el examen.

Ejercicio 1:

Para cada situación:

1. Identifique la variable respuesta y la variable que define los grupos.
2. Determine si las muestras son independientes o relacionadas.
3. Formule hipótesis nula y alternativa.
4. Seleccione el test más apropiado.
5. Indique sus supuestos y cómo los verificaría.
6. Proponga una visualización complementaria.

Situación	**Información disponible**
A	Se desea determinar si la duración media de las películas de una plataforma es diferente de 100 minutos.
B	Se compara la presión arterial entre dos grupos independientes. Los datos son aproximadamente normales, pero las varianzas son diferentes.
C	Se mide la calidad del sueño de las mismas 35 personas antes y después de una intervención. Las diferencias no siguen una distribución normal.
D	Se compara el ancho del sépalo entre tres especies de iris. Los residuos son normales y las varianzas homogéneas.
E	Se compara una escala ordinal de satisfacción entre cuatro servicios. Las distribuciones son asimétricas.
F	Se desea evaluar si la presencia de trastornos del sueño está asociada con la categoría de índice de masa corporal.

Ejercicio 2:

La calidad del sueño se registra mediante una escala entera de 1 a 10. Se desea determinar si existen diferencias entre hombres y mujeres. Suponga que se obtuvieron los siguientes resultados:

Grupo	**nn**	**Media**	**Mediana**	**RIC**
Mujeres	188	7.21	7	2
Hombres	187	6.94	7	2

Shapiro-Wilk, mujeres: $W=0.903$, $p<0.001$
Shapiro-Wilk, hombres: $W=0.917$, $p<0.001$

Mann-Whitney U, bilateral: $U=15940$, $p=0.032$

Responda:

1. Explique por qué la naturaleza de la escala debe considerarse al elegir el test.
2. Formule H0 y H1 para el test utilizado.
3. Interprete el resultado estadístico.
4. ¿Puede concluirse directamente que las medianas poblacionales son diferentes? Indique qué condición adicional permitiría esa interpretación.
5. Analice la diferencia entre significancia estadística y relevancia práctica en este caso.
6. Un estudiante propone repetir el test con `alternative="greater"` porque la media de las mujeres es mayor. Evalúe esa decisión.
7. Proponga una visualización que muestre la distribución completa y no solamente las medias.

Ejercicio 3:

Un programa de ocho semanas busca mejorar la calidad del sueño. Se estudian 28 personas, medidas antes y después de la intervención.

Momento	**Media**	**Desvío**
Antes	6,4	1,3
Después	7,1	1,2
Diferencia después − antes	0,7	1,19

Shapiro-Wilk de las diferencias: W=0.961, p=0.238
Test t apareado: t=3.12, p=0.0043
IC 95% de la diferencia: [0.23, 1.17]

Responda:

1. Explique por qué las dos muestras no son independientes.
2. Formule H0H_0 y H1H_1.
3. ¿Sobre qué valores debe comprobarse el supuesto de normalidad?
4. Justifique la prueba utilizada.
5. Interprete conjuntamente el p-valor y el intervalo de confianza.
6. ¿Qué significa el signo positivo de la diferencia?
7. Explique por qué un test t para muestras independientes desperdiciaría información.
8. ¿Es posible atribuir causalmente el cambio a la intervención si no existió un grupo de control?
9. Indique qué prueba utilizaría si las diferencias fueran fuertemente asimétricas.