Fundamentos de la Ciencia de Datos
Cursada 2026
Práctico 7: Reducción de dimensionalidad

1. Utilizando el conjunto de datos “ObesityDataSet_raw_and_data_sinthetic” trabajado en los prácticos 2 y 3 y 5:
    a. Aplicar PCA únicamente sobre las variables cuantitativas, y graficar las dos principales componentes en un scatter plot.
    b. ¿Cuál es el total de la varianza explicada? ¿Y cuál es el ratio de varianza explicada por cada una de las componentes? ¿alcanzan las dos componentes para obtener una imagen representativa?
    c. Generar diferentes versiones de ese scatter plot, coloreando en gráficas separadas distintos valores de variable categórica. ¿Qué características se observan en los grupos? ¿Es posible separar grupos en función de esas observaciones? Justificar.
    d. Representar las dos componentes principales en un biplot y analizar la influencia de las diferentes variables en cada dimensión.
2. Generar visualizaciones sobre el mismo dataset utilizando t-SNE y UMAP, y comparar los grupos identificados en el punto 1.c.
3. Identificar en el mismo dataset cuántas componentes son necesarias para retener un 95% de la varianza.
4. La pestaña “Proteins” del archivo disponible en https://ignaciorlando.github.io/datasets/data-science/datospractico6csdatos.xlsx corresponde a resultados de un estudio cuyo objetivo era comprender qué alimentos se utilizan como fuentes proteicas en las dietas de los habitantes de países europeos, registrando los alimentos consumidos.
    a. Describir el comportamiento conjunto del consumo de proteínas en los diferentes paises
    b. Realizar PCA y analizar e interpretar la descomposición obtenida. ¿Con cuántas componentes principales recomendarías trabajar con el objeto de reducir la dimensión del problema?
    c. Realizar un biplot
    d. ¿Qué podrías decir del consumo de pescado de estos países?
    e. ¿Qué países consumen mayor cantidad de frutas y verduras?
    f. Describir a Alemania, Polonia e Inglaterra según su consumo de fuentes proteicas.
5. La pestaña “Classic Wines” del archivo disponible en https://ignaciorlando.github.io/datasets/data-science/datospractico6csdatos.xlsx contiene variables clínicas medidas de 178 muestras diferentes de un vino italiano:

- Alcohol: Porcentaje de alcohol en el vino. Indica fuerza, fermentación y estilo del vino.
- Malic acid: Ácido málico (g/l). Ácido orgánico presente en frutas; contribuye a acidez y sabor.
- Ash: Cenizas totales (g/100ml). Representa minerales sólidos después de quemar el vino; indica contenido mineral.

- Alcalinity of ash: Alcalinidad de las cenizas (meq/L). Relacionada con la capacidad tampón del vino; regula acidez.
- Magnesium: Magnesio (mg/L). Mineral que puede influir en la fermentación y la estabilidad del vino.
- Total phenols: Fenoles totales (g/L). Compuestos antioxidantes; afectan color, sabor y propiedades sensoriales.
- Flavanoids: Flavonoides (g/L). Subgrupo de fenoles; influyen en color, sabor y propiedades antioxidantes.
- Nonflavanoid phenols: Fenoles no flavonoides (g/L). Otros compuestos fenólicos presentes, contribuyen al sabor y amargor.
- Proanthocyanins: Proantocianidinas (g/L). Polifenoles que afectan color y astringencia.
- Color intensity: Intensidad del color (absorbancia). Medida espectrofotométrica de la coloración del vino.
- Hue: Matiz o tonalidad del color. Relación entre componentes rojo/amarillo del vino.
- OD280/OD315 of diluted wines: Ratio absorbancia 280/315 nm. Indica concentración de compuestos fenólicos de bajo peso molecular.
- Proline Prolina (mg/L): Aminoácido que puede reflejar madurez de la uva y calidad del vino.

    a. ¿Qué dimensión tiene el espacio de las variables? Realizar un PCA y responder:
        i. ¿Cuál es el porcentaje de variación recuperado con la primera componente principal? ¿Y con las dos primeras? ¿Cuántas componentes principales son necesarias para recuperar el 70% de la variación de los datos? En términos del problema, ¿con cuántas componentes te quedarías y por qué?
        ii. ¿Qué variables explican la primera dirección de variabilidad? Expresar la combinación lineal que define a la primera componente principal.
        iii. Colorear el biplot según la variable cualitativa: se observan grupos? ¿Cuántos? ¿Cuáles? ¿Cómo los describiría? Comparar el grupo de Target 2 con target 0.

6. La pestaña “Arroyos Fco-Qcas” del archivo disponible en https://ignaciorlando.github.io/datasets/data-science/datospractico6csdatos.xlsx contiene información sobre muestreos realizados en aguas de arroyos, donde se registró:

P-PO_4	Fósforo como fosfato (PO_4^{3-})	Nutriente esencial; en exceso causa eutrofización.	mg/L
N-NO_3	Nitrógeno como nitrato (NO_3^-)	Forma oxidada del nitrógeno, relacionada con contaminación agrícola.	mg/L

N-NO_2	Nitrógeno como nitrito (NO_2^-)	Intermedio en el ciclo del nitrógeno, tóxico en altas concentraciones.	mg/L
N-NH_4	Nitrógeno como amonio (NH_4^+)	Producto de descomposición orgánica; indica contaminación reciente.	mg/L
DBO_5	Demanda Bioquímica de Oxígeno (5 días)	Oxígeno requerido por bacterias para degradar materia orgánica biodegradable.	mg/L O_2
DQO	Demanda Química de Oxígeno	Oxígeno requerido para oxidar toda la materia orgánica con un agente químico.	mg/L O_2
CE	Conductividad eléctrica	Mide la capacidad del agua para conducir corriente eléctrica, relacionada con sales disueltas.	µS/cm
OD	Oxígeno disuelto	Cantidad de oxígeno presente en el agua; esencial para la vida acuática.	mg/L O_2

Realizar un PCA para describir y comparar los arroyos y sus características físico químicas. Indicar el porcentaje de variabilidad explicado con 2 componentes principales.

A continuación incluimos algunos ejercicios tipo parcial para que puedan hacer con papel y lápiz para prepararse mejor para el examen.

Ejercicio 1:

El conjunto Classic Wine contiene 178 muestras de vinos, descritas mediante 13 variables químicas y una variable categórica target que identifica tres clases. Se aplicó PCA sobre las 13 variables químicas estandarizadas, excluyendo target. Se obtuvo la siguiente varianza explicada por componente:

Componente	Varianza explicada (%)
CP1	36,20
CP2	19,21
CP3	11,12
CP4	7,07
CP5	6,56
CP6	4,94
CP7	4,24
CP8	2,68

CP9	2,22
CP10	1,93
CP11	1,74
CP12	1,30
CP13	0,80

a. ¿Cuál es la dimensión del espacio original utilizado por PCA? ¿Qué porcentaje de varianza conserva la primera componente y qué porcentaje conservan las dos primeras conjuntamente?

b. ¿Cuántas componentes son necesarias para recuperar al menos el 70 % de la varianza?

c. ¿Recomendaría conservar sólo dos componentes para visualizar los datos? ¿Y para reemplazar las variables originales en un análisis posterior? Justifique diferenciando ambos objetivos.

d. ¿Qué problema introduciría incluir target como una variable numérica más dentro del PCA? Considere qué representan sus valores 0, 1 y 2.

Ejercicio 2:

El conjunto Proteins registra el consumo de nueve fuentes alimentarias en 25 países europeos. El siguiente biplot se obtuvo mediante PCA sobre las variables estandarizadas. Los puntos representan países y las flechas, las correlaciones de cada variable con las dos primeras componentes.

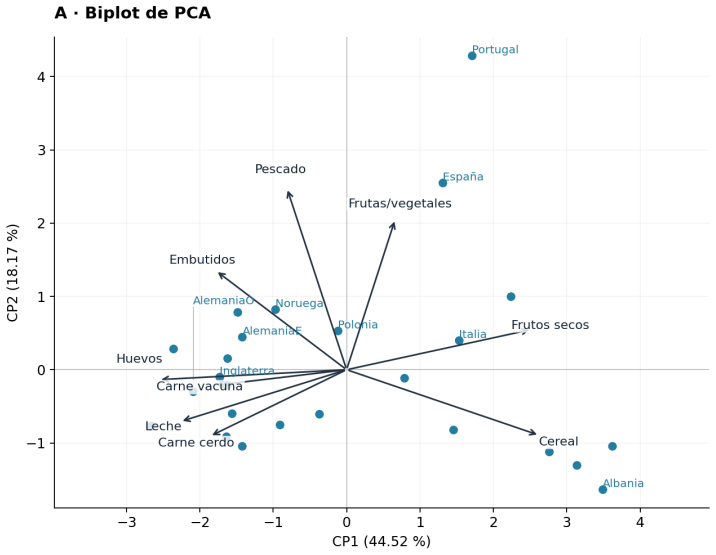


Figura 1. Biplot del conjunto Proteins. Las flechas se ampliaron por un mismo factor de 3 para facilitar su lectura.

a. Describa el contraste alimentario asociado con CP1. Considere las direcciones de cereal, frutos secos, huevos, leche y carnes.

b. Compare Portugal y Noruega respecto del consumo de pescado. Explique cómo debe proyectar los puntos sobre la flecha para fundamentar la comparación.

c. Compare España, Italia y Albania respecto de frutas y vegetales. ¿Alcanza con observar cuál está más arriba en el gráfico? Justifique.

d. Describa las similitudes y diferencias entre Inglaterra, Alemania oriental y Alemania occidental utilizando al menos tres variables. Considere también la varianza explicada por el plano al formular sus conclusiones.

Ejercicio 3

Se aplicó t-SNE sobre ocho columnas numéricas estandarizadas del conjunto de obesidad: Age, Height, Weight, FCVC, NCP, CH2O, FAF y TUE. Cada punto representa uno de los 2.111 registros. La categoría NObeyesdad no se utilizó para obtener la representación; sólo se empleó para colorear los puntos.

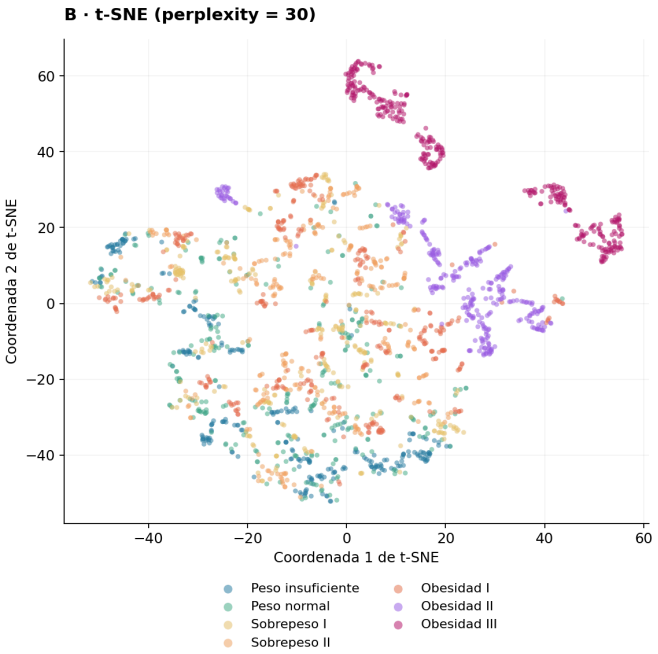


Figura 2. Representación t-SNE del conjunto de obesidad. Perplexity = 30; semilla aleatoria = 42.

a. Describa qué categorías presentan mayor separación visual y cuáles muestran mayor mezcla. Fundamente con observaciones concretas del gráfico.

b. ¿La aparición de varias regiones separadas permite afirmar que existen exactamente siete grupos naturales en los datos? Justifique.

c. ¿Qué representan las coordenadas de los ejes? ¿Sería correcto interpretar la coordenada horizontal como nivel de obesidad?

d. ¿Qué verificaría mediante nuevas ejecuciones antes de considerar estables las separaciones observadas? Considere la semilla aleatoria.: